



TECHNISCHE UNIVERSITÄT BERLIN

Skript zur Vorlesung und Übung

Statistik

gelesen von Prof. Dr. Michael Scheutzow im Sommersemester 2022

Übung von Dr. Isabell Vorkastner.

Inhaltsverzeichnis

1	Parameterschätzung	3
1.1	Grundlagen und Beispiele	3
1.2	Maximum Likelihood Schätzung	10
1.3	Beste Schätzer und die CRAMÉR-RAO Ungleichung	17
1.4	Suffizienz und Vollständigkeit	29
1.5	Konsistenz	38
1.6	BAYES-Schätzer	46
2	Konfidenzbereiche	53
2.1	Grundlagen	53
2.2	Konstruktionsmethode im Standardmodell mit $\tau = \text{id}$	55
3	Rund um die Normalverteilung: χ^2, F- und t-Verteilungen	59
4	Hypothesentests	63
4.1	Grundlagen	63
4.2	NEYMAN-PEARSON-Lemma	66
4.3	Beste einseitige Tests	69
4.4	Likelihood-Quotiententest	71
4.5	Einseitige GAUSS-Tests	72
5	Asymptotische Tests und Rangtest	75
5.1	Anpassungstests	75
5.2	χ^2 -Test auf Unabhängigkeit	83
5.3	Vorzeichen- und Rangtests	85
6	Lineare Modelle und Varianzanalyse	91
6.1	Einfache lineare Regression	91
6.2	Das lineare Modell	93
6.3	Das lineare GAUß-Modell	96
6.4	Varianzanalyse	101
A	Wiederholung: Gemeinsame Verteilung und Randverteilungen	102
B	Wiederholung: Bedingte Wahrscheinlichkeit und Erwartungswert	104
C	Übersicht: Modelle, Schätzer und deren Eigenschaften	106
	Index	107

L^AT_EX von [Viktor Stein](#).

Vielen Dank an Paul, Gemma, Lena, Joris, Hagen und Le Nam für das Finden und Korrigieren von Fehlern.

Diese Mitschrift ist weder von der Universität noch von dem Professor gebilligt und enthält fast sicher Fehler.

Zuletzt verändert am 16. November 2022.

INHALTSVERZEICHNIS

Diese Vorlesung orientiert sich vornehmlich an [2, Kap. 7 - 12].

Liste der noch zu erledigenden Punkte

Nur, wenn U stetig ist (Hauptsatz)!	19
Angenommen, U sei stetig. Können wir die Stetigkeit von TU garantieren?	19
Ist dieser Schätzer erwartungstreu?	63
Können wir diese Prozedur auch anwenden, wenn $\rho(k) = 0$ gilt?	75
Wie kann man den Schwellenwert bestimmen?	86

1 Parameterschätzung

1.1 Grundlagen und Beispiele

19.04.2022

DEFINITION 1.1.1 (STATISTISCHES MODELL)

Ein **statistisches Modell** ist ein Tripel $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$, wobei

- $\mathfrak{X} \neq \emptyset$ der Beobachtungs- oder **Stichprobenraum**,
- $\Theta \neq \emptyset$ eine Indexmenge, der **Parameterraum**,
- \mathcal{F} eine σ -Algebra auf \mathfrak{X} (die Algebra der **Beobachtungen**),
- \mathbb{P}_ϑ für $\vartheta \in \Theta$ ein **Wahrscheinlichkeitsmaß** auf $(\mathfrak{X}, \mathcal{F})$

sind.

statistisches
Modell

Bemerkung (Interpretation des statistischen Modells) Sei ϑ unbekannt. Man beobachtet eine Realisierung $x \in \mathfrak{X}$, die mittels \mathbb{P}_ϑ generiert wird, und will daraus Rückschlüsse auf ϑ oder Funktionen, welche von ϑ abhängen, ziehen. \circ

Notation. Es bezeichne stets \mathcal{B} die **BOREL- σ -Algebra**. Ist $Y: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ messbar, so sind $\mathbb{E}_\vartheta[Y] := \int_{\mathfrak{X}} Y(\omega) d\mathbb{P}_\vartheta(\omega) \in [-\infty, \infty]$ beziehungsweise $\mathbb{V}_\vartheta[Y] \in [0, \infty]$ der **Erwartungswert** beziehungsweise die **Varianz** bezüglich \mathbb{P}_ϑ .

DEFINITION 1.1.2 (STATISTIK, SCHÄTZER, KENNGRÖSSE)

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell und (Σ, \mathcal{S}) ein **Messraum**.

- Eine messbare Abbildung $S: (\mathfrak{X}, \mathcal{F}) \rightarrow (\Sigma, \mathcal{S})$ heißt **Statistik**.
- Ist $\tau: \Theta \rightarrow \Sigma$ eine Abbildung, so heißt τ **Kenngröße** für ϑ und eine Statistik $T: \mathfrak{X} \rightarrow \Sigma$ **Schätzer** für τ .

Statistik

Schätzer

DEFINITION 1.1.3 (ERWARTUNGSTREUE)

Ein Schätzer $T: \mathfrak{X} \rightarrow \mathbb{R}^n$ für $\tau: \Theta \rightarrow \mathbb{R}^n$ ist **erwartungstreu**, wenn

$$\mathbb{E}_\vartheta[T] = \tau(\vartheta) \quad \forall \vartheta \in \Theta.$$

Der **Bias von T** ist

$$\mathbb{B}[T]: \Theta \rightarrow [-\infty, \infty]^n, \quad \vartheta \mapsto \mathbb{E}_\vartheta[T] - \tau(\vartheta).$$

Das **Risiko von T** ist

$$\mathbb{F}_\vartheta[T] := \mathbb{E}_\vartheta[|T - \tau(\vartheta)|^2].$$

erwartungstreu

Bias

Risiko

DEFINITION 1.1.4 (PRODUKTMODELL)

Ist $(E, \mathfrak{E}, (\mathbb{Q}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell, so ist $(E^n, \mathfrak{E}^{\otimes n}, (\mathbb{Q}_\vartheta^{\otimes n})_{\vartheta \in \Theta})$ für $n \in \mathbb{N}_{>0}$ das zugehörige n -fache Produktmodell.

Produktmodell

Notation. In der Situation von Definition 1.1.4 schreiben wir oft

$$X: E^n \rightarrow E^n, \quad (x_1, \dots, x_n) \mapsto (x_1, \dots, x_n)$$

für die Identität auf $\mathfrak{X} := E^n$ und $X_k(e_1, \dots, e_n) := e_k$ für $k \in \{1, \dots, n\}$. Dann sind X_1, \dots, X_n bezüglich $\mathbb{Q}_\vartheta^{\otimes n}$ unabhängig und identisch verteilt (u.i.v.) mit Verteilung \mathbb{Q}_ϑ .

Beispiele statistischer Modelle**Beispiel 1.1.5 (Strahlenbelastung von Waldpilzen)**

Die **Strahlenbelastung von Waldpilzen** soll überprüft werden. Dazu wird bei n unabhängigen Pilzproben die Anzahl der **Geigerzähler-Impulse** jeweils während einer Zeiteinheit gemessen. Ein geeignetes statistisches Modell aufzustellen ist Hausaufgabe 1.1. \diamond

Beispiel 1.1.6 (BERNOULLI-Modell)

Um den **Wurf einer verbogenen Münze** mit den Seiten "0" und "1" zu beschreiben, wählen wir $\mathfrak{X} = \{0, 1\}$, $\mathcal{F} := \mathcal{P}(\mathfrak{X})$ sowie $\Theta := [0, 1]$ und $\mathbb{P}_\vartheta(\{1\}) = \vartheta$ und $\mathbb{P}_\vartheta(\{0\}) = 1 - \vartheta$, sodass $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ alle Wahrscheinlichkeitsmaße auf $(\mathfrak{X}, \mathcal{F})$ umfasst. Es ist auch möglich, stattdessen z.B. $\Theta = [\frac{1}{4}, \frac{3}{4}]$ zu wählen.

Um ϑ zu schätzen, wählen wir $\tau: \Theta \rightarrow \Theta$ als die Identität. Auf $\Sigma := \Theta$ wählen wir die σ -Algebra $\mathcal{B}(\Theta)$. Ein naheliegender Schätzer für τ ist

$$T: \mathfrak{X} \rightarrow \Theta, \quad x \mapsto x.$$

Wäre stattdessen
z.B. $\Theta = (0, 1)$, ist T
kein Schätzer, da
 $T(0) = 0 \notin \Theta$.

welcher erwartungstreu ist, denn für $\vartheta \in \Theta$ gilt

$$\mathbb{E}_\vartheta[T] = 1 \cdot \mathbb{P}_\vartheta(T = 1) + 0 \cdot \mathbb{P}_\vartheta(T = 0) = 1 \cdot \vartheta + 0 \cdot (1 - \vartheta) = \vartheta = \tau(\vartheta). \quad \diamond$$

Beispiel 1.1.7 (BERNOULLI-Produktmodell)

Um $n \in \mathbb{N}_{>0}$ unabhängige Münzwürfe zu modellieren, wählen wir das n -fache Produktmodell des Modells aus Beispiel 1.1.6: für $x \in \mathfrak{X} := \{0, 1\}^n$ und $\vartheta \in \Theta := [0, 1]$ ist

$$\mathbb{P}_\vartheta^{\otimes n}(\{x\}) = \vartheta^{\sum_{k=1}^n x_k} (1 - \vartheta)^{n - \sum_{k=1}^n x_k}.$$

Sei die Kenngröße τ wieder die Identität auf Θ . Ein natürlicher Schätzer für τ ist der **empirische Mittelwert** $T: \mathfrak{X} \rightarrow \Theta$, $x \mapsto T(x_1, \dots, x_n) := \frac{1}{n} \sum_{k=1}^n x_k$, welcher erwartungstreu ist:

$$\mathbb{E}_\vartheta[T] = \mathbb{E}_\vartheta \left[\frac{1}{n} \sum_{k=1}^n X_k \right] = \frac{1}{n} \sum_{k=1}^n \underbrace{\mathbb{E}_\vartheta[X_k]}_{=\vartheta} = \vartheta. \quad \diamond$$

Beispiel 1.1.8 (Binomialmodell: Anzahl der Einsen bei n -fachem Münzwurf)

Um den n -fachen Münzwurf, bei welchem lediglich die Anzahl der Einsen und nicht die Reihenfolge beachtet wird, zu modellieren, wählen wir $\mathfrak{X} := \{0, \dots, n\}$ (viel kleiner als $\{0, 1\}^n$!), $\mathcal{F} := \mathcal{P}(\mathfrak{X})$, $\Theta := [0, 1]$ und die Binomialverteilungen $\mathbb{P}_\vartheta(\{k\}) := \binom{n}{k} \vartheta^k (1 - \vartheta)^{n-k}$ für $k \in \mathfrak{X}$ und $\vartheta \in \Theta$.

Um ϑ zu schätzen, wählen wir wieder τ als die Identität auf Θ . Die Statistik $T: \mathfrak{X} \rightarrow \Theta$, $x \mapsto \frac{1}{n}x$ ist ein natürlicher und erwartungstreuer Schätzer für τ , denn für $\vartheta \in \Theta$ gilt

$$\mathbb{E}_\vartheta[T] = \sum_{k=0}^n T(k) \mathbb{P}_\vartheta(\{k\}) = \frac{1}{n} \sum_{k=0}^n k \cdot \binom{n}{k} \vartheta^k (1 - \vartheta)^{n-k} = \frac{1}{n} \cdot n\vartheta = \vartheta. \quad \diamond$$

Beispiel 1.1.9 (Lebensdauer von Glühbirnen)

Die Lebensdauer von Glühbirnen sei **exp(ϑ)-verteilt** mit $\vartheta \in (0, \infty)$. Wir wählen das statistische Modell mit $\mathfrak{X} = (0, \infty)$, $\mathcal{F} = \mathcal{B}(\mathfrak{X})$, $\Theta = \mathfrak{X}$ und als \mathbb{P}_ϑ die Exponentialverteilungen mit Dichte $x \mapsto \vartheta e^{-\vartheta x}$ bezüglich des LEBESGUE-Maßes für $\vartheta \in \Theta$. Betrachte nun das zugehörige n -fache Produktmodell.

Ein natürlicher (da $\mathbb{E}[\exp(\lambda)] = \lambda^{-1}$ ist) Schätzer für ϑ ist

$$T(x) := T(x_1, \dots, x_n) := \frac{1}{\frac{1}{n} \sum_{k=1}^n x_k},$$

welcher schon für $n = 1$ nicht erwartungstreu ist: für $\vartheta \in \Theta$ gilt

$$\mathbb{E}_\vartheta[T] = \int_0^\infty T(x) \vartheta e^{-\vartheta x} dx = \vartheta \underbrace{\int_0^\infty \frac{1}{x} e^{-\vartheta x} dx}_{=\infty} = \infty \neq \vartheta.$$

Man kann aber fast analog zeigen, dass $\frac{1}{T}$ ein erwartungstreuer Schätzer für $\frac{1}{\vartheta}$ ist. \diamond

Beispiel 1.1.10 (GAUSS-Produktmodell)

Zu einem gegebenen Mittelwert $m \in \mathbb{R}$ ist $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m, \vartheta}^{\otimes n})_{\vartheta > 0})$ das **n -fache GAUSSsche Produktmodell**. Die Statistik

$$T_n: \mathbb{R}^n \rightarrow [0, \infty), \quad x \mapsto \sqrt{\frac{\pi}{2}} \frac{1}{n} \sum_{k=1}^n |x_k - m|$$

ist ein erwartungstreuer Schätzer für $\tau: (0, \infty) \rightarrow (0, \infty)$ $\vartheta \mapsto \sqrt{\vartheta}$ (Hausaufgabe 1.2). \diamond

Beispiel 1.1.11 (Nichtparametrisches Modell)

Seien $\mathfrak{X} = \mathbb{R}$, $\mathcal{F} = \mathcal{B}(\mathbb{R})$ sowie $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ die Familie aller Wahrscheinlichkeitsmaße auf $(\mathfrak{X}, \mathcal{F})$. Wir können Θ als die (unendlichdimensionale) Menge der **Verteilungsfunktionen** F wählen¹. In diesem Fall nennt man $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ **unparametrisches** statistisches Modell.

Im dazugehörigen n -fachen Produktmodell wollen wir die Verteilungsfunktion $\vartheta = F$ schätzen. Eine natürlicher Schätzer für die Identität τ auf Θ ist

$$T_n: \mathbb{R}^n \rightarrow \Theta, \quad (x_1, \dots, x_n) \mapsto \left(F_n: \mathbb{R} \rightarrow [0, 1], \quad s \mapsto \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{(-\infty, s]}(x_k) \right).$$

Wir nennen F_n die **empirische Verteilungsfunktion**. \diamond

empirische Verteilungsfunktion

¹Eine sinnvolle σ -Algebra auf Θ wird durch die Punktauswertungen $F \mapsto F(t)$ für $t \in \mathbb{R}$ erzeugt, cf. WT II: Konstruktion des WIENER-Maßen / BROWNSche Bewegung.

Beispiel 1.1.12 (Produktmodell mit Gleichverteilung)

Für das Modell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{U}_\vartheta^{\otimes n})_{\vartheta \in \mathbb{R}})$, wobei $n \geq 1$ und \mathcal{U}_ϑ die Gleichverteilung auf dem Intervall $[\vartheta - \frac{1}{2}, \vartheta + \frac{1}{2}]$ sind, sind

$$M(x) := \frac{1}{n} \sum_{k=1}^n x_k \quad \text{und} \quad T(x) := \frac{1}{2} \left(\max_{1 \leq k \leq n} x_k + \min_{1 \leq j \leq n} x_j \right)$$

zwei erwartungstreue Schätzer für den Parameter ϑ . Die Verifizierung dieser Aussage und die Berechnung der Varianzen $\mathbb{V}[M]$ und $\mathbb{V}[T]$ ist Hausaufgabe 1.3. Der Wert $M(x)$ heißt empirischer Mittelwert der Beobachtung x . ◇ empirischer Mittelwert

Beispiel 1.1.13 (Qualitätskontrolle - Verschiedene Ansätze der Statistik)

Wir bekommen eine Lieferung von N Orangen, von denen $\vartheta \in \Theta := \{0, \dots, N\}$ Stück faul sind. Anhand einer Stichprobe von $n \ll N$ Orangen, von denen $x \in \{0, \dots, n\}$ faul sind, schätzen wir die Anzahl der faulen Orangen in der gesamten Lieferung.

Ansatz 1: Naive Schätzung / Hochrechnung. Unter der Annahme, dass die Stichprobe ungefähr repräsentativ ist, gilt $\frac{x}{n} \approx \frac{\vartheta}{N}$. Ein natürlicher Schätzer für $\tau = \text{id}_\Theta$ ist also

$$T: \mathfrak{X} \rightarrow \Sigma, \quad x \mapsto x \cdot \frac{N}{n},$$

wobei $\mathfrak{X} = \{0, \dots, n\}$, $\mathcal{F} = \mathcal{P}(\mathfrak{X})$ und $\Sigma = \Theta$ sind. Für $\vartheta \in \Theta$ wählen wir \mathbb{P}_ϑ als die hypergeometrische Verteilung

$$\text{Hyp}_{n, \vartheta, N-\vartheta}(k) = \frac{\binom{\vartheta}{k} \binom{N-\vartheta}{n-k}}{\binom{N}{n}} \mathbb{1}_{\{0, \dots, \vartheta\}}(k).$$

Der Schätzer T ist erwartungstreu, denn für $\vartheta \in \Theta$ gilt

$$\begin{aligned} \mathbb{E}_\vartheta[T] &= \sum_{k=0}^n T(k) \mathbb{P}_\vartheta(\{k\}) = \sum_{k=0}^{n \wedge \vartheta} k \frac{N}{n} \frac{\binom{\vartheta}{k} \binom{N-\vartheta}{n-k}}{\binom{N}{n}} = \vartheta \sum_{k=1}^{n \wedge \vartheta} \frac{\binom{\vartheta-1}{k-1} \binom{N-\vartheta}{n-k}}{\binom{N-1}{n-1}} \\ &= \vartheta \sum_{k=0}^{(n-1) \wedge (\vartheta-1)} \underbrace{\frac{\binom{\vartheta-1}{k} \binom{N-\vartheta}{n-1-k}}{\binom{N-1}{n-1}}}_{=\text{Hyp}_{n-1, \vartheta-1, N-\vartheta}(k)} = \vartheta, \end{aligned}$$

wobei $a \wedge b := \min(a, b)$ eine Kurzschreibweise ist.

Ansatz 2: Schätzung mit Fehlerangabe. Wir wählen ein Konfidenzintervall $C(x)$ (cf. Abschnitt 2), sodass mit hinreichender Wahrscheinlichkeit $\vartheta \in C(x)$ gilt. Zu einem Irrtumsniveau $0 < \alpha \ll 1$ können wir z.B. ein $m \in \mathbb{N}$ wählen, sodass

$$\mathbb{P}_\vartheta(\{x \in \mathfrak{X} : \vartheta \in [T(x) - m, T(x) + m]\}) \geq 1 - \alpha \quad \forall \vartheta \in \Theta$$

oder ein $\tilde{m} \in \mathbb{N}$, sodass

$$\mathbb{P}_\vartheta(\{x \in \mathfrak{X} : \vartheta \in [0, T(x) + \tilde{m}]\}) \geq 1 - \alpha \quad \forall \vartheta \in \Theta.$$

Ansatz 3: Entscheidungsfindung (cf. Abschnitt 4.) Die Orangen sollen zurück geschickt werden, wenn mehr als 5% aller Orangen faul sind.²

²Wir nehmen an, dass N durch 20 teilbar ist.

Die **Nullhypothese** H_0 ist $\vartheta \in \{0, \dots, \frac{N}{20}\}$ und die **Alternative** H_1 ist $\vartheta \in \{\frac{N}{20} + 1, \dots, N\}$.

Wir benötigen ein **Entscheidungsverfahren** bzw. einen Schwellenparameter $c \geq 0$ sodass $x \leq c$ eine Entscheidung für H_0 und $x > c$ eine Entscheidung für H_1 bedingt und müssen dafür ein geeignetes $c > 0$ wählen. \diamond

Beispiel 1.1.14 (Einzigster erwartungstreuer Schätzer ist unsinnig)

Im folgenden Modell existiert genau ein erwartungstreuer Schätzer für eine bestimmte Kenngröße, doch dieser ist Unsinn.

Die wöchentliche Anzahl an Unfällen in einer Stadt sei $\text{Poiss}(\vartheta)$ -verteilt und das statistische Modell $(\mathbb{N}_0, \mathcal{P}(\mathbb{N}_0), (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ mit $\mathbb{P}_\vartheta \sim \text{Poiss}(\vartheta)$ für $\vartheta \in \Theta := (0, \infty)$. Es gilt $\mathbb{P}_\vartheta(\{k\}) = e^{-\vartheta} \frac{\vartheta^k}{k!}$. Die Wahrscheinlichkeit, dass in drei unabhängigen Wochen keine Unfälle passieren ist $\tau: \Theta \rightarrow \mathbb{R}, \vartheta \mapsto \mathbb{P}_\vartheta(\{0\})^3 = e^{-3\vartheta}$. Ein Schätzer $T: \mathbb{N}_0 \rightarrow \mathbb{R}$ ist erwartungstreu genau dann wenn für alle $\vartheta \in \Theta$ gilt

$$e^{-3\vartheta} \stackrel{!}{=} \mathbb{E}_\vartheta[T] = \sum_{k=0}^{\infty} T(k) e^{-\vartheta} \frac{\vartheta^k}{k!},$$

also genau dann wenn

$$\sum_{k=0}^{\infty} (-2)^k \frac{\vartheta^k}{k!} = e^{-2\vartheta} \stackrel{!}{=} \sum_{k=0}^{\infty} T(k) \frac{\vartheta^k}{k!},$$

für alle $\vartheta \in \Theta$ gilt. Nach dem **Identitätssatz** sind die beiden Potenzreihen genau dann gleich, wenn ihre Koeffizienten übereinstimmen, das heißt, wenn $T(k) = (-2)^k$ für alle $k \in \mathbb{N}_0$ gilt.

Dieser Schätzer ist jedoch unsinnig, da $[0, 1] \ni \tau(\vartheta) \neq (-2)^k$ für alle $k \in \mathbb{N}_0$ gilt. \diamond

Beispiel 1.1.15 (Gameshow)

21.04.2022

Der Moderator wählt ein beliebiges $\vartheta > 0$. Dann produziert ein Apparat Realisierungen von unabhängig auf $[0, \vartheta]$ gleichmäßig verteilten Zufallsvariablen X_1, \dots, X_n . Die Spieler sollen ϑ anhand der Realisierungen schätzen. Wir wählen $\Theta := (0, \infty)$ sowie das n -fache Produktmodell des Modells mit $\mathfrak{X} = [0, \infty)$ (eine andere Möglichkeit wäre \mathbb{R}), $\mathcal{F} := \mathcal{B}(\mathfrak{X})$ und $\mathbb{P}_\vartheta := \mathcal{U}_{[0, \vartheta]}$ für $\vartheta \in \Theta$, wobei $\mathcal{U}_{[0, \vartheta]}$ die Gleichverteilung auf $[0, \vartheta]$ ist, das heißt

$$\mathcal{U}_{[0, \vartheta]}([0, t]) = \frac{t}{\vartheta} \wedge 1 \quad \forall t \geq 0.$$

Wir wählen $\Sigma := \Theta$, $\mathcal{S} := \mathcal{F}$ und wollen einen guten Schätzer für die Identität τ finden.

1. Möglichkeit. Wir wählen

$$T_n: \mathfrak{X}^n \rightarrow \mathfrak{X}, \quad x = (x_1, \dots, x_n) \mapsto \frac{2}{n} \sum_{k=1}^n x_k,$$

da $\mathbb{E}[X] = \frac{1}{2}\vartheta$ für $X \sim \mathcal{U}_{[0, \vartheta]}$ ist.

2. Möglichkeit. Wir wählen

$$\tilde{T}_n: \mathfrak{X}^n \rightarrow \mathfrak{X}, \quad x = (x_1, \dots, x_n) \mapsto \max(x_1, \dots, x_n).$$

Wir zeigen, dass die **Schätzfolgen** $(T_n)_{n \in \mathbb{N}}$ und $(\tilde{T}_n)_{n \in \mathbb{N}}$ konsistent sind, also, dass $\mathbb{P}_\vartheta(|T_n - \vartheta| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$ (und analog für \tilde{T}_n) für alle $\vartheta \in \Theta$ und $\varepsilon > 0$ gilt.

Für $\vartheta \in \Theta$ und $\varepsilon > 0$ gilt

$$\begin{aligned}\mathbb{P}_\vartheta(|T_n - \vartheta| > \varepsilon) &= \mathbb{P}_\vartheta\left(\left|\frac{2}{n} \sum_{k=1}^n X_k - \vartheta\right| > \varepsilon\right) \\ &= \mathbb{P}_\vartheta\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \mathbb{E}_\vartheta[X_k]\right| > \frac{\varepsilon}{2}\right) \xrightarrow[\text{Gesetz der großen Zahlen}]{n \rightarrow \infty} 0.\end{aligned}$$

Wir können ohne Beschränkung der Allgemeinheit zu $\vartheta \in \Theta$ ein $0 < \varepsilon < \vartheta$ wählen. Dann gilt, weil $\tilde{T}_n(x)$ für alle $x \in \mathfrak{X}$ kleiner gleich ϑ ist, dass

$$\begin{aligned}\mathbb{P}_\vartheta(|\tilde{T}_n - \vartheta| > \varepsilon) &= \mathbb{P}_\vartheta(\tilde{T}_n < \vartheta - \varepsilon) = \mathbb{P}_\vartheta(X_1 \vee \dots \vee X_n < \vartheta - \varepsilon) \\ &= \mathbb{P}_\vartheta(X_1 < \vartheta - \varepsilon, \dots, X_n < \vartheta - \varepsilon) \stackrel{(\star)}{=} \mathbb{P}_\vartheta(X_1 < \vartheta - \varepsilon)^n \\ &= \left(\frac{\vartheta - \varepsilon}{\vartheta}\right)^n \xrightarrow[0 < \varepsilon < \vartheta]{n \rightarrow \infty} 0,\end{aligned}$$

wobei wir in (\star) die Unabhängigkeit der X_1, \dots, X_n und deren identische Verteilung ausnutzen.

Nun untersuchen wir für jedes $n \in \mathbb{N}$ die Erwartungstreue der beiden Schätzer. Für $\vartheta \in \Theta$ gilt

$$\mathbb{E}_\vartheta[T_n] = \frac{2}{n} \sum_{k=1}^n \mathbb{E}_\vartheta[X_k] = \frac{2}{n} \cdot n \cdot \frac{\vartheta}{2} = \vartheta.$$

Die **Dichte** von \tilde{T}_n bezüglich \mathbb{P}_ϑ ist $n \left(\frac{\cdot}{\vartheta}\right)^{n-1} \frac{1}{\vartheta} \mathbb{1}_{[0, \vartheta]}$, die Ableitung von der Verteilungsfunktion $\mathbb{P}_\vartheta(\tilde{T}_n \leq y) = \left(\frac{y}{\vartheta} \wedge 1\right)^n \mathbb{1}_{[0, \infty)}(y)$. Somit gilt

$$\mathbb{E}_\vartheta[\tilde{T}_n] = n \int_0^\vartheta y \cdot \left(\frac{y}{\vartheta}\right)^{n-1} \frac{1}{\vartheta} dy = n \vartheta^{-n} \int_0^\vartheta y^n dy = n \vartheta^{-n} \frac{\vartheta^{n+1}}{n+1} = \frac{n}{n+1} \vartheta, \quad (1)$$

also ist \tilde{T}_n nicht erwartungstreu, aber die Folge $(\tilde{T}_n)_{n \in \mathbb{N}}$ **asymptotisch erwartungstreu**, das heißt

$$\mathbb{B}_\vartheta(\tilde{T}_n) = \frac{n}{n+1} \vartheta - \vartheta \xrightarrow{n \rightarrow \infty} 0 \quad \forall \vartheta \in \Theta.$$

asymptotisch
erwartungstreu

3. Möglichkeit. Wir wählen den Schätzer $T_n^* := \frac{n+1}{n} \tilde{T}_n$. Nach den vorangegangenen Berechnung ist T_n^* erwartungstreu für jedes $n \in \mathbb{N}$ und die Schätzfolge $(T_n^*)_{n \in \mathbb{N}}$ ist konsistent.

Vergleich der Schätzer. Wir berechnen nun die Varianz der Schätzer, um sie zu vergleichen. Die Varianz einer Zufallsvariable $X \sim \mathcal{U}_{[0, \vartheta]}$ ist $\mathbb{V}_\vartheta[X] = \frac{\vartheta^2}{12}$. Die X_1, \dots, X_n sind unabhängig identisch verteilt. Aufgrund der Rechenregeln für die Varianz gilt

$$\mathbb{V}_\vartheta[T_n] = \mathbb{V}_\vartheta\left[\frac{2}{n} \sum_{k=1}^n X_k\right] = \frac{4}{n^2} \mathbb{V}_\vartheta\left[\sum_{k=1}^n X_k\right] = \frac{4}{n} \mathbb{V}_\vartheta[X_1] = \frac{4}{n} \frac{\vartheta^2}{12} = \frac{1}{3n} \vartheta^2. \quad (2)$$

Ferner gilt

$$\begin{aligned}\mathbb{V}_\vartheta[\tilde{T}_n] &= \int_0^\vartheta x^2 n \left(\frac{x}{\vartheta}\right)^{n-1} \frac{1}{\vartheta} dx - \mathbb{E}_\vartheta[\tilde{T}_n]^2 \stackrel{(1)}{=} n \vartheta^{-n} \int_0^\vartheta x^{n+1} dx - \left(\frac{n}{n+1}\right)^2 \vartheta^2 \\ &= \frac{n}{n+2} \vartheta^2 - \frac{n^2}{(n+1)^2} \vartheta^2 = \frac{n}{(n+1)^2(n+2)} \vartheta^2.\end{aligned} \quad (3)$$

Beachte, dass dieser Schätzer sich eventuell nicht um ϑ zentriert. Es folgt

$$\mathbb{V}_{\vartheta}[T_n^*] = \left(\frac{n+1}{n}\right)^2 \mathbb{V}_{\vartheta}[\tilde{T}_n] \stackrel{(3)}{=} \frac{1}{n(n+2)}\vartheta^2. \quad (4)$$

Daher ist T_n^* ein besserer Schätzer: er zentriert sich schneller um ϑ .

Wichtiger ist die **mittlere quadratische Abweichung** von ϑ $\mathbb{F}_{\vartheta}[T]$. Aufgrund der Erwartungstreue von T_n gilt

$$\mathbb{F}_{\vartheta}[T_n] = \mathbb{V}_{\vartheta}[T_n] \stackrel{(2)}{=} \frac{1}{3n}\vartheta^2$$

und ferner

$$\begin{aligned} \mathbb{F}_{\vartheta}[\tilde{T}_n] &= \mathbb{E}_{\vartheta} \left[|\tilde{T}_n - \vartheta|^2 \right] = \mathbb{V}_{\vartheta}[\tilde{T}_n - \vartheta] + \left(\mathbb{E}_{\vartheta}[\tilde{T}_n - \vartheta] \right)^2 \\ &= \mathbb{V}_{\vartheta}[\tilde{T}_n] + \mathbb{B}_{\vartheta}[\tilde{T}_n]^2 \stackrel{(3)}{=} \frac{n}{(n+1)^2(n+2)}\vartheta^2 + \frac{1}{(n+1)^2}\vartheta^2 = \frac{2}{(n+1)(n+2)}\vartheta^2. \end{aligned}$$

Schließlich gilt aufgrund der Erwartungstreue von T_n^*

$$\mathbb{F}_{\vartheta}[T_n^*] = \mathbb{V}_{\vartheta}[T_n^*] \stackrel{(4)}{=} \frac{1}{n(n+2)}\vartheta^2.$$

Für jedes $n \in \mathbb{N}$ gilt also

$$\mathbb{F}_{\vartheta}[T_n^*] \leq \mathbb{F}_{\vartheta}[\tilde{T}_n] \leq \mathbb{F}_{\vartheta}[T_n] \quad \forall \vartheta \in (0, \infty).$$

Ein Schätzer mit noch geringerem Risiko wäre $\hat{T}_n := \frac{n+2}{n+1}\tilde{T}_n$, denn dann gilt $\mathbb{F}_{\vartheta}[\hat{T}_n] \leq \mathbb{F}_{\vartheta}[T_n^*]$. Dieser Schätzer ist aber nicht erwartungstreu!

In diesem Beispiel existiert **kein risikominimierender Schätzer** T_n^{**} mit $\mathbb{F}_{\vartheta}[T_n^{**}] \leq \mathbb{F}_{\vartheta}[\tilde{T}_n]$ für alle $\vartheta \in \Theta$ und alle Schätzer \tilde{T}_n .

Beweis. Angenommen, so ein Schätzer T_n^{**} existiert. Seien $\vartheta_0 \in \Theta$ und $T_n^{(\vartheta_0)} \equiv \vartheta_0$ ein Schätzer auf \mathfrak{X} . Dann gilt $\mathbb{F}_{\vartheta_0}[T_n^{**}] \leq \mathbb{F}_{\vartheta_0}[T_n^{(\vartheta_0)}] = 0$ und somit $\mathbb{F}_{\vartheta_0}[T_n^{**}] = 0$ für alle $\vartheta_0 \in \Theta$, was einen Widerspruch darstellt. \square

Es kann hingegen risikominimierende erwartungstreue Schätzer geben. \diamond

1.2 | Maximum Likelihood Schätzung

DEFINITION 1.2.1 (ABSOLUT STETIG [4, DEF. 3.5])

Seien μ und ν Maße auf (Ω, Q) . Dann ist ν **absolut stetig** bezüglich μ und wir schreiben $\nu \ll \mu$ wenn aus $A \in Q$ und $\mu(A) = 0$ folgt, dass $\nu(A) = 0$.

absolut stetig

SATZ 1.2.1: RADON-NIKODYM (1913, 1930)

Seien μ und ν **σ -endliche** Maße auf (Ω, Q) . Dann hat ν eine **Dichte f bezüglich μ** , das heißt $\nu(A) = \int_A f d\mu$ für alle $A \in Q$, und wir schreiben $f = \frac{d\nu}{d\mu}$, genau dann wenn $\nu \ll \mu$ gilt. Dann ist f bis auf Modifikation auf μ -Nullmengen eindeutig und reellwertig.

DEFINITION 1.2.2 (STANDARDMODELL, LIKELIHOODFUNKTION)

Ein Modell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ist ein **Standardmodell**, wenn ein **dominierendes σ -endliches** Maß μ_0 auf $(\mathfrak{X}, \mathcal{F})$ existiert, das heißt $\mathbb{P}_\vartheta \ll \mu_0$ für alle $\vartheta \in \Theta$. Die **Likelihoodfunktion** ist

Standardmodell
Likelihoodfunktion

$$\rho: \mathfrak{X} \times \Theta \rightarrow \mathbb{R}, \quad (x, \theta) \mapsto \frac{d\mathbb{P}_\theta}{d\mu_0}(x).$$

DEFINITION 1.2.3 (MAXIMUM-LIKELIHOOD-SCHÄTZER)

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell mit Likelihoodfunktion ρ . Ein Schätzer $T: \mathfrak{X} \rightarrow \Sigma \supset \Theta$ ist ein **Maximum-Likelihood-Schätzer** für $\tau: \Theta \rightarrow \Theta, \vartheta \mapsto \vartheta$, wenn

Maximum-Likelihood-Schätzer

$$\rho(x, T(x)) = \sup_{\vartheta \in \Theta} \rho(x, \vartheta) \quad \text{für } \mathbb{P}_\vartheta - \text{fast alle } x \in \mathfrak{X} \quad \forall \vartheta \in \Theta.$$

Beispiel 1.2.4 (Likelihoodfunktion für abzählbares \mathfrak{X})

Seien \mathfrak{X} höchstens abzählbar unendlich und μ_0 das Zählmaß auf \mathfrak{X} , welches σ -endlich ist. Dann gilt für jede Familie $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ von Wahrscheinlichkeitsmaßen auf $(\mathfrak{X}, \mathcal{P}(\mathfrak{X}))$ das $\mathbb{P}_\vartheta \ll \mu_0$ für alle $\vartheta \in \Theta$ gilt, denn aus $\mu_0(A) = 0$ für $A \in \mathcal{P}(\mathfrak{X})$ folgt $A = \emptyset$ und somit $\mathbb{P}_\vartheta(A) = 0$, also ist $(\mathfrak{X}, \mathcal{P}(\mathfrak{X}), (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell.

Da nur \emptyset eine μ_0 -Nullmenge ist, ist die eindeutige (nicht fast sicher, sondern sicher!) Likelihoodfunktion

26.04.2022

$$\rho(x, \vartheta) = \frac{d\mathbb{P}_\vartheta}{d\mu_0}(x) = \mathbb{P}_\vartheta(\{x\})$$

für $\vartheta \in \Theta$ und $x \in \mathfrak{X}$, denn es gilt

$$\mathbb{P}_\vartheta(\{x\}) = \int_{\{x\}} \rho(y, \vartheta) d\mu_0(y) = \rho(x, \vartheta) \cdot \mu_0(\{x\}) = \rho(x, \vartheta).$$

◇

Beispiel 1.2.5 (Kontinuierliches \mathfrak{X})

Seien $\mathfrak{X} = \mathbb{R}^n$ und $\mathcal{F} = \mathcal{B}(\mathbb{R}^n) = \mathcal{B}(\mathbb{R})^{\otimes n}$. Das LEBESGUE-Maß auf $(\mathfrak{X}, \mathcal{F})$ ist σ -endlich. Sei $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ eine Familie von Wahrscheinlichkeitsmaßen auf $(\mathfrak{X}, \mathcal{F})$, welche eine Dichte $\rho(\cdot, \vartheta)$ bezüglich μ_0 haben. Dann ist $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell. ◇

Gegenbeispiel 1.2.6 (Kein dominierendes σ -endliches Maß)

Seien $\mathfrak{X} = \mathbb{R}$ (man könnte auch \mathbb{R}^n wählen), $\mathcal{F} = \mathcal{B}(\mathfrak{X})$ und $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ die Menge aller Wahrscheinlichkeitsmaße auf $(\mathfrak{X}, \mathcal{F})$. Dann gibt es kein σ -endliches Maß μ_0 mit $\mathbb{P}_\vartheta \ll \mu_0$ für alle $\vartheta \in \Theta$.

Beweis. Angenommen, so ein σ -endliches Maß μ_0 existiert. Für $x \in \mathfrak{X}$ sei $\delta_x(A) := \mathbb{1}_A(x)$ für $A \in \mathcal{F}$. Da nach Annahme $\delta_x \ll \mu_0$ für alle $x \in \mathfrak{X}$ gilt, folgt wegen $\delta_x(\{x\}) = 1 > 0$, dass $\mu_0(\{x\}) > 0$ ist. Dies widerspricht der σ -Endlichkeit von μ_0 : Da μ_0 σ -endlich ist, existiert eine Folge $(A_n)_{n \in \mathbb{N}} \subset \mathcal{F}$ mit $\mu_0(A_k) < \infty$ für alle $k \in \mathbb{N}$ und $\bigcup_{k \in \mathbb{N}} A_k = \mathfrak{X}$. Da die abzählbare Vereinigung abzählbarer Menge abzählbar ist, aber \mathfrak{X} überabzählbar, existiert ein $j \in \mathbb{N}$ sodass A_j überabzählbar ist. Für jedes $x \in A_j$ existiert ein $k_x \in \mathbb{N}$ sodass $\mu(\{x\}) > \frac{1}{k_x}$ ist. Für $k \in \mathbb{N}$ definieren wir $B_k := \{x \in A_j : \mu_0(\{x\}) > \frac{1}{k}\}$. Dann ist $A_j = \bigcup_{k \in \mathbb{N}} B_k$. Da A_j überabzählbar ist, existiert ein $m \in \mathbb{N}$ sodass B_m überabzählbar ist. Dann ist $\mu_0(B_m) = \sum_{x \in B_m} \mu_0(\{x\}) > \sum_{x \in B_m} \frac{1}{m} = \infty$. \square

Beispiel 1.2.7 (Maximum-Likelihood-Schätzer für das Binomialmodell)

Betrachte $\mathfrak{X} = \{0, \dots, n\}$, $\mathcal{F} = \mathcal{P}(\mathfrak{X})$ und μ_0 das Zählmaß auf $(\mathfrak{X}, \mathcal{F})$ (oder jedes andere Maß, dessen einzige Nullmenge \emptyset ist) sowie $\Theta = [0, 1]$. Nach Beispiel 1.2.4 ist die Dichte $\rho(x, \vartheta) = \mathbb{P}_\vartheta(\{x\}) = \binom{n}{x} \vartheta^x (1 - \vartheta)^{n-x}$ für alle $x \in \mathfrak{X}$ und $\vartheta \in \Theta$.

Wir wollen für beobachtetes $x \in \mathfrak{X}$ das $\vartheta \in \Theta$ wählen, für das die Likelihoodfunktion $\rho(x, \cdot)$ maximal ist. Da \ln streng monoton wachsend ist, ist es äquivalent die **Loglikelihoodfunktion**

$$(0, 1) \ni \vartheta \mapsto \ln(\rho(\vartheta, x)) = \ln\left(\binom{n}{x}\right) + x \ln(\vartheta) + (n - x) \ln(1 - \vartheta)$$

Loglikelihood-
funktion

zu maximieren, da das Maximum nicht am Rand auftreten kann, da $\rho(0, \cdot) = \rho(1, \cdot) \equiv 0$ ist. Für $\vartheta \in (0, 1)$ ist

$$\frac{\partial}{\partial \vartheta} \ln(\rho(\vartheta, x)) = \frac{x}{\vartheta} - \frac{n - x}{1 - \vartheta}$$

fallend in ϑ und Nullsetzen ergibt den Maximierer - den Maximum-Likelihood-Schätzer -

$$T_{\text{ML}}(x) := \vartheta_{\text{ML}}(x) = \frac{x}{n},$$

welchen wir bereits in Beispiel 1.1.8 gefunden hatten. \diamond

Beispiel 1.2.8 (Erfolg beim Münzwurf)

Wir wollen schätzen **mit welcher Wahrscheinlichkeit ein Münzwurf erfolgreich** ist. Dafür werfen wir die Münze solange bis der erste Erfolg eintritt, stoppen dann und notieren uns die Anzahl der Würfe. Ein geeignetes statisches Modell anzugeben und den Maximum-Likelihood-Schätzer für den unbekannten Erfolgsparameter der Münze anzugeben und auf Erwartungstreue zu prüfen ist Hausaufgabe 2.2. \diamond

Wir sehen nun, dass ein Maximum-Likelihood-Schätzer nicht immer gut sein muss.

Beispiel 1.2.9 (Maximum-Likelihood-Schätzer für die Gameshow)

Das Modell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ der Gameshow ist ein Standardmodell bezüglich des LEBESGUE-Maßes μ_0 auf $(\mathfrak{X}, \mathcal{F})$. Es gilt $\mathbb{P}_\vartheta \ll \mu_0$ z.B. mit Dichte $\rho(x, \vartheta) = \vartheta^{-n} \mathbb{1}_{[0, \vartheta]^n}$. Demnach ist der Maximum-Likelihood-Schätzer für ϑ

$$T_{\text{ML}}(x) = \vartheta_{\text{ML}}(x) = \max(\{x_1, \dots, x_n\}),$$

welcher **systematisch unterschätzt**, da stets $\vartheta_{\text{ML}} \leq \vartheta$ ist. \diamond

Beispiel 1.2.10 (Maximum-Likelihood-Schätzer für LAPLACE-Produktmodell)

Betrachte das statistische Produktmodell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{Q}_\vartheta^{\otimes n})_{\vartheta \in \mathbb{R}})$, wobei \mathcal{Q}_ϑ für jedes $\vartheta \in \mathbb{R}$ ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit Dichte

$$\rho(\vartheta, x) := \frac{1}{2} e^{-|x-\vartheta|}, \quad x \in \mathbb{R}$$

bezüglich des LEBESGUE-Maßes ist. Das Bestimmen des Maximum-Likelihood-Schätzers für ϑ , der nur für ungerades n eindeutig bestimmt ist, ist Hausaufgabe 2.3. \diamond

Beispiel 1.2.11 (Maximum-Likelihood-Schätzer für Glühbirnen)

Das Glühbirnenmodell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ist ein Standardmodell bezüglich des LEBESGUE-Maßes mit Dichte $\rho(x, \vartheta) = \prod_{k=1}^n \vartheta e^{-\vartheta x_k}$. Für $x \in \mathfrak{X}$ und $\vartheta \in (0, \infty)$ gilt

$$\ln(\rho(x, \vartheta)) = \sum_{k=1}^n \ln(\vartheta) - \vartheta x_k = n \ln(\vartheta) - \vartheta \sum_{k=1}^n x_k.$$

und somit ist

$$\frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) = \frac{n}{\vartheta} - \sum_{k=1}^n x_k$$

fallend in ϑ . Der Maximum-Likelihood-Schätzer für ϑ ist daher

$$\vartheta_{\text{ML}}(x) = \frac{1}{\frac{1}{n} \sum_{k=1}^n x_k}.$$

Bemerkung 1.2.12 (Andere Dichte gibt andere Maximum-Likelihood-Schätzer)

Wählen wir anstatt die Dichte

$$\tilde{\rho}: \mathfrak{X} \times \Theta \rightarrow \mathfrak{X}, \quad (x, \vartheta) \mapsto \begin{cases} \vartheta e^{-\vartheta x}, & \text{für } x \neq \vartheta, \\ h(x), & \text{sonst,} \end{cases}$$

wobei $h: \mathfrak{X} \rightarrow \mathfrak{X}$ eine messbare Funktion mit $h(x) > \sup_{\vartheta \in \Theta} \vartheta e^{-\vartheta x} = \frac{1}{e \cdot x}$ ist, so ist auch $\tilde{\rho}(\cdot, \vartheta)$ eine Dichte von \mathbb{P}_ϑ bezüglich μ_0 .

Der Maximum-Likelihood-Schätzer für $\tilde{\rho}$ ist $\tilde{T}_{\text{ML}}(x) = x$, da $\max_{\vartheta \in \Theta} \tilde{\rho}(x, \vartheta) = h(x)$ für alle $x \in \mathfrak{X}$ ist, während der Maximum-Likelihood-Schätzer für die „kanonische“ Dichte $T_{\text{ML}}(x) = \frac{1}{x}$ und somit völlig verschieden ist. \circ




Abb. 1: Der Graph der Abbildung $\tilde{\rho}(x_0, \cdot)$ für ein $x_0 \in \mathfrak{X}$.

Beispiel 1.2.13 (Maximum-Likelihood-Schätzer für Mittelwert im GAUSS-Modell)

Betrachte das GAUSS I Modell mit $\mathfrak{X} = \mathbb{R}^n$, $\mathcal{F} = \mathcal{B}(\mathfrak{X})$, $\mathbb{P}_\vartheta := \mathcal{N}_{\vartheta, \sigma^2}^{\otimes n}$ für $\vartheta \in \Theta := \mathbb{R}$ und $\sigma > 0$. Dies ist ein Standardmodell bezüglich des LEBESGUE-Maßes mit den Dichten

$$\rho(x, \vartheta) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_k - \vartheta)^2}{2\sigma^2}\right).$$

Somit gilt

$$\ln(\rho(x, \vartheta)) = \sum_{k=1}^n -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x_k - \vartheta)^2}{2\sigma^2}$$

und

$$\frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) = \frac{1}{\sigma^2} \sum_{k=1}^n (x_k - \vartheta).$$

Nullsetzen ergibt den Maximum-Likelihood-Schätzer

$$\vartheta_{\text{ML}} = \frac{1}{n} \sum_{k=1}^n x_k.$$

◇

Beispiel 1.2.14 (ML-Schätzer für Varianz und Mittelwert des GAUSS-Modells)

Betrachte das vorangegangene Modell, jetzt aber mit $\Theta = \mathbb{R} \times (0, \infty)$ und $\mathbb{P}_{\vartheta=(\mu, \sigma^2)} = \mathcal{N}_{\mu, \sigma^2}^{\otimes n}$. Dies ist ein Standardmodell bezüglich des LEBESGUE-Maßes mit den Dichten

$$\rho(x, (\mu, \sigma^2)) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_k - \mu)^2}{2\sigma^2}\right).$$

Somit gilt

$$\ln \rho(x, (\mu, \sigma^2)) = \sum_{k=1}^n -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x_k - \mu)^2}{2\sigma^2}$$

und

$$\frac{\partial}{\partial \mu} \ln(\rho(x, (\mu, \sigma^2))) = \frac{1}{\sigma^2} \sum_{k=1}^n (x_k - \mu)$$

sowie (cf. [4, Bsp. 10.16])

$$\frac{\partial}{\partial \sigma^2} \ln(\rho(x, (\mu, \sigma^2))) = \frac{\partial}{\partial \sigma^2} \left(-\frac{n}{2} \ln(2\pi\sigma^2) - \sum_{k=1}^n \frac{(x_k - \mu)^2}{2\sigma^2} \right) = -\frac{n}{2\sigma^2} + \sum_{k=1}^n \frac{(x_k - \mu)^2}{2\sigma^4}.$$

Nullsetzen ergibt den Maximum-Likelihood-Schätzer

$$T_{\text{ML}}(x) := (\hat{\mu}, \hat{\sigma}) := \left(\frac{1}{n} \sum_{k=1}^n x_k, \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2 \right)$$

als Komponenten den **empirischen Mittelwert** $\hat{\mu}$ und die **empirische Varianz** $\hat{\sigma}$ von x haben. ◇

**empirische
Varianz**

Bemerkung 1.2.15 (Der Fall $n = 1$) Im Fall $n = 1$ ist $(\hat{\mu}, \hat{\sigma}) = (\hat{\mu}, 0) \notin \Theta$, somit ist T_{ML} kein Schätzer. Wir sollten deshalb den Fall $n = 1$ "verbieten", denn für $\tilde{\Theta} := \mathbb{R} \times [0, \infty)$ haben die Maße \mathbb{P}_{ϑ} nicht mehr alle Dichten bezüglich des LEBESGUE-Maßes und somit ist $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_{\vartheta})_{\vartheta \in \tilde{\Theta}})$ kein Standardmodell mehr, da es kein dominierendes σ -endliches Maß mehr gibt (cf. Gegenbeispiel 1.2.6). ○

Lemma 1.2.16 (Erwartungstreue der Stichprobenmittel und -varianz)

Sei $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{Q}_{\vartheta}^{\otimes n})_{\vartheta \in \Theta})$ ein Produktmodell mit Erwartungswert $m(\vartheta) := \mathbb{E}_{\vartheta}[X] := \mathbb{E}[\mathbb{Q}_{\vartheta}] < \infty$ und Varianz $v(\vartheta) := \mathbb{V}_{\vartheta}[X] := \mathbb{V}[\mathbb{Q}_{\vartheta}] < \infty$ für $X \sim \mathbb{P}_{\vartheta}$.

Das **Stichprobenmittel** $M(x) := \frac{1}{n} \sum_{k=1}^n x_k$ ist ein erwartungstreuer Schätzer für $m(\vartheta)$, jedoch ist die **Stichprobenvarianz** $V(x) := \frac{1}{n} \sum_{k=1}^n (x_k - M(x))^2$ kein erwartungstreuer (aber ein asymptotisch erwartungstreuer) Schätzer für $v(\vartheta)$. Die **korrigierte Stichprobenvarianz** $V^*(x) := \frac{1}{n-1} \sum_{k=1}^n (x_k - M(x))^2$ hingegen ist ein erwartungstreuer Schätzer für $v(\vartheta)$.

27.04.2022

Beweis. Aufgrund der Linearität des Erwartungswerts gilt für alle $\vartheta \in \Theta$

$$\mathbb{E}_{\vartheta}[M] = \frac{1}{n} \sum_{k=1}^n \mathbb{E}_{\vartheta}[X_k] = \frac{1}{n} \sum_{k=1}^n m(\vartheta) = m(\vartheta)$$

und

$$\begin{aligned} \mathbb{E}_{\vartheta}[V] &= \frac{1}{n} \sum_{k=1}^n \mathbb{E}_{\vartheta}[(X_k - M)^2] = \frac{1}{n} \sum_{k=1}^n \mathbb{V}_{\vartheta}[X_k - M] \stackrel{\text{u.i.v.}}{=} \mathbb{V}_{\vartheta}[X_1 - M] \\ &= \mathbb{V}_{\vartheta} \left[\frac{n-1}{n} X_1 - \frac{1}{n} \sum_{k=2}^n X_k \right] \\ &\stackrel{\text{u.i.v.}}{=} \left(\frac{n-1}{n} \right)^2 \mathbb{V}_{\vartheta}[X_1] + \frac{n-1}{n^2} \mathbb{V}_{\vartheta}[X_1] = \frac{n-1}{n} v(\vartheta). \end{aligned}$$

□

Beispiel 1.2.17 (Maximum-Likelihood-Schätzer für Qualitätskontrolle)

Betrachte wieder das Modell zur Qualitätskontrolle gelieferter Orangen aus Beispiel 1.1.13.

Die Likelihoodfunktion ist

$$\rho(x, \vartheta) = \mathbb{P}_{\vartheta}(\{x\}) = \frac{\binom{\vartheta}{x} \binom{N-\vartheta}{n-x}}{\binom{N}{n}} \mathbb{1}_{x \leq \vartheta}(x, \vartheta).$$

Um die Maxima von $\rho(x, \cdot)$ zu finden, betrachten wir für $x \leq \vartheta$ den Quotienten

$$\frac{\rho(x, \vartheta)}{\rho(x, \vartheta - 1)} = \frac{\binom{\vartheta}{x} \binom{N-\vartheta}{n-x}}{\binom{\vartheta-1}{x} \binom{N-\vartheta+1}{n-x}} = \frac{\vartheta(N - \vartheta + 1 - n + x)}{(\vartheta - x)(N - \vartheta + 1)},$$

wobei wir im letzten Schritt zwei mal die Identität $\binom{n-1}{k} = \frac{n-k}{n} \binom{n}{k}$ benutzen. Dann gilt für $x \leq \vartheta$

$$\begin{aligned} \frac{\rho(x, \vartheta)}{\rho(x, \vartheta - 1)} \geq 1 &\iff \vartheta(x - n) \geq -x(N - \vartheta + 1) \iff \vartheta(\cancel{x} - n \cancel{x}) \geq -x(N + 1) \\ &\iff \vartheta \leq x \frac{N + 1}{n}. \end{aligned}$$

Somit ist $\rho(x, \cdot)$ wachsend auf $\{0, \dots, \min(\lfloor x \frac{N+1}{n} \rfloor, N)\}$ und fallend für größere Werte.

Daher ist der Maximum-Likelihood-Schätzer

$$T(x) = \begin{cases} \lfloor x \frac{N+1}{n} \rfloor, & \text{für } x < n, \\ N, & \text{für } x = n \end{cases}$$

◇

Beispiel 1.2.18 (Fischpopulation)

Ein Teich enthält eine unbekannte Anzahl Fische. Um die Anzahl ϑ zu schätzen, markieren wir r Fische. Später fangen wir n Fische, von denen x markiert sind.

Das zugehörige statistische Modell hat $\mathfrak{X} = \{0, \dots, n\}$, $\mathcal{F} = \mathcal{P}(\mathfrak{X})$ und $\mathbb{P}_{\vartheta} := \text{Hyp}_{n,r,\vartheta-r}$ für $\Theta := \mathbb{N}_{\geq r}$. Die Likelihoodfunktion ist

$$\rho(x, \vartheta) = \frac{\binom{r}{x} \binom{\vartheta-r}{n-x}}{\binom{\vartheta}{n}} \mathbb{1}_{\{x \leq \vartheta\}}(x, \vartheta).$$

Analog zu Beispiel 1.2.17 können wir für $x \neq 0$ zeigen, dass $\rho(x, \cdot)$ auf $\{r, \dots, \lfloor \frac{nr}{x} \rfloor\}$ wachsend ist und für größere Werte fallend. Dann ist $T(x) := \lfloor \frac{nr}{x} \rfloor$ ein Maximum-Likelihood-Schätzer für ϑ , wenn $x \neq 0$ ist.

Die Funktion $\rho(0, \cdot)$ ist wachsend auf ganz Θ . Man könnte $T(0) = \infty$ setzen, jedoch ist $\infty \notin \Theta$. Man könnte also Θ um $\{\infty\}$ erweitern und $\mathbb{P}_\infty := \delta_0$ setzen.

Ein anderes Problem ist, dass für kleine x der Schätzer $T(x)$ stark davon abhängt, ob man einen Fischer mehr oder weniger fängt und daher ist der Schätzer unzuverlässig. Ist x klein, ist es besser, das Experiment mit größerem r zu wiederholen. \diamond

Beispiel 1.2.19 (HARDY-WEINBERG Gleichgewicht)

In einer (unendlich großen) Population gibt es drei genetische Typen; aa, aA und AA mit den Häufigkeiten

$$p_{aa}(\vartheta) := \vartheta^2, \quad p_{aA}(\vartheta) := 2\vartheta(1 - \vartheta), \quad p_{AA}(\vartheta) := (1 - \vartheta)^2$$

für $\vartheta \in [0, 1]$. Beachte, dass mit der binomischen Formel $p_{aa} + p_{aA} + p_{AA} \equiv 1$ gilt.

Sei $E := \{aa, aA, AA\}$. In einer Stichprobe der Größe n beobachten wir n_t Individuen vom Typ $t \in E$.

Wir könnten als statistisches Modell eine **Multinomialverteilung** auf E wählen oder (einfacheres Modell, aber größerer Beobachtungsraum und die unnötige Information der Reihenfolge wird vermerkt) das n -fache Produktmodell von $(E, \mathcal{P}(E), (\mathbb{P}_\vartheta)_{\vartheta \in [0,1]})$, wobei $\mathbb{P}_\vartheta(\{k\}) = p_k(\vartheta)$ für $k \in E$ und $\vartheta \in \Theta := [0, 1]$.

Sei $n_k(x) := |\{i \in \{1, \dots, n\} : x_i = k\}|$ die Anzahl der Individuen von Typ $k \in E$ in der Stichprobe.

Die Likelihoodfunktion ist

$$\rho(x, \vartheta) = \prod_{k=1}^n p_{x_k}(\vartheta) = \prod_{k \in E} p_k(\vartheta)^{n_k(x)} = \vartheta^{2n_{aa}(x)} (2\vartheta(1 - \vartheta))^{n_{aA}(x)} (1 - \vartheta)^{2n_{AA}(x)}$$

und somit die Log-Likelihoodfunktion für $\vartheta \in (0, 1)$

$$\ln(\rho(x, \vartheta)) = 2n_{aa}(x) \ln(\vartheta) + n_{aA}(x) \ln(2\vartheta(1 - \vartheta)) + 2n_{AA}(x) \ln(1 - \vartheta).$$

Es folgt

$$\begin{aligned} \frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) &= \frac{2n_{aa}(x)}{\vartheta} + \frac{n_{aA}(x)}{2\vartheta(1 - \vartheta)} (2 - 4\vartheta) - \frac{2n_{AA}(x)}{1 - \vartheta} \\ &= \frac{2(1 - \vartheta)n_{aa}(x) + (1 - 2\vartheta)n_{aA}(x) - 2\vartheta n_{AA}(x)}{\vartheta(1 - \vartheta)} \end{aligned}$$

und somit unter Ausnutzung von $n_{aa} + n_{aA} + n_{AA} \equiv n$

$$\frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) = 0 \iff \vartheta = \frac{2n_{aa}(x) + n_{aA}(x)}{2(n_{aa}(x) + n_{aA}(x) + n_{AA}(x))} = \frac{2n_{aa}(x) + n_{aA}(x)}{2n}.$$

Ist $n_{aa}(x) = n$, so ist $\rho(x, \vartheta) = \vartheta^{2n}$ und somit $\arg \max_{\vartheta \in [0,1]} \rho(x, \vartheta) = 1$. Ist $n_{AA}(x) = n$, so ist $\rho(x, \vartheta) = (1 - \vartheta)^{2n}$ und somit $\arg \max_{\vartheta \in [0,1]} \rho(x, \vartheta) = 0$.

Gilt $n_{aa} < n$ und $n_{AA} < n$, so gilt $\rho(\cdot, 0) = \rho(\cdot, 1) \equiv 0$ und $\rho(x, \vartheta) > 0$ für $\vartheta \in (0, 1)$. Daher wird das Maximum in

$$\vartheta = \frac{2n_{aa}(x) + n_{aA}(x)}{2n}$$

angenommen, und dieser Ausdruck ist der Maximum-Likelihood-Schätzer $T(x)$ für ϑ . \diamond

28.04.2022

Gegenbeispiel 1.2.20 (Entauschen von Bildern)

Sei $\vartheta \in \mathbb{R}^{m \times n}$ ein aus logarithmierten³ Grauwerten bestehendes „Bild“, welches zufällig vertauscht ist. Wir wählen als Modell $\mathfrak{X} = \mathbb{R}^{m \times n}$, $\mathcal{F} = \mathcal{B}(\mathfrak{X})$ und \mathbb{P}_ϑ als die Verteilung von $(\vartheta_{i,j} + Y_{i,j})_{i,j=1}^{m,n}$, wobei $Y_{i,j} \stackrel{\text{u.i.v.}}{\sim} \mathcal{N}(0, 1)$. Dies ist ein Standardmodell bezüglich des LEBESGUE-Maßes auf $\mathbb{R}^{m \times n}$ und der (unsinnige!) Maximum-Likelihood-Schätzer ist $T_{\text{ML}}(x) = x$ für $x \in \mathfrak{X}$, weil $\mathbb{E}[Y_{i,j}] = 0$ gilt: die Likelihoodfunktion des (i, j) -ten Eintrages ist $\mathcal{N}(\vartheta_{i,j}, 1)$ verteilt und somit ist $\arg \max_{\vartheta \in \mathbb{R}} (2\pi)^{-\frac{1}{2}} \exp\left(-\frac{(x-\vartheta)^2}{2}\right) = x$.

Später werden wir sehen, dass ein BAYESScher Ansatz sinnvoller ist, bei welchem man eine a-priori Verteilung der ϑ wählt. Dies ist realistischer, da Bilder strukturiert sind und nicht nur zufällige Ansammlungen von Grauwerten. \diamond

³Damit die alle Werte in \mathbb{R} angenommen werden können. Den Grauwert 0 müssen wir ignorieren.

1.3 | Beste Schätzer und die Cramér-Rao Ungleichung

Wir haben in Beispiel 1.1.15 gesehen, dass die minimale quadratische Abweichung („Risiko“) überall kein gutes Kriterium für die Güte von Schätzern ist: man kann *nicht* erwarten, dass in einem Modell ein Schätzer T für reellwertige Kenngrößen τ existiert mit $\mathbb{E}_\vartheta[|T - \tau(\vartheta)|^2] \leq \mathbb{E}_\vartheta[|S - \tau(\vartheta)|^2]$ für alle $\vartheta \in \Theta$ und alle Schätzer S . Wenn wir nur erwartungstreue T und S zulassen, können wir aber sinnvolle Aussagen treffen.

DEFINITION 1.3.1 (BESTER SCHÄTZER)

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell. Ein erwartungstreuer Schätzer T für die reelle Kenngröße τ heißt **varianzminimierend** oder **bester Schätzer für τ** (oder UMVU - *uniformly minimal variance unbiased*), wenn $\mathbb{V}_\vartheta[T] < \infty$ und

bester Schätzer

$$\mathbb{V}_\vartheta[T] \leq \mathbb{V}_\vartheta[S] \quad \forall \vartheta \in \Theta, \forall \text{ erwartungstreue Schätzer } S \text{ für } \tau.$$

SATZ 1.3.1: EINDEUTIGKEIT BESTER SCHÄTZER

Der beste Schätzer ist \mathbb{P}_ϑ -fast sicher eindeutig.

Beweis. Angenommen, S und T sind beste Schätzer. Da aufgrund der Linearität des Erwartungswerts auch der Schätzer $\frac{1}{2}(S + T)$ erwartungstreu ist, gilt für alle $\vartheta \in \Theta$

$$\begin{aligned} \mathbb{V}_\vartheta[T] &\stackrel{T \text{ UMVU}}{\leq} \mathbb{V}_\vartheta\left[\frac{1}{2}(S + T)\right] = \frac{1}{4}(\mathbb{V}_\vartheta[S] + \mathbb{V}_\vartheta[T] + 2\text{Cov}_\vartheta[S, T]) \\ &\stackrel{\mathbb{V}_\vartheta[S] = \mathbb{V}_\vartheta[T]}{=} \frac{1}{2}(\mathbb{V}_\vartheta[T] + \text{Cov}_\vartheta[S, T]). \end{aligned}$$

Es folgt

$$\text{Cov}_\vartheta[S, T] \geq \mathbb{V}_\vartheta[S] \quad \forall \vartheta \in \Theta. \quad (5)$$

Daher gilt

$$\mathbb{V}_\vartheta[T - S] = \mathbb{V}_\vartheta[T] + \mathbb{V}_\vartheta[S] - 2\text{Cov}_\vartheta[S, T] = 2\mathbb{V}_\vartheta[T] - 2\text{Cov}_\vartheta[S, T] \stackrel{(5)}{\leq} 0$$

und somit $\mathbb{V}_\vartheta[T - S] = 0$ für alle $\vartheta \in \Theta$, also ist $T - S$ \mathbb{P}_ϑ -fast sicher konstant. Aufgrund der erwartungstreue von T und S gilt $\mathbb{E}_\vartheta[T - S] = 0$, und daher ist $T = S$ \mathbb{P}_ϑ -fast sicher für alle $\vartheta \in \Theta$. \square

Bemerkung 1.3.2 (Intuition: Existenz bester Schätzer) Nehmen wir an, dass es genau drei Schätzer T_1 , T_2 und T_3 gibt, deren Varianzen von der folgenden Form sind




Abb. 2: Im linken Fall ist der beste Schätzer T_3 , im rechten Fall existiert kein bester Schätzer. [Bild getexed von Thomas.]

Der Nachweis, dass kein bester Schätzer existiert, kann aufwendig sein.

SATZ 1.3.2: CHARAKTERISIERUNG BESTER SCHÄTZER

Sei U_0 die Menge aller erwartungstreuen Schätzer von 0 mit endlicher Varianz, das heißt

$$U_0 = \{S: \mathfrak{X} \rightarrow \Theta \text{ messbar} : \mathbb{E}_\vartheta[S] = 0, \mathbb{V}_\vartheta[S] < \infty \forall \vartheta \in \Theta\}.$$

Sei T ein erwartungstreuer Schätzer von τ mit $\mathbb{V}_\vartheta[T] < \infty$ für alle $\vartheta \in \Theta$. Dann sind die folgenden Aussagen äquivalent

- ① T ist ein bester Schätzer für τ .
- ② $\mathbb{E}_\vartheta[TU] = 0$ für alle $U \in U_0$ und alle $\vartheta \in \Theta$.

Beweis. "① \implies ②": Seien $U \in U_0$ und $\vartheta \in \Theta$ beliebig. Für $c \in \mathbb{R}$ sei $T_c := T + cU$. Dann ist auch T_c erwartungstreu und es gilt

$$\mathbb{V}_\vartheta[T_c] \geq \mathbb{V}_\vartheta[T] \quad \forall c \in \mathbb{R}.$$

Dies ist genau dann der Fall, wenn für alle $c \in \mathbb{R}$

$$c^2 \mathbb{V}_\vartheta[U] + 2c \text{Cov}_\vartheta[U, T] \geq 0$$

gilt, was genau dann der Fall ist, wenn $\text{Cov}_\vartheta[U, T] = 0$ ist. Somit ist

$$\mathbb{E}_\vartheta[TU] = \mathbb{E}_\vartheta[T] \mathbb{E}_\vartheta[U] + \text{Cov}_\vartheta[T, U] = 0$$

für alle $\vartheta \in \Theta$.

"② \implies ①": Sei S ein erwartungstreuer Schätzer von τ mit $\mathbb{V}_\vartheta[S] < \infty$. Dann gilt $T - S \in U_0$, da aufgrund von CAUCHY-SCHWARZ $\mathbb{V}_\vartheta[T - S] \leq \mathbb{V}_\vartheta[T] + \mathbb{V}_\vartheta[S] + 2\sqrt{\mathbb{V}_\vartheta[T] \mathbb{V}_\vartheta[S]}$ gilt. Für alle $\vartheta \in \Theta$ folgt aufgrund von $\mathbb{E}_\vartheta[T] = \mathbb{E}_\vartheta[S] = \tau(\vartheta)$ (*), dass

$$\begin{aligned} 0 &= \mathbb{E}_\vartheta[T(T - S)] = \mathbb{E}_\vartheta[T^2] - \mathbb{E}_\vartheta[ST] \\ &\stackrel{(*)}{=} \mathbb{E}_\vartheta[T^2] - \mathbb{E}_\vartheta[T]^2 - \mathbb{E}_\vartheta[ST] + \mathbb{E}_\vartheta[T] \mathbb{E}_\vartheta[S] = \mathbb{V}_\vartheta[T] - \text{Cov}_\vartheta[T, S]. \end{aligned}$$

Aufgrund der CAUCHY-SCHWARZ-Ungleichung $\text{Cov}_\vartheta[T, S]^2 \leq \mathbb{V}_\vartheta[T] \mathbb{V}_\vartheta[S]$ folgt

$$\mathbb{V}_\vartheta[T] \leq \mathbb{V}_\vartheta[S] \quad \forall \vartheta \in \Theta.$$

□

Beispiel 1.3.3 (Modell ohne besten Schätzer: Gleichverteilung)

Wir betrachten $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (\mathbb{P}_\vartheta)_{\vartheta \in \mathbb{R}})$, wobei \mathbb{P}_ϑ die Gleichverteilung auf $[\vartheta - \frac{1}{2}, \vartheta + \frac{1}{2}]$ ist, das heißt die Likelihoodfunktion ist

$$\rho(x, \vartheta) = \mathbb{1}_{[\vartheta - \frac{1}{2}, \vartheta + \frac{1}{2}]}(x).$$

In diesem Modell existiert **kein** bester Schätzer für ϑ .

Beweis. Angenommen, T ist ein bester Schätzer für ϑ . Für $U \in U_0$ gilt

$$\int_{\vartheta - \frac{1}{2}}^{\vartheta + \frac{1}{2}} U(x) dx = \mathbb{E}_\vartheta[U] = 0$$

Nur, wenn U stetig ist (Hauptsatz)!

für alle $\vartheta \in \Theta$. Differenzieren beider Seiten nach ϑ ergibt

$$U\left(\vartheta + \frac{1}{2}\right) - U\left(\vartheta - \frac{1}{2}\right) = 0.$$

Für alle $U \in U_0$ gilt also $U(x) = U(x+1)$ für alle $x \in \mathbb{R}$.

Analog folgt aus $\mathbb{E}_\vartheta[UT] = 0$ für alle $U \in U_0$ und alle $\vartheta \in \Theta$, dass für alle $U \in U_0$

$$T(x)U(x) = T(x+1)U(x+1) \quad \forall x \in \mathbb{R}$$

Angenommen, U sei stetig. Können wir die Stetigkeit von TU garantieren?

gilt. Mit $U(x) = U(x+1)$ für alle $x \in \mathbb{R}$ folgt daraus

$$T(x) = T(x+1) \quad \forall x \in \mathbb{R}. \tag{6}$$

Da T erwartungstreu ist, gilt

$$\int_{\vartheta - \frac{1}{2}}^{\vartheta + \frac{1}{2}} T(x) dx = \mathbb{E}_\vartheta[T] = \vartheta \quad \forall \vartheta \in \Theta.$$

Differenzieren nach ϑ dieser Gleichung ergibt

$$T\left(\vartheta + \frac{1}{2}\right) - T\left(\vartheta - \frac{1}{2}\right) = 1,$$

was (6) widerspricht. □

Unsere Aufgabe ist es nun, einen besten Schätzer T zu berechnen, sofern dies möglich ist. Dafür benötigen wir jedoch einige **Regularitätsbedingungen**: wir betrachten nur spezielle statistische Modelle.

DEFINITION 1.3.4 (REGULÄRES MODELL, SCOREFUNKTION, FISHER-INFO)

Ein Standardmodell $(\mathcal{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ist **regulär**, wenn

regulär

- $\Theta \subset \mathbb{R}$ ein **offenes Intervall** ist,

- die Likelihoodfunktion ρ strikt positiv auf $\mathfrak{X} \times \Theta$ und nach ϑ stetig differenzierbar ist (man kann diese Eigenschaften auch nur fast überall fordern).

Dann ist die **Scorefunktion**

Scorefunktion

$$U_{\vartheta}(x) := \frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) = \frac{\frac{\partial}{\partial \vartheta} \rho(x, \vartheta)}{\rho(x, \vartheta)}$$

wohldefiniert. Wir benutzen die Kurzschreibweise $\rho'(x, \vartheta) := \frac{\partial}{\partial \vartheta} \rho(x, \vartheta)$.

Zuletzt fordern wir, dass die **FISHER-Information** des Modells $I(\vartheta) := \mathbb{V}_{\vartheta}[U_{\vartheta}] \in (0, \infty)$ ist und die **Vertauschungsrelation**

FISHER-
Information

$$\int_{\mathfrak{X}} \frac{\partial}{\partial \vartheta} \rho(x, \vartheta) d\mu_0(x) \stackrel{!}{=} \underbrace{\frac{\partial}{\partial \vartheta} \int_{\mathfrak{X}} \rho(x, \vartheta) d\mu_0(x)}_{=1} = 0 \quad (7)$$

gilt, wobei wir fordern, dass die linke Seite wohldefiniert ist, das heißt, dass $\frac{\partial}{\partial \vartheta} \rho(\cdot, \vartheta)$ bezüglich μ_0 integrierbar ist.

Es ist Hausaufgabe 3.1 (a), zu zeigen, dass die FISHER-Information unabhängig von dem dominierenden Maß ist.

Bemerkung 1.3.5 (Hinreichende Bedingungen für die Vertauschungsrelation)

Die Vertauschungsrelation (7) ist erfüllt, wenn \mathfrak{X} endlich und μ_0 das Zählmaß auf $(\mathfrak{X}, \mathcal{P}(\mathfrak{X}))$ ist. Allgemein ist hinreichend, dass für alle $\vartheta_0 \in \Theta$ eine Umgebung $N(\vartheta_0) \subset \Theta$ existiert mit

$$\int_{\mathfrak{X}} \sup_{\vartheta \in N(\vartheta_0)} \left| \frac{\partial}{\partial \vartheta} \rho(x, \vartheta) \right| d\mu_0(x) < \infty.$$

Dies folgt aus dem **Satz über majorisierte Konvergenz**, denn für $h \neq 0$ mit $\vartheta + h \in N(\vartheta_0)$ gilt

$$\int_{\mathfrak{X}} \underbrace{\frac{\rho(x, \vartheta + h) - \rho(x, \vartheta)}{h}}_{\xrightarrow{h \rightarrow 0} \frac{\partial}{\partial \vartheta} \rho(x, \vartheta)} d\mu_0(x) < \infty$$

und $\frac{\partial}{\partial \vartheta} \rho(\cdot, \vartheta)$ ist als punktweise Grenzwert messbarer Funktionen eine messbare Funktion. Nach dem **Mittelwertsatz** existiert ein $\tilde{\vartheta}(x)$ zwischen ϑ und $\vartheta + h$ mit $\frac{\rho(x, \vartheta + h) - \rho(x, \vartheta)}{h} = \frac{\partial}{\partial \vartheta} \rho(x, \tilde{\vartheta}(x))$. ○

Bemerkung 1.3.6 ($\mathbb{E}_{\vartheta}[U_{\vartheta}] = 0$ im regulären Modell)

In einem regulären Modell gilt

$$\mathbb{E}_{\vartheta}[U_{\vartheta}] = \int_{\mathfrak{X}} U_{\vartheta}(x) d\mathbb{P}_{\vartheta}(x) = \int_{\mathfrak{X}} \frac{\rho'(x, \vartheta)}{\rho(x, \vartheta)} \rho(x, \vartheta) d\mu_0(x) = \int_{\mathfrak{X}} \rho'(x, \vartheta) d\mu_0(x) \stackrel{(7)}{=} 0. \quad (8)$$

Es folgt

$$I(\vartheta) = \mathbb{V}_{\vartheta}[U_{\vartheta}] = \mathbb{E}_{\vartheta}[U_{\vartheta}^2]. \quad (9)$$

○

Lemma 1.3.7 (I unterhalbstetig)

Im regulären Modell ist I unterhalbstetig, das heißt

$$I(\vartheta) \leq \liminf_{h \rightarrow 0} I(\vartheta + h) \quad \text{für hinreichend kleine } h.$$

Beweis. Da $\vartheta \mapsto U_\vartheta$ als Quotient stetiger Funktionen stetig ist, gilt

$$\liminf_{h \rightarrow 0} U_{\vartheta+h}(x) = \lim_{h \rightarrow 0} U_{\vartheta+h}(x) = U_\vartheta(x) \quad \forall x \in \mathfrak{X}.$$

Nach dem **Lemma von FATOU** folgt daraus

$$\mathbb{E}_\vartheta[U_\vartheta^2] \leq \liminf_{h \rightarrow 0} \mathbb{E}_\vartheta[U_{\vartheta+h}^2].$$

□

Frage: Ist I im regulären Modell sogar stetig?

Beispiel 1.3.8 (Formel für die FISHER-Information im Produktmodell)

Gegeben sei das reguläre statistische Modell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathbb{P}_\vartheta^{\otimes n} : \vartheta \in \mathbb{R}_{>0})$, wobei \mathbb{P}_ϑ die Dichte

$$\rho(\vartheta, \cdot) = \frac{1}{\vartheta} f\left(\frac{\cdot}{\vartheta}\right),$$

besitzt und $f(x) > 0$ ist sowie $f'(x)$ existiert für alle $x \in \mathbb{R}$. Die Fisher-Information ist (Hausaufgabe 3.1 (b))

$$I(\vartheta) = \frac{n}{\vartheta^2} \int_{\mathbb{R}} \frac{(xf'(x) + f(x))^2}{f(x)} dx.$$

◇

DEFINITION 1.3.9 (REGULÄRER SCHÄTZER)

Ein erwartungstreuer Schätzer T für eine reelle Kenngröße τ in einem regulären Modell ist **regulär**, wenn

regulär

$$\int_{\mathfrak{X}} T(x) \rho'(x, \vartheta) d\mu_0(x) = \frac{\partial}{\partial \vartheta} \int_{\mathfrak{X}} T(x) \rho(x, \vartheta) d\mu_0(x) \quad \forall \vartheta \in \Theta$$

und beide Seiten definiert sind.

Bemerkung 1.3.10 Für einen erwartungstreuen Schätzer T für die Kenngröße τ gilt

$$\frac{\partial}{\partial \vartheta} \int_{\mathfrak{X}} T(x) \rho(x, \vartheta) d\mu_0(x) = \frac{\partial}{\partial \vartheta} \int_{\mathfrak{X}} T(x) d\mathbb{P}_\vartheta(x) = \frac{\partial}{\partial \vartheta} \mathbb{E}_\vartheta[T] = \frac{\partial}{\partial \vartheta} \tau(\vartheta) = \tau'(\vartheta).$$

○

SATZ 1.3.3: CRAMÉR-RAO INFORMATIONSUNGLEICHUNG I

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ regulär, $\tau : \Theta \rightarrow \mathbb{R}$ stetig differenzierbar (mit $\tau' \neq 0$) und T ein regulärer Schätzer für τ . Dann gilt

$$\mathbb{V}_\vartheta[T] \geq \frac{\tau'(\vartheta)^2}{I(\vartheta)} \quad \forall \vartheta \in \Theta. \quad (10)$$

Bemerkung 1.3.11 Gilt für T Gleichheit in (10), so existiert kein besserer regulärer Schätzer für τ . \circ

Beweis. (von Satz 1.3.3) Sei $\vartheta \in \Theta$. Ohne Beschränkung der Allgemeinheit sei $\mathbb{V}_\vartheta[T] < \infty$. Es gilt

$$\begin{aligned} \text{Cov}_\vartheta[T, U_\vartheta] &= \mathbb{E}_\vartheta[TU_\vartheta] - \underbrace{\mathbb{E}_\vartheta[T] \mathbb{E}_\vartheta[U_\vartheta]}_{\stackrel{(8)}{=} 0} = \mathbb{E}_\vartheta[TU_\vartheta] = \int_{\mathfrak{X}} T(x)U_\vartheta(x) \, d\mathbb{P}_\vartheta(x) \\ &= \int_{\mathfrak{X}} T(x) \frac{\rho'(x, \vartheta)}{\rho(x, \vartheta)} \rho(x, \vartheta) \, d\mu_0(x) = \int_{\mathfrak{X}} T(x) \rho'(x, \vartheta) \, d\mu_0(x) \\ &\stackrel{T \text{ regulär}}{=} \frac{\partial}{\partial \vartheta} \int_{\mathfrak{X}} T(x) \rho(x, \vartheta) \, d\mu_0(x) = \tau'(\vartheta) \end{aligned} \quad (11)$$

und somit folgt mit der **CAUCHY-SCHWARZ-Ungleichung**

$$\tau'(\vartheta)^2 \stackrel{(11)}{=} \text{Cov}_\vartheta[T, U_\vartheta]^2 \leq \mathbb{V}_\vartheta[T] \mathbb{V}_\vartheta[U_\vartheta] \stackrel{(9)}{=} \mathbb{V}_\vartheta[T] I(\vartheta). \quad \square$$

Bemerkung 1.3.12 (Bedeutung der FISHER-Information)

Gilt $I(\vartheta) = 0$, so ist fast sicher $\rho'(x, \vartheta) = 0$; $I(\vartheta)$ gibt uns die Information, die uns die Beobachtung von x über ϑ gibt. Ist $\rho(x, \vartheta)$ konstant auf einem Intervall, sind die zugehörigen \mathbb{P}_ϑ alle gleich, also hilft die Beobachtung x uns auch nicht, sie zu unterscheiden. \circ

Beispiel 1.3.13 (Kein Widerspruch zu Satz 1.3.3)

Betrachte das statistische Modell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_\vartheta^{\otimes n})_{\vartheta \in \mathbb{R}})$, wobei \mathbb{P}_ϑ für $\vartheta \in \Theta$ die Dichte

$$\rho(\vartheta, x) := e^{\vartheta - x} \mathbb{1}_{[\vartheta, \infty)}(x)$$

bezüglich des LEBESGUE-Maßes hat.

Es ist Hausaufgabe 3.2 zu zeigen, dass für $\tau(\vartheta) := \vartheta$ der Maximum-Likelihood Schätzer $T(x) = x_{(1)}$ ist und den Erwartungswert $\vartheta + \frac{1}{n}$ hat, sowie dass $I(\vartheta) < \frac{1}{\mathbb{V}_\vartheta[T]}$ für alle $\vartheta \in \mathbb{R}$ gilt, was aber keinen Widerspruch zu Satz 1.3.3 darstellt. \diamond

03.05.2022

SATZ 1.3.4: CRAMÉR-RAO INFORMATIONSUNGLEICHUNG II

Unter den Voraussetzungen von Satz 1.3.3 gilt Gleichheit in (10) für $\vartheta \in \Theta$ genau dann wenn

$$T(x) - \tau(\vartheta) = \tau'(\vartheta) \frac{U_\vartheta(x)}{I(\vartheta)} \quad \text{für alle } \mathbb{P}_\vartheta\text{-fast alle } x \in \mathfrak{X}. \quad (12)$$

Dann ist I stetig und die Likelihoodfunktion ρ hat die Darstellung

$$\rho(x, \vartheta) = h(x) \exp(a(\vartheta)T(x) - b(\vartheta)), \quad x \in \mathfrak{X}, \vartheta \in \Theta,$$

(insb. ist das Modell exponentiell) wobei

$$a(\vartheta) := \int_{\Delta} \frac{I(\kappa)}{\tau'(\kappa)} \, d\kappa$$

für ein beliebiges $\Delta \in \Theta$, $h: (\mathfrak{X}, \mathcal{F}) \rightarrow ((0, \infty), \mathcal{B}((0, \infty)))$ messbar und

$$b(\vartheta) := \ln \left(\int_{\mathfrak{X}} h(x) \exp(a(\vartheta)T(x)) d\mu_0(x) \right)$$

die Normalisierungskonstante bezüglich \mathfrak{X} sind.

Beweis. ① **Die Gleichung (12).** Sowohl unter (10) sowie unter (12) gilt $\mathbb{V}_{\vartheta}[T] < \infty$.

Sei $c: \Theta \rightarrow \mathbb{R}$, $\vartheta \mapsto \frac{\tau'(\vartheta)}{I(\vartheta)}$. Dann gilt

$$\begin{aligned} 0 &\leq \mathbb{V}_{\vartheta}[T - c(\vartheta)U_{\vartheta}] = \mathbb{V}_{\vartheta}[T] + c(\vartheta)^2 \underbrace{\mathbb{V}_{\vartheta}[U_{\vartheta}]}_{\stackrel{(9)}{=} I(\vartheta)} - 2c(\vartheta) \underbrace{\text{Cov}_{\vartheta}[T, U_{\vartheta}]}_{\stackrel{(11)}{=} \tau'(\vartheta)} \\ &= \mathbb{V}_{\vartheta}[T] + \frac{\tau'(\vartheta)^2}{I(\vartheta)} - 2 \frac{\tau'(\vartheta)^2}{I(\vartheta)} = \mathbb{V}_{\vartheta}[T] - \frac{\tau'(\vartheta)^2}{I(\vartheta)}. \end{aligned}$$

Daraus folgt wieder die CRÁMER-RAO Ungleichung. Ferner folgt, dass genau dann Gleichheit in (10) gilt, wenn

$$\mathbb{V}_{\vartheta}[T - c(\vartheta)U_{\vartheta}] = 0 \quad \forall \vartheta \in \Theta,$$

beziehungsweise, wenn $x \mapsto T(x) - c(\vartheta)U_{\vartheta}(x)$ \mathbb{P}_{ϑ} -fast sicher konstant ist. Diese (von ϑ abhängige) Konstante muss für jedes ϑ mit dem Erwartungswert

$$\mathbb{E}_{\vartheta}[T - c(\vartheta)U_{\vartheta}] = \mathbb{E}_{\vartheta}[T] - c(\vartheta) \cdot 0 = \tau(\vartheta)$$

übereinstimmen. Somit gilt Gleichheit in (10) für alle $\vartheta \in \Theta$ genau dann, wenn

$$T(x) - c(\vartheta)U_{\vartheta}(x) = \tau(\vartheta)$$

für \mathbb{P}_{ϑ} -fast alle $x \in \mathfrak{X}$, und das ist (12).

② **Stetigkeit von I .** Angenommen, I ist unstetig in $\vartheta_0 \in \Theta$. Dann existiert ein $\varepsilon > 0$ und eine Folge $(\vartheta_n)_{n \in \mathbb{N}} \subset \Theta$ mit $\vartheta_n \xrightarrow{n \rightarrow \infty} \vartheta_0$, sodass $|I(\vartheta_n) - I(\vartheta_0)| > \varepsilon$ für alle $n \in \mathbb{N}$ gilt.

Sei $N_n := \{x \in \mathfrak{X} : T(x) - \tau(\vartheta_n) \neq c(\vartheta_n)U_{\vartheta_n}(x)\}$ für $n \in \mathbb{N}_0$. Nach der Voraussetzung (12) ist N_n eine \mathbb{P}_{ϑ_n} -Nullmenge. Da ρ auf $\mathfrak{X} \times \Theta$ positiv ist, gilt auch $\mu_0(N_n) = 0$ für alle $n \in \mathbb{N}_0$ (cf. Lemma 1.5.10). Man sagt \mathbb{P}_{ϑ_n} und μ_0 sind **äquivalent** - sie haben dieselben Nullmengen). Da die abzählbare Vereinigung von μ_0 -Nullmengen eine μ_0 -Nullmenge ist, folgt $\mu_0(\bigcup_{n \in \mathbb{N}_0} N_n) = 0$.

Sei $x \notin N := \bigcup_{n \in \mathbb{N}_0} N_n$. Dann gilt für alle $n \in \mathbb{N}_0$

$$T(x) - \tau(\vartheta_n) = c(\vartheta_n)U_{\vartheta_n}(x) = \frac{\tau'(\vartheta_n)U_{\vartheta_n}(x)}{I(\vartheta_n)}. \quad (13)$$

Um die Stetigkeit von I zu zeigen, genügt es nun, nach I umzustellen.

Da $\mathbb{V}_{\vartheta_0}[U_{\vartheta_0}] = I(\vartheta_0) > 0$ gilt, existiert ein $x \notin N$ mit $U_{\vartheta_0}(x) \neq 0$. Wegen der Stetigkeit von $\vartheta \mapsto U_{\vartheta}(x)$ können wir annehmen, dass (möglicherweise erst durch

Wahl einer Teilfolge) $U_{\vartheta_n}(x) \neq 0$ für alle $n \in \mathbb{N}_0$ gilt. Aus (13) folgt somit jeweils $T(x) - \tau(\vartheta_n) \neq 0$ und damit

$$I(\vartheta_n) = \frac{\tau'(\vartheta_n)U_{\vartheta_n}(x)}{T(x) - \tau(\vartheta_n)} \xrightarrow{n \rightarrow \infty} \frac{\tau'(\vartheta_0)U_{\vartheta_0}(x)}{T(x) - \tau(\vartheta_0)} = I(\vartheta_0),$$

im Widerspruch zur Annahme $|I(\vartheta_n) - I(\vartheta_0)| > \varepsilon$ für alle $n \in \mathbb{N}$.

- ③ **Darstellung von ρ .** Sei nun $N_\vartheta := \{x \in \mathfrak{X} : T(x) - c(\vartheta)U_\vartheta(x) \neq \tau(\vartheta)\}$ für $\vartheta \in \Theta$. Dann gilt wie zuvor $\mu_0\left(\bigcup_{\vartheta \in \Theta \cap \mathbb{Q}} N_\vartheta\right) = 0$. Für $x \notin N := \bigcup_{\vartheta \in \Theta \cap \mathbb{Q}} N_\vartheta$ gilt

$$T(x) - c(\vartheta)U_\vartheta(x) - \tau(\vartheta) = 0 \quad \forall \vartheta \in \Theta \cap \mathbb{Q}.$$

Wegen der Stetigkeit der linken Seite in $\vartheta \in \Theta$ folgt sogar

$$T(x) - c(\vartheta)U_\vartheta(x) - \tau(\vartheta) = 0 \quad \forall \vartheta \in \Theta$$

und somit

$$\frac{1}{c(\vartheta)}(T(x) - \tau(\vartheta)) = (T(x) - \tau(\vartheta)) \frac{I(\vartheta)}{\tau'(\vartheta)} = U_\vartheta(x) = \frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)).$$

Integrieren dieser Gleichung bezüglich ϑ von $\Delta \in \Theta$ bis ϑ ergibt

$$\ln(\rho(x, \vartheta)) = \ln(\rho(x, \Delta)) + T(x) \int_\Delta^\vartheta \frac{I(\kappa)}{\tau'(\kappa)} d\kappa - \underbrace{\int_\Delta^\vartheta \frac{I(\kappa)}{\tau'(\kappa)} \tau(\kappa) d\kappa}_{=: \gamma(\vartheta)}.$$

Es folgt

$$\rho(x, \vartheta) = \underbrace{\rho(x, \Delta)}_{=: h(x)} \exp(T(x)a(\vartheta) - \gamma(\vartheta)).$$

Da $\int_{\mathfrak{X}} \rho(x, \vartheta) d\mu_0(x) = 1$ für alle $\vartheta \in \Theta$ gilt, folgt

$$\int_{\mathfrak{X}} h(x) \exp(T(x)a(\vartheta)) d\mu_0(x) = e^{\gamma(\vartheta)}$$

und somit $\gamma = b$. Für $x \in N$ definieren wir $h(x) \equiv 1 > 0$. □

Bemerkung 1.3.14 (Anschauung für c) Sei $\langle \cdot, \cdot \rangle_\vartheta$ das $L^2(\mathbb{P}_\vartheta)$ -Skalarprodukt. Dann gilt (weil die CAUCHY-SCHWARZ-Ungleichung genau eine Gleichung ist, wenn die Terme linear abhängig ist)

$$T - \tau(\vartheta) = \frac{\tau'(\vartheta)}{I(\vartheta)} U_\vartheta = \frac{\langle T - \tau(\vartheta), T - \tau(\vartheta) \rangle_\vartheta}{\langle U_\vartheta, U_\vartheta \rangle_\vartheta} U_\vartheta,$$

also ist $T - \tau(\vartheta)$ die orthogonale Projektion auf die Scorefunktion bzgl. des $L^2(\mathbb{P}_\vartheta)$ -Skalarprodukts. ◻

Wir geben Modellen, bei denen die Likelihoodfunktion diese Form hat, einen Namen.

DEFINITION 1.3.15 (EXPONENTIELLES MODELL (PITMAN, DARMOIS, KOOPMAN))

Ein Standardmodell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$, wobei Θ ein offenes Intervall ist (es gibt auch eine [technischere Theorie](#), wobei $\Theta \subset \mathbb{R}^k$ offen ist), heißt **exponentielles Modell** und $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ eine **exponentielle Familie bezüglich der** Statistik $T: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$, wenn die Likelihoodfunktion die Gestalt

$$\rho(x, \vartheta) = h(x) \exp(\alpha(\vartheta)T(x) - b(\vartheta))$$

für $x \in \mathfrak{X}$ und $\vartheta \in \Theta$ hat, wobei $a \in \mathcal{C}^1(\Theta)$ mit $a'(\vartheta) \neq 0$ für alle $\vartheta \in \Theta$ und $h: (\mathfrak{X}, \mathcal{F}) \rightarrow ((0, \infty), \mathcal{B}((0, \infty)))$ messbar ist. Weiter sei vorausgesetzt, dass für jedes $\vartheta \in \Theta$ die Statistik T nicht \mathbb{P}_ϑ -fast überall konstant ist.

exponentielles
Modell

Bemerkung 1.3.16 (Gestalt von b) Da $\rho(\cdot, \vartheta)$ für jedes $\vartheta \in \Theta$ eine Dichte bezüglich μ_0 ist, gilt wie im dritten Schritt des Beweises von Satz 1.3.4

$$b(\vartheta) = \log \left(\int_{\mathfrak{X}} h(x) \exp(a(\vartheta)T(x)) d\mu_0(x) \right).$$

◦

SATZ 1.3.5: EIGENSCHAFTEN EXPONENTIELLER MODELLE

Für ein exponentielles Modell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ bezüglich der Statistik T mit der Likelihoodfunktion

$$\rho(x, \vartheta) = h(x) \exp(a(\vartheta)T(x) - b(\vartheta)) \quad (14)$$

gilt

- ① $\mathbb{E}_\vartheta[T^2] < \infty$ für alle $\vartheta \in \Theta$,
- ② $b \in \mathcal{C}^1(\Theta)$ und $b'(\vartheta) = a'(\vartheta) \mathbb{E}_\vartheta[T]$ für alle $\vartheta \in \Theta$. Insbesondere ist $\rho(x, \cdot) \in \mathcal{C}^1(\Theta)$ für alle $x \in \mathfrak{X}$,
- ③ die Kenngröße $\tau(\vartheta) := \mathbb{E}_\vartheta[T]$ ist stetig differenzierbar mit $\tau'(\vartheta) = a'(\vartheta) \mathbb{V}_\vartheta[T] \neq 0$ (merke, dass $\mathbb{V}_\vartheta[T] > 0$ da T nach Definition 1.3.15 \mathbb{P}_ϑ -fast sicher nicht konstant ist),
- ④ $I(\vartheta) = a'(\vartheta)^2 \mathbb{V}_\vartheta[T] > 0$,
- ⑤ Jede Statistik $S: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\mathbb{E}_\vartheta[|S|] < \infty$ für alle $\vartheta \in \Theta$ erfüllt die Vertauschungsrelation.

Insbesondere gilt $\mathbb{V}_\vartheta[T] \stackrel{\textcircled{3}}{=} \frac{\tau'(\vartheta)}{a'(\vartheta)} \stackrel{\textcircled{4}}{=} \frac{\tau'(\vartheta)^2}{I(\vartheta)}$ für alle $\vartheta \in \Theta$, somit gilt die CRAMÉR-RAO-Ungleichung mit Gleichheit und das Modell und der Schätzer T sind regulär. Weiter ist T bester Schätzer für τ .

Beweis. Wir können durch Reparametrisierung annehmen, dass a die Identität auf Θ ist, da a streng monoton ist. (Warum sich dadurch die Likelihoodfunktion nicht ändert, ist nicht prüfungsrelevant.)

- ① Seien $S: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ eine Statistik mit $\mathbb{E}_\vartheta[|S|] < \infty$ für alle $\vartheta \in \Theta$ sowie

$$u_S: \Theta \rightarrow \mathbb{R}, \quad \vartheta \mapsto e^{b(\vartheta)} \mathbb{E}_\vartheta[S] = \int_{\mathfrak{X}} S(x) e^{\vartheta T(x)} h(x) d\mu_0(x). \quad (15)$$

Für $\vartheta \in \Theta$ und $t \in \mathbb{R}$ mit $\vartheta \pm t \in \Theta$ (existiert da Θ ein offenes Intervall ist) gilt aufgrund des Satzes von BEPPO-LEVI (BL)

$$\begin{aligned} \sum_{k=0}^{\infty} \frac{|t|^k}{k!} \int_{\mathfrak{X}} |S(x)| |T(x)|^k e^{\vartheta T(x)} h(x) d\mu_0(x) &\stackrel{\text{BL}}{=} \int_{\mathfrak{X}} |S(x)| e^{|tT(x)|} e^{\vartheta T(x)} h(x) d\mu_0(x) \\ &\stackrel{(\star)}{\leq} \int_{\mathfrak{X}} |S(x)| \left(e^{tT(x)} + e^{-tT(x)} \right) e^{\vartheta T(x)} h(x) d\mu_0(x) \\ &= \mathbb{E}_{\vartheta+t}[|S|] + \mathbb{E}_{\vartheta-t}[|S|] < \infty, \end{aligned}$$

wobei (\star) die Ungleichung $e^{|x|} \leq e^x + e^{-x}$ für alle $x \in \mathbb{R}$ ist⁴. Also ist $\mathbb{E}_\vartheta[|S| \cdot |T|^k] < \infty$ für alle $k \in \mathbb{N}$ und alle $\vartheta \in \Theta$. Insbesondere $\mathbb{E}_\vartheta[T^2] < \infty$ folgt für $S \equiv 1$ und $k = 2$.

⁴Da beide Funktionen gerade sind, können wir ohne Beschränkung der Allgemeinheit $x > 0$ annehmen (für $x = 0$ ist die Ungleichung offensichtlich strikt). Für diese x ist die Ungleichung einfach $e^x \leq e^x + e^{-x} \iff 0 \leq e^{-x}$.

② und ③. Die Reihe

$$\sum_{k=0}^{\infty} \frac{t^k}{k!} \int_{\mathfrak{X}} S(x) T(x)^k e^{\vartheta T(x)} h(x) d\mu_0(x)$$

ist absolut konvergent für alle $t \in \mathbb{R}$ mit $\vartheta \pm t \in \Theta$. Die Summe und das Integral sind vertauschbar nach dem Satz von FUBINI, das heißt die Reihe hat den Wert

$$\int_{\mathfrak{X}} S(x) e^{(\vartheta+t)T(x)} h(x) d\mu_0(x) = u_S(\vartheta + t).$$

Somit ist u_S in einer entsprechenden Umgebung **analytisch** und es gilt

$$\begin{aligned} u'_S(\vartheta) &= \lim_{t \rightarrow 0} \frac{1}{t} (u_S(\vartheta + t) - u_S(\vartheta)) \\ &= \lim_{t \rightarrow 0} \int_{\mathfrak{X}} S(x) \left(\frac{e^{(\vartheta+t)T(x)} - e^{\vartheta T(x)}}{t} \right) h(x) d\mu_0(x) \\ &= \int_{\mathfrak{X}} S(x) \left(\lim_{t \rightarrow 0} \frac{e^{(\vartheta+t)T(x)} - e^{\vartheta T(x)}}{t} \right) h(x) d\mu_0(x) \\ &= \int_{\mathfrak{X}} S(x) T(x) e^{\vartheta T(x)} h(x) d\mu_0(x) = e^{b(\vartheta)} \mathbb{E}_{\vartheta}[S \cdot T]. \end{aligned} \tag{16}$$

Für $S \equiv 1$ folgt

$$u'_1(\vartheta) = e^{b(\vartheta)} \mathbb{E}_{\vartheta}[T] \quad \text{und} \quad u''_1(\vartheta) = e^{b(\vartheta)} \mathbb{E}_{\vartheta}[T^2]. \tag{17}$$

Wegen $b(\vartheta) = \ln(u_1(\vartheta))$ folgt

$$b'(\vartheta) = \frac{u'_1(\vartheta)}{u_1(\vartheta)} \stackrel{(15)}{=} \mathbb{E}_{\vartheta}[T] = \tau(\vartheta) \tag{18}$$

für alle $\vartheta \in \Theta$ und somit

$$\begin{aligned} \tau'(\vartheta) &= b''(\vartheta) = \left(\frac{u'_1(\vartheta)}{u_1(\vartheta)} \right)' = \frac{u_1(\vartheta) u''_1(\vartheta) - u'_1(\vartheta)^2}{u_1(\vartheta)^2} \\ &\stackrel{(17)}{=} \frac{e^{2b(\vartheta)} \mathbb{E}_{\vartheta}[T^2] - e^{2b(\vartheta)} \mathbb{E}_{\vartheta}[T]^2}{e^{2b(\vartheta)}} = \mathbb{E}_{\vartheta}[T^2] - \mathbb{E}_{\vartheta}[T]^2 = \mathbb{V}_{\vartheta}[T]. \end{aligned} \tag{19}$$

Mit $a'(\vartheta) = 1$ folgen die Aussagen.

④ Für alle $\vartheta \in \Theta$ gilt

$$U_{\vartheta}(x) = \frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) \stackrel{(14)}{=} T(x) - b'(\vartheta), \tag{20}$$

und somit gilt

$$\mathbb{E}_{\vartheta}[U_{\vartheta}] = \mathbb{E}_{\vartheta}[T] - b'(\vartheta) \stackrel{(18)}{=} \tau(\vartheta) - \tau(\vartheta) = 0$$

und

$$I(\vartheta) = \mathbb{V}_{\vartheta}[U_{\vartheta}] \stackrel{(20)}{=} \mathbb{V}_{\vartheta}[T - b'(\vartheta)] = \mathbb{V}_{\vartheta}[T] \stackrel{(19)}{=} \tau'(\vartheta).$$

⑤ Es gilt

$$\begin{aligned} \frac{d}{d\vartheta} \mathbb{E}_{\vartheta}[S] &\stackrel{(15)}{=} \frac{d}{d\vartheta} u_S(\vartheta) e^{-b(\vartheta)} = [u'_S(\vartheta) - b'(\vartheta) u_S(\vartheta)] e^{-b(\vartheta)} \\ &\stackrel{(16)}{=} \mathbb{E}_{\vartheta}[S \cdot T] - b'(\vartheta) \mathbb{E}_{\vartheta}[S] \stackrel{(18)}{=} \mathbb{E}_{\vartheta}[ST] - \mathbb{E}_{\vartheta}[S] \mathbb{E}_{\vartheta}[T]. \end{aligned} \tag{21}$$

Also folgt

$$\begin{aligned}
\int_{\mathfrak{X}} S(x) \frac{\partial}{\partial \vartheta} \rho(x, \vartheta) d\mu_0(x) &= \mathbb{E}_{\vartheta}[S \cdot U_{\vartheta}] \stackrel{(20)}{=} \mathbb{E}_{\vartheta}[S \cdot (T - \tau(\vartheta))] \\
&= \mathbb{E}_{\vartheta}[ST] - \mathbb{E}_{\vartheta}[S] \underbrace{\mathbb{E}_{\vartheta}[T]}_{=\tau(\vartheta)} \\
&\stackrel{(21)}{=} \frac{d}{d\vartheta} \mathbb{E}_{\vartheta}[S] = \frac{d}{d\vartheta} \int_{\mathfrak{X}} S(x) \rho(x, \vartheta) d\mu_0(x). \quad \square
\end{aligned}$$

Das Produkt regulärer Modelle ist regulär.

Lemma 1.3.17 (Produkt exponentieller Modelle ist exponentiell)

Ist $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_{\vartheta})_{\vartheta \in \Theta})$ ein exponentielles Modell bezüglich T und $n \in \mathbb{N}$, so ist das n -fache Produktmodell exponentiell bezüglich $T_n(x) := \frac{1}{n} \sum_{k=1}^n T(x_k)$. Insbesondere ist T_n der beste Schätzer für $\tau := \mathbb{E}[T]$ (nach Satz 1.3.5).

Beweis. Ist $\rho(x, \vartheta) = h(x)e^{a(\vartheta)T(x)-b(\vartheta)}$ die Likelihoodfunktion von $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_{\vartheta})_{\vartheta \in \Theta})$, so ist die Likelihoodfunktion des Produktmodells

$$\begin{aligned}
(x, \vartheta) \mapsto \prod_{k=1}^n \rho(x_k, \vartheta) &= \left(\prod_{k=1}^n h(x_k) \right) \exp \left(a(\vartheta) \cdot \sum_{k=1}^n T(x_k) - nb(\vartheta) \right) \\
&= \underbrace{\left(\prod_{k=1}^n h(x_k) \right)}_{=:h_n(x)} \exp \left(\underbrace{n \cdot a(\vartheta)}_{=:a_n(\vartheta)} \cdot T_n(x) - \underbrace{nb(\vartheta)}_{=:b_n(\vartheta)} \right) \quad \square
\end{aligned}$$

Bemerkung 1.3.18 (FISHER-Information des Produktmodells)

Ist I die FISHER-Information des Modells, so ist die FISHER-Information des Produktmodells

$$I_n(\vartheta) \stackrel{1.3.5}{=} a'_n(\vartheta) \tau'(\vartheta) = na'(\vartheta) \tau'(\vartheta) = nI(\vartheta).$$

Die FISHER-Information ist also **exakt additiv** - mehr Versuche geben uns mehr Information. \circ

Bemerkung 1.3.19 Die Formel $I_n = nI$ gilt allgemein für reguläre Produktmodelle (cf. [2, Bem. 7.17]). Unter den Voraussetzungen von Satz 1.3.3 gilt für jedes $n \in \mathbb{N}$ und jeden regulären erwartungstreuen Schätzer T_n für τ des Produktmodells

$$\mathbb{V}_{\vartheta}[T_n] \geq \frac{\tau'(\vartheta)^2}{I_n(\vartheta)} = \frac{\tau'(\vartheta)^2}{nI(\vartheta)} \in O(n^{-1}) \text{ für } n \rightarrow \infty \quad \forall \vartheta \in \Theta. \quad \circ$$

Bemerkung 1.3.20 Im Gameshow-Modell sahen wir, dass $T_n^*(x) := \frac{n+1}{n}x_{(n)}$ ein erwartungstreuer Schätzer für ϑ ist und $\mathbb{V}_{\vartheta}[T_n^*] = \frac{\vartheta^2}{n(n+2)}$. Dies ist *kein* Widerspruch, da dieses Modell nicht regulär ist, da die Likelihoodfunktion für $n = 1$

$$\rho(x, \vartheta) = \frac{1}{\vartheta} \mathbb{1}_{[0, \vartheta]}(x)$$

und somit nicht stetig (und schon gar nicht differenzierbar) ist. \circ

Beispiel 1.3.21 (Binomialmodell ist exponentiell)

Für $n \in \mathbb{N}$ bilden die **Binomialverteilung** $(B_{n,\vartheta})_{\vartheta \in \Theta := (0,1)}$ eine exponentielle Familie auf $(\mathfrak{X} := \{0, \dots, n\}, \mathcal{F} := \mathcal{P}(\mathfrak{X}))$ mit dem Zählmaß μ_0 und $T(x) = \frac{1}{n}x$: für $x \in \mathfrak{X}$ und $\vartheta \in \Theta$ gilt

$$\begin{aligned} \rho(x, \vartheta) &= \binom{n}{x} \vartheta^x (1 - \vartheta)^{n-x} = \binom{n}{x} \exp(x \ln(\vartheta) + (n-x) \ln(1 - \vartheta)) \\ &= \underbrace{\binom{n}{x}}_{=: h(x) > 0} \exp \left(\underbrace{\frac{1}{n}x}_{=: T(x)} \cdot \underbrace{n \ln \left(\frac{\vartheta}{1 - \vartheta} \right)}_{=: a(\vartheta)} + \underbrace{n \ln(1 - \vartheta)}_{=: b(\vartheta)} \right). \end{aligned}$$

Nach Satz 1.3.5 ist T bester Schätzer für $\tau(\vartheta) := \mathbb{E}_{\vartheta}[T] = \vartheta$. ◇

Beispiel 1.3.22 (Gauß-I-Modell ist exponentiell)

Bei gegebener Varianz $\sigma^2 > 0$ hat die Familie $(\mathcal{N}_{\vartheta, \sigma^2})_{\vartheta \in \mathbb{R}}$ die Likelihoodfunktion

$$\begin{aligned} \rho(x, \vartheta) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2\sigma^2} (x - \vartheta)^2 \right) \\ &= \underbrace{\exp \left(-\frac{1}{2\sigma^2} x^2 \right)}_{=: h(x)} \exp \left(\underbrace{x}_{=: T(x)} \underbrace{\frac{\vartheta}{\sigma^2}}_{=: a(\vartheta)} - \underbrace{\frac{1}{2\sigma^2} \vartheta^2 - \frac{1}{2} \ln(2\pi\sigma^2)}_{=: -b(\vartheta)} \right). \end{aligned}$$

Nach Lemma 1.3.17 ist $T(x) := \frac{1}{n} \sum_{k=1}^n x_k$ der beste Schätzer für $\tau = \text{id}_{(0,\infty)}$ im n -fachen Produktmodell. ◇

Beispiel 1.3.23 (Gauß-III-Modell ist exponentiell)

Bei gegebenen Mittelwert $m \in \mathbb{R}$ hat die Familie $(\mathcal{N}_{m, \vartheta})_{\vartheta \in (0, \infty)}$ auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ die Likelihoodfunktion

$$\begin{aligned} \rho(x, \vartheta) &= \frac{1}{\sqrt{2\pi\vartheta}} \exp \left(-\frac{1}{2\vartheta} (x - m)^2 \right) \\ &= \exp \left(-\frac{1}{2\vartheta} (x - m)^2 - \frac{1}{2} \ln(2\pi\vartheta) \right), \end{aligned}$$

welche die Form (14) mit $T(x) := (x - m)^2$, $a(\vartheta) := -\frac{1}{2\vartheta}$, $b(\vartheta) := \frac{1}{2} \ln(2\pi\vartheta)$ und $h(x) = 1$. Nach Satz 1.3.5 ist T ein bester Schätzer für $\tau(\vartheta) := \frac{b'(\vartheta)}{a'(\vartheta)} = \vartheta$ mit Varianz $\mathbb{V}_{\vartheta}[T] = \frac{\tau'(\vartheta)}{a'(\vartheta)} = 2\vartheta^2$. Nach Lemma 1.3.17 ist $T(x) := \frac{1}{n} \sum_{k=1}^n (x_k - m)^2$ der beste Schätzer für $\tau = \text{id}_{(0,\infty)}$ im n -fachen Produktmodell. ◇

(Das GAUSS-Modell mit unbekanntem Mittelwert und unbekannter Varianz ist **exponentiell im erweitertem Sinne**.)

Beispiel 1.3.24 (POISSON-Modell ist exponentiell)

Das POISSON-Modell ist ein exponentielles Modell bezüglich $T(x) = x$, da

$$\rho(x, \vartheta) = e^{-\vartheta} \frac{\vartheta^x}{x!} = \frac{1}{x!} \exp(x \ln(\vartheta) - \vartheta)$$

die Form (14) mit $a(\vartheta) = \ln(\vartheta)$, $b(\vartheta) = \vartheta$ und $h(x) = \frac{1}{x!}$ hat. Also ist T ein bester Schätzer für $\tau(\vartheta) = \frac{b'(\vartheta)}{a'(\vartheta)} = \vartheta$ mit Varianz $\mathbb{V}_{\vartheta}[T] = \frac{\tau'(\vartheta)}{a'(\vartheta)} = \vartheta$.

Nach Lemma 1.3.17 ist $T(x) := \frac{1}{n} \sum_{k=1}^n x_k$ der beste Schätzer für $\tau = \text{id}_{(0,\infty)}$ im n -fachen Produktmodell. ◇

1.4 | Suffizienz und Vollständigkeit

10.05.2022

Motivation. Was sind die für τ relevanten Information, die wir aus einer Beobachtung erfahren können?

Bei n unabhängigen Münzwürfen (n -faches BERNOULLI-Produktmodell) ist $\mathfrak{X} = \{0, 1\}^n$ und $\Theta := (0, 1)$. Es scheint so zu sein, dass $x = (x_1, \dots, x_n) \in \mathfrak{X}$ den selben „Informationsgehalt“ über ϑ enthält, wie $\sum_{k=1}^n x_k$, obwohl weniger Informationen über x bekannt sind.

Wie können wir diesen Verhalt mathematisch präzisieren?

Beim Gameshow-Modell „sollte“ $\tilde{T}_n(x) := x_{(n)}$ **suffizient** sein, obwohl \tilde{T}_n (oder $a\tilde{T}_n$ für irgendein $a \in \mathbb{R}$) kein bester Schätzer ist. ○

DEFINITION 1.4.1 (SUFFIZIENZ)

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell.

- Die σ -Algebra $\mathcal{B} \subset \mathcal{F}$ ist **suffizient**, wenn für alle $A \in \mathcal{F}$ eine messbare Funktion $f_A: (\mathfrak{X}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ existiert, sodass für alle $\vartheta \in \Theta$

suffizient

$$f_A(x) = \mathbb{P}_\vartheta[A \mid \mathcal{B}](x) \quad \text{für } \mathbb{P}_\vartheta\text{-fast alle } x \in \mathfrak{X}.$$

- Die Statistik $T: (\mathfrak{X}, \mathcal{F}) \rightarrow (\Sigma, \mathcal{S})$ ist **suffizient**, wenn $\sigma(T) := \{T^{-1}(A) : A \in \mathcal{S}\} \subset \mathcal{F}$ suffizient ist, das heißt, wenn für alle $A \in \mathcal{F}$ $\mathbb{P}_\vartheta[A \mid \sigma(T)]$ nicht von ϑ abhängt.

Bemerkung 1.4.2 (Interpretation der Suffizienz) Beim Übergang von X zu $T(X)$ gehen typischerweise Informationen verloren. Die Statistik T ist *suffizient*, wenn T alle relevanten Informationen bezüglich des unbekannten Parameters enthält. ○

Bemerkung 1.4.3 Ist $\mathcal{B} \subset \mathcal{F}$ suffizient, so ist $T = \text{id}$ suffizient. Ist T suffizient, so ist $\sigma(T)$ suffizient, es gibt also eine Art 1-1-Beziehung. ○

Wir betrachten zunächst die beiden Extremfälle.

Beispiel 1.4.4 ($T = \text{id}$)

Sei $T: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathfrak{X}, \mathcal{F})$ die Identität („wir werfen keine Informationen weg“). Dann ist $\sigma(T) = \mathcal{F}$ suffizient, denn für $A \in \mathcal{B} := \mathcal{F}$ und die \mathcal{F} -messbare Abbildung $f_A := \mathbb{1}_A$ gilt für \mathbb{P}_ϑ -fast alle $x \in \mathfrak{X}$

$$\mathbb{1}_A(x) = \mathbb{P}_\vartheta[A \mid \mathcal{B}](x) \quad \forall \vartheta \in \Theta. \quad \diamond$$

Beispiel 1.4.5 (T konstant)

Sei $T: (\mathfrak{X}, \mathcal{F}) \rightarrow (\Sigma, \mathcal{S})$ konstant, das heißt, T nimmt nur einen Wert an. Dann ist $\sigma(T) = \{\emptyset, \mathfrak{X}\}$ und für \mathbb{P}_ϑ -fast alle $x \in \mathfrak{X}$ gilt

$$\mathbb{P}_\vartheta[A \mid \{\emptyset, \mathfrak{X}\}](x) = \mathbb{P}_\vartheta[A].$$

Wenn ein f_A wie in Definition 1.4.1 existiert, dann gilt $\mathbb{P}_\vartheta(A) = f_A(x)$ \mathbb{P}_ϑ -fast sicher für alle $\vartheta \in \Theta$. Somit ist $\vartheta \mapsto \mathbb{P}_\vartheta[A]$ für alle A konstant, also sind alle \mathbb{P}_ϑ , $\vartheta \in \Theta$ gleich. Also ist T , abgesehen von diesem uninteressanten Spezialfall, nicht suffizient. ◇

Lemma 1.4.6 (Charakterisierung der Suffizienz)

Es ist $\mathcal{B} \subset \mathcal{F}$ genau dann *suffizient*, wenn für alle messbaren Funktionen $g: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $g \in L^1(\mathbb{P}_\vartheta)$ für alle $\vartheta \in \Theta$ eine messbare Abbildung $f_g: (\mathfrak{X}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ existiert, sodass für alle $\vartheta \in \Theta$ gilt

$$f_g(x) = \mathbb{E}_\vartheta[g(x) \mid \mathcal{B}] \quad \text{für } \mathbb{P}_\vartheta\text{-fast alle } x \in \mathfrak{X}. \quad (22)$$

Beweis. " \Leftarrow ": Setze $g := \mathbb{1}_A$ für $A \in \mathcal{F}$.

" \Rightarrow ": (*Maßtheoretische Induktion*) Die Aussage (22) gilt für Funktionen $g := \mathbb{1}_A$ mit $A \in \mathcal{F}$ mit $f_g(x) := f_A(x)$ (letzte ist aus Definition 1.4.1, erster aus (22)).

Ist $g = \sum_{k=1}^n \alpha_k \mathbb{1}_{A_k}$ mit $\alpha_k \geq 0$ und $A_k \in \mathcal{F}$ für alle $k \in \{1, \dots, n\}$, dann folgt (22) mit $f_g(x) := \sum_{k=1}^n \alpha_k f_{A_k}(x)$.

Für $g \in L^1$ mit $g \geq 0$ benutzt man des Satz über monotone Konvergenz und für allgemeine $g \in L^1$ die Zerlegung in Positiv- und Negativteil. \square

Ist T eine diskrete Zufallsvariable, dessen Suffizienz wir zeigen wollen, genügt es, zu zeigen, dass $\mathbb{P}_\vartheta[X \in A \mid T(x) = m]$ unabhängig von ϑ ist.

Beispiel 1.4.7 (Bernoulli-Produktmodell)

Wir zeigen, dass in diesem Modell $S(x_1, \dots, x_n) := \sum_{k=1}^n x_k$ *suffizient* ist.

Für $B \subset \{0, 1\}^n = \mathfrak{X}$ und $x \in \mathfrak{X}$ gilt

$$\mathbb{P}_\vartheta[B \mid \sigma(S)](x) = \mathbb{P}_\vartheta[B \mid S = m],$$

wobei $m := \sum_{k=1}^n x_k$.

Für $m \in \{1, \dots, n\}$ gilt

$$\begin{aligned} \mathbb{P}_\vartheta[B \mid S = m] &= \frac{\mathbb{P}_\vartheta[B \cap \{S = m\}]}{\mathbb{P}_\vartheta[S = m]} = \frac{1}{\mathbb{P}_\vartheta[S = m]} \sum_{b \in B} \mathbb{P}_\vartheta[\underbrace{\{b\} \cap \{S = m\}}_{=0 \text{ wenn } \sum_{k=1}^n b_k \neq m}] \\ &= \frac{1}{\mathbb{P}_\vartheta[S = m]} \sum_{\substack{b \in B \\ S(b)=m}} \mathbb{P}_\vartheta[\{b\}] = \frac{1}{\mathbb{P}_\vartheta[S = m]} \sum_{\substack{b \in B \\ S(b)=m}} \vartheta^m (1 - \vartheta)^{n-m} \\ &= \frac{\sum_{\substack{b \in B \\ S(b)=m}} \vartheta^m (1 - \vartheta)^{n-m}}{\binom{n}{m} \vartheta^m (1 - \vartheta)^{n-m}} = \frac{1}{\binom{n}{m}} \#\{b \in B : S(b) = m\}, \end{aligned}$$

also ist $\mathbb{P}_\vartheta[B \mid S = m]$ unabhängig von ϑ .

Jedoch ist für $n \geq 2$ der Schätzer $\tilde{S}(x_1, \dots, x_n) := \sum_{k=1}^{n-1} x_k$ nicht *suffizient*: für $B \subset \mathcal{P}(\mathfrak{X})$

und $m \in \{0, \dots, n-1\}$ ist nach der obigen Rechnung $\mathbb{P}_\vartheta[B \mid \tilde{S} = m]$ gleich

$$\begin{aligned} & \frac{1}{\mathbb{P}_\vartheta[\tilde{S} = m]} \left(\sum_{\substack{b \in B \\ \tilde{S}(b) = m}} \vartheta^{m+1} (1-\vartheta)^{n-1-m} + \sum_{\substack{b \in B \\ \tilde{S}(b) = m}} \vartheta^m (1-\vartheta)^{n-m} \right) \\ &= \frac{1}{\binom{n-1}{m} \vartheta^m (1-\vartheta)^{n-1-m}} \left(\sum_{\substack{b \in B \\ \tilde{S}(b) = m}} \vartheta^{m+1} (1-\vartheta)^{n-1-m} + \sum_{\substack{b \in B \\ \tilde{S}(b) = m}} \vartheta^m (1-\vartheta)^{n-m} \right) \\ &= \frac{1}{\binom{n-1}{m}} \left(\vartheta \cdot \#\{b \in B : \tilde{S}(b) = m, b_n = 1\} + (1-\vartheta) \cdot \#\{b \in B : \tilde{S}(b) = m, b_n = 0\} \right). \end{aligned}$$

Die auftretenden Kardinalitäten sind verschieden, z.B. für $B = \{b \in \mathfrak{X} : b_n = 1\}$. \diamond

Bemerkung 1.4.8 (Anschauung für Suffizienz (cf. Renesse-Skript, Satz 2.18))

Durch Bedingen / Festlegen auf das Ergebnis eine Hilfsbeobachtung $S = S(X)$ verbleibt zwar noch ein gewisser „Restzufall“ in der Beobachtung X , allerdings hängt dessen Verteilung nicht mehr von ϑ ab.

Ist S suffizient, so ist \mathbb{P}_ϑ durch $\mathbb{P}_\vartheta \circ S$ festgelegt. \circ

Beispiel 1.4.9 (Geometrische Verteilung)

Wir werfen eine Münze und zählen die Anzahl der Misserfolge bis zum ersten Erfolg. Dies wiederholen wir n mal.

Sei $(\mathbb{N}_0^n, \mathbb{P}(\mathbb{N}_0^n), (\mathbb{P}_\vartheta)_{\vartheta \in \Theta := (0,1)})$ das zugehörige statistische Modell mit $\mathbb{P}_\vartheta(\{k\}) = (1-\vartheta)^k \vartheta$. Die Statistik $S(x) := \sum_{k=1}^n x_k$ ist **negativ-binomialverteilt**:

$$\mathbb{P}_\vartheta[S(x) = s] = \binom{s+n-1}{n-1} (1-\vartheta)^s \vartheta^n \quad \forall s \in \mathbb{N}_0.$$

Die Statistik S ist **suffizient**, denn für alle $k \in \mathbb{N}_0^n$ und $s \in \mathbb{N}_0$ hängt

$$\begin{aligned} \mathbb{P}_\vartheta[X = k \mid S(X) = s] &= \frac{\mathbb{P}_\vartheta[X = k, S(X) = s]}{\mathbb{P}_\vartheta[S(X) = s]} = \mathbb{1}_{\{S(k)=s\}} \frac{\mathbb{P}_\vartheta[X = k]}{\mathbb{P}_\vartheta[S(X) = s]} \\ &= \mathbb{1}_{\{S(k)=s\}} \frac{\prod_{j=1}^n (1-\vartheta)^{k_j} \vartheta}{\binom{s+n-1}{n-1} (1-\vartheta)^s \vartheta^n} = \mathbb{1}_{\{S(k)=s\}} \frac{(1-\vartheta)^{\sum_{j=1}^n k_j} \vartheta^n}{\binom{s+n-1}{n-1} (1-\vartheta)^s \vartheta^n} \\ &= \mathbb{1}_{\{\sum_{j=1}^n k_j = s\}} \frac{(1-\vartheta)^{\sum_{j=1}^n k_j} \vartheta^n}{\binom{s+n-1}{n-1} (1-\vartheta)^s \vartheta^n} = \mathbb{1}_{\{\sum_{j=1}^n k_j = s\}} \frac{1}{\binom{s+n-1}{n-1}} \end{aligned}$$

nicht von ϑ ab. \diamond

Beispiel 1.4.10 (Suffizienz im GAUSS-Produktmodell (Hausaufgabe 4.2))

Betrachte für $n > 1$ das n -fache Gausssche Produktmodell $(\mathfrak{X}^n, \mathcal{B}(\mathfrak{X}^n), (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$, wobei $\mathfrak{X} := \mathbb{R}^d$ und $\mathbb{P}_\vartheta := \mathcal{N}_{\mu, \Sigma}$ die d -dimensionale Normalverteilung mit Erwartungswertvektor $\mu \in \mathbb{R}^d$ und Kovarianzmatrix $\Sigma \in \mathbb{R}_{\geq 0}^{d \times d}$, $d > 1$ und $\Theta := \mathbb{R}^d \times \mathbb{R}_{\geq 0}^{d \times d}$ sind. Definiere $M_n := M_n(X) := \frac{1}{n} \sum_{k=1}^n X_k$. Dann ist

$$U(X) := \left(M_n, \frac{1}{n-1} \sum_{k=1}^n (X_k - M_n)(X_k - M_n)^\top \right)$$

eine suffiziente Statistik für dieses Modell. \diamond

SATZ 1.4.1: RAO-BLACKWELL

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell, $\tau: \Theta \rightarrow \mathbb{R}$ eine Kenngröße, $S: (\mathfrak{X}, \mathcal{F}) \rightarrow (\Sigma, \mathcal{S})$ suffizient und $T: (\mathfrak{X}, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ erwartungstreu für τ . Dann existiert eine messbare Abbildung $\tilde{T}: (\mathfrak{X}, \sigma(S)) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$, sodass für alle $\vartheta \in \Theta$

$$\tilde{T}(x) = \mathbb{E}_\vartheta[T \mid \sigma(S)](x) \quad \mathbb{P}_\vartheta - \text{fast sicher} \quad (23)$$

gilt. Dann ist \tilde{T} erwartungstreu für τ und für alle $\vartheta \in \Theta$ gilt $\mathbb{V}_\vartheta[\tilde{T}] \leq \mathbb{V}_\vartheta[T]$.

Beweis. Existenz. Zu $g = T$ existiert nach Lemma 1.4.6 ein $f_T = \tilde{T}$ mit $\tilde{T}(x) = \mathbb{E}_\vartheta[T \mid \sigma(S)](x)$ \mathbb{P}_ϑ -fast sicher für alle $\vartheta \in \Theta$.

Erwartungstreue. Für $\vartheta \in \Theta$ gilt nach der Turmeigenschaft (T)

$$\mathbb{E}_\vartheta[\tilde{T}] = \mathbb{E}_\vartheta[\mathbb{E}_\vartheta[T \mid \sigma(S)]] \stackrel{(T)}{=} \mathbb{E}_\vartheta[T] = \tau(\vartheta).$$

Varianz. Sei $\vartheta \in \Theta$. Ohne Beschränkung der Allgemeinheit sei $\mathbb{V}_\vartheta[T] < \infty$. Dann folgt mit der JENSEN-Ungleichung für bedingte Erwartungswerte (J) (da $x \mapsto x^2$ konvex ist) und der Erwartungstreue von \tilde{T}

$$\begin{aligned} \mathbb{V}_\vartheta[\tilde{T}] &= \mathbb{E}_\vartheta[(\tilde{T} - \tau(\vartheta))^2] \stackrel{(23)}{=} \mathbb{E}_\vartheta[(\mathbb{E}_\vartheta[T - \tau(\vartheta) \mid \sigma(S)])^2] \\ &\stackrel{(J)}{\leq} \mathbb{E}_\vartheta[\mathbb{E}_\vartheta[(T - \tau(\vartheta))^2 \mid \sigma(S)]] \stackrel{(T)}{\leq} \mathbb{E}_\vartheta[(T - \tau(\vartheta))^2] = \mathbb{V}_\vartheta[T] \end{aligned} \quad (24)$$

aufgrund der Erwartungstreue von T . \square

Bemerkung 1.4.11 Mit diesem Satz lässt sich einen erwartungstreuen Schätzer T mittels einer suffizienten Statistik verbessern, in dem Sinne, dass die Erwartungstreue erhalten bleibt und die Varianz nicht größer wird. Ist S die Identität (suffizient nach Beispiel 1.4.4), so ist $\tilde{T} = T$ \mathbb{P}_ϑ -fast überall für alle $\vartheta \in \Theta$, also ist keine Verbesserung erreicht worden. \circ

Beispiel 1.4.12 (POISSON-MODELL (HAUSAUFGABE 4.1))

Betrachte das statistische Produktmodell $(\mathbb{N}_0^n, \mathcal{P}(\mathbb{N}_0^n), (\text{Poi}(\vartheta)^{\otimes n})_{\vartheta > 0})$. Dann ist $T(X) = X_1 \cdot X_2$ ein erwartungstreu Schätzer für ϑ^2 . Die Statistik $U(X) := \sum_{k=1}^n X_k$ ist in diesem Modell suffizient und vollständig. Mit Satz 1.4.1 kann man U zu einem Schätzer S verbessern, welcher ein bester erwartungstreu Schätzer für ϑ^2 ist. \diamond

11.05.2022

SATZ 1.4.2: NEYMAN-FISHER FAKTORISIERUNGSLEMMA (DISKRET)

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell, wobei das dominierende Maß μ_0 das Zählmaß ist und $\rho: \Theta \times \mathfrak{X} \rightarrow (0, \infty)$ die Likelihoodfunktion.

Die Statistik $S: \mathfrak{X} \rightarrow \Sigma$ ist suffizient genau dann wenn Funktionen $h: \Theta \times \Sigma \rightarrow \mathbb{R}$ und $k: \mathfrak{X} \rightarrow \mathbb{R}$ existieren, sodass

$$\rho(\vartheta, x) = h(\vartheta, S(x))k(x)$$

für alle $x \in \mathfrak{X}$ und alle $\vartheta \in \Theta$ gilt.

Beweis. Für $s \in \Sigma$ mit $\mathbb{P}[S(X) = s] > 0$ und $x \in \mathfrak{X}$ gilt

$$\begin{aligned}\mathbb{P}_\vartheta[X = x \mid S(X) = s] &= \frac{\mathbb{P}_\vartheta[X = x, S(X) = s]}{\mathbb{P}_\vartheta[S(X) = s]} \\ &= \mathbb{1}_{\{S(X)=s\}} \frac{\mathbb{P}_\vartheta[X = x]}{\mathbb{P}_\vartheta[S(X) = s]} = \mathbb{1}_{\{S(X)=s\}} \frac{\rho(\vartheta, x)}{\sum_{y \in S^{-1}(s)} \rho(\vartheta, y)}.\end{aligned}\quad (25)$$

" \implies ": Sei S suffizient. Dann existiert eine Funktion $f: \mathfrak{X} \times \Sigma \rightarrow \mathbb{R}$ mit

$$f(x, s) = \mathbb{P}_\vartheta[X = x \mid S(X) = s] \quad \forall (s, x) \in \Sigma \times \mathfrak{X}.$$

Für $x \in \mathfrak{X}$ und $s = S(x)$ gilt dann

$$\rho(\vartheta, x) \stackrel{(25)}{=} \underbrace{f(x, S(x))}_{=: k(x)} \underbrace{\sum_{y \in S^{-1}(s)} \rho(\vartheta, y)}_{=: h(\vartheta, s)}.$$

" \longleftarrow ": Sei $\rho(\vartheta, x) = h(\vartheta, S(x))k(x)$. Dann gilt für $x \in \mathfrak{X}$ und $s \in \Sigma$

$$\begin{aligned}\mathbb{P}_\vartheta[X = x \mid S(X) = s] &\stackrel{(25)}{=} \mathbb{1}_{\{S(X)=s\}} \frac{h(\vartheta, S(x))k(x)}{\sum_{y \in S^{-1}(s)} h(\vartheta, S(y))k(y)} \\ &= \mathbb{1}_{\{S(X)=s\}} \frac{h(\vartheta, s)k(x)}{\sum_{y \in S^{-1}(s)} h(\vartheta, S(y))k(y)} \\ &= \mathbb{1}_{\{S(X)=s\}} \frac{k(x)}{\sum_{y \in S^{-1}(s)} k(y)}.\end{aligned}$$

□

Beispiel 1.4.13 (Geometrische Verteilung)

Die Dichte bezüglich des Zählmaßes ist

$$\rho(x, \vartheta) = \prod_{k=1}^n (1 - \vartheta)^{x_k} \vartheta = (1 - \vartheta)^{S(x)} \vartheta^n =: h(\vartheta, S(x)),$$

somit ist S suffizient nach Satz 1.4.2. ◇

Beispiel 1.4.14 (BERNOULLI-Produktmodell)

12.05.2022

Sei wie in Beispiel 1.4.7 $S(x_1, \dots, x_n) := \sum_{k=1}^n x_k$. Dann ist S suffizient. Sei $\tau(\vartheta) := \vartheta \in \Theta := (0, 1)$ und $T(x_1, \dots, x_n) := x_1$. Dann ist T erwartungstreu.

Sei

$$\tilde{T}(x_1, \dots, x_n) := \mathbb{E}_\vartheta[T \mid \sigma(S)](x_1, \dots, x_n) = \mathbb{E}_\vartheta[T(x) \mid S(x) = m],$$

wobei $m = \sum_{k=1}^n x_k$.

Dann gilt

$$\begin{aligned}\frac{\mathbb{E}_\vartheta[T \cdot \mathbb{1}_{\{S(x)=m\}}]}{\mathbb{P}_\vartheta[S = m]} &= \frac{1}{\mathbb{P}_\vartheta[S = m]} \mathbb{E}_\vartheta[X_1 \cdot \mathbb{1}_{\{S=m\}}] = \frac{1}{\mathbb{P}_\vartheta[S = m]} \mathbb{P}_\vartheta[X_1 = 1, S = m] \\ &= \frac{1}{\mathbb{P}_\vartheta[S = m]} \mathbb{P}_\vartheta[X_1 = 1] \mathbb{P}_\vartheta[S = m \mid X_1 = 1] \\ &= \frac{1}{\mathbb{P}_\vartheta[S = m]} \vartheta \vartheta^{m-1} (1 - \vartheta)^{n-1-(m-1)} \binom{n-1}{m-1} \\ &= \frac{\vartheta^m (1 - \vartheta)^{n-m} \binom{n-1}{m-1}}{\binom{n}{m} \vartheta^m (1 - \vartheta)^{n-m}} = \frac{m}{n}\end{aligned}$$

und diese Formel gilt auch für $m = 0$. Also ist $\tilde{T}(x) = \frac{m}{n}$ für alle $m \in \{0, \dots, n\}$. Nach Satz 1.3.5 und Lemma 1.3.17 ist das der beste Schätzer. \diamond

SATZ 1.4.3: NEYMAN-KRITERIUM FÜR SUFFIZIENZ

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell mit dominierendem Maß μ_0 und Likelihoodfunktion ρ . Eine Unter- σ -Algebra $\mathcal{B} \subset \mathcal{F}$ ist genau dann suffizient, wenn eine messbare Funktion $h: (\mathfrak{X}, \mathcal{F}) \rightarrow [0, \infty)$ und für jedes $\vartheta \in \Theta$ eine messbare Funktion $f_\vartheta: (\mathfrak{X}, \mathcal{B}) \rightarrow [0, \infty)$ existiert, sodass

$$\rho(x, \vartheta) = f_\vartheta(x)h(x)$$

μ_0 -fast sicher und für alle $\vartheta \in \Theta$ gilt.

Beweis. Siehe [3]. \square

Bemerkung 1.4.15 (Schätzer im exponentiellen Modell ist suffizient) In einem exponentiellen Modell gilt

$$\rho(x, \vartheta) = h(x) \exp(a(\vartheta)T(x) - b(\vartheta)).$$

Es ist h positiv und wir können $f_\vartheta(x) := \exp(a(\vartheta)T(x) - b(\vartheta))$ setzen. Dann ist $\mathcal{B} := \sigma(T)$ nach Satz 1.4.3 suffizient, also auch T . \circ

Beispiel 1.4.16 (Gameshow)

Der Schätzer $\tilde{T}_n := \max(\{x_1, \dots, x_n\})$ ist suffizient, denn die Likelihoodfunktion ist

$$\rho(x, \vartheta) = \vartheta^{-n} \mathbb{1}_{[0, \vartheta]}(\tilde{T}_n(x)) =: f_\vartheta(x)$$

ist $\mathcal{B} := \sigma(\tilde{T}_n)$ messbar für alle $\vartheta \in \Theta$. \diamond

Bemerkung 1.4.17 In der Situation von Satz 1.4.3 folgt: ist \mathcal{B} suffizient und ist $\tilde{\mathcal{B}} \subset \mathcal{F}$ ein σ -Algebra mit $\mathcal{B} \subset \tilde{\mathcal{B}}$, so ist $\tilde{\mathcal{B}}$ ebenfalls suffizient (aus der \mathcal{B} -Messbarkeit von f_ϑ folgt auch die $\tilde{\mathcal{B}}$ -Messbarkeit von f_ϑ). Allgemein ist das tatsächlich falsch (cf. [3]). \circ

DEFINITION 1.4.18 (VOLLSTÄNDIGE STATISTIK)

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell. Die Statistik $S: (\mathfrak{X}, \mathcal{F}) \rightarrow (\Sigma, \mathcal{S})$ ist **vollständig**, wenn für alle messbaren Funktionen $h: (\Sigma, \mathcal{S}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\mathbb{E}_\vartheta[|h(S)|] < \infty$ gilt

$$\mathbb{E}_\vartheta[h(S)] = 0 \quad \forall \vartheta \in \Theta \quad \implies \quad h(S) = 0 \quad \mathbb{P}_\vartheta\text{-fast sicher } \forall \vartheta \in \Theta.$$

vollständig

Lemma 1.4.19 (Charakterisierung von Vollständigkeit)

Die Statistik S ist genau dann vollständig, wenn aus $f, g \in L^1(\mathfrak{X}, \sigma(S), \mathbb{P}_\vartheta)$ und $\int_{\mathfrak{X}} f(x) d\mathbb{P}_\vartheta(x) = \int_{\mathfrak{X}} g(x) d\mathbb{P}_\vartheta(x)$ für alle $\vartheta \in \Theta$ folgt, dass $\mathbb{P}_\vartheta[f = g] = 1$ für alle $\vartheta \in \Theta$ gilt.

Bemerkung 1.4.20 (Von Wikipedia) Die (äquivalente) Kontraposition der obigen Charakterisierung von Vollständigkeit ist: gilt nicht $f = g$ \mathbb{P}_{ϑ_0} -fast sicher für ein $\vartheta_0 \in \Theta$, so folgt $\int_{\mathfrak{X}} f(x) - g(x) d\mathbb{P}_{\vartheta_0}(x) \neq 0$, also ist $\sigma(S)$ klein genug, damit $(\mathbb{P}_\vartheta)_{\vartheta \in \Theta}$ alle Funktionen aus $L^1(\mathfrak{X}, \sigma(S), (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ unterscheiden kann. \circ

Beweis. " \implies ": Seien S vollständig und $f, g \in L^1(\mathfrak{X}, \sigma(S), \mathbb{P}_\vartheta)$ mit $\int_{\mathfrak{X}} f d\mathbb{P}_\vartheta = \int_{\mathfrak{X}} g d\mathbb{P}_\vartheta$ für alle $\vartheta \in \Theta$. Aufgrund des Faktorisierungssatzes [4, Satz 8.11] existiert eine messbare Funktion $h: (\Sigma, \mathcal{S}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $h \circ S = f - g$. Dann gilt für alle $\vartheta \in \Theta$

$$\mathbb{E}_\vartheta[|h(S)|] = \mathbb{E}_\vartheta[|f - g|] \leq \mathbb{E}_\vartheta[|f|] + \mathbb{E}_\vartheta[|g|] \stackrel{f, g \in L^1}{<} \infty$$

sowie

$$0 = \int_{\mathfrak{X}} f(x) - g(x) d\mathbb{P}_\vartheta(x) = \int_{\mathfrak{X}} h(S(x)) d\mathbb{P}_\vartheta(x) = \mathbb{E}_\vartheta[h(S)].$$

Aufgrund der Vollständigkeit von S folgt $h(S) = f - g = 0$ \mathbb{P}_ϑ -fast sicher für alle $\vartheta \in \Theta$.

" \impliedby ": Sei $h: \Sigma \rightarrow \mathbb{R}$ messbar, sodass $\mathbb{E}_\vartheta[|h(S)|] < \infty$ und $\mathbb{E}_\vartheta[h(S)] = 0$ für alle $\vartheta \in \Theta$ gilt. Dann können wir h als $h = h^+ - h^-$ zerlegen, wobei h^+ und h^- nichtnegativ und integrierbar sind. Aus der Linearität von $\mathbb{E}_\vartheta[h(S)] = 0$ folgt sowie

$$\mathbb{E}_\vartheta[h^+(S)] = \mathbb{E}_\vartheta[h^-(S)] \quad \forall \vartheta \in \Theta$$

und somit nach Voraussetzung $\mathbb{P}_\vartheta[h^+(S) = h^-(S)] = 1$ und somit $\mathbb{P}_\vartheta[h(S) = 0] = 1$ für alle $\vartheta \in \Theta$. \square

Lemma 1.4.21 (Konstante Schätzer sind vollständig)

Nimmt S nur einen Wert an, so ist S vollständig.

Beweis. Sei $S(x) := s$ für alle $x \in \mathfrak{X}$. Für eine messbare Funktion $h: \Sigma \rightarrow \mathbb{R}$ mit $\mathbb{E}_\vartheta[|h(S)|] < \infty$ mit $\mathbb{E}_\vartheta[h(S)] = 0$ für alle $\vartheta \in \Theta$ gilt

$$0 = \mathbb{E}_\vartheta[h(S)] = \mathbb{E}_\vartheta[h(s)] = h(s)$$

für alle $\vartheta \in \Theta$. Somit ist $h(s) = 0$, also folgt $h(S) = 0$. \square

Beispiel 1.4.22 (BERNOULLI-Produktmodell)

Im BERNOULLI-Produktmodell ist $\mathfrak{X} = \{0, 1\}^n$. Die Statistik $S(x) := \sum_{k=1}^n x_k$ ist vollständig, denn für $h: \{0, \dots, n\} \rightarrow \mathbb{R}$ ist

$$\begin{aligned} \mathbb{E}_\vartheta[h(S)] &= \sum_{m=0}^n h(m) \mathbb{P}_\vartheta[S = m] = \sum_{m=0}^n h(m) \binom{n}{m} \vartheta^m (1 - \vartheta)^{n-m} \\ &= \underbrace{(1 - \vartheta)^n}_{>0} \sum_{m=0}^n h(m) \binom{n}{m} \left(\frac{\vartheta}{1 - \vartheta} \right)^m \end{aligned}$$

ein Polynom in $y := \frac{\vartheta}{1 - \vartheta}$, welches genau dann für alle ϑ (das heißt, für alle $y \in (0, \infty)$) Null ist, wenn $h(m) = 0$ für alle $m \in \{0, \dots, n\}$ ist.

Jedoch ist $S(x) := (x_1, \frac{1}{n} \sum_{k=1}^n x_k)$ nicht vollständig für $n \geq 2$. Das kann man so sehen: für $h: [0, 1]^2 \rightarrow \mathbb{R}$, $(s_1, s_2) \mapsto s_1 - s_2$ gilt

$$\mathbb{E}_\vartheta[h(S)] = \mathbb{E}_\vartheta \left[X_1 - \frac{1}{n} \sum_{k=1}^n X_k \right] = \vartheta - \frac{1}{n} \cdot n\vartheta = 0$$

für alle $\vartheta \in \Theta$, aber $\mathbb{P}_\vartheta[h(S) = 0] < 1$ für alle $\vartheta \in (0, 1)$, da $n \geq 2$ ist (es ist $h(S(x)) = 0$ genau dann wenn $x_1 = \frac{1}{n-1} \sum_{k=2}^n x_k$ ist). \diamond




Abb. 3: Kommutatives Diagram für den Faktorisierungssatz.

SATZ 1.4.4: LEHMANN-SCHEFFÉ (1950, 1955)

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell und $T: \mathfrak{X} \rightarrow \mathbb{R}$ ein erwartungstreuer Schätzer für die Kenngröße $\tau: \Theta \rightarrow \mathbb{R}$ mit $\mathbb{E}_\vartheta[T^2] < \infty$. Ist $S: (\mathfrak{X}, \mathcal{F}) \rightarrow (\Sigma, \mathcal{S})$ suffizient und vollständig, dann ist

$$\tilde{T} := \mathbb{E}_\vartheta[T \mid \sigma(S)]$$

bester Schätzer für τ (nach Satz 1.4.1 kennen wir eine Version von \tilde{T} , welche unabhängig von ϑ ist).

Beweis. Existenz. Aus Satz 1.4.1 folgt: \tilde{T} existiert und hängt nicht von ϑ ab und \tilde{T} ist erwartungstreu mit $\mathbb{V}_\vartheta[\tilde{T}] \leq \mathbb{V}_\vartheta[T]$ für alle $\vartheta \in \Theta$.

UMVU. Zunächst folgt aus $\mathbb{E}_\vartheta[T^2] < \infty$ wie in (24) $\mathbb{E}_\vartheta[\tilde{T}^2] < \infty$ und somit ist $\mathbb{V}_\vartheta[\tilde{T}] < \infty$. Sei nun U ein erwartungstreuer Schätzer für τ . Sei analog zu \tilde{T}

$$\tilde{U} := \mathbb{E}_\vartheta[U \mid \sigma(S)].$$

Nach dem Satz von RAO-BLACKWELL gilt $\mathbb{V}_\vartheta[\tilde{U}] \leq \mathbb{V}_\vartheta[U]$ für alle $\vartheta \in \Theta$.

Nach dem Faktorisierungssatz existieren messbare Funktionen $t, u: (\Sigma, \mathcal{S}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\tilde{T} = t \circ S$ und $\tilde{U} = u \circ S$. Für $\vartheta \in \Theta$ folgt

$$0 = \tau(\vartheta) - \tau(\vartheta) = \mathbb{E}_\vartheta[\tilde{U} - \tilde{T}] = \mathbb{E}_\vartheta[(u - t)(S)].$$

Mit der Vollständigkeit folgt nach Lemma 1.4.19 $(u - t)(S) = 0$ \mathbb{P}_ϑ -fast sicher für alle $\vartheta \in \Theta$ und somit $\tilde{T} = \tilde{U}$ \mathbb{P}_ϑ -fast sicher.

Also folgt für alle $\vartheta \in \Theta$

$$\mathbb{V}_\vartheta[\tilde{T}] = \mathbb{V}_\vartheta[\tilde{U}] \stackrel{1.4.1}{\leq} \mathbb{V}_\vartheta[U]$$

und somit ist \tilde{T} bester Schätzer. \square

17.05.2022

Alternative: Es gilt $\tilde{T}, \tilde{U} \in L^1(\mathfrak{X}, \sigma(S), \mathbb{P}_\vartheta)$ und $\mathbb{E}_\vartheta[\tilde{T}] = \mathbb{E}_\vartheta[\tilde{U}]$ für alle $\vartheta \in \Theta$ wegen der Turmeigenschaft und der Erwartungstreue von U und T , also folgt aus Lemma 1.4.19 $\tilde{T} = \tilde{U}$ \mathbb{P}_ϑ -fast sicher für alle $\vartheta \in \Theta$.

Lemma 1.4.23

Ist ein Modell exponentiell bezüglich einer Statistik T , dann ist T vollständig.

Beweis. Sei die Likelihoodfunktion

$$\rho(x, \vartheta) = \exp(\vartheta T(x) - b(\vartheta)) \tilde{h}(x),$$

wobei $\tilde{h}(x) > 0$, für alle $x \in \mathfrak{X}$ und $\vartheta \in \Theta$. Wir können wieder ohne Beschränkung der Allgemeinheit $a(\vartheta) = \vartheta$ wählen. Ferner sei $h: \mathbb{R} \rightarrow \mathbb{R}$ messbar mit $\mathbb{E}_\vartheta[|h(T)|] < \infty$ und $\mathbb{E}_\vartheta[h(T)] = 0$ für alle $\vartheta \in \Theta$.

Dann folgt mit $\mu_1 := \tilde{h}\mu_0$ und $\nu_1 := \mu_1 \circ T^{-1}$ für alle $\vartheta \in \Theta$

$$\begin{aligned} 0 &= \mathbb{E}_\vartheta[h(T)] = \int_{\mathfrak{X}} h(T(x)) d\mathbb{P}_\vartheta(x) \\ &= \int_{\mathfrak{X}} h(T(x)) \exp(\vartheta T(x) - b(\vartheta)) \tilde{h}(x) d\mu_0(x) \\ &= \int_{\mathfrak{X}} h(T(x)) \exp(\vartheta T(x) - b(\vartheta)) d\mu_1(x) = e^{-b(\vartheta)} \int_{\mathbb{R}} h(y) e^{\vartheta y} d\nu_1(y) \end{aligned}$$

und somit ($h = h^+ - h^-$)

$$\int_{\mathbb{R}} h^+(y) e^{\vartheta y} d\nu_1(y) = \int_{\mathbb{R}} h^-(y) e^{\vartheta y} d\nu_1(y). \quad (26)$$

(Jetzt orientieren wir uns an [3].) Ohne Beschränkung der Allgemeinheit sei $0 \in \Theta$. Einsetzen von $\vartheta = 0$ gibt

$$w := \int_{\mathbb{R}} h^+(y) d\nu_1(y) = \int_{\mathbb{R}} h^-(y) d\nu_1(y) \geq 0.$$

Wir unterscheiden in zwei Fälle.

- ① Ist $w = 0$, folgt $h^+(y) = h^-(y) = 0$ für ν_1 -fast alle $y \in \mathbb{R}$ und somit $h(y) = 0$ für ν_1 -fast alle $y \in \mathbb{R}$. Daraus folgt $h(T(x)) = 0$ für μ_1 -fast alle $x \in \mathfrak{X}$, also $h(T(x)) = 0$ für \mathbb{P}_ϑ -fast alle $x \in \mathfrak{X}$ für alle $\vartheta \in \Theta$.
- ② Ist $w > 0$, definiere $d\kappa_1(y) = \frac{h^+(y)}{w} d\nu_1(y)$, das heißt $\kappa_1(A) = \int_A \frac{h^+(y)}{w} d\nu_1(y)$ für $A \in \mathcal{B}(\mathbb{R})$. Analog definiere $d\kappa_2(y) = \frac{h^-(y)}{w} d\nu_1(y)$. Dann sind κ_1 und κ_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ und wegen (26) gilt

$$\int_{\mathbb{R}} e^{\vartheta y} d\kappa_1(y) = \int_{\mathbb{R}} e^{\vartheta y} d\kappa_2(y)$$

für $\vartheta \in \Theta$. Auf der linken Seite steht die *momenterzeugende Funktion* von κ_1 . Aus dem **Eindeutigkeitssatz für momenterzeugende Funktionen** folgt (da die Integrale für ϑ in einer Umgebung von 0 konvergieren) $\kappa_1 = \kappa_2$. Es folgt $h^+(y) = h^-(y)$ für ν_1 -fast alle $y \in \mathbb{R}$ und somit wie in ① $h(T(x)) = 0$ für \mathbb{P}_ϑ -fast alle $x \in \mathfrak{X}$ für alle $\vartheta \in \Theta$. \square

1.5 | Konsistenz

Literatur: [2].

DEFINITION 1.5.1 (KONSISTENTE SCHÄTZFOLGE)

Sei $((\mathfrak{X}_n, \mathcal{F}_n, (\mathbb{P}_{\vartheta, n})_{\vartheta \in \Theta}))_{n \in \mathbb{N}}$ eine Folge statistischer Modelle mit gleichem Θ . Seien $\tau: \Theta \rightarrow \mathbb{R}^d$ eine Kenngröße und $T_n: \mathfrak{X}_n \rightarrow \mathbb{R}^d$ ein Schätzer für τ für jedes $n \in \mathbb{N}$. Die Folge $(T_n)_{n \in \mathbb{N}}$ ist **konsistent**, wenn für alle $\varepsilon > 0$ und alle $\vartheta \in \Theta$ gilt, dass

$$\mathbb{P}_{\vartheta, n}[|T_n - \tau(\vartheta)| \geq \varepsilon] \xrightarrow{n \rightarrow \infty} 0.$$

konsistent

Bemerkung 1.5.2

Von besonderem Interesse ist der Produktfall: $\mathfrak{X}_n = E^n$, $\mathcal{F}_n = \mathfrak{E}^{\otimes n}$ und $\mathbb{P}_{\vartheta, n} = Q_{\vartheta}^{\otimes n}$, wobei $(E, \mathfrak{E}, (Q_{\vartheta})_{\vartheta \in \Theta})$ ein statistisches Modell ist. Der Einfachheit halber betrachten wir das unendliche Produkt $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_{\vartheta})_{\vartheta \in \Theta}) = (E^{\mathbb{N}}, \mathfrak{E}^{\otimes \mathbb{N}}, (Q_{\vartheta}^{\otimes \mathbb{N}})_{\vartheta \in \Theta})$ und vereinbaren, dass $T_n: \mathfrak{X} \rightarrow \mathbb{R}^d$ nur von den ersten n Komponenten abhängt. (In diesem Fall ist die obigen Konvergenz **Konvergenz in Wahrscheinlichkeit**. Konvergenz im p -ten Mittel und fast sichere Konvergenz implizieren Konvergenz in Wahrscheinlichkeit.) \circ

SATZ 1.5.1: KONSISTENZ VON STICHPROBENMITTEL UND STICHPROBEN-VARIANZ

Seien $(E, \mathfrak{E}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ und $\int_{\mathbb{R}} x^2 dQ_{\vartheta}(x) < \infty$ für alle $\vartheta \in \Theta$. Im Produktmodell seien $M_n := \frac{1}{n} \sum_{k=1}^n X_k$ das **Stichprobenmittel** nach n Beobachtungen sowie $V_n^* := \frac{1}{n-1} \sum_{k=1}^n (X_k - M_n)^2$ die korrigierte **Stichprobenvarianz**. Dann sind M_n bzw. V_n^* erwartungstreue Schätzer für $m(\vartheta) := \int_{\mathbb{R}} x dQ_{\vartheta}(x)$ bzw. $v(\vartheta) := \int_{\mathbb{R}} (x - m(\vartheta))^2 dQ_{\vartheta}(x)$ und die Folgen $(M_n)_{n \in \mathbb{N}}$ bzw. $(V_n^*)_{n \in \mathbb{N}}$ konsistente Schätzfolgen für m bzw. v .

Beweis. ① Die Erwartungstreue wurde in Lemma 1.2.16 gezeigt.

② **Konsistenz von M_n .** Für $\varepsilon > 0$ gilt

$$\mathbb{P}_{\vartheta, n}[|M_n - m(\vartheta)| > \varepsilon] = \mathbb{P}_{\vartheta, n}\left[\left|\frac{1}{n} \sum_{k=1}^n X_k - \mathbb{E}_{\vartheta, n}\right| > \varepsilon\right] \xrightarrow{n \rightarrow \infty} 0$$

nach dem Gesetz der großen Zahlen.

③ **Konsistenz von V_n^* .** Vorbetrachtung: Im HILBERTraum $(\mathbb{R}^n, |\cdot|_2)$ ist die orthogonale Projektion von $x \in \mathbb{R}^n$ auf den eindimensionalen Unterraum $U := \text{span}\{(1, \dots, 1)\}$ gerade $M_n := (m_n, \dots, m_n)$, wobei $m_n := \frac{1}{n} \sum_{k=1}^n x_k$ (denn $\arg \min_m \sum_{k=1}^n (x_k - m)^2 = \frac{1}{n} \sum_{k=1}^n x_k$). Es gilt⁵




Abb. 4: Die orthogonale Projektion von x auf den Unterraum U .

⁵Seien $X := (x_1, \dots, x_n)$ und $M := (m, \dots, m) \in U$. Per Definition der orthogonalen Projektion ist $X - M_n$ orthogonal zu dem von M_n aufgespannten Unterraum U , insbesondere zu $M - M_n \in U$ und daher gilt $|X - M|_2^2 = |X - M_n + M_n - M|_2^2 = |X - M_n|_2^2 + |M - M_n|_2^2$. (Es gilt $|x + y|_2^2 = |x|_2^2 + |y|_2^2$ genau dann, wenn $x \perp y$.)

$$\sum_{k=1}^n (x_k - m_n)^2 = \sum_{k=1}^n (x_k - m)^2 - n(m - m_n)^2 \quad (27)$$

und somit

$$\begin{aligned} V_n^* &= \frac{n}{n-1} \frac{1}{n} \sum_{k=1}^n (x_k - m_n)^2 \\ &\stackrel{(27)}{=} \underbrace{\frac{n}{n-1}}_{\xrightarrow{n \rightarrow \infty} 1} \underbrace{\frac{1}{n} \sum_{k=1}^n (x_k - m(\vartheta))^2}_{\xrightarrow[n \rightarrow \infty]{\text{GGZ}} v(\vartheta)} - \underbrace{\frac{n}{n-1}}_{\xrightarrow{n \rightarrow \infty} 1} \underbrace{(m_n - m(\vartheta))^2}_{\xrightarrow{n \rightarrow \infty} 0} \xrightarrow{n \rightarrow \infty} v(\vartheta). \end{aligned}$$

□

Beispiel 1.5.3 (Verschobene Exponentialverteilung)

18.05.2022

Sei $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_{\vartheta}^{\otimes n})_{\vartheta \in \mathbb{R}})$ ein statistisches Modell, wobei \mathbb{P}_{ϑ} die Dichte $\rho(\vartheta, \cdot) = \frac{1}{\exp(\cdot)} e^{\vartheta} \mathbb{1}_{[\vartheta, \infty)}$ hat. Aus Beispiel 1.3.13 wissen wir, dass $T_{\text{ML}}^{(n)}(x) =: x_{(1)}$ der Maximum-Likelihood-Schätzer für ϑ ist.

Die Folge $(T_{\text{ML}}^{(n)})_{n \in \mathbb{N}}$ ist konsistent, da für alle $\varepsilon > 0$ und alle $\vartheta \in \mathbb{R}$ gilt:

$$\mathbb{P}_{\vartheta}^{\otimes n} \left[|T_{\text{ML}}^{(n)} - \vartheta| > \varepsilon \right] = \mathbb{P}_{\vartheta}^{\otimes n} \left[\min_{1 \leq k \leq n} X_k > \vartheta + \varepsilon \right] = \mathbb{P}_{\vartheta} [X_1 > \vartheta + \varepsilon]^n = e^{-\varepsilon n} \xrightarrow{n \rightarrow \infty} 0,$$

da

$$\mathbb{P}_{\vartheta} [X_1 > \vartheta + \varepsilon] = \int_{\vartheta + \varepsilon}^{\infty} e^{\vartheta - x} dx = \int_{\varepsilon}^{\infty} e^{-x} dx = e^{-\varepsilon}.$$

◇

SATZ 1.5.2: HINREICHENDES KONSISTENZ-KRITERIUM

Gelten $\mathbb{E}_{\vartheta, n}[T_n] \xrightarrow{n \rightarrow \infty} \tau(\vartheta)$ und $\mathbb{V}_{\vartheta, n}[T_n] \xrightarrow{n \rightarrow \infty} 0$, so ist Folge $(T_n)_{n \in \mathbb{N}}$ konsistent.

Somit m

Beweis. Für feste $\varepsilon > 0$ und $\vartheta \in \Theta$ existiert ein $N_{\varepsilon, \vartheta} \in \mathbb{N}$, sodass $|\mathbb{E}_{\vartheta, n}[T_n] - \tau(\vartheta)| \leq \frac{\varepsilon}{2}$ für alle $n > N_{\varepsilon, \vartheta}$ gilt (wegen $\mathbb{E}_{\vartheta, n}[T_n] \xrightarrow{n \rightarrow \infty} \tau(\vartheta)$). Für $n > N_{\varepsilon, \vartheta}$ gilt mit der MARKOV-Ungleichung (M)

$$\begin{aligned} \mathbb{P}_{\vartheta, n} [|T_n - \tau(\vartheta)| > \varepsilon] &\stackrel{\triangle \neq}{\leq} \mathbb{P}_{\vartheta, n} [|T_n - \mathbb{E}_{\vartheta, n}[T_n]| + |\mathbb{E}_{\vartheta, n}[T_n] - \tau(\vartheta)| > \varepsilon] \\ &\stackrel{(\star)}{\leq} \mathbb{P}_{\vartheta, n} \left(|T_n - \mathbb{E}_{\vartheta, n}[T_n]| > \frac{\varepsilon}{2} \right) + \mathbb{P}_{\vartheta, n} \left(|\mathbb{E}_{\vartheta, n}[T_n] - \tau(\vartheta)| > \frac{\varepsilon}{2} \right) \\ &\stackrel{(M)}{\leq} \underbrace{\frac{1}{\frac{\varepsilon^2}{4}} \mathbb{V}_{\vartheta, n}[T_n]}_{\xrightarrow{n \rightarrow \infty} 0} + \underbrace{\mathbb{1}_{\{|\mathbb{E}_{\vartheta, n}[T_n] - \tau(\vartheta)| > \frac{\varepsilon}{2}\}}(n)}_{=0} \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

In (\star) nutzen wir, dass für nichtnegative Zufallsvariablen X und Y und $\delta > 0$ gilt:

$$\mathbb{P}[X + Y > \delta] \leq \mathbb{P} \left[X > \frac{\delta}{2} \text{ oder } Y > \frac{\delta}{2} \right] \leq \mathbb{P} \left[X > \frac{\delta}{2} \right] + \mathbb{P} \left[Y > \frac{\delta}{2} \right].$$

□

Bemerkung 1.5.4 (Verschobene Exponentialverteilung, Gameshow)

Die Aussage von Beispiel 1.5.3 folgt auch mit Satz 1.5.2, da wir aus Hausaufgabe 3.2 wissen, dass $\mathbb{E}_\vartheta[T_{\text{ML}}^n] = \vartheta + \frac{1}{n}$ und $\mathbb{V}_\vartheta[T_{\text{ML}}^{(n)}] = \frac{1}{n^2}$ gelten.

Die Konsistenzaussage aus Beispiel 1.1.15 folgt auch mit Satz 1.5.2, da wir aus Beispiel 1.1.15 $\mathbb{E}_\vartheta[T_{\text{ML}}^n] = \frac{n}{n+1}\vartheta + \frac{1}{n}$ und $\mathbb{V}_\vartheta[T_{\text{ML}}^{(n)}] = \frac{n}{(n+1)^2(n+2)}\vartheta^2$ wissen. \square

Beispiel 1.5.5 (Konsistente Schätzfolge für das Gameshow-Modell)

Betrachte $(\mathbb{R}_+^n, \mathcal{B}(\mathbb{R}_+^n), (\mathbb{P}_\vartheta^{\otimes n} := \mathcal{U}_{[0, \vartheta]^n})_{\vartheta \in (0, \infty)})$ und setze $T_n(x) := (\prod_{k=1}^n x_k)^{\frac{1}{n}}$. Dann ist $(T_n)_{n \in \mathbb{N}}$ eine konsistente Schätzfolge für $\frac{\vartheta}{e}$. \diamond

Beweis. Für alle $\vartheta \in (0, \infty)$ gilt

$$\begin{aligned} \mathbb{E}_\vartheta[T_n] &\stackrel{\text{u.i.v.}}{=} \mathbb{E} \left[X_1^{\frac{1}{n}} \right]^n = \left(\int_0^\vartheta \frac{1}{\vartheta} x^{\frac{1}{n}} dx \right)^n \\ &= \left(\frac{1}{\vartheta} \frac{1}{1 + \frac{1}{n}} x^{1 + \frac{1}{n}} \Big|_{x=0}^\vartheta \right)^n = \frac{1}{(1 + \frac{1}{n})^n} \vartheta \xrightarrow{n \rightarrow \infty} \frac{\vartheta}{e} \end{aligned}$$

sowie analog

$$\mathbb{E}_\vartheta[T_n^2] = \left(\int_0^\vartheta \frac{1}{\vartheta} x^{\frac{2}{n}} dx \right)^n = \left(\frac{1}{\vartheta} \frac{1}{1 + \frac{2}{n}} x^{1 + \frac{2}{n}} \Big|_{x=0}^\vartheta \right)^n = \frac{1}{(1 + \frac{2}{n})^n} \vartheta^2 \xrightarrow{n \rightarrow \infty} \frac{\vartheta^2}{e^2}$$

und somit

$$\mathbb{V}_\vartheta[T_n] = \mathbb{E}_\vartheta[T_n^2] - \mathbb{E}_\vartheta[T_n]^2 \xrightarrow{n \rightarrow \infty} \frac{\vartheta^2}{e^2} - \frac{\vartheta^2}{e^2} = 0.$$

Die Aussage folgt mit Satz 1.5.2. \square

Beispiel 1.5.6 (Konsistente Schätzfolgen für besondere Kovarianzmatrizen)

Betrachte das statistische Modell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{\vartheta, \mathbf{1}, C})_{\vartheta \in \mathbb{R}})$, wobei $C = (C_{i,j})_{i,j=1}^n$ die Kovarianzmatrix mit $C_{i,j} = \rho_j - i$ für $i \leq j$ ist, wobei $\rho_0 = \sigma^2$ und $\rho_k \in \mathbb{R}$ sind. Weiterhin sei $M_n := \frac{1}{n} \sum_{k=1}^n X_k$ ein Schätzer für ϑ . Es ist Hausaufgabe 5.1 zu zeigen, dass M_n

- ① keine konsistente Schätzfolge für ϑ ist, wenn $\rho_{j-i} = \rho \in (0, \sigma^2]$ für alle $i < j$ gilt.
- ② eine konsistente Schätzfolge für ϑ ist, wenn $\rho_{j-i} = c\gamma^{j-i}$ mit $\gamma \in (-1, 1)$ für $i < j$ und $c \geq 0$. \diamond

Beispiel 1.5.7 (Schätzfolge für Funktionen der ersten r Momente)

Seien $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell und $r \in \mathbb{N}$. Zu jedem $\vartheta \in \Theta$ und jedem $k \in \{1, \dots, r\}$ existiere das k -te Moment $m_k(\vartheta) := \mathbb{E}_\vartheta[X^k]$ von \mathbb{P}_ϑ . Sei ferner $g: \mathbb{R}^r \rightarrow \mathbb{R}$ stetig und $\tau(\vartheta) := g(m_1(\vartheta), \dots, m_r(\vartheta))$. Im zugehörigen Produktmodell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_\vartheta^{\otimes n})_{\vartheta \in \Theta})$ ist

$$T_n(x) := g \left(\frac{1}{n} \sum_{k=1}^n x_k, \frac{1}{n} \sum_{k=1}^n x_k^2, \dots, \frac{1}{n} \sum_{k=1}^n x_k^r \right)$$

ein Schätzer für τ und $(T_n)_{n \in \mathbb{N}}$ eine konsistente Schätzfolge für τ (Hausaufgabe 5.2). \diamond

Konsistenz von ML-Schätzern

19.05.2022

DEFINITION 1.5.8 (RELATIVE ENTROPIE)

Seien P und Q Wahrscheinlichkeitsmaße auf (E, \mathfrak{E}) und μ_0 ein σ -endliches Maß auf (E, \mathfrak{E}) mit $P \ll \mu_0$ und $Q \ll \mu_0$. (So ein Maß existiert immer, z.B. $\mu_0 = P + Q$.) Seien $\rho := \frac{dP}{d\mu_0}$ und $\sigma := \frac{dQ}{d\mu_0}$. Dann ist

$$H(P; Q) := \int_E \rho(x) \ln \left(\frac{\rho(x)}{\sigma(x)} \right) d\mu_0(x)$$

die **relative Entropie** (oder: KULLBACK-LEIBLER-Divergenz/Abstand/Information) **von P bezüglich Q** .

relative Entropie

Hierbei seien $0 \cdot \ln \left(\frac{0}{0} \right) := 0$, $a \cdot \ln \left(\frac{a}{0} \right) := \infty$ und $0 \cdot \ln \left(\frac{0}{a} \right) := 0$ für alle $a > 0$.

Bemerkung 1.5.9 Es ist zumindest unklar, ob das Integral definiert ist und ob $H(P; Q)$ von μ_0 abhängt. \circ

Lemma 1.5.10

Es gilt $P \ll Q$ genau dann wenn $P(\{\sigma = 0\}) = 0$ ist.

Beweis. Es gilt immer $Q(\{\sigma = 0\}) = \int_{\{\sigma=0\}} \sigma(x) d\mu_0(x) = 0$.

" \implies ": Sei $P \ll Q$, dann gilt wegen $Q(\{\sigma = 0\}) = 0$ auch $P(\{\sigma = 0\}) = 0$.

" \impliedby ": Seien $P(\{\sigma = 0\}) = 0$ und $A \in \mathfrak{E}$ mit $Q(A) = 0$. Angenommen, $P(A) > 0$. Dann gilt

$$0 < P(A) = P(A \setminus \{\sigma = 0\}) + P(\{\sigma = 0\}) = P(A \setminus \{\sigma = 0\}).$$

Aus $P(A \setminus \{\sigma = 0\}) > 0$ und $P \ll \mu_0$ folgt $\mu_0(A \setminus \{\sigma = 0\}) > 0$. Es folgt

$$0 = Q(A) = \int_A \sigma(x) d\mu_0(x) \geq \int_{A \setminus \{\sigma=0\}} \sigma(x) d\mu_0(x) > 0,$$

was einen Widerspruch darstellt. \square

Lemma 1.5.11

Es gilt

$$H(P; Q) = \begin{cases} \int_E \frac{dP}{dQ}(x) \ln \left(\frac{dP}{dQ}(x) \right) dQ(x), & \text{wenn } P \ll Q, \\ \infty, & \text{sonst.} \end{cases}$$

Insbesondere ist $H(P; Q)$ unabhängig von μ_0 und das Integral ist wohldefiniert und größer als $-\infty$.

Beweis. Sei $P \not\ll Q$. Nach Lemma 1.5.10 folgt $P(\{\sigma = 0\}) > 0$. Weiter gilt $P(\{\rho > 0\}) = 1$, also folgt $P(\{\rho > 0\} \cap \{\sigma = 0\}) > 0$ und somit $\mu_0(\{\rho > 0\} \cap \{\sigma = 0\}) > 0$. Betrachte

$$H(P; Q) = \underbrace{\int_{\{\rho=0\}} 0 d\mu_0(x)}_{=0} + \underbrace{\int_{\{\sigma=0\} \cap \{\rho>0\}} \infty d\mu_0(x)}_{=\infty, \text{ da } \mu_0(\{\rho>0\} \cap \{\sigma=0\}) > 0} + \int_{\{\sigma>0\} \cap \{\rho>0\}} \rho(x) \ln \left(\frac{\rho(x)}{\sigma(x)} \right) d\mu_0(x).$$

Der letzte Summand ist gleich

$$\int_{\{\sigma>0\} \cap \{\rho>0\}} \sigma(x) \frac{\rho(x)}{\sigma(x)} \ln \left(\frac{\rho(x)}{\sigma(x)} \right) d\mu_0(x) = \int_{\{\sigma>0\} \cap \{\rho>0\}} \underbrace{f(x) \ln(f(x))}_{\geq C} dQ(x)$$

für ein $C \in \mathbb{R}$ und somit nach unten beschränkt. Daher ist $H(P; Q)$ wohldefiniert und es folgt $H(P; Q) = \infty$.

Seien $P \ll Q$ und $f := \frac{dP}{dQ}$. Dann gilt $\frac{dP}{d\mu_0} = \frac{dP}{dQ} \frac{dQ}{d\mu_0}$ μ_0 -fast sicher. \square

Lemma 1.5.12 (Eigenschaften der relativen Entropie)

Es gilt $H(P; Q) \geq 0$ und $H(P; Q) = 0$ genau dann, wenn $P = Q$ gilt.

Beweis. ① Die Aussage $H(P; Q) \geq 0$ ist klar, wenn $P \not\ll Q$ gilt. Sei also $P \ll Q$. Da die Funktion $\psi(y) := y \ln(y) \mathbb{1}_{(0, \infty)}(y)$ strikt konvex ist, folgt mit der JENSEN-Ungleichung

$$H(P; Q) = \int_E \frac{dP}{dQ} \ln \left(\frac{dP}{dQ} \right) dQ = \int_E \psi \left(\frac{dP}{dQ} \right) dQ \geq \psi \left(\int_E \frac{dP}{dQ} dQ \right) = \psi(1) = 0.$$

② Ist $P = Q$, so ist $\frac{dP}{dQ} \equiv 1$ fast sicher und daher $H(P; Q) = 0$. Sei $H(P; Q) = 0$, dann gilt $P \ll Q$ und somit Q -fast sicher $\frac{dP}{dQ} \equiv C$, da ψ strikt konvex ist (aus der vorherigen Ungleichung). Wegen $1 = P(E) = \int_E \frac{dP}{dQ}(x) dQ(x)$ folgt $\frac{dP}{dQ} \equiv 1$ Q -fast sicher und daher $P = Q$. \square

Bemerkung 1.5.13 (Anschauung für die Entropie) Im Spezialfall, dass $|E| < \infty$ gilt und μ_0 das Zählmaß ist, ist die „Entropie von P “

$$H(P) := - \sum_{p \in E} p \ln(p),$$

welche z.B. die mittlere Anzahl von Bits pro Buchstabe bei optimaler Codierung gibt. Dann ist $H(P; Q)$ die Zusatzkosten, die man benötigt, wenn man als (HUFFMANN-)Codierung die Häufigkeit in z.B. deutscher Sprache verwendet hat, der Text jedoch in z.B. englisch ist. \circ

SATZ 1.5.3: KONSISTENZ VON ML-SCHÄTZERN

Sei $(E, \mathfrak{E}, (Q_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell mit Likelihoodfunktion ρ . Wir betrachten das (abzählbar) unendliche Produktmodell. Es gelte:

- ① Θ ist ein offenes Intervall und für $\vartheta \neq \vartheta'$ ist $Q_\vartheta \neq Q_{\vartheta'}$.
- ② Für jedes $n \in \mathbb{N}$ und jeden Vektor $(x_1, \dots, x_n) \in E^n$ ist $\prod_{k=1}^n \rho(x_k, \cdot)$ **unimodal**, das heißt für einen ML-Schätzer T_n für ϑ ist $\prod_{k=1}^n \rho(x_k, \cdot)$ wachsend für $\vartheta < T_n(x)$ und fallend für $\vartheta > T_n(x)$.

Dann ist die Folge $(T_n)_{n \in \mathbb{N}}$ für ϑ konsistent.

unimodal

Bemerkung 1.5.14 (Hinreichende Bedingung für ②) Die Bedingung ② ist erfüllt, wenn $\ln(\rho(y, \cdot))$ für alle $y \in E$ konkav ist mit zuerst positiver und am Ende negativer strikter Veränderung (bzw. Ableitung), denn dasselbe gilt für $\ln(\prod_{k=1}^n \rho(x_k, \cdot))$, da endliche Summen konkaver Funktionen konkav sind. \circ

Bemerkung 1.5.15 (Vererbung der Unimodalität) Das Produkt unimodaler Funktionen ist im Allgemeinen *nicht* unimodal. \circ

Beweis. (von Satz 1.5.3) Seien $\vartheta \in \Theta$ und $\varepsilon > 0$, sodass $\vartheta \pm \varepsilon \in \Theta$. Nach Lemma 1.5.12 und Voraussetzung ① existiert ein $\delta \in (0, H(Q_\vartheta; Q_{\vartheta \pm \varepsilon}))$. Wir zeigen (später)

$$Q_\vartheta^{\otimes n} \left[\frac{1}{n} \ln \left(\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta \pm \varepsilon}^{\otimes n}} \right) > \delta \right] \xrightarrow{n \rightarrow \infty} 1, \quad (28)$$

wobei $\rho_\vartheta^{\otimes n} := \prod_{k=1}^n \rho(x_k, \vartheta)$.

Wenn (28) gilt, so folgt für $n \in \mathbb{N}$

$$\bigcap_{\sigma \in \{-1, 1\}} \left\{ \frac{1}{n} \ln \left(\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta + \sigma \varepsilon}^{\otimes n}} \right) > \delta \right\} \subset \{ \rho_{\vartheta - \varepsilon}^{\otimes n} < \rho_\vartheta^{\otimes n} > \rho_{\vartheta + \varepsilon}^{\otimes n} \} \subset \{ \vartheta - \varepsilon < T_n < \vartheta + \varepsilon \},$$

Die erste Inklusion folgt so: Wenn $\frac{1}{n} \ln \left(\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta + \sigma \varepsilon}^{\otimes n}} \right) > \delta$ gilt, dann auch

$$\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta + \sigma \varepsilon}^{\otimes n}} > e^{n\delta} > 1.$$

Die zweite Inklusion folgt aus der Unimodalität.

Wegen (28) folgt

$$\mathbb{P}_\vartheta[\vartheta - \varepsilon < T_n < \vartheta + \varepsilon] \xrightarrow{n \rightarrow \infty} 1.$$

Wir zeigen nun (28) mit $\pm = +$.

24.05.2022

- ① Fall 1. $Q_\vartheta \ll Q_{\vartheta + \varepsilon}$. Sei $f := \frac{dQ_\vartheta}{dQ_{\vartheta + \varepsilon}}$ eine Version der RADON-NIKODŸM-Dichte. Aufgrund der Absolutstetigkeit aller Maße bezüglich μ_0 folgt $f = \frac{\rho_\vartheta}{\rho_{\vartheta + \varepsilon}}$ (vgl. Beweis von 1.54) fast sicher.

Dann gilt

$$\frac{1}{n} \ln \left(\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta + \varepsilon}^{\otimes n}} \right) = \frac{1}{n} \sum_{k=1}^n \ln \left(\frac{\rho_\vartheta}{\rho_{\vartheta + \varepsilon}}(X_k) \right) = \frac{1}{n} \sum_{k=1}^n \ln(f(X_k)) =: (**).$$

Es sind $(\ln(f(X_i)))_{i=1}^n$ u.i.v. bezüglich $\mathbb{P}_\vartheta = Q_\vartheta^{\otimes n}$. Wir wollen ein Gesetz der großen Zahlen anwenden.

Es gilt

$$\mathbb{E}_\vartheta[\ln(f(X_1))] = \int_{\mathcal{X}} \ln(f) dQ_\vartheta = \int_{\mathcal{X}} f \ln(f) dQ_{\vartheta + \varepsilon} \stackrel{1.54}{=} H(Q_\vartheta; Q_{\vartheta + \varepsilon}) > \delta > 0.$$

Wenn zusätzlich $H(Q_\vartheta; Q_{\vartheta + \varepsilon}) < \infty$ gilt, so folgt aus beiden großen Gesetzen der großen Zahlen

$$\lim_{n \rightarrow \infty} \frac{1}{n} \ln \left(\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta \pm \varepsilon}^{\otimes n}} \right) = H(Q_\vartheta; Q_{\vartheta \pm \varepsilon}) > \delta$$

und somit (28).

Ist $H(Q_\vartheta; Q_{\vartheta+\varepsilon}) = \infty$, dann folgt mit einem „Abschneideargument“ die Behauptung (28), denn für $c > 0$ gilt

$$\mathbb{E}_\vartheta [\ln(f(X_1)) \wedge c] \xrightarrow{c \rightarrow \infty} H(Q_\vartheta; Q_{\vartheta+\varepsilon}) = \infty$$

(mit dem Satz über monotone Konvergenz und da $x \mapsto x \ln(x)$ nach unten beschränkt ist). Wähle nun $c > 0$ so groß, dass die linke Seite größer als δ ist. Dann folgt, da \ln monoton wachsend ist,

$$\frac{1}{n} \sum_{k=1}^n \ln(f(X_k)) \geq \frac{1}{n} \sum_{k=1}^n (\ln(f(X_k)) \wedge c) \xrightarrow{n \rightarrow \infty} \mathbb{E}_\vartheta [\ln(f(X_1)) \wedge c] > \delta$$

mit dem Gesetz der großen Zahlen, und das zeigt (28).

- ② $Q_\vartheta \not\ll Q_{\vartheta+\varepsilon}$. Dann gilt $Q_\vartheta[\rho_{\vartheta+\varepsilon} = 0] = \alpha > 0$ und $Q_\vartheta^{\otimes n}[\rho_\vartheta^{\otimes n} > 0] = 1$ (cf. (1.53) mit anderen Bezeichnungen). Dann folgt

$$\begin{aligned} Q_\vartheta^{\otimes n} \left[\frac{1}{n} \ln \left(\frac{\rho_\vartheta^{\otimes n}}{\rho_{\vartheta+\varepsilon}^{\otimes n}} \right) = \infty \right] &= Q_\vartheta^{\otimes n}[\rho_\vartheta^{\otimes n} > 0 \text{ und } \rho_{\vartheta+\varepsilon}^{\otimes n} = 0] \\ &= Q_\vartheta^{\otimes n}[\rho_{\vartheta+\varepsilon}^{\otimes n} = 0] \\ &= 1 - Q_\vartheta^{\otimes n}[\rho_{\vartheta+\varepsilon}^{\otimes n} > 0] \\ &= 1 - Q_\vartheta^{\otimes n} \left[\bigcap_{i=1}^n \{\rho_{\vartheta+\varepsilon}(X_i) > 0\} \right] \\ &= 1 - \prod_{i=1}^n Q_\vartheta^{\otimes n}[\rho_{\vartheta+\varepsilon}(X_i) > 0] \\ &= 1 - (1 - Q_\vartheta[\rho_{\vartheta+\varepsilon} = 0])^n \xrightarrow[\alpha > 0]{n \rightarrow \infty} 1. \end{aligned}$$

□

Beispiel 1.5.16 (Konsistente Folge von ML-Schätzern für das Poisson-Modell)

Seien $\rho(x, \vartheta) := e^{-\vartheta} \frac{\vartheta^x}{x!}$, $\vartheta \in \Theta := (0, \infty)$, $E := \mathbb{N}_0$ und μ_0 das Zählmaß. Die Bedingung ① ist offensichtlich erfüllt. Wir überprüfen die log-Konkavität der Dichte, um die Bedingung ② zu verifizieren. Es gilt

$$\ln(\rho(x, \vartheta)) = -\vartheta + x \log(\vartheta) - \log(x!)$$

und somit ist

$$\frac{\partial}{\partial \vartheta} \ln(\rho(x, \vartheta)) = \frac{x}{\vartheta} - 1$$

fallend bezüglich ϑ .

Ist $(T_n)_{n \in \mathbb{N}}$ eine ML-Folge, dann folgt aus Satz 1.5.3 die Konsistenz.

Wir berechnen nun den ML-Schätzer. Die Produktdichte ist $\rho^{\otimes n}(x, \vartheta) = \prod_{k=1}^n e^{-\vartheta} \frac{\vartheta^{x_k}}{x_k!}$ und somit gilt

$$\ln(\rho^{\otimes n}(x, \vartheta)) = -n\vartheta + \sum_{k=1}^n x_k \log(\vartheta) - \log(x_k!).$$

Nullsetzen der Ableitung bezüglich ϑ ergibt

$$\frac{\partial}{\partial \vartheta} \ln(\rho^{\otimes n}(x, \vartheta)) = -n + \frac{1}{\vartheta} \sum_{k=1}^n x_k \stackrel{!}{=} 0.$$

Also wird $\rho^{\otimes n}(x, \vartheta)$ maximal für $\vartheta_0 := \frac{1}{n} \sum_{k=1}^n x_k$.

◇

Beispiel 1.5.17 (Konsistente Folge von ML-Schätzern fürs Gameshow-Modell)

Wir wissen, dass $\tilde{T}_n(x) := x_{(n)}$ ein Maximum-Likelihood-Schätzer ist und, dass die Folge $(\tilde{T}_n)_{n \in \mathbb{N}}$ nach Beispiel 1.1.15 konsistent ist. Die Konsistenz folgt auch mit Satz 1.5.3, denn

$$\prod_{k=1}^n \rho(x_k, \vartheta) = \vartheta^{-n} \mathbb{1}_{[0, \vartheta]}(x_{(n)})$$

ist unimodal für jedes $n \in \mathbb{N}$, wie man in Abb. 5 sehen kann.

Aber die Dichte ist nicht log-konkav:

$$\ln \left(\frac{1}{\vartheta} \mathbb{1}_{[0, \vartheta]}(x_1) \right) = -\ln(\vartheta) + \ln(\mathbb{1}_{[0, \vartheta]}(x_1))$$




Abb. 5: Die Likelihoodfunktion im Gameshow-Modell ist unimodal.

◇

1.6 | Bayes-Schätzer

DEFINITION 1.6.1 (A-PRIORI VERTEILUNG, A-POSTERIORI VERTEILUNG)

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell und (Θ, \mathcal{T}) ein Messraum. Sei ferner die Likelihoodfunktion ρ gemeinsam $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ -messbar auf $\mathcal{F} \otimes \mathcal{T}$. Ein Wahrscheinlichkeitsmaß μ auf (Θ, \mathcal{T}) ist eine **a-priori Verteilung** (oder: Vorbewertung).

Die **a-posteriori Verteilung zur a-priori Verteilung μ** ist für $x \in \mathfrak{X}$ ist das Wahrscheinlichkeitsmaß ν_x auf (Θ, \mathcal{T}) definiert durch

$$\nu_x(A) = \begin{cases} \frac{1}{Z_x} \int_A \rho(x, \vartheta) d\mu(\vartheta), & \text{wenn } Z_x \in (0, \infty), \\ \mu(A), & \text{wenn } Z_x \in \{0, \infty\}, \end{cases}$$

für $A \in \mathcal{T}$, wobei $Z_x := \int_{\Theta} \rho(x, \vartheta) d\mu(\vartheta)$ eine Normalisierungskonstante ist.

a-priori
Verteilung
a-posteriori
Verteilung

Bemerkung 1.6.2 Die a-posteriori Verteilung ν_x ist ein Wahrscheinlichkeitsmaß für alle $x \in \mathfrak{X}$ und hat die Dichte $\frac{1}{Z_x} \rho(x, \cdot)$ bezüglich μ , wenn $Z_x \in (0, \infty)$ ist und 1 sonst. ◦

Beispiel 1.6.3 ($\mu = \delta_{\vartheta_0}$) Ist $\mu = \delta_{\vartheta_0}$ für $\vartheta_0 \in \Theta$ (drückt aus, dass wir denken, dass ϑ_0 genau das richtige ϑ ist), so folgt $\nu_x = \mu$ für alle $x \in \mathfrak{X}$. ◇

Bemerkung 1.6.4 In diesem Szenario ist \mathbb{P}_ϑ die bedingte Verteilung der Stichprobe X gegeben, dass der Parameter ϑ ist, μ die Randverteilung der Parameters und ν_x die bedingte Verteilung des Parameters gegeben der Stichprobe $X = x$. ◦

Beispiel 1.6.5 ($\mathbb{P}_\vartheta = \text{Bin}(n, \vartheta)$, $\mu = \mathcal{U}_\Theta$, $\nu_x^{(n)} = \text{Beta}(x+1, n-x+1)$)

Seien $\Theta := (0, 1)$, $\mathfrak{X} := \{0, \dots, n\}$ und $\mathbb{P}_\vartheta(\{x\}) = \rho(x, \vartheta) := \binom{n}{x} \vartheta^x (1-\vartheta)^{n-x}$. Sei μ eine a-priori Verteilung auf Θ . Für die a-posteriori Verteilung gilt nach Bemerkung 1.6.2

$$\frac{d\nu_x^{(n)}}{d\mu}(\vartheta) = \frac{\rho(x, \vartheta)}{Z_x},$$

wobei $Z_x := \int_0^1 \rho(x, \tilde{\vartheta}) d\mu(\tilde{\vartheta})$.

In Spezialfall, dass μ die Gleichverteilung auf Θ ist, gilt

$$Z_x = \int_0^1 \binom{n}{x} \vartheta^x (1-\vartheta)^{n-x} d\vartheta = \binom{n}{x} B(x+1, n-x+1),$$

wobei B die **Betafunktion** ist. Es folgt

$$\frac{d\nu_x^{(n)}}{d\mu}(\vartheta) = \frac{\vartheta^x (1-\vartheta)^{n-x}}{B(x+1, n-x+1)},$$


und das ist die Dichte der **Betaverteilung**.

Es ist Hausaufgabe 6.2 zu zeigen, dass für alle $\varepsilon > 0$ gilt:

$$\sup_{x \in \mathfrak{X}} \nu_x^{(n)} \left(\left[\frac{x+1}{n+2} - \varepsilon, \frac{x+1}{n+2} + \varepsilon \right] \right) \xrightarrow{n \rightarrow \infty} 1$$

$$\mathbb{P}_\vartheta^{\otimes n} \left[x \in \mathfrak{X} : \nu_x^{(n)}([\vartheta - \varepsilon, \vartheta + \varepsilon]) \geq 1 - \varepsilon \right] \xrightarrow{n \rightarrow \infty} 0 \quad \forall \vartheta \in [0, 1].$$

◇

Abb. 6: Die Steigung der Dichte der a-posteriori-Verteilung wächst mit n .

Beispiel 1.6.6 ($\mathbb{P}_\vartheta = \mathcal{U}_{[0,\vartheta]}$, $\mu \sim \text{Par}(k, a)$, $\nu_x^{(n)} \sim \text{Par}(\max\{x_{(n)}, k\}, n + a)$)

Gegeben sei das n -fache Produktmodell von $(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), (\mathcal{U}_{[0,\vartheta]})_{\vartheta>0})$ und $\text{Par}(k, a)$ für $k, a > 0$ die a-priori Verteilung. Es ist Hausaufgabe 6.1(i) zu zeigen, dass die a-priori Verteilung $\nu_x \text{Par}(\max\{x_{(n)}, k\}, n + a)$ -verteilt ist. \diamond

Beispiel 1.6.7 ($\mathbb{P}_\vartheta = \text{Bin}(n, \vartheta)$, $\mu \sim \text{Beta}(a, b)$, $\nu_k \sim \text{Beta}(k + a, n - k + b)$)

Betrachte das statistische Modell mit $\mathfrak{X} := \{0, \dots, n\}$, $\mathcal{F} := \mathcal{P}(\mathfrak{X})$ und $\mathbb{P}_\vartheta := \text{Bin}(n, \vartheta)$ für $\vartheta \in \Theta := (0, 1)$. Die a-priori Verteilung sei die $\text{Beta}(a, b)$ -Verteilung mit $a, b > 0$. Es ist Hausaufgabe 6.1(ii) zu zeigen, dass die a-priori Verteilung $\nu_k \text{Beta}(k + a, n - k + b)$ -verteilt ist. \diamond

DEFINITION 1.6.8 (Q)

Wir definieren auf $(\mathfrak{X} \times \Theta, \mathcal{F} \otimes \mathcal{T})$ das Wahrscheinlichkeitsmaß Q durch

$$Q(C) := \int_C \rho(x, \vartheta) d\mu_0(x) d\mu(\vartheta), \quad C \in \mathcal{F} \otimes \mathcal{T},$$

welches die gemeinsame Verteilung von x und ϑ beschreibt.

Es ist Q ein Wahrscheinlichkeitsmaß: mit FUBINI folgt

$$Q(\mathfrak{X} \times \Theta) = \int_{\Theta} \int_{\mathfrak{X}} \rho(x, \vartheta) d\mu_0(x) d\mu(\vartheta) = \int_{\Theta} \underbrace{\mathbb{P}_\vartheta(\mathfrak{X})}_{=1} d\mu(\vartheta) = 1,$$

da \mathbb{P}_ϑ und μ Wahrscheinlichkeitsmaße sind. Nach Konstruktion hat Q die Dichte ρ bezüglich des Produktmaßes $\mu_0 \otimes \mu$.

Für $A \in \mathcal{F}$ gilt mit FUBINI

$$Q(A \times \Theta) = \int_A \left(\underbrace{\int_{\Theta} \rho(x, \vartheta) d\mu(\vartheta)}_{=Z_x} \right) d\mu_0(x) \stackrel{(F)}{=} \int_{\Theta} \mathbb{P}_\vartheta[A] d\mu(\vartheta) \quad (29)$$

und für $B \in \mathcal{T}$ mit FUBINI


$$Q(\mathfrak{X} \times B) = \int_B \left(\underbrace{\int_{\mathfrak{X}} \rho(x, \vartheta) d\mu_0(x)}_{=\mathbb{P}_\vartheta[\mathfrak{X}]=1} \right) d\mu(\vartheta) = \mu(B). \quad (30)$$

Bezeichnen $\pi_{\mathfrak{X}}$ und π_{Θ} die Projektionen von $\mathfrak{X} \times \Theta$ auf \mathfrak{X} bzw. Θ , so folgt wegen (29) ($Q \circ \pi_{\mathfrak{X}}^{-1}$)(A) = $\int_A Z_x d\mu_0(x)$ für $A \in \mathcal{F}$ und wegen (30) $Q \circ \pi_{\Theta}^{-1} = \mu$.

Insbesondere ist $Z_x > 0$ $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast sicher, da $(Q \circ \pi_{\mathfrak{X}}^{-1})(\{x : Z_x = 0\}) = \int_{\{x: Z_x=0\}} Z_x d\mu_0(x) = 0$. Weiter gilt für $C \in \mathcal{F} \otimes \mathcal{T}$ mit

$$C^{(\vartheta)} := \{x \in \mathfrak{X} : (x, \vartheta) \in C\} \quad C_{(x)} := \{\vartheta \in \Theta : (x, \vartheta) \in C\}$$

31.05.2022



(welche messbare Mengen sind)

$$Q(C) = \int_C \rho(x, \vartheta) d\mu_0(x) d\mu(\vartheta) = \int_{\Theta} \underbrace{\left(\int_{C(\vartheta)} \rho(x, \vartheta) d\mu_0(x) \right)}_{=\mathbb{P}_{\vartheta}(C(\vartheta))} d\mu(\vartheta)$$

aber auch

$$\begin{aligned} Q(C) &= \int_{\mathfrak{X}} \left(\int_{C(x)} \rho(x, \vartheta) d\mu(\vartheta) \right) d\mu_0(x) = \int_{\mathfrak{X} \cap \{x: Z_x > 0\}} \left(\int_{C(x)} \rho(x, \vartheta) d\mu(\vartheta) \right) d\mu_0(x) \\ &= \int_{\mathfrak{X} \cap \{x: Z_x > 0\}} \underbrace{\left(\int_{C(x)} \frac{\rho(x, \vartheta)}{Z_x} d\mu(\vartheta) \right)}_{=\nu_x(C(x))} Z_x d\mu_0(x). \end{aligned}$$

Also ist ν_x die bedingte Verteilung für ϑ gegeben einer Beobachtung x .

Wir wollen nun das ϑ schätzen.

DEFINITION 1.6.9 (BAYES-SCHÄTZER, \mathbb{F}_T)

Sei $\tau: \Theta \rightarrow \mathbb{R}$ messbar mit $\mathbb{E}_{\mu}[\tau^2] < \infty$. Die Statistik $T: \mathfrak{X} \rightarrow \mathbb{R}$ ist ein **BAYES-Schätzer** für τ zur a-priori-Verteilung μ , wenn

BAYES-Schätzer

$$\begin{aligned} \mathbb{F}_T &:= \int_{\mathfrak{X} \times \Theta} (T(x) - \tau(\vartheta))^2 dQ(x, \vartheta) \\ &= \int_{\Theta} \left(\int_{\mathfrak{X}} (T(x) - \tau(\vartheta))^2 \rho(x, \vartheta) d\mu_0(x) \right) d\mu(\vartheta) = \int_{\Theta} \mathbb{F}_{\vartheta}[T] d\mu(\vartheta) \end{aligned}$$

minimal ist unter allen Schätzern T für τ .

Bemerkung 1.6.10 Sei $\|\cdot\|_2$ die L^2 -Norm auf $(\mathfrak{X} \times \Theta, \mathcal{F} \otimes \mathcal{T}, Q)$. Dann ist

$$\mathbb{F}_T = \|T(\pi_{\mathfrak{X}}) - \tau(\pi_{\Theta})\|_2^2.$$

○

Bemerkung 1.6.11 (Endliches Risiko des BAYES-Schätzers)

Existiert ein **BAYES-Schätzer** für τ , so ergibt der Vergleich mit dem Nullschätzer

$$\mathbb{F}_T \leq \int_{\mathfrak{X} \times \Theta} \tau^2(\vartheta) dQ(x, \vartheta) = \int_{\Theta} \tau^2(\vartheta) d\mu(\vartheta) = \mathbb{E}_{\mu}[\tau^2] < \infty.$$

○

Bemerkung 1.6.12 Es ist naheliegend zu vermuten, dass für den **BAYES-Schätzer** die Formel $T(x) = \int_{\Theta} \tau(\vartheta) d\nu_x(\vartheta)$ gilt, da $\int_{\Theta} \tau(\vartheta) d\nu_x(\vartheta)$ eine Minimalwert der Funktion $\mathbb{R} \ni C \mapsto \int_{\Theta} (C - \tau(\vartheta))^2 d\nu_x(\vartheta)$ ist.

○

SATZ 1.6.1: EXISTENZ + EINDEUTIGKEIT DES BAYES-SCHÄTZERS

Der **BAYES-Schätzer** T für τ zur a-priori-Verteilung μ existiert, ist $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast sicher eindeutig und es gilt $T(x) = \int_{\Theta} \tau(\vartheta) d\nu_x(\vartheta)$ $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast sicher.

Beweis. ① Wir zeigen erst, dass $\int_{\Theta} \tau(\vartheta) d\nu_x(\vartheta)$ für $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast alle $x \in \mathfrak{X}$ definiert ist und messbar in x und reellwertig und endlich ist.

Es gilt $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast sicher

$$\int_{\Theta} \tau^2(\vartheta) d\nu_x(\vartheta) = \int_{\Theta} \tau^2(\vartheta) \frac{\rho(x, \vartheta)}{Z_x} d\mu(\vartheta)$$

und somit ist dieser Ausdruck nach dem Satz von FUBINI messbar in x (aber eventuell ∞).

Integration über \mathfrak{X} mit $Z_x d\mu_0(x)$ ergibt

$$\int_{\mathfrak{X} \times \Theta} \tau^2(\vartheta) dQ(x, \vartheta) = \int_{\Theta} \tau^2(\vartheta) d\mu(\vartheta) < \infty.$$

Also gilt $\int_{\Theta} \tau^2(\vartheta) d\mu(\vartheta) < \infty$ für $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast alle $x \in \mathfrak{X}$.

Damit gilt

$$T^2(x) = \left(\int_{\Theta} \tau(\vartheta) d\nu_x(\vartheta) \right)^2 \stackrel{(J)}{\leq} \int_{\Theta} \tau(\vartheta)^2 d\nu_x(\vartheta) < \infty$$

für $Q \circ \pi_{\mathfrak{X}}^{-1}$ -fast alle $x \in \mathfrak{X}$.

Weiter ist T messbar (wie in voriger Zeile). Nach Integration über \mathfrak{X} mit $Z_x d\mu_0(x)$ folgt

$$\int_{\mathfrak{X}} T^2(x) Z_x d\mu_0(x) \leq \int_{\mathfrak{X}} \int_{\Theta} \tau^2(\vartheta) d\nu_x(\vartheta) Z_x d\mu_0(x) = \int_{\Theta} \tau^2(\vartheta) d\mu(\vartheta) < \infty$$

und

$$\int_{\mathfrak{X}} T^2(x) Z_x dQ(x, \vartheta) = \int_{\Theta} \tau^2(\vartheta) d\mu(\vartheta) < \infty.$$

Insbesondere gilt $\mathbb{F}_T < \infty$.

② Sei nun S ein Schätzer für τ . Wir zeigen $\mathbb{F}_T \leq \mathbb{F}_S$. Ohne Beschränkung der Allgemeinheit sei $\mathbb{F}_S < \infty$.

Es gilt

$$\mathbb{F}_S - \mathbb{F}_T = \int_{\mathfrak{X}} \int_{\Theta} (S^2 - 2S\tau - T^2 + 2T\tau) dQ(x, \vartheta).$$

Nebenrechnung: es gilt

$$\begin{aligned} \int_{\mathfrak{X}} \int_{\Theta} T\tau dQ(x, \vartheta) &= \int_{\mathfrak{X}} T(x) \underbrace{\left(\int_{\Theta} \tau(\vartheta) \underbrace{\frac{\rho(x, \vartheta)}{Z_x} d\mu(\vartheta)}_{=d\nu_x(\vartheta)} \right)}_{=T(x)} Z_x d\mu_0(x) \\ &= \int_{\mathfrak{X} \times \Theta} T^2(x) dQ(x, \vartheta) \end{aligned}$$

und analog

$$\int_{\mathfrak{X}} \int_{\Theta} S\tau dQ(x, \vartheta) = \int_{\mathfrak{X} \times \Theta} S(x)T(x) dQ(x, \vartheta).$$

Einsetzen ergibt

$$\begin{aligned}\mathbb{F}_S - \mathbb{F}_T &= \int_{\mathfrak{X}} \int_{\Theta} S^2 - 2ST - T^2 + 2T^2 \, dQ(x, \vartheta) \\ &= \int_{\mathfrak{X}} \int_{\Theta} S^2 - 2ST + T^2 \, dQ(x, \vartheta) \\ &= \int_{\mathfrak{X}} \int_{\Theta} (S - T)^2 \, dQ(x, \vartheta) = \int_{\mathfrak{X}} \int_{\Theta} (S - T)^2 Z_x \, d\mu_0(x) \geq 0\end{aligned}$$

und somit $\mathbb{F}_T \leq \mathbb{F}_S$, somit ist T ein BAYES-Schätzer.

Wenn auch S ein BAYES-Schätzer ist, dann gilt $\mathbb{F}_S = \mathbb{F}_T$. Gleichheit gilt genau dann, wenn $Q \circ \pi_X^{-1}$ -fast sicher $S = T$ gilt. \square

Beispiel 1.6.13 (BAYES-Schätzer des E-Werts einer Normalverteilung)

Dieses Beispiel folgt [2, 7.39].

Sei $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{\vartheta, v}^{\otimes n})_{\vartheta \in \mathbb{R}})$ das n -fache GAUSSsche Produktmodell mit bekannter Varianz $v > 0$. Dann ist (bezüglich des n -dimensionalen LEBESGUEmaßes)

$$\rho(x, \vartheta) = (2\pi v)^{-\frac{n}{2}} \exp\left(-\frac{1}{2v} \sum_{k=1}^n (x_k - \vartheta)^2\right).$$

Sei die a-priori-Verteilung $\mu = \mathcal{N}_{m, u}$ mit $m \in \mathbb{R}$ und $u > 0$. Je kleiner wir u wählen, desto sicherer sind wir uns, dass der Erwartungswert nahe bei m liegt.

Wir bestimmen den BAYES-Schätzer für $\tau(\vartheta) := \vartheta$.

Wir schreiben im Folgenden c_x, c'_x und c''_x für von ϑ unabhängig (aber von x abhängige) Konstanten. Weil μ absolutstetig bezüglich des Lebesgue-Maßes λ ist, gilt

$$\begin{aligned}\frac{d\nu_x}{d\lambda}(\vartheta) &= \frac{d\nu_x}{d\mu}(\vartheta) \frac{d\mu}{d\lambda}(\vartheta) = \frac{\rho(x, \vartheta)}{Z_x} \frac{1}{\sqrt{2\pi u}} \exp\left(-\frac{(\vartheta - m)^2}{2u}\right) \\ &= c_x \exp\left(-\frac{1}{2v} \sum_{k=1}^n (x_k - \vartheta)^2 - \frac{(\vartheta - m)^2}{2u}\right).\end{aligned}\tag{31}$$

Durch Ausmultiplizieren erhalten wir

$$\begin{aligned}-\frac{1}{2v} \sum_{k=1}^n (x_k - \vartheta)^2 - \frac{(\vartheta - m)^2}{2u} &= -\frac{1}{2v} \sum_{k=1}^n (x_k^2 - 2x_k\vartheta + \vartheta^2) - \frac{(\vartheta^2 - 2\vartheta m + m^2)}{2u} \\ &= -\frac{1}{2} \left(\frac{1}{u} + \frac{n}{v}\right) \vartheta^2 + \left(\frac{m}{u} + \frac{1}{v} \sum_{k=1}^n x_k\right) \vartheta + c'_x.\end{aligned}$$

Quadratische Ergänzung liefert dann

$$-\frac{1}{2v} \sum_{k=1}^n (x_k - \vartheta)^2 - \frac{(\vartheta - m)^2}{2u} = -\frac{\frac{1}{u} + \frac{n}{v}}{2} \left(\vartheta - \left(\frac{\frac{1}{u}m + \frac{1}{v} \sum_{k=1}^n x_k}{\frac{1}{u} + \frac{n}{v}}\right)\right)^2 + c''_x$$

und durch Einsetzen in Gleichung (31) folgt

$$\frac{d\nu_x}{d\lambda}(\vartheta) = \tilde{c}_x \exp\left[-\frac{\frac{1}{u} + \frac{n}{v}}{2} \left(\vartheta - \left(\frac{\frac{1}{u}m + \frac{1}{v} \sum_{k=1}^n x_k}{\frac{1}{u} + \frac{n}{v}}\right)\right)^2\right].$$

Diese Dichte ist bis auf einen konstanten Faktor gleich der Dichte von $\mathcal{N}\left(\frac{\frac{1}{u}m + \frac{1}{v}\sum_{k=1}^n x_k}{\frac{1}{u} + \frac{n}{v}}, \frac{1}{\frac{1}{u} + \frac{n}{v}}\right)$, also gilt

$$\nu_x = \mathcal{N}\left(\frac{\frac{1}{u}m + \frac{1}{v}\sum_{k=1}^n x_k}{\frac{1}{u} + \frac{n}{v}}, \frac{1}{\frac{1}{u} + \frac{n}{v}}\right).$$

Aus Satz 1.6.1 folgt schließlich

$$T(x) = \int_{\Theta} \tau(\vartheta) d\nu_x(\vartheta) = \int_{\Theta} \vartheta d\nu_x(\vartheta) = \frac{\frac{1}{u}m + \frac{1}{v}\sum_{k=1}^n x_k}{\frac{1}{u} + \frac{n}{v}} = sm + (1-s)\frac{1}{n}\sum_{k=1}^n x_k,$$

wobei $s = \frac{\frac{1}{u}}{\frac{1}{u} + \frac{n}{v}}$, also ist $T(x)$ eine **Konvexkombination** aus der Voreinschätzung m und dem empirischen Mittelwert der Beobachtungen. Je mehr Beobachtungen wir machen, desto kleiner wird s , da es sinnvoll ist, weniger auf die Voreinschätzung und mehr auf die Beobachtungen zu vertrauen. \diamond

02.06.2022

Bemerkung 1.6.14 In diesem Fall ist T auch ein MAP-Schätzer. \circ

DEFINITION 1.6.15 (MAP-SCHÄTZER)

Ein Schätzer T heißt **Maximum-a-posteriori-Schätzer** wenn

$$\frac{d\nu_x}{d\lambda}(T(x)) = \sup_{\vartheta \in \Theta} \frac{d\nu_x}{d\lambda}(\vartheta),$$

wobei λ das LEBESGUE-Maß ist.

Maximum-a-posteriori-Schätzer

Beispiel 1.6.16 (BAYES-Ansätze in der Bildrestauration)

Seien S und I endliche Mengen und S eine Teilmenge der Pixel und I die Menge der Farben oder Graustufen sowie $\Theta = I^S$ die Menge aller möglichen Bilder. Für $x \in \Theta$ und $y \in \mathfrak{X} = \Theta$ sei $P(x, y)$ die Wahrscheinlichkeit y zu beobachten, wenn das Bild x ist. Hier ist es unsinnig, beispielsweise Maximum-Likelihood-Schätzer zu verwenden; ein BAYESScher Ansatz ist notwendig, da nicht alle Bilder gleichwahrscheinlich sind.

Ansatz. Sei μ eine a-priori-Verteilung auf Θ mit $\mu(\{x\}) > 0$ für alle $x \in \Theta$. Dann gilt (Achtung: x und y haben hier die Rollen getauscht)

$$\nu_y(x) = \frac{1}{Z_y} \mu(x) P(x, y) \quad \text{mit } Z_y = \sum_{z \in \Theta} \mu(\{z\}) P(z, y).$$

Mögliche Wahl von x nach Beobachtung y ist der MAP-Schätzer, der $\mu(\{x\})P(x, y)$ maximiert. (Ist μ die Gleichverteilung auf Θ , so ist der MAP-Schätzer identisch zu dem Maximum-Likelihood-Schätzer.)

Fragen. 1. Wie wählt man μ ? 2. Wie findet man das Maximum von $\mu(\{x\})P(x, y)$?

Zu 1.: wir wählen $\mu(\{x\}) = \frac{1}{Z} \exp(-H(x))$, wobei H die „Energie von x “ ist. Diese Darstellung existiert immer, da wir $\mu(\{x\}) > 0$ vorausgesetzt haben. Das Maß μ heißt **Gibbs-Verteilung** zur Energiefunktion H , zum Beispiel, z.B. im Fall, dass I eine endliche Teilmenge reeller Zahlen ist. Eine mögliche Wahl ist

$$H(x) = \beta \sum_{(s,t) \text{ benachbarte Pixel}} (x_s - x_t)^2,$$

wobei $\beta > 0$ die inverse Temperatur ist. Dann folgt

$$\nu_y(x) = \frac{1}{Z_y} \exp(-H(x) \ln(P(x, y))).$$

Es verbleibt nun die Maximierung des Exponenten. ◇

Beispiel 1.6.17 ($\mathbb{P}_\vartheta \sim \text{Poi}(\vartheta)$, $\mu \sim \Gamma_{a,r} \implies \nu_x \sim \Gamma_{a+n, r+\sum_{k=1}^n x_k}$)

01.06.2022

Betrachte $(\mathbb{N}_0^n, \mathbb{P}(\mathbb{N}_0^n), (\text{Poi}(\vartheta)^{\otimes n})_{\vartheta>0})$ mit der a-priori-Verteilung $\mu \sim \Gamma_{a,r}$ für $a, r > 0$. Für $x \in \mathbb{N}_0^n$ hat die a-posteriori-Verteilung ν_x die folgende Dichte bezüglich des LEBESGUE-Maßes

$$\begin{aligned} \frac{\rho(x, \vartheta) f_{a,r}(\vartheta)}{\int_0^\infty \rho(x, \theta) f_{a,r}(\theta) d\theta} &= \frac{\left(\prod_{k=1}^n \frac{1}{x_k!} \vartheta^{x_k} e^{-\vartheta} \right) \frac{a^r}{\Gamma(r)} \vartheta^{r-1} e^{-a\vartheta}}{\int_0^\infty \left(\prod_{k=1}^n \frac{1}{x_k!} \theta^{x_k} e^{-\theta} \right) \frac{a^r}{\Gamma(r)} \theta^{r-1} e^{-a\theta} d\theta} \\ &= \frac{\vartheta^{\sum_{k=1}^n x_k + r - 1} e^{-(a+n)\vartheta}}{\int_0^\infty \theta^{\sum_{k=1}^n x_k + r - 1} e^{-(a+n)\theta} d\theta} \\ &= \frac{(a+n)^{r+\sum_{k=1}^n x_k}}{\Gamma(r + \sum_{k=1}^n x_k)} \vartheta^{\sum_{k=1}^n x_k + r - 1} e^{-(a+n)\vartheta}, \end{aligned}$$

welche die Dichte der $\Gamma_{a+n, r+\sum_{k=1}^n x_k}$ -Verteilung ist.

Der BAYES-Schätzer ist $T_B^{(n)}(x) = \int_0^\infty \vartheta d\nu_x(\vartheta) = \frac{r+\sum_{k=1}^n x_k}{a+n}$ genau der Erwartungswert von ν_x .

Nullsetzen der Ableitung nach ϑ der Dichte von ν_x ergibt

$$\frac{(a+n)^{r+\sum_{k=1}^n x_k}}{\Gamma(r + \sum_{k=1}^n x_k)} \left(r + \sum_{k=1}^n x_k - 1 - \vartheta(a+n) \right) \vartheta^{r+\sum_{k=1}^n x_k - 2} e^{-(a+n)\vartheta} \stackrel{!}{=} 0$$

also ist der Maximum-a-posteriori-Schätzer $T_{\text{MAP}}^{(n)}(x) = \frac{1}{a+n} (r + \sum_{k=1}^n x_k - 1)$.

Die Schätzfolgen $(T_{\text{MAP}}^{(n)})_{n \in \mathbb{N}}$ und $(T_B^{(n)})_{n \in \mathbb{N}}$ sind asymptotisch erwartungstreu, jedoch sind die einzelnen Schätzer nicht erwartungstreu: für $n \in \mathbb{N}$ und $\vartheta \in \Theta$ gilt

$$\mathbb{E}_\vartheta [T_B^{(n)}] = \frac{1}{a+n} \left(\mathbb{E} \left[\sum_{k=1}^n X_k \right] + r \right) = \frac{n\vartheta + r}{a+n} \xrightarrow{n \rightarrow \infty} \vartheta$$

und analog

$$\mathbb{E}_\vartheta [T_{\text{MAP}}^{(n)}] = \frac{n\vartheta + r - 1}{a+n} \xrightarrow{n \rightarrow \infty} \vartheta.$$

Ferner folgt

$$\mathbb{V}_\vartheta [T_B^{(n)}] = \frac{1}{(a+n)^2} \mathbb{V}_\vartheta \left[\sum_{k=1}^n X_k + r \right] = \frac{1}{(a+n)^2} \sum_{k=1}^n \mathbb{V}_\vartheta [X_k] = \frac{n}{(a+n)^2} \vartheta \xrightarrow{n \rightarrow \infty} 0$$

und analog

$$\mathbb{V}_\vartheta [T_{\text{MAP}}^{(n)}] = \frac{n}{(a+n)^2} \vartheta \xrightarrow{n \rightarrow \infty} 0.$$

Somit sind beide Schätzfolgen konsistent. ◇

Konfidenzbereiche

2.1 | Grundlagen

02.06.2022

Wir wollen wissen, wie genau $\tau: \Theta \rightarrow \Sigma$ von einem Schätzer $T: \mathfrak{X} \rightarrow \Sigma$ geschätzt wird.

DEFINITION 2.1.1 (KONFIDENZBEREICH)

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell, $\tau: \Theta \rightarrow \Sigma$ eine Kenngröße und $\alpha \in (0, 1)$. Eine Abbildung $C: \mathfrak{X} \rightarrow \mathcal{P}(\Sigma)$ ist ein **Konfidenzbereich** für τ zum **Irrtumsniveau** α (oder zum **Sicherheitsniveau** $1 - \alpha$), wenn

$$\inf_{\vartheta \in \Theta} \mathbb{P}_\vartheta[x \in \mathfrak{X} : \tau(\vartheta) \in C(x)] \geq 1 - \alpha,$$

wobei wir annehmen, dass $\{x \in \mathfrak{X} : s \in C(x)\} \in \mathcal{F}$ für alle $s \in \Sigma$ gilt.

Ist $\Sigma \subset \mathbb{R}$, und $C(x)$ ein Intervall für jedes $x \in \mathfrak{X}$, so ist C ein **Konfidenzintervall**.

Konfidenzbereich

Bemerkung 2.1.2 Die Funktion C heißt auch **Bereichsschätzer** im Gegensatz zum **Punktschätzer** T . ○

Bemerkung 2.1.3 Man kann immer $C(x) = \Sigma$ wählen, aber das ist uninteressant, stattdessen will man $C(x)$ möglichst „klein“ wählen. ○

Bemerkung 2.1.4 Es ist *nicht* verboten, $C(x) = \emptyset$ für $x \in \mathfrak{X}$ zu wählen (sogar auf nicht-Nullmengen). ○

Bemerkung 2.1.5 Typische Werte für α sind 0,05 oder 0,1. ○

Warnung. Hat man ein konkretes $x_0 \in \mathfrak{X}$ beobachtet, so sollte man *nicht* sagen „ $\tau(\vartheta)$ liegt mit der Mindestwahrscheinlichkeit $1 - \alpha$ in $C(x_0)$ “.

Beispiel 2.1.6 (Verschobene Exponentialverteilung)

Betrachte das statistische Modell $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (\mathbb{P}_\vartheta)_{\vartheta \in \mathbb{R}})$, wobei \mathbb{P}_ϑ die Dichte

$$\rho(x, \vartheta) = e^{-x+\vartheta} \mathbb{1}_{[\vartheta, \infty)}(x)$$

bezüglich des LEBESGUE-Maßes hat.

- **Konfidenzintervalle der Form $(-\infty, b]$.** Wir wollen ein $b > 0$ finden, sodass

$$\mathbb{P}_\vartheta[x \in \mathbb{R} : \vartheta \in (-\infty, x - b]] \geq 1 - \alpha$$

gilt.

Für $\vartheta \in \mathbb{R}$ gilt

$$\begin{aligned} \mathbb{P}_\vartheta[x \in \mathbb{R} : \vartheta \in (-\infty, x - b]] &= \mathbb{P}_\vartheta[x - b \geq \vartheta] = \mathbb{P}_\vartheta[x \geq \vartheta + b] \\ &= \int_{\vartheta+b}^{\infty} e^{-x+\vartheta} \mathbb{1}_{[\vartheta, \infty)}(x) dx = \int_b^{\infty} e^{-y} dy = e^{-b}. \end{aligned}$$

Wir wählen deshalb $b := -\ln(1 - \alpha)$.

- **Konfidenzintervall der Form $[a, x]$.**

Wir wollen ein $a > 0$ finden, sodass

$$\mathbb{P}_\vartheta[x : \vartheta \in [x - a, x]] \geq 1 - \alpha$$

gilt.

Für $\vartheta \in \mathbb{R}$ gilt

$$\begin{aligned} \mathbb{P}_\vartheta[x : \vartheta \in [x - a, x]] &= \mathbb{P}_\vartheta[x - a \leq \vartheta \leq x] = \mathbb{P}_\vartheta[\vartheta \leq x \leq \vartheta + a] \\ &= \int_{\vartheta}^{\vartheta+a} e^{-x+\vartheta} \mathbb{1}_{[\vartheta, \infty)}(x) dx = \int_0^a e^{-x} dx = 1 - e^{-a}, \end{aligned}$$

also wählen wir $a := -\ln(\alpha)$.

- **Konfidenzintervall minimaler Länge.** Wir wollen $a, b \geq 0$ finden, sodass $\mathbb{P}_\vartheta[x : \vartheta \in [x - a, x - b]] \geq 1 - \alpha$ und $a - b$ minimal ist.

Für $\vartheta \in \mathbb{R}$ gilt

$$\begin{aligned} \mathbb{P}_\vartheta[x : \vartheta \in [x - a, x - b]] &= \mathbb{P}_\vartheta[x : x - a \leq \vartheta \leq x - b] \\ &= \mathbb{P}_\vartheta[x : \vartheta + b \leq x \leq \vartheta + a] \\ &= \int_{\vartheta+b}^{\vartheta+a} e^{-x+\vartheta} \mathbb{1}_{[\vartheta, \infty)}(x) dx = \int_b^a e^{-y} dy = e^{-b} - e^{-a}. \end{aligned}$$

Daher setzen wir $1 - \alpha = e^{-b} - e^{-a}$ und erhalten $a = -\ln(e^{-b} - 1 + \alpha)$ unter der Bedingung $e^{-b} > 1 - \alpha$.

Die Länge des Konfidenzintervalls ist

$$\ell(b) := a - b = -\ln(e^{-b} - 1 + \alpha) - b.$$

Für $b < -\ln(1 - \alpha)$ gilt

$$\ell'(b) = \frac{e^{-b}}{\underbrace{e^{-b} - 1 + \alpha}_{>1}} - 1 > 0.$$

Also ist die Länge minimal für $b = 0$ und das Konfidenzintervall $[x + \ln(\alpha), x]$. ◇

Beispiel 2.1.7

Gegeben sei das statistische Modell $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (\mathbb{P}_\vartheta)_{\vartheta \in \mathbb{R}})$, wobei für die festen Parameter $a, b > 0$ die Dichte des Wahrscheinlichkeitsmaßes \mathbb{P}_ϑ

$$\rho(\vartheta, x) = \frac{ab}{a+b} \left(e^{-a|x-\vartheta|} \mathbb{1}_{\{x < \vartheta\}}(x, \vartheta) + e^{-b|x-\vartheta|} \mathbb{1}_{\{x \geq \vartheta\}}(x, \vartheta) \right)$$

ist. Es ist Hausaufgabe 7.2, ein Konfidenzintervall für ϑ zum Niveau $\alpha \in (0, 1)$ mit minimaler Länge zu konstruieren. ◇

2.2 | Konstruktionsmethode im Standardmodell mit

$$\tau = \text{id}$$

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell mit Likelihoodfunktion ρ , $\tau := \text{id}_\Theta$ und $\alpha \in (0, 1)$. Für $\vartheta \in \Theta$ setzen wir $C_\vartheta := \{x \in \mathfrak{X} : \rho(x, \vartheta) \geq c_\vartheta\}$, wobei die „kritische Größe“ $c_\vartheta \geq 0$ so gewählt ist, dass $\mathbb{P}_\vartheta[C_\vartheta] \geq 1 - \alpha$. (Es gilt $C_\vartheta \in \mathcal{F}$ als Urbild der messbaren Abbildung $\rho(\cdot, \vartheta)$.)

Definiere nun $\tilde{C} := \{(x, \vartheta) : x \in C_\vartheta\}$ und dann

$$C(x) := \{\vartheta \in \Theta : x \in C_\vartheta\} = \{\vartheta \in \Theta : (x, \vartheta) \in \tilde{C}\}.$$

Dann gilt

$$\mathbb{P}_\vartheta[x \in \mathfrak{X} : \vartheta \in C(x)] = \mathbb{P}_\vartheta[x \in \mathfrak{X} : (x, \vartheta) \in \tilde{C}] = \mathbb{P}_\vartheta[C_\vartheta] \geq 1 - \alpha$$

für alle $\vartheta \in \Theta$. Somit ist C ein Konfidenzbereich.

Beispiel 2.2.1 (Schadstoffausstoß von Kraftwerken [2, Bsp. 8.3])

Von $N := 10$ Kraftwerken werden bei $n := 4$ zufällig ausgewählten der Schadstoffausstoß gemessen. Gesucht ist ein Konfidenzbereich für die Anzahl ϑ der Kraftwerke, mit zu hohem Ausstoß. Wir wählen $\Theta := \{0, \dots, N\}$ und $\mathfrak{X} := \{0, \dots, n\}$ sowie $\alpha := \frac{1}{5}$. Die Likelihoodfunktion ist

$$\rho(x, \vartheta) = \frac{\binom{\vartheta}{x} \binom{N-\vartheta}{n-x}}{\binom{N}{n}} \sim \text{Hyp}_{N, \vartheta, n}.$$

$\vartheta \backslash x$	0	1	2	3	4
6	1	24	90	80	15
5	5	50	100	50	5
4	15	80	90	24	1
3	35	105	63	7	0
2	70	112	28	0	0
1	126	84	0	0	0
0	210	0	0	0	0

Tabelle 1: Die Tabelle wird symmetrisch ($\rho(x, \vartheta) = \rho(n - x, N - \vartheta)$) fortgeführt, sie zeigt die Werte $\binom{N}{n} \rho(x, \vartheta)$ für $x \in \mathfrak{X}$ und $\vartheta \in \Theta$.

Um C_ϑ zu erhalten, summieren wir in absteigender Reihenfolge der Größe nach die Einträge der ϑ -Zeile, bis $(1 - \alpha) \binom{N}{n} = \frac{4}{5} \cdot 210 = 168$ erreicht wird, z.B. ist für $\vartheta = 6$ der größte Wert in der Zeile, 90, kleiner als 168, aber $90 + 80 > 168$, also markieren wir diese beiden Einträge blau. Also ist $C(x)$ die Menge aller $\vartheta \in \Theta$, sodass $\rho(x, \vartheta)$ blau markiert ist. Somit sind $C(0) = \{0, 1, 2\}$, $C(1) = \{1, \dots, 5\}$, $C(2) = \{3, \dots, 7\}$, $C(3) = \{5, \dots, 9\}$ und $C(4) = \{8, 9, 10\}$. \diamond




Abb. 7: Die Idee ist, für alle ϑ die Schnitte zu konstruieren und damit die x -Schnitte $C(x)$ zu erhalten.

Beispiel 2.2.2 (Konfidenzintervall für den E-Wert im GAUSS-Modell)

Betrachte das GAUSSsche Produktmodell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m,v}^{\otimes n})_{m \in \mathbb{R}, v > 0})$ für $n \geq 2$.

Gesucht ist ein Konfidenzintervall für den $\tau(\vartheta) := \tau = (m, v)$. Für $\vartheta = (m, v)$ bezeichnen wir $m(\vartheta) = m$.

Wir modifizieren die Konstruktion in Beispiel 2.2.1 dahingehend, was wir für $m \in \mathbb{R}$ wollen wir $C_m \in \mathcal{B}(\mathbb{R}^n)$ wählen mit $\mathbb{P}_\vartheta(C_{m(\vartheta)}) \geq 1 - \alpha$ (möglichst "="). Dann sei $C(x) := \{m \in \mathbb{R} : x \in C_m\}$ für $x \in \mathbb{R}^n$. Dann gilt

$$\mathbb{P}_\vartheta[\{x \in \mathbb{R}^n : m(\vartheta) \in C(x)\}] = \mathbb{P}_\vartheta[\{x : x \in C_{m(\vartheta)}\}] \geq 1 - \alpha.$$

Wir definieren die Statistik $T_m(x) := (M(x) - m)\sqrt{\frac{n}{V^*(x)}}$ für $m \in \mathbb{R}$ und $x \in \mathbb{R}^n$, wobei $M(x) := \frac{1}{n} \sum_{k=1}^n x_k$ der empirische Mittelwert und $V^*(x) := \frac{1}{n-1} \sum_{k=1}^n (x_k - M(x))^2$ die empirische Varianz sind.

Behauptung. Die Verteilung von $T_{m(\vartheta)}(x)$ unter \mathbb{P}_ϑ hängt nicht von ϑ ab.

Beweis. Sind X_1, \dots, X_n unabhängig $\mathcal{N}_{m,v}$ -verteilt, so haben sie die Darstellung $X_k = m + \sqrt{v}Y_k$, wobei Y_1, \dots, Y_n $N(0, 1)$ -verteilt sind. Es folgt

$$\begin{aligned} T_m(x_1, \dots, x_n) &= (M(x) - m)\sqrt{\frac{n}{V^*(x)}} \\ &= \left(\bar{x} + \frac{\sqrt{v}}{n} \sum_{k=1}^n Y_k - m \right) \sqrt{\frac{n(n-1)}{\sum_{k=1}^n \left(\sqrt{v}Y_k + m - \left(m + \frac{\sqrt{v}}{n} \sum_{k=1}^n Y_k \right) \right)^2}} \\ &= \left(\frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k \right) \sqrt{\frac{n-1}{\sum_{k=1}^n \left(Y_k - \frac{1}{n} \sum_{k=1}^n Y_k \right)^2}} = T_0(Y_1, \dots, Y_n). \end{aligned}$$

Das heißt die Verteilung Q von $T_{m(\vartheta)}(X)$ unter \mathbb{P}_ϑ hängt nicht von ϑ ab. \square

Q heißt t_{n-1} -Verteilung (oder t -Verteilung mit $n-1$ Freiheitsgraden). Es gilt $Q(A) = Q(-A)$ und Q hat eine Dichte (cf. später), welche auf $[0, \infty)$ fallend ist.

Konstruktion von C_m . Zu $\alpha \in (0, 1)$ wähle ein Intervall $I \subset \mathbb{R}$ der Form $[-t, t]$ mit $Q([-t, t]) = 1 - \alpha$ (dies können wir nur machen, da wir eine Dichte haben). Sei $C_m := T_m^{-1}([-t, t])$. Dann folgt für $\vartheta \in \Theta := \mathbb{R} \times \mathbb{R}_{>0}$

$$\mathbb{P}_\vartheta[C_{m(\vartheta)}] = \mathbb{P}_\vartheta[|T_{m(\vartheta)}| \leq t] = Q([-t, t]) = 1 - \alpha.$$

Also ist $C(x) := \{m \in \mathbb{R} : x \in C_m\}$ ein Konfidenzintervall für $m(\vartheta)$ zu α .

Für $x \in \mathbb{R}^n$ gilt

$$\begin{aligned} C(x) &= \{m \in \mathbb{R} : x \in C_m\} = \{m \in \mathbb{R} : |T_m(x)| \leq t\} \\ &= \left[M(x) - t\sqrt{\frac{V^*(x)}{n}}, M(x) + t\sqrt{\frac{V^*(x)}{n}} \right]. \end{aligned}$$

\diamond

Beispiel 2.2.3 (Konfidenzbereiche für die Normalverteilung)

08.06.2022

Wir nehmen n unabhängige Messwerte, welche normalverteilt mit unbekannten Erwartungswert μ sind.

- ① Wir sind sicher, dass wir die Varianz $v > 0$ kennen. Welchen Konfidenzbereich für m zum Niveau $\alpha \in (0, 1)$ wählen wir?
- ② Die Varianz ist doch unbekannt. Wie groß ist das Niveau für den in a) gewählten Bereich?
- ① Wir betrachten das Stichprobenmittel $M := \frac{1}{n} \sum_{k=1}^n X_k$ und transformieren es zu T_m , sodass die Verteilung von T_m nicht von m oder v abhängt.

Wir wählen $T_m := \sqrt{\frac{n}{v}}(M - m) \sim \mathcal{N}_{0,1}$. Sei $q_{\frac{\alpha}{2}}$ das $\frac{\alpha}{2}$ -Fraktil der Standardnormalverteilung (das heißt $\mathcal{N}_{0,1}([q_{\frac{\alpha}{2}}, \infty)) = \frac{\alpha}{2}$). Dann gilt

$$\mathbb{P}_m(T_m \in [-q_{\frac{\alpha}{2}}, q_{\frac{\alpha}{2}}]) = 1 - \alpha$$

und

$$\begin{aligned} 1 - \alpha &= \mathbb{P}_m\left(-q_{\frac{\alpha}{2}} \leq \sqrt{\frac{n}{v}}(M - m) \leq q_{\frac{\alpha}{2}}\right) \\ &\leq \mathbb{P}_m\left(M - \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}} \leq m \leq M + \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}\right) \\ &= \mathbb{P}_m\left(m \in \left[M - \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}, M + \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}\right]\right). \end{aligned}$$

Wir wählen den Konfidenzbereich

$$C_\alpha(x) = \left[M - \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}, M + \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}\right].$$

- ② Bei unbekannter Varianz können wir T_m nicht wie in a) wählen. In den Vorlesung wurde $T_m := \sqrt{\frac{n}{V^*}}(M - m)$ gewählt, wobei V^* die korrigierte Stichprobenvarianz ist. Es gilt $T_m \sim t_{n-1}$. Sei $t_{\frac{\alpha}{2}}$ das $\frac{\alpha}{2}$ -Fraktil der t_{n-1} -Verteilung. Dann ist

$$C_b(x) = \left[M_n - \sqrt{\frac{v^*}{n}}t_{\frac{\alpha}{2}}, M_n + \sqrt{\frac{v^*}{n}}t_{\frac{\alpha}{2}}\right]$$

ein Konfidenzintervall zum Niveau α .

Für den Konfidenzbereich aus ① gilt dann

$$\begin{aligned} C_\alpha(x) &= \left[M_n - \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}, M_n + \sqrt{\frac{v}{n}}q_{\frac{\alpha}{2}}\right] \\ &= \left[M_n - \left(\sqrt{\frac{v}{v^*}}q_{\frac{\alpha}{2}}\right)\sqrt{\frac{v^*}{n}}, M_n + \left(\sqrt{\frac{v}{v^*}}q_{\frac{\alpha}{2}}\right)\sqrt{\frac{v^*}{n}}\right] \end{aligned}$$

und C_α ist ein Konfidenzbereich zum Niveau

$$\tilde{\alpha} = 2t_{n-1}\left(\left[q_{\frac{\alpha}{2}}\sqrt{\frac{v}{v^*}}, \infty\right)\right).$$

◇

Beispiel 2.2.4 (Schlafmittel)

Es sollen zwei Schlafmittel miteinander verglichen werden. Es werden $n := 10$ Patienten beide Schlafmittel in unterschiedlichen Nächten gegeben und die Differenz der Schlafdauer gemessen. Alle Patienten mit dem zweiten Schlafmittel haben mindestens genau so lange

Patient	1	2	3	4	5	6	7	8	9	10
Differenz	1.2	2.4	1.3	1.3	0.0	1.0	1.8	0.8	4.6	1.4

geschlafen wie mit dem ersten. Wir nehmen an, dass die Messwerte normalverteilt sind. Das Stichprobenmittel und die korrigierte Stichprobenvarianz sind

$$M = \frac{1}{10} \sum_{k=1}^{10} X_k = 1.58 \quad \text{und} \quad V^* = \frac{1}{9} \sum_{k=1}^{10} (X_k - M)^2 = 1.513.$$

Mit dem Irrtumsniveau $\alpha = 0.05$ erhalten wir für die t_9 -Verteilung das $\frac{\alpha}{2}$ -Fraktil $t = 2.262$. Ein Konfidenzbereich zum Niveau α ist

$$C(x) = \left[M - t \sqrt{\frac{V^*}{10}}, M + t \sqrt{\frac{V^*}{10}} \right] = [1.58 - 0.88, 1.58 + 0.88] = [0.7, 2.46].$$

◇

Beispiel 2.2.5 (Konfidenzbereich im Binomialmodell)

Seien $\mathfrak{X} := \{0, \dots, n\}$, $\Theta := \{0, 1\}$ sowie $\mathbb{P}_\vartheta := B_{n, \vartheta}$.

1. Methode: MARKOV-Ungleichung. Der beste Schätzer für ϑ ist $T(x) := \frac{x}{n}$. Eine natürliche Wahl ist $\left[\frac{x}{n} - \varepsilon, \frac{x}{n} + \varepsilon\right]$ für ein geeignetes $\varepsilon > 0$. Mit der MARKOV-Ungleichung folgt

$$\mathbb{P}_\vartheta(\vartheta \notin C(x)) = \mathbb{P}_\vartheta\left(\left|\frac{x}{n} - \vartheta\right| < \varepsilon\right) \leq \frac{1}{\varepsilon^2} \mathbb{V}_\vartheta\left[\frac{x}{n}\right] = \frac{\vartheta(1-\vartheta)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2} \stackrel{!}{\leq} \alpha$$

für alle $\vartheta \in (0, 1)$. Wir wählen $\varepsilon = \frac{1}{2\sqrt{n\alpha}}$. Für $n = 1000$ und $\alpha = 0.025$ ist also $\varepsilon = 0.1$.

2. Methode: Normalapproximation. Wir nehmen an, dass n so groß ist, dass wir den zentralen Grenzwertsatz anwenden können. Wie zuvor wählen wir $C(x) := \left[\frac{x}{n} - \varepsilon, \frac{x}{n} + \varepsilon\right]$. Dann gilt

$$\begin{aligned} \mathbb{P}_\vartheta[\vartheta \in C(x)] &= \mathbb{P}_\vartheta\left(\left|\frac{x}{n} - \vartheta\right| < \varepsilon\right) = \mathbb{P}_\vartheta\left(\left|\frac{x - n\vartheta}{\sqrt{n\vartheta(1-\vartheta)}}\right| < \varepsilon\sqrt{\frac{n}{\vartheta(1-\vartheta)}}\right) \\ &\approx \Phi\left(\varepsilon\sqrt{\frac{n}{\vartheta(1-\vartheta)}}\right) - \Phi\left(-\varepsilon\sqrt{\frac{n}{\vartheta(1-\vartheta)}}\right) \\ &= 2\Phi\left(\varepsilon\sqrt{\frac{n}{\vartheta(1-\vartheta)}}\right) - 1 \geq 2\Phi(2\varepsilon\sqrt{n}) - 1, \end{aligned}$$

wobei Φ die Verteilungsfunktion der Standardnormalverteilung ist.

Sei $\alpha = 0.025$. Wir wählen einen [Sicherheitszuschlag](#) von 0.02 für den Approximationsfehler und erhalten

$$2\Phi(2\varepsilon\sqrt{n}) - 1 \geq 0.975 + 0.02 \iff \varepsilon \geq \frac{1}{2\sqrt{n}} \Phi^{-1}(0.995) = \frac{1}{2\sqrt{n}} \cdot 2.575.$$

Wählen wir $n = 1000$, erhalten wir $\varepsilon \geq 0.0407$.

Verglichen mit der ersten Methoden ist das Konfidenzintervall hier nur halb so groß. ◇

3 Rund um die Normalverteilung: χ^2 , F - und t -Verteilungen

Literatur zur mehrdimensionalen Normalverteilung: [4, 7.12-7.19].

DEFINITION 3.0.1 (GAMMAVERTEILUNG)

Für $\alpha, r > 0$ ist das Wahrscheinlichkeitsmaß $\Gamma_{\alpha,r}$ auf $((0, \infty), \mathcal{B}((0, \infty)))$ mit der Dichte

$$\gamma_{\alpha,r}(x) := \frac{\alpha^r}{\Gamma(r)} x^{r-1} e^{-\alpha x}, \quad x > 0,$$

die **Gammaverteilung** mit **Skalenparameter** α und **Formparameter** r , wobei

$$\Gamma(r) := \int_0^\infty y^{r-1} e^{-y} dy.$$

Die Gammaverteilung mit $r = 1$ ist die Exponentialverteilung.

DEFINITION 3.0.2 (BETAVEILUNG)

Für $a, b > 0$ ist das Wahrscheinlichkeitsmaß $\mathcal{B}_{a,b}$ auf $((0, 1), \mathcal{B}((0, 1)))$ mit der Dichte

$$\beta_{a,b}(s) := \frac{1}{B(a,b)} s^{a-1} (1-s)^{b-1}, \quad s \in (0, 1),$$

die **Betaverteilung** zu a, b , wobei

$$B(a,b) := \int_0^1 s^{a-1} (1-s)^{b-1} ds.$$

Lemma 3.0.3 ($X \sim \mathcal{N}(0, 1) \implies X^2 \sim \Gamma_{\frac{1}{2}, \frac{1}{2}}$)

Ist $X \mathcal{N}(0, 1)$ -verteilt, so ist $X^2 \Gamma_{\frac{1}{2}, \frac{1}{2}}$ -verteilt.

Beweis. Seien $\varphi_{0,1}(x) := \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$ für $x \in \mathbb{R}$ die Dichte von X und $T: (0, \infty) \rightarrow (0, \infty)$, $x \mapsto x^2$ ein Diffeomorphismus. Also hat $|X|$ auf $(0, \infty)$ die Dichte $2\varphi_{0,1}$. Nach dem **Transformationssatz** hat $X^2 = T(|X|)$ die Dichte

$$\begin{aligned} \rho_T(y) &= 2\varphi_{0,1}(T^{-1}(y)) \left| \frac{d}{dy} T^{-1}(y) \right| = 2\varphi_{0,1}(\sqrt{y}) \left| \frac{d}{dy} \sqrt{y} \right| \\ &= 2\varphi_{0,1}(\sqrt{y}) \left| \frac{1}{2\sqrt{y}} \right| = \frac{1}{\sqrt{y}} \varphi_{0,1}(\sqrt{y}) = \frac{1}{\sqrt{2\pi}} y^{-\frac{1}{2}} e^{-\frac{1}{2}y}, \end{aligned}$$

und das ist die Dichte einer $\Gamma_{\frac{1}{2}, \frac{1}{2}}$ -Verteilung. \square

Lemma 3.0.4 ($X \sim \Gamma_{\alpha,r}, Y \sim \Gamma_{\alpha,s} \implies X+Y \sim \Gamma_{\alpha,r+s}, \frac{X}{X+Y} \sim \mathcal{B}_{r,s}$)

Sind $\alpha, r, s > 0$ sowie X und Y unabhängig mit den Verteilungen $\Gamma_{\alpha,r}$ und $\Gamma_{\alpha,s}$, so sind $X+Y$ und $\frac{X}{X+Y}$ unabhängig mit den Verteilungen $\Gamma_{\alpha,r+s}$ resp. $\mathcal{B}_{r,s}$.

Gammaverteilung




Abb. 8: Die Dichte $\gamma_{a,r}$ für verschiedene $a, r > 0$. Von Sinner1 - Eigenes Werk, CC BY-SA 3.0, <https://commons.wikimedia.org/w/index.php?curid=3546723>.

Betaverteilung




Abb. 9: Die Dichte $\beta_{a,b}$ für verschiedene $a, b > 0$.

Beweis. Die gemeinsame Verteilung von X und Y auf $(0, \infty)^2$ hat die Dichte

$$\rho(x, y) = \gamma_{\alpha, r}(x) \gamma_{\alpha, s}(y) = \frac{\alpha^{r+s}}{\Gamma(r)\Gamma(s)} x^{r-1} y^{s-1} e^{-\alpha(x+y)}.$$

Wir definieren die Transformation $T(x, y) := \left(x + y, \frac{x}{x+y}\right)$ für $x, y > 0$. Dann ist T ein Diffeomorphismus von $(0, \infty)^2$ nach $(0, \infty) \times (0, 1)$, denn die Abbildung ist offensichtlich glatt und das Gleichungssystem $x + y = u$ und $\frac{x}{x+y} = v$ für $u \in (0, \infty)$ und $v \in (0, 1)$ eindeutig lösbar: $x = uv$ und $y = u(1-v)$ und somit $T^{-1}(u, v) = (uv, u(1-v))$ (offensichtlich glatt).

Es gilt

$$DT^{-1}(u, v) = \begin{pmatrix} v & u \\ 1-v & -u \end{pmatrix}$$

und somit $\det(DT^{-1}(u, v)) = -uv - (1-v)u = -u$.

Also ist die Dichte von $\left(X + Y, \frac{X}{X+Y}\right) = T(X, Y)$

$$\begin{aligned} \rho(u, v) &= \rho(T^{-1}(u, v)) |\det(DT^{-1}(u, v))| = \rho(uv, u(1-v)) u \\ &= \frac{\alpha^{r+s}}{\Gamma(r)\Gamma(s)} (uv)^{r-1} (u(1-v))^{s-1} e^{-\alpha(uv+u(1-v))} u \\ &= \frac{\alpha^{r+s}}{\Gamma(r)} u^{r+s-1} e^{-\alpha u} \frac{1}{\Gamma(s)} v^{s-1} (1-v)^{s-1} = \gamma_{\alpha, r+s}(u) \beta_{r,s}(v). \end{aligned}$$

Somit sind $X + Y$ und $\frac{X}{X+Y}$ unabhängig verteilt mit den entsprechenden Verteilungen. \square

Korollar 3.0.5

Für $\alpha, r, s > 0$ gilt $\gamma_{\alpha, r} * \gamma_{\alpha, s} = \gamma_{\alpha, r+s}$.

Korollar 3.0.6 (Summe quadrierter Normalverteilungen)

Sind X_1, \dots, X_n unabhängig $\mathcal{N}(0, 1)$ -verteilt, so ist $\sum_{k=1}^n X_k^2 \sim \Gamma\left(\frac{1}{2}, \frac{n}{2}\right)$ -verteilt.

DEFINITION 3.0.7 (χ^2 -VERTEILUNG)

Die χ_n^2 -Verteilung (mit n Freiheiten) ist die $\Gamma\left(\frac{1}{2}, \frac{n}{2}\right)$ -Verteilung.

χ_n^2 -Verteilung

Bemerkung 3.0.8 Die χ_n^2 -Verteilung hat die Dichte $\frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} x^{\frac{n}{2}-1} e^{-\frac{1}{2}x}$ für $x > 0$. \circ

09.06.2022

SATZ 3.0.1: FISHER-VERTEILUNG

Seien X_1, \dots, X_m sowie Y_1, \dots, Y_n unabhängig $\mathcal{N}(0, 1)$ -verteilt. Dann hat die Zufallsvariable $F_{m,n} := \frac{\frac{1}{m} \sum_{k=1}^m X_k^2 / \frac{1}{n} \sum_{j=1}^n Y_j^2}{1}$ die Dichte

$$f_{m,n}(x) := \frac{m^{\frac{m}{2}} n^{\frac{n}{2}}}{B\left(\frac{m}{2}, \frac{n}{2}\right)} \frac{x^{\frac{m}{2}-1}}{(n+mx)^{\frac{m+n}{2}}}, \quad x > 0.$$




Abb. 10: Die Dichte der FISHER-Verteilung für verschiedene $m, n \in \mathbb{N}$.
Von Caustic, CC BY-SA 3.0, <https://commons.wikimedia.org/w/index.php?curid=3757043>.

Beweis. Nach Korollar 3.0.6 ist die Zufallsvariable $X := \sum_{k=1}^m X_k^2$ $\Gamma_{\frac{1}{2}, \frac{m}{2}}$ -verteilt und die Zufallsvariable $Y := \sum_{j=1}^n Y_j^2$ $\Gamma_{\frac{1}{2}, \frac{n}{2}}$ -verteilt. Weiter sind X und Y unabhängig. Nach Lemma 3.0.4 ist $Z := \frac{X}{X+Y}$ $\mathcal{B}_{\frac{m}{2}, \frac{n}{2}}$ -verteilt. Es ist

$$F_{m,n} = \frac{n}{m} \frac{X}{Y} = \frac{n}{m} \frac{Z}{1-Z} =: T(Z),$$

wobei $T: (0, 1) \rightarrow (0, \infty)$, $z \mapsto \frac{n}{m} \frac{z}{1-z}$ (strikt monoton wachsend und somit) ein Diffeomorphismus mit $T^{-1}(y) = \frac{my}{n+my}$ für $y > 0$ ist. Also hat $F_{m,n}$ die Dichte von

$$\beta_{\frac{m}{2}, \frac{n}{2}}(T^{-1}(y)) \cdot \frac{mn}{(n+my)^2} = f_{m,n}(y), \quad y > 0,$$

wobei $\frac{mn}{(n+my)^2}$ die Funktionaldeterminante ist. \square

DEFINITION 3.0.9 (FISHER-VERTEILUNG)

Die Verteilung $\mathcal{F}_{m,n}$ von $F_{m,n}$ heißt **FISHER-Verteilung** mit m und n Freiheitsgraden.

FISHER-
Verteilung

Bemerkung 3.0.10 Es gilt $\mathcal{F}_{m,n} = \mathcal{B}_{m,n} \circ T^{-1}$ (FISHER-Verteilung ist Bildmaß der Beta-Verteilung unter T), wobei T wie oben ist. \circ

Korollar 3.0.11


Seien X, Y_1, \dots, Y_n unabhängig $\mathcal{N}(0, 1)$ -verteilt. Dann hat die Zufallsvariable $Z := \frac{X}{\sqrt{\frac{1}{n} \sum_{j=1}^n Y_j^2}}$ die Dichte

$$\tau_n(x) = \frac{1}{\sqrt{n} B(\frac{1}{2}, \frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad x \in \mathbb{R}.$$

Beweis. Nach Satz 3.0.1 hat Z^2 die Dichte $f_{1,n}(x)$ für $x > 0$. Nach dem Transformationssatz (mit $\Phi: (0, \infty) \rightarrow (0, \infty)$, $z \mapsto \sqrt{z}$ und $(\Phi^{-1})'(z) = \frac{1}{2\sqrt{z}}$) hat $|Z|$ die Dichte $f_{1,n}(y^2) \cdot 2y$ für $y > 0$. Aufgrund der Symmetrie hat Z die Dichte $f_{1,n}(y^2)|y|$ für $y \in \mathbb{R}$. \square

DEFINITION 3.0.12 (STUDENT t -VERTEILUNG)

Das Wahrscheinlichkeitsmaß t_n auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit Dichte τ_n heißt **STUDENT t -Verteilung** mit n Freiheitsgraden.



Bemerkung 3.0.13 Im Moment ist unklar, ob die Verteilung mit der in Kapitel zwei definierten übereinstimmt. \circ

Bemerkung 3.0.14 Die Funktion $\tau_1(x) := \frac{1}{\pi} \frac{1}{1+x^2}$ für $x \in \mathbb{R}$ ist die Dichte der **Standard-CAUCHY-Verteilung**. \circ

Bemerkung 3.0.15 ($\lim_{n \rightarrow \infty} t_n$) Für $n \rightarrow \infty$ konvergiert die t_n -Verteilung schwach gegen $\mathcal{N}(0, 1)$, was aus Anwendung des schwachen Gesetzes der großen Zahlen auf den Nenner oder aus der gleichmäßigen Konvergenz der Dichten folgt. \circ

SATZ 3.0.2: STUDENT (1908) [2, SATZ 9.17]

Im Modell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m,v}^{\otimes n})_{m \in \mathbb{R}, v > 0})$ für $n \geq 2$ gilt für $\vartheta := (m, v) \in \mathbb{R} \times (0, \infty) =: \Theta$ bezüglich $\mathbb{P}_{\vartheta} := \mathcal{N}_{m,v}^{\otimes n}$ für den empirischen Mittelwert $M(X) := \frac{1}{n} \sum_{k=1}^n X_k$ sowie die korrigierte empirische Varianz $V^*(X) := \frac{1}{n-1} \sum_{j=1}^n (X_j - M(X))^2$

Abb. 11: Die Dichte der t_{ν} -Verteilung für verschiedene ν . Von Skbkekas - Eigenes Werk, CC BY 3.0, <https://commons.wikimedia.org/w/index.php?curid=9546828>.

- ① M und V^* sind unabhängig.
- ② M ist $\mathcal{N}\left(m, \frac{v}{n}\right)$ -verteilt und $\frac{n-1}{v}V^*$ ist χ_{n-1}^2 -verteilt.
- ③ $T_m := \sqrt{\frac{n}{V^*}}(M - m)$ ist t_{n-1} -verteilt (hier ist der Zusammenhang mit Kapitel zwei).

Beweis. Ohne Beschränkung der Allgemeinheit seien $m = 0$ und $v = 1$, andernfalls können wir X_k durch $Y_k := \frac{1}{\sqrt{v}}(X_k - m)$ ersetzen und beachten, dass sich m in der Definition von V^* weghebt (d.h. $M(Y) = \frac{1}{\sqrt{v}}(M(X) - m)$, $V^*(Y) = \frac{1}{v}V^*(X)$), und dass sich \sqrt{v} in der Definition von T_m wegekürzt (d.h. $T_m(Y) = T_m(X)$).

- ① Sei C eine orthogonale $n \times n$ -Matrix mit erster Zeile $\frac{1}{\sqrt{n}}(1, \dots, 1)$. Dann gilt $C \cdot (1, \dots, 1)^T = (\sqrt{n}, 0, \dots, 0)^T$. Sei nun $Y := CX$, wobei $X \in \mathbb{R}^n$ $\mathcal{N}(0, I_n)$ -verteilt ist. Dann ist (cf. [4]) Y auch $\mathcal{N}(0, I_n)$ -verteilt. Insbesondere sind die Komponenten Y_1, \dots, Y_n unabhängig $\mathcal{N}(0, 1)$ -verteilt. Es gilt $M(X) = \frac{1}{\sqrt{n}} \sum_{k=1}^n \frac{1}{\sqrt{n}} X_k = \frac{1}{\sqrt{n}} Y_1$ und somit

$$\begin{aligned}
 (n-1)V^*(X) &= \sum_{k=1}^n (X_k - M(X))^2 = \sum_{k=1}^n X_k^2 - 2M(X)X_k + M(X)^2 \\
 &= \sum_{k=1}^n X_k^2 + nM(X)^2 - 2M(X) \sum_{k=1}^n X_k = \sum_{k=1}^n X_k^2 - nM(X)^2 \quad (32) \\
 &= \sum_{j=1}^n Y_j^2 - Y_1^2 = \sum_{j=2}^n Y_j^2,
 \end{aligned}$$

da $\sum_{k=1}^n X_k^2 = \|X\|_2^2 = \|CX\|_2^2 = \|Y\|_2^2 = \sum_{k=1}^n Y_k^2$ wegen der Orthogonalität von C gilt. Also folgt die Unabhängigkeit.

- ② Der erste Teil ist klar und der zweite folgt aus (32).

- ③ Es gilt

$$\sqrt{\frac{n}{V^*}}(M - m) = \frac{\sqrt{\frac{n}{v}}(M - m)}{\sqrt{\frac{1}{n-1} \frac{n-1}{v} V^*}} \stackrel{\text{①}}{\sim} \frac{\mathcal{N}(0, 1)}{\sqrt{\frac{1}{n-1} \chi_{n-1}^2}} \stackrel{\text{Def. 3.0.12}}{=} t_{n-1}.$$

□

4 Hypothesentests

4.1 Grundlagen

DEFINITION 4.1.1 (TEST, NULLHYPOTHESE, ALTERNATIVE, GÜTEFUNKTION)

Seien $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell und $\Theta = \Theta_0 \sqcup \Theta_1$ mit $\Theta_0 \neq \emptyset \neq \Theta_1$. Wir bezeichnen Θ_0 als **Nullhypothese** und Θ_1 als **Alternative**.

- Eine Statistik $\varphi: \mathfrak{X} \rightarrow [0, 1]$ heißt **Test von Θ_0 gegen Θ_1** und **nicht-randomisiert**, wenn $\varphi(\mathfrak{X}) \subset \{0, 1\}$ und sonst **randomisiert**. Ist φ nicht-randomisiert, heißt die Menge $\{x \in \mathfrak{X} : \varphi(x) = 1\}$ **Ablehnungsbereich** (oder Verwerfungsbereich) der Nullhypothese.
- Ferner heißt $\sup_{\vartheta \in \Theta_0} \mathbb{E}_\vartheta[\varphi]$ **Fehler erster Art** von φ und φ heißt (zufälliger) **Test zum (Irrtums)niveau $\alpha \in (0, 1)$** , wenn $\sup_{\vartheta \in \Theta_0} \mathbb{E}_\vartheta[\varphi] \leq \alpha$.
- Die **Gütefunktion** des Tests φ ist $G_\varphi: \Theta \rightarrow [0, 1]$, $\vartheta \mapsto \mathbb{E}_\vartheta[\varphi]$. Für $\vartheta \in \Theta_1$ heißt $G_\varphi(\vartheta)$ (die Wahrscheinlichkeit, die Alternative zu akzeptieren) **Macht von φ** an der Stelle ϑ und $\beta_\varphi(\vartheta) := 1 - G_\varphi(\vartheta)$ **Fehler zweiter Art** an der Stelle $\vartheta \in \Theta_1$.

Nullhypothese

Test

Ablehnungsbe-

reich
Fehler erster Art

Gütefunktion

Fehler zweiter
Art

14.06.2022

Bemerkung 4.1.2 Ist $\varphi(x) = 1$, so heißt das, dass die **Alternative** akzeptiert wird und $\varphi(x) = 0$ heißt, dass die „Nullhypothese akzeptiert wird“ (besser: die Nullhypothese wird nicht verworfen). Ist $\varphi(x) = 0$ (und der **Test** noch so gut und n sehr groß) sollte man *nicht* sagen „die Nullhypothese ist mit großer Sicherheit korrekt“.

Ist $\varphi(x) \in (0, 1)$, so heißt das, dass man sich mit Wahrscheinlichkeit $\varphi(x)$ für die **Alternative** entscheidet. ○

In vielen Fällen besteht Θ_0 nur aus einem Element (z.B. „Ein Würfel ist fair“). Oft konstruiert man zu einem gegebenen Irrtumsniveau einen **Test** und wählt dann (wenn möglich) den mit der größten **Macht**.

Bemerkung 4.1.3 Oft entspricht Θ_0 dem „Normalfall“ und Θ_1 einer ungewöhnlichen Abweichung. ○

Bemerkung 4.1.4 (Tests als Schätzer) Einen nicht-randomisierten **Test** φ kann man als Schätzer für die Kenngröße $\tau := \mathbb{1}_{\Theta_1}$ auf Θ interpretieren. ○

Beispiel 4.1.5 (Ist ein Würfel fair?)

Ein Würfel wir n mal unabhängig geworfen. Wir wollen herausfinden, ob er fair ist. Seien dafür $\mathfrak{X} := \{1, \dots, 6\}^n$, $\mathcal{F} := \mathcal{P}(\mathfrak{X})$ und Θ die Menge aller Wahrscheinlichkeitsmaße auf $\{1, \dots, 6\}$. (Wir identifizieren diese Maße mit ihren Zähldichten.) Seien $\vartheta_0 := \frac{1}{6}(1, \dots, 1)$, und $\Theta_0 := \{\vartheta_0\}$ sowie $\Theta_1 := \Theta \setminus \Theta_0$ und $\mathbb{P}_\vartheta := \vartheta^{\otimes n}$.

Ein „vernünftiger“ **Test** φ sieht so aus: wir setzen $\varphi(x) = 1$ wenn die relativen Häufigkeiten, mit denen $1, \dots, 6$ auftreten, nicht nahe bei ϑ_0 liegen, und $\varphi(x) = 0$ sonst. ◇

Bemerkung 4.1.6 Man muss immer das Modell sowie α und φ festlegen, *bevor* man Beobachtungen durchführt. ○

Ist dieser Schätzer erwartungstreu?

Beispiel 4.1.7 (Qualitätskontrolle (cf. [2, (10.1)]))

Es werden $N := 10.000$ Orangen an einen Händler geliefert, welcher die Lieferung nur akzeptiert, wenn höchstens fünf Prozent der Orangen faul sind. Der Händler entnimmt eine Stichprobe mit $n := 50$ Orangen, von welchen $x \in \{0, \dots, n\}$ faul sind.

Wir wählen $\mathfrak{X} := \{0, \dots, n\}$, $\Theta := \{0, \dots, N\}$, $\Theta_0 := \{0, \dots, \frac{1}{20}N\}$, $\Theta_1 := \{\frac{1}{20}N + 1, \dots, N\}$ und

$$\mathbb{P}_\vartheta(x) = \frac{\binom{\vartheta}{x} \binom{N-\vartheta}{n-x}}{\binom{N}{n}}.$$

Es ist naheliegend, die Nullhypothese abzulehnen, wenn mehr als $c \in \mathbb{N}_0$ Orangen in der Stichprobe faul sind und sonst nicht abzulehnen.

Der Händler wählt c so, dass der Fehler erster Art höchstens α ist. \diamond

Beispiel 4.1.8 (Münzwurf-Glücksspieler)

Einem Glücksspieler wird vorgeworfen beim Münzspiel zu betrügen und anstatt einer fairen Münze eine Münze mit Erfolgswahrscheinlichkeit $p = 0.75$ zu verwenden. Diese Anschuldigung soll nun mit n Münzwürfen überprüft werden. \diamond

Allgemein	Beispiel (Münzwurf-Glücksspieler)
Statistisches Modell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$	$\mathfrak{X} = \{0, \dots, n\}$, $\mathcal{F} = \mathbb{P}(\mathfrak{X})$, $\Theta = \{\frac{1}{2}, \frac{3}{4}\}$, $\mathbb{P}_\vartheta(\{k\}) = \binom{n}{k} \vartheta^k (1 - \vartheta)^{n-k}$
Nullhypothese und Alternative: Zerlege $\Theta = \Theta_0 \sqcup \Theta_1$. Nullhypothese: $H_0 : \vartheta \in \Theta_0$. Bedeutung: Der Parameter ϑ ist für mich akzeptabel. Wir sind im (gewünschten) Normalfall. Alternative: $H_1 : \vartheta \in \Theta_1$. Bedeutung: Der Parameter ϑ ist für mich problematisch. Es liegt eine Abweichung vom Normalfall vor.	Wir wählen die Zerlegung nach dem Prinzip „im Zweifel für den Angeklagten“. Der Normalfall ist hier, das kein Betrug begangen wurde, das heißt $\Theta_0 := \{\frac{1}{2}\}$ und $\Theta_1 := \{\frac{3}{4}\}$. Nullhypothese: $\vartheta = \frac{1}{2}$. Der Spieler hat nicht betrogen und mit fairer Münze gespielt. Alternative: $\vartheta = \frac{3}{4}$. Der Spieler hat betrogen.
Fehlerarten. <i>Fehler erster Art (gravierender / peinlicher Fehler):</i> Entscheidung für Alternative, obwohl Nullhypothese stimmt. <i>Fehler zweiter Art:</i> Entscheidung für Nullhypothese obwohl die Alternative stimmt.	<i>Fehler erster Art:</i> Der Spieler wird wegen Betrugs bestraft, obwohl er unschuldig ist. <i>Fehler zweiter Art:</i> Der Spieler wird nicht bestraft, obwohl er betrogen hat.
Entscheidungsregel: Test $\varphi : \mathfrak{X} \rightarrow [0, 1]$. Bei Beobachtung $x \in \mathfrak{X}$ entscheidet man nach folgender Regel: ist $\varphi(x) = 0$, wählt man die Nullhypothese, ist $\varphi(x) = 1$, die Alternative und ist $\varphi(x) \in (0, 1)$ wählen wir mit Wahrscheinlichkeit $\varphi(x)$ die Alternative.	Wähle einen Schwellenwert $c \in \mathfrak{X}$ und setze $\varphi(x) := \mathbb{1}_{x > c}$. Der Spieler wird nicht bestraft, wenn weniger als c von n Würfeln erfolgreich sind, aber bestraft wenn dem nicht so ist. Hierbei hängen c und $\varphi(x)$ vom Irrtumsniveau ab.

Tabelle 2: Aufbau eines Hypothesentests.

DEFINITION 4.1.9 (BESTER TEST)

Ein Test φ von Θ_0 gegen Θ_1 heißt (gleichmäßig) **bester Test** (engl.: UMP - *uniformly most powerful*) **zum Niveau α** , wenn der Fehler erster Art höchstens α ist und für jeden Test ψ mit Niveau α gilt:

$$G_\varphi(\vartheta) \geq G_\psi(\vartheta) \quad \forall \vartheta \in \Theta_1$$

bester Test

DEFINITION 4.1.10 (UNVERFÄLSCHTER TEST)

Ein Test φ heißt **unverfälscht zum Niveau α** , wenn $G_\varphi(\vartheta_0) \leq \alpha \leq G_\varphi(\vartheta_1)$ für alle $\vartheta_0 \in \Theta_0$ und $\vartheta_1 \in \Theta_1$.

unverfälscht

Bemerkung 4.1.11 (Beziehungen zwischen Tests und Konfidenzbereichen)

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein statistisches Modell. Ist $C: \mathfrak{X} \rightarrow \mathcal{P}(\Theta)$ ein Konfidenzbereich zum Irrtumsniveau $\alpha \in (0, 1)$ und $\vartheta_0 \in \Theta$, so ist $\{x \in \mathfrak{X} : \vartheta_0 \notin C(x)\}$ der Ablehnungsbereich eines Test von $H_0 : \vartheta = \vartheta_0$ gegen $H_1 : \vartheta \neq \vartheta_0$ zum Niveau α . Ist umgekehrt für jedes $\vartheta_0 \in \Theta$ ein nicht-randomisierter Test für $H_0 : \vartheta = \vartheta_0$ gegen $H_1 : \vartheta \neq \vartheta_0$ zum Niveau α gegeben, so lässt sich daraus ein Konfidenzbereich zum Irrtumsniveau α gewinnen (HA 9.1, [2, Aufg. 10.1]).◦

4.2 | Neyman-Pearson-Lemma

DEFINITION 4.2.1 (NEYMAN-PEARSON TEST)

Seien $\Theta := \{0, 1\}$ mit $\Theta_k := \{k\}$ für $k \in \{0, 1\}$ sowie \mathbb{P}_0 und \mathbb{P}_1 Wahrscheinlichkeitsmaße auf $(\mathfrak{X}, \mathcal{F})$ mit $\mathbb{P}_0 \neq \mathbb{P}_1$. Seien μ ein σ -endliches Maß auf $(\mathfrak{X}, \mathcal{F})$ mit $\mathbb{P}_0, \mathbb{P}_1 \ll \mu$ (z.B. $\mu = \frac{1}{2}(\mathbb{P}_0 + \mathbb{P}_1)$) und ρ die zugehörigen Likelihoodfunktion sowie

$$R(x) := \begin{cases} \frac{\rho(x, 1)}{\rho(x, 0)}, & \text{wenn } \rho(x, 0) > 0, \\ \infty, & \text{sonst} \end{cases}$$

der **Likelihood-Quotient**.

Ein Test φ ist ein NEYMAN-PEARSON Test (NPT), wenn ein $c \in [0, \infty)$ existiert mit

$$\varphi(x) \begin{cases} = 1, & R(x) > c, \\ = 0, & R(x) < c, \\ \in [0, 1], & R(x) = c. \end{cases}$$

Likelihood-
Quotient

SATZ 4.2.1: NEYMAN-PEARSON LEMMA (1932)

Sei $\alpha \in (0, 1)$.

- ① Es existiert ein NEYMAN-PEARSON Test φ mit $\mathbb{E}_0[\varphi] = \alpha$.
- ② Jeder NEYMAN-PEARSON Test mit $\mathbb{E}_0[\varphi] = \alpha$ ist ein bester Test zum Niveau α .

Je größer $R(x)$ ist, desto eher wird man sich für die Alternative \mathbb{P}_1 entscheiden.

Beweis. ① Wähle ein $c \in [0, \infty)$, sodass $\mathbb{P}_0[R(x) > c] \leq \alpha$ und $\mathbb{P}_0[R(x) \geq c] \geq \alpha$. Dann ist c das α -Fraktil von $\mathbb{P}_0 \circ R^{-1}$. Dieses c existiert, denn unter der Nullhypothese ist $\rho(x, 0)$ fast sicher positiv, das heißt $\rho(x, 0) > 0$ gilt \mathbb{P}_0 -fast sicher.

Fall 1: $\mathbb{P}_0[R(x) = c] = 0$. Dann folgt $\mathbb{P}_0[R(x) > c] = \alpha$ und für $\varphi := \mathbb{1}_{\{R > c\}}$ ist ein NEYMAN-PEARSON Test.

Fall 2: $\mathbb{P}_0[R(x) = c] > 0$. Dann gilt $\gamma := \frac{\alpha - \mathbb{P}_0[R(x) > c]}{\mathbb{P}_0[R(x) = c]} \in (0, 1]$, da $\mathbb{P}_0[R(x) > c] + \mathbb{P}_0[R(x) = c] = \mathbb{P}_0[R(x) \geq c] \geq \alpha$. Wir definieren

$$\varphi(x) := \begin{cases} 1, & R(x) > c, \\ 0, & R(x) < c, \\ \gamma, & R(x) = c. \end{cases}$$

Dann ist φ ein NEYMAN-PEARSON Test und $\mathbb{E}_0[\varphi] = 1 \cdot \mathbb{P}_0[R(X) > c] + \gamma \cdot \mathbb{P}_0[R(X) = c] = \alpha$.

- ② Sei φ ein NEYMAN-PEARSON Test mit $\mathbb{E}_0[\varphi] = \alpha$ mit Schwellenwert $c \in [0, \infty)$ und ψ

ein beliebiger Test zum Niveau α . Dann gilt

$$\begin{aligned}\mathbb{E}_1[\varphi] - \mathbb{E}_1[\psi] &= \int_{\mathfrak{X}} \varphi(x) d\mathbb{P}_1(x) - \int_{\mathfrak{X}} \psi(x) d\mathbb{P}_1(x) \\ &= \int_{\mathfrak{X}} \varphi(x) - \psi(x) d\mathbb{P}_1(x) = \int_{\mathfrak{X}} (\varphi(x) - \psi(x)) \rho(x, 1) d\mu(x).\end{aligned}$$

Gilt $\varphi(x) - \psi(x) > 0$ für ein $x \in \mathfrak{X}$, dann ist $\varphi(x) > 0$ und somit $R(x) \geq c$, also $\rho(x, 1) \geq c\rho(x, 0)$ (auch wenn $R(x) = \infty$). Ist $\varphi(x) - \psi(x) < 0$ für $x \in \mathfrak{X}$, dann ist $\varphi(x) < 1$ und somit $R(x) \leq c$, also $\rho(x, 1) \leq c\rho(x, 0)$.

Also folgt

$$\begin{aligned}\int_{\mathfrak{X}} (\varphi(x) - \psi(x)) \rho(x, 1) d\mu(x) &\geq c \int_{\mathfrak{X}} (\varphi(x) - \psi(x)) \rho(x, 0) d\mu(x) \\ &= \underbrace{c}_{\geq 0} \underbrace{(\underbrace{\mathbb{E}_0[\varphi]}_{=\alpha} - \underbrace{\mathbb{E}_0[\psi]}_{\leq \alpha})}_{\geq 0} \geq 0.\end{aligned}$$

□

Beispiel 4.2.2 (Münzwurf-Glücksspieler)

15.06.2022

Die Dichte bezüglich des Zählmaßes auf $\{0, \dots, n\}$ ist $\rho(x, \vartheta) = \binom{n}{x} \vartheta^x (1 - \vartheta)^{n-x}$. Dann ist

$$R(x) = \frac{\rho(x, \frac{3}{4})}{\rho(x, \frac{1}{2})} = \frac{\binom{n}{x} 3^x \frac{1}{4^n}}{\binom{n}{x} \frac{1}{2^n}} = 3^x 2^{-n}.$$

Für $n = 10$ wollen wir den besten Test zum Niveau $\alpha = \frac{1}{100}$ bestimmen.

Für $c \in [0, \infty)$ gilt

$$\mathbb{P}_0[R(x) > c] = \mathbb{P}_0[3^x 2^{-10} > c] = \mathbb{P}_0[3^x > 2^{10} c] = \mathbb{P}_0\left[x > \frac{1}{\ln(3)} \ln(2^{10} c)\right].$$

Wir wählen also c so, dass $\frac{1}{\ln(3)} \ln(2^{10} c)$ ein α -Fraktil von \mathbb{P}_0 ist.

Es gilt

$$\mathbb{P}_0(X = k) = \binom{10}{k} 2^{-10}$$

und somit

$$\mathbb{P}_0(X = 10) = \frac{1}{1024} \approx 0.001 \quad \text{und} \quad \mathbb{P}_0(X = 9) = \frac{5}{512} \approx 0.010$$

und daher $\mathbb{P}_0(X \in \{9, 10\}) \approx 0.011$. Somit ist 9 das α -Fraktil von \mathbb{P}_0 (das heißt $\mathbb{P}_0(X > 9) < \alpha < \mathbb{P}_0(X \geq 9)$). Wir wählen $c \in [0, \infty)$, sodass $\frac{1}{\ln(3)} \ln(2^{10} c) = 9$ ist (das heißt $c = 2^{-10} 3^9 = \frac{19683}{1024} \approx 19.2$) und

$$\gamma = \frac{\alpha - \mathbb{P}_0(R > c)}{\mathbb{P}_0(R = c)} = \frac{\alpha - \mathbb{P}_0(X > 9)}{\mathbb{P}_0(X = 9)} = \frac{\frac{1}{100} - \frac{5}{512}}{\frac{1}{1024}} = \frac{6}{25}.$$

Somit ist der beste Test

$$\varphi(x) = \begin{cases} 1, & \text{wenn } R(x) > c, \\ \frac{6}{25}, & \text{wenn } R(x) = c, \\ 0, & \text{wenn } R(x) < c, \end{cases} = \begin{cases} 1, & \text{wenn } X > 9, \\ \frac{6}{25}, & \text{wenn } X = 9, \\ 0, & \text{wenn } X < 9, \end{cases}$$

◇

16.06.2022

SATZ 4.2.2: LEMMA VON STEIN (1952)

Im unendlichen Produktmodell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \{0,1\}}) = (E^{\mathbb{N}}, \mathfrak{E}^{\otimes n}, (Q_\vartheta^{\otimes n})_{\vartheta \in \{0,1\}})$ mit $Q_0 \neq Q_1$ betrachten wir für jedes $n \in \mathbb{N}$ den NEYMAN-PEARSON Test φ_n mit $\mathbb{E}_0[\varphi_n] = \alpha$, wobei $\alpha \in (0, 1)$ fest ist. Dann gilt

$$\lim_{n \rightarrow \infty} \frac{1}{n} \ln(1 - \mathbb{E}_1[\varphi_n]) = -H(Q_0, Q_1)$$

Insbesondere konvergiert $\mathbb{E}_1[\varphi_n]$ exponentiell gegen 1.

Beweis. Siehe [2, 10.4]. □

Wir sehen nun, dass die obigen Aussage nicht mehr richtig ist, wenn wir zweiseitige Testprobleme betrachten (und dafür brauchen wir mindestens drei Wahrscheinlichkeitsmaße).

Beispiel 4.2.3 (Münzwurf)

Seien $\Theta = \{\frac{1}{4}, \frac{1}{2}, \frac{3}{4}\}$, $\mathfrak{X} = \{0, 1\}$ und $\mathbb{P}_\vartheta(\{1\}) = \vartheta$ sowie $\mathbb{P}_\vartheta(\{0\}) = 1 - \vartheta$.

Fall (a): $\Theta_0 = \{\frac{1}{4}\}$ und $\Theta_1 := \{\frac{1}{4}, \frac{3}{4}\}$. Wir zeigen, dass es *keinen* besten Test zum Niveau $\alpha \in (0, 1)$ gibt. Sei $\varphi: \mathfrak{X} \rightarrow [0, 1]$ ein Test zum Niveau α . Dann gilt $\alpha \geq \mathbb{E}_0[\varphi] = \frac{1}{2}\varphi(0) + \frac{1}{2}\varphi(1)$. Ohne Beschränkung der Allgemeinheit sei $\varphi(1) \geq \varphi(0)$. Wenn φ ein bester Test zum Niveau α ist, dann wähle $\psi: \mathfrak{X} \rightarrow [0, 1]$ mit $\psi(0) > \psi(1)$ und $\psi(0) + \psi(1) = 2\alpha$. Es folgt

$$G_\psi\left(\frac{1}{4}\right) = \mathbb{E}_{\frac{1}{4}}[\psi] = \frac{1}{4}\psi(1) + \frac{3}{4}\psi(0) = \underbrace{\frac{1}{4}(\psi(1) + \psi(0))}_{=\frac{\alpha}{2}} + \underbrace{\frac{1}{2}\psi(0)}_{>\frac{\alpha}{2}} > \alpha$$

sowie

$$G_\varphi\left(\frac{1}{4}\right) = \mathbb{E}_{\frac{1}{4}}[\varphi] = \frac{1}{4}\varphi(1) + \frac{3}{4}\varphi(0) = \underbrace{\frac{1}{4}(\varphi(1) + \varphi(0))}_{\leq \frac{\alpha}{2}} + \underbrace{\frac{1}{2}\varphi(0)}_{\leq \frac{\alpha}{2}} \leq \alpha.$$

Es folgt $G_\varphi(\frac{1}{4}) < G_\psi(\frac{1}{4})$, es gibt also keinen besten Test.

Fall (b): $\Theta_0 = \{\frac{1}{4}\}$ und $\Theta_1 := \{\frac{1}{2}, \frac{3}{4}\}$. Sei φ ein Test mit $\mathbb{E}_{\frac{1}{4}}[\varphi] = \frac{1}{4}\varphi(1) + \frac{3}{4}\varphi(0) = \alpha$. Wähle $\varphi(1)$ maximal unter den Nebenbedingungen $\frac{1}{4}\varphi(1) + \frac{3}{4}\varphi(0) = \alpha$ und $\varphi(1), \varphi(0) \in [0, 1]$.

Wir zeigen, dass φ ein bester Test ist. Für $p \in [\frac{1}{4}, 1]$ (insbesondere für $p \in \{\frac{1}{2}, \frac{3}{4}\}$) gilt für jeden Test ψ zum Niveau α

$$\begin{aligned} \mathbb{E}_p[\varphi] &= p \cdot \varphi(1) + (1-p)\varphi(0) = p(4\alpha - 3\varphi(0)) + (1-p)\varphi(0) \\ &= 4\alpha p + (1-4p)\varphi(0) \geq 4\alpha p + \underbrace{(1-4p)\varphi(0)}_{\leq 0} \geq \mathbb{E}_p[\psi]. \end{aligned}$$

Also ist φ ein bester Test. ◇

4.3 | Beste einseitige Tests

DEFINITION 4.3.1 (WACHSENDE LIKELIHOODQUOTIENTEN)

Ein Standardmodell $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ mit $\Theta \subset \mathbb{R}$ hat **wachsende Likelihoodquotienten** bezüglich einer Statistik $T: \mathfrak{X} \rightarrow \mathbb{R}$, wenn für alle $\vartheta_1 < \vartheta_2$ und $R_{\vartheta_2:\vartheta_1}(x) := \frac{\rho(x, \vartheta_2)}{\rho(x, \vartheta_1)}$ gilt, dass $R_{\vartheta_2:\vartheta_1}(x) = f_{\vartheta_2:\vartheta_1}(T(x))$ für eine streng wachsende Funktion $f_{\vartheta_2:\vartheta_1}: \mathbb{R} \rightarrow \mathbb{R}$ gilt.

wachsende Likelihoodquotienten

Beispiel 4.3.2 (Exponentielles Modell hat wachsende Likelihoodquotienten)

Jedes exponentielle Modell bezüglich T hat wachsende Likelihoodquotienten bezüglich T oder $-T$, denn

$$\begin{aligned} R_{\vartheta_2:\vartheta_1}(x) &= \frac{\rho(x, \vartheta_2)}{\rho(x, \vartheta_1)} = \frac{\exp(a(\vartheta_2)T(x) - b(\vartheta_2)) \underline{h(x)}}{\exp(a(\vartheta_1)T(x) - b(\vartheta_1)) \underline{h(x)}} \\ &= \exp((a(\vartheta_2) - a(\vartheta_1))T(x) + b(\vartheta_1) - b(\vartheta_2)). \end{aligned}$$

Also ist für $\vartheta_2 > \vartheta_1$ $R_{\vartheta_2:\vartheta_1} = f_{\vartheta_2:\vartheta_1}(T(x))$ mit $y \mapsto f_{\vartheta_2:\vartheta_1}(y)$ streng wachsend, wenn a streng wachsend ist. Ist a hingegen streng fallend, ersetze a durch $-a$ und T durch $-T$. \diamond

SATZ 4.3.1: WACHSENDE LIKELIHOODQUOTIENTEN $\implies \exists$ BESTER TEST FÜR EINSEITIGES TESTPROBLEM

Sei $(\mathfrak{X}, \mathcal{F}, (\mathbb{P}_\vartheta)_{\vartheta \in \Theta})$ ein Standardmodell mit $\Theta \subset \mathbb{R}$ und wachsenden Likelihoodquotienten. Dann existiert ein bester Test zum Niveau $\alpha \in (0, 1)$ für das einseitige Testproblem $H_0: \vartheta \leq \vartheta_0 \in \Theta$ gegen $H_1: \vartheta > \vartheta_0$. Dieser hat die Gestalt

$$\varphi(x) = \begin{cases} 1, & \text{wenn } T(x) > c, \\ \gamma, & \text{wenn } T(x) = c, \\ 0, & \text{wenn } T(x) < c, \end{cases}$$

wobei sich c und γ aus der Bedingung $G_\varphi(\vartheta_0) = \alpha$ ergeben. Die Gütefunktion von φ ist monoton **wachsend**.

Beweis. Sei $\alpha \in (0, 1)$. Dann lassen sich c und γ durch $\mathbb{E}_{\vartheta_0}[\varphi] = \mathbb{P}_{\vartheta_0}[T(x) > c] + \gamma \mathbb{P}_{\vartheta_0}(T(x) = c) \stackrel{!}{=} \alpha$ bestimmen.

Sei $\vartheta_1 > \vartheta_0$. Wir zeigen, dass φ ein NEYMAN-PEARSON Test zu ϑ_0 und ϑ_1 zum Niveau α und damit bester Test zwischen ϑ_0 und ϑ_1 ist. Da $R_{\vartheta_1:\vartheta_0}$ eine streng wachsende Funktion von $T(x)$ ist, gilt

$$\varphi(x) = \begin{cases} 1, & \text{wenn } R_{\vartheta_1:\vartheta_0} > f_{\vartheta_1:\vartheta_0}(c), \\ \gamma, & \text{wenn } R_{\vartheta_1:\vartheta_0} = f_{\vartheta_1:\vartheta_0}(c), \\ 0, & \text{wenn } R_{\vartheta_1:\vartheta_0} < f_{\vartheta_1:\vartheta_0}(c), \end{cases}$$

also ist φ ein NEYMAN-PEARSON Test.

Ebenso ist φ für das eben berechnete c und γ ein NEYMAN-PEARSON Test zwischen ϑ und $\bar{\vartheta}$ für $\vartheta < \bar{\vartheta}$ zum Niveau

$$\mathbb{E}_\vartheta[\varphi] = \mathbb{P}[T(x) > c] + \gamma \mathbb{P}_\vartheta[T(x) = c] =: \beta$$

Damit ist φ auch bester Test zwischen ϑ und $\bar{\vartheta}$, also insbesondere besser als der konstante Test $\psi \equiv \beta$ (welcher Niveau β hat). Also gilt

$$G_\varphi(\bar{\vartheta}) \geq G_\psi(\bar{\vartheta}) = \beta = G_\varphi(\vartheta)$$

und damit ist $\vartheta \mapsto G_\varphi(\vartheta)$ monoton wachsend. Weiter gilt

$$\sup_{\vartheta \leq \vartheta_0} \mathbb{E}_\vartheta[\varphi] = \sup_{\vartheta \leq \vartheta_0} G_\varphi(\vartheta) = G_\varphi(\vartheta_0) = \alpha,$$

also hat φ das Niveau α für H_0 gegen H_1 .

Sei nun ψ ein weiterer Test von H_0 gegen H_1 zum Niveau α und $\vartheta_1 > \vartheta_0$ beliebig. Dann ist ψ insbesondere ein Test von ϑ_0 gegen ϑ_1 zum Niveau α .

Da φ wie oben gezeigt in dieser Situation bester Test zum Niveau α ist, gilt insbesondere $\mathbb{E}_{\vartheta_1}[\varphi] \geq \mathbb{E}_{\vartheta_1}[\psi]$. Da $\vartheta_1 > \vartheta_0$ beliebig war, ist φ sogar bester Test von H_0 gegen H_1 zum Niveau α . \square

Bemerkung 4.3.3 Der Satz 4.3.1 gilt analog für $H_0 : \vartheta \geq \vartheta_0$ gegen $H_1 : \vartheta < \vartheta_0$. In diesem Fall muss $R_{\vartheta_2:\vartheta_1}$ streng monoton steigend in T für $\vartheta_2 < \vartheta_1$ sein. \circ

Beispiel 4.3.4 (Einseitiger GAUSS-Test mit bekanntem Erwartungswert)

Sei $(\mathbb{R}^n, \mathcal{B}(\mathbb{R})^{\otimes n}, (\mathcal{N}_{m,\vartheta}^{\otimes n})_{\vartheta>0})$ das GAUSS-Produktmodell mit bekanntem Mittelwert $m \in \mathbb{R}$. Seien $H_0 : \vartheta \geq \vartheta_0$ und $H_1 : \vartheta < \vartheta_0$. Dann ist die Likelihoodfunktion ρ_1 für $n = 1$

$$\rho_1(x, \vartheta) = \frac{1}{\sqrt{2\pi\vartheta}} \exp\left(-\frac{1}{2\vartheta}(x-m)^2\right) = \exp\left(-\frac{1}{2\vartheta}(x-m)^2 - \frac{1}{2}\ln(2\pi\vartheta)\right).$$

Sei $T_1(x) := (x-m)^2$. Dann ist das Modell für $n = 1$ exponentiell bezüglich T_1 und somit ist das Produktmodell ebenfalls exponentiell bezüglich $T(x) := \frac{1}{n} \sum_{k=1}^n T_1(x_k)$. Somit ist Satz 4.3.1 anwendbar und der beste Test φ zum Niveau $\alpha \in (0, 1)$ hat den Verwerfungsbereich

$$\left\{ \sum_{k=1}^n (x_k - m)^2 < nc \right\},$$

wobei c so ist, dass $\mathbb{P}_{\vartheta_0}(\sum_{k=1}^n (X_k - m)^2 < nc) \stackrel{!}{=} \alpha$. Mit $X_k - m = \sqrt{\vartheta_0} Y_k$, wobei $Y_1, \dots, Y_n \sim \mathcal{N}(0, 1)$ unabhängig unter \mathbb{P} sind, gilt

$$\mathbb{P}_{\vartheta_0} \left(\sum_{k=1}^n (X_k - m)^2 < nc \right) = \mathbb{P} \left(\sum_{k=1}^n Y_k^2 < \frac{nc}{\vartheta_0} \right) = F \left(\frac{nc}{\vartheta_0} \right),$$

wobei F die Verteilungsfunktion einer χ_n^2 -verteilten Zufallsvariable ist. Somit ist $c = n\vartheta_0 F^{-1}(\alpha)$. \diamond

4.4 | Likelihood-Quotiententest

21.06.2022

DEFINITION 4.4.1 (LIKELIHOOD-QUOTIENTENTEST)

In einem Standardmodell sei

$$R(x) := \frac{\sup_{\vartheta \in \Theta_1} \rho(x, \vartheta)}{\sup_{\vartheta \in \Theta_0} \rho(x, \vartheta)}.$$

Ein Test

$$\varphi(x) = \begin{cases} 1, & \text{wenn } R(x) > a, \\ 0, & \text{wenn } R(x) < a. \end{cases}$$

mit $a \geq 0$ heißt **Likelihood-Quotiententest** (LQ-Test).

Ist R groß, spricht viel für Θ_1 , da es dann ein $\vartheta_1 \in \Theta_1$ gibt, sodass $\rho(x, \vartheta_1) \gg \rho(x, \vartheta)$ für alle $\vartheta \in \Theta_0$ gilt.

Bemerkung 4.4.2 LQ-Tests sind nicht immer beste Tests, auch wenn welche existieren (analog zu Maximum-Likelihood-Schätzern, welche nicht immer beste Schätzer sind), aber oft „gut“. ◦

4.5 | Einseitige Gauß-Tests

22.06.2022

Beispiel 4.5.1 (Einseitiger GAUSS-Test mit bekannter Varianz)

Betrachte $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m,v}^{\otimes n})_{m \in \mathbb{R}})$ mit bekannter Varianz $v > 0$. Für $m_0 \in \mathbb{R}$ testen wir $H_0 : m \leq m_0$ gegen $H_1 : m > m_0$ zum Niveau $\alpha \in (0, 1)$.

Für $m_2 > m_1$ ist der Likelihoodquotient

$$\begin{aligned} R_{m_2, m_1}(x) &= \frac{\rho(x, m_2)}{\rho(x, m_1)} = \frac{\exp\left(-\frac{1}{2v} \sum_{k=1}^n (x_k - m_2)^2\right)}{\exp\left(-\frac{1}{2v} \sum_{k=1}^n (x_k - m_1)^2\right)} \\ &= \exp\left(\frac{1}{v} (m_2 - m_1) \sum_{k=1}^n x_k - n \frac{m_2^2}{2v} + n \frac{m_1^2}{2v}\right) \end{aligned}$$

und somit R eine wachsende Funktion von $M(x) := \frac{1}{n} \sum_{k=1}^n x_k$. Somit hat der beste Test die Form $\varphi(x) = \mathbb{1}_{M(x) > c}$, wobei $c \in \mathbb{R}$ so gewählt ist, dass

$$\begin{aligned} \alpha &= \mathbb{E}_{m_0}[\varphi] = \mathbb{P}_{m_0}[M(X) > c] \\ &= \mathbb{P}_{m_0}\left[\frac{M(X) - m_0}{\sqrt{\frac{v}{n}}} > \sqrt{\frac{n}{v}}(c - m_0)\right] = 1 - \Phi\left(\sqrt{\frac{n}{v}}(c - m_0)\right), \end{aligned}$$

wobei Φ die Verteilungsfunktion der Standardnormalverteilung ist. Wir lösen nach c auf und erhalten den Test

$$\varphi(x) = \mathbb{1}_{\{M(x) > m_0 + \sqrt{\frac{v}{n}} \Phi^{-1}(1-\alpha)\}}. \quad \diamond$$

Beispiel 4.5.2 (Einseitiger GAUSS-Test mit bekanntem Erwartungswert)

Betrachte $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m,v}^{\otimes n})_{v > 0})$ mit bekanntem Erwartungswert $m \in \mathbb{R}$. Wir haben bereits gezeigt, dass

$$\varphi(x) = \mathbb{1}_{\{\sum_{k=1}^n (X_k - m)^2 < v \chi_{n,\alpha}^2\}},$$

wobei $\chi_{n,\alpha}^2$ das α -Quantil der χ_n^2 -Verteilung ist, ein gleichmäßig bester Test zum Niveau α von $H_0 : v \geq v_0$ gegen $H_1 : v < v_0$ ist. \diamond

Bemerkung 4.5.3 In den vorigen Beispielen war ein Parameter der Normalverteilung bekannt. Bei der Durchführung von Experiment sind aber üblicherweise beide Parameter unbekannt. Hierfür liefert Satz 4.3.1 jedoch keinen besten Test, da nicht $\Theta \subset \mathbb{R}$ gilt. Eine natürliche Modifikation der Tests ist, den unbekannten Parameter, welcher nicht getestet wird, durch seinen erwartungstreuen Schätzer zu ersetzen. Eine weitere Konstruktionsmöglichkeit für diese Tests ist der [verallgemeinerte Likelihood-Quotient](#)

$$R(x) = \frac{\sup_{\vartheta \in \Theta_1} \rho(x, \vartheta)}{\sup_{\vartheta \in \Theta_0} \rho(x, \vartheta)}$$

mit dem Likelihood-Quotienten-Test

$$\varphi(x) = \begin{cases} 1, & \text{wenn } R(x) > c, \\ 0, & \text{wenn } R(x) \leq c. \end{cases}$$

Die Optimalität dieser Tests zu beweisen kann aufwendig sein (cf. [2, 10.4]). Wir beschränken uns auf die Konstruktion und die Aussagen. \circ

Beispiel 4.5.4 (χ^2 -Test für die Varianz)

Betrachte $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m,v}^{\otimes n})_{m \in \mathbb{R}, v > 0})$ und $\Theta_0 := \{(m, v) \in \mathbb{R} \times (0, \infty) : v \leq v_0\}$ sowie $\Theta_1 := \{(m, v) \in \mathbb{R} \times (0, \infty) : v > v_0\}$. Der verallgemeinerte Likelihood-Quotient ist

$$R(x) = \frac{\sup_{m \in \mathbb{R}, v > v_0} \rho(x, (m, v))}{\sup_{m \in \mathbb{R}, v \leq v_0} \rho(x, (m, v))} = \frac{\sup_{m \in \mathbb{R}, v > v_0} v^{-\frac{n}{2}} \exp\left(-\sum_{k=1}^n \frac{(X_k - m)^2}{2v}\right)}{\sup_{m \in \mathbb{R}, v \leq v_0} v^{-\frac{n}{2}} \exp\left(-\sum_{k=1}^n \frac{(X_k - m)^2}{2v}\right)}.$$

Für $M(x) = \frac{1}{n} \sum_{k=1}^n x_k$ gilt

$$\sup_{m \in \mathbb{R}} \exp\left(-\sum_{k=1}^n \frac{(x_k - m)^2}{2v}\right) = \exp\left(-\sum_{k=1}^n \frac{(x_k - M(x))^2}{2v}\right).$$

Wir setzen $V(x) = \frac{1}{n} \sum_{k=1}^n (x_k - M(x))^2$. Dann gilt

$$\begin{aligned} R(x) &= \frac{\sup_{v > v_0} v^{-\frac{n}{2}} \exp\left(-n \frac{V(x)}{2v}\right)}{\sup_{v \leq v_0} v^{-\frac{n}{2}} \exp\left(-n \frac{V(x)}{2v}\right)} \\ &= \begin{cases} \exp\left(\frac{n}{2} \left(\frac{V(x)}{v_0} - \ln\left(\frac{V(x)}{v_0}\right) - 1\right)\right), & \text{wenn } V(x) > v_0, \\ \exp\left(-\frac{n}{2} \left(\frac{V(x)}{v_0} - \ln\left(\frac{V(x)}{v_0}\right) - 1\right)\right), & \text{wenn } V(x) \leq v_0. \end{cases} \end{aligned}$$

Somit ist $R(x)$ strikt monoton wachsend in $V(x)$ und der Likelihood-Quotiententest hat die Form $\varphi(x) = \mathbb{1}_{\{V(x) > c\}}$. Wir haben bereits gezeigt, dass $\frac{1}{v} V(X) \sim \chi_{n-1}^2$. Es kann gezeigt werden, dass

$$\varphi(X) = \mathbb{1}_{\left\{\sum_{k=1}^n (x_k - M(x))^2 > v_0 \chi_{n-1; 1-\alpha}^2\right\}},$$

wobei $\chi_{n-1, 1-\alpha}^2$ das α -Fraktil der χ_{n-1}^2 -Verteilung ist, ein gleichmäßig bester Test ist. \diamond

Bemerkung 4.5.5 Für den rechtsseitigen Test mit $\Theta_0 = \{(m, v) \in \mathbb{R} \times (0, \infty) : v \geq v_0\}$ und $\Theta_1 := \{(m, v) \in \mathbb{R} \times (0, \infty) : v < v_0\}$ existiert allerdings **kein gleichmäßig bester Test**. Hierfür muss man sich auf den **unverfälschten Test** einschränken. \circ

Beispiel 4.5.6 (t -Test für den Erwartungswert)

Betrachte $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathcal{N}_{m,v}^{\otimes n})_{m \in \mathbb{R}, v > 0})$ und $\Theta_0 := \{(m, v) \in \mathbb{R} \times (0, \infty) : m \leq m_0\}$ sowie $\Theta_1 := \{(m, v) \in \mathbb{R} \times (0, \infty) : m > m_0\}$. Der verallgemeinerte Likelihood-Quotient ist

$$R(x) = \begin{cases} \left(\frac{V}{\tilde{V}}\right)^{-\frac{n}{2}}, & \text{wenn } M(x) \leq m_0, \\ \left(\frac{V}{\tilde{V}}\right)^{\frac{n}{2}}, & \text{wenn } M(x) > m_0, \end{cases}$$

wobei $\tilde{V}(x) := \frac{1}{n} \sum_{k=1}^n (x_k - m)^2$ und $V(x) := \frac{1}{n} \sum_{k=1}^n (x_k - M(x))^2$.

Außerdem gilt

$$\frac{\tilde{V}}{V} = 1 + \frac{1}{n-1} T_{m_0}^2 \quad \text{mit } T_{m_0} = \sqrt{\frac{n}{V^*}} (M(x) - m_0).$$

Dann ist R strikt monoton wachsend in T_{m_0} und der Likelihood-Quotienten-Test hat die Form

$$\varphi(x) = \mathbb{1}_{\{T_{m_0}(x) > c\}}.$$

Wir wissen bereits, dass T_{m_0} t_{n-1} -verteilt ist. Es kann gezeigt werden, dass

$$\varphi(x) = \mathbb{1}_{\{T_{m_0}(x) > t_{n-1, 1-\alpha}\}}$$

der gleichmäßig beste Test zum Niveau α innerhalb der Klasse der unverfälschten Tests ist, wobei $t_{n-1, 1-\alpha}$ ist das α -Fraktil der t_{n-1} -Verteilung ist. \diamond

Asymptotische Tests und Rangtest

5.1 | Anpassungstests

Wie testet man, ob ein Würfel fair ist? Wir betrachten allgemeiner $E = \{1, \dots, s\}$ für $s \geq 2$. Dann ist $\Theta := \{\vartheta = (\vartheta(k))_{k \in E} \in [0, 1]^s : \sum_{k=1}^s \vartheta(k) = 1\}$ die Menge aller Wahrscheinlichkeitsmaße auf E .

Das zugehörige unendliche Produktmodell ist $(E^{\otimes \mathbb{N}}, \mathcal{P}(E)^{\otimes \mathbb{N}}, (\vartheta^{\otimes \mathbb{N}})_{\vartheta \in \Theta})$. Für gegebenes $\rho \in \Theta$ mit $\rho(k) > 0$ für alle $k \in E$ (z.B. $\rho = (\frac{1}{6}, \dots, \frac{1}{6})$ beim Würfel) soll die Hypothese $H_0 : \vartheta = \rho$ gegen die Alternative $H_1 : \vartheta \neq \rho$ getestet werden. Seien $\Theta_0 := \{\rho\}$ und $\Theta_1 := \Theta \setminus \{\rho\}$.

Können wir diese Prozedur auch anwenden, wenn $\rho(k) = 0$ gilt?

Seien X_n das (E -wertige) Ergebnis des n -ten Wurfes und $h_n(k) := \#\{j \leq n : X_j = k\}$ die absoluten Häufigkeiten und $L_n(k) := \frac{1}{n} h_n(k)$ die relativen Häufigkeiten. Dann ist L_n ein zufälliges Wahrscheinlichkeitsmaß.

Wir betrachten für festes $n \in \mathbb{N}$ den LQ-Test

$$R_n(x) = R_n(x_1, \dots, x_n) = \frac{\sup_{\vartheta \in \Theta_1} \prod_{k=1}^s \vartheta(k)^{h_n(k)}}{\prod_{k=1}^s \rho(k)^{h_n(k)}} = \frac{\sup_{\vartheta \in \Theta} \prod_{k=1}^s \vartheta(k)^{h_n(k)}}{\prod_{k=1}^s \rho(k)^{h_n(k)}},$$

wobei die letzte Gleichung aus der Stetigkeit des Zählers in ϑ und der Dichtheit $\Theta_1 \subset \Theta$ folgt.

Der Zähler ist gleich $\prod_{k=1}^s L_n(k)^{h_n(k)}$ (das ist leicht zu überprüfen⁶, cf. [2, Bsp. 7.7]). Daher gilt

$$R_n(x) = \prod_{k=1}^s \left(\frac{L_n(k)}{\rho(k)} \right)^{h_n(k)}$$

und somit

$$\ln(R_n(x)) = n \sum_{k=1}^s L_n(k) \ln \left(\frac{L_n(k)}{\rho(k)} \right) = nH(L_n; \rho).$$

Somit hat der LQ-Test die Form

$$\varphi_n = \begin{cases} 1, & \text{wenn } nH(L_n; \rho) > c, \\ 0, & \text{wenn } nH(L_n; \rho) < c. \end{cases}$$

für ein $c = c_n \in \mathbb{R}$.

Wie kann man zu gegebenen $\alpha \in (0, 1)$ und $n \in \mathbb{N}$ das c so berechnen, dass φ_n Niveau α hat?

Nota bene. Es ist $(h_n(k))_{k=1}^s \in \{0, \dots, n\}^s$ unter \mathbb{P}_ρ multinomial verteilt: für $k_1, \dots, k_s \in \{0, \dots, n\}$ mit $\sum_{j=1}^s k_j = n$ gilt

$$\mathbb{P}_\rho((h_n(j))_{j=1}^s = (k_j)_{j=1}^s) = \frac{n!}{k_1! \cdot \dots \cdot k_s!} \prod_{j=1}^s (\rho(j))^{k_j}.$$

⁶Ist $\vartheta(k) = 0$ für ein $k \in E$, so ist die zu maximierende Funktion gleich Null. Wir können also annehmen, dass stets $\vartheta(k) > 0$ gilt. Wir maximieren stattdessen $\ln(\prod_{k=1}^s \vartheta(k)^{h_n(k)}) = n \sum_{k=1}^s L_n(k) \ln(\vartheta(k))$ unter der Nebenbedingung $\sum_{k=1}^s \vartheta(k) = 1$. Die LAGRANGE-Funktion ist $\mathcal{L}(\vartheta, \lambda) := \sum_{k=1}^s (nL_n(k) \ln(\vartheta(k)) + \lambda \vartheta(k)) - \lambda$. Nullsetzen der ϑ -Ableitung von \mathcal{L} ergibt $\frac{1}{n} \lambda = \frac{L_n(k)}{\vartheta(k)}$ für alle $k \in E$. Also ist $\frac{L_n(k)}{\vartheta(k)}$ konstant, wir nennen diese Konstante $C_n > 0$. Mit der Nebenbedingung folgt $1 = \sum_{k=1}^s \vartheta(k) = \frac{1}{C_n} \sum_{k=1}^s L_n(k) = \frac{1}{C_n}$ und somit $C_n = 1$, also $\vartheta(j) = L_n(j)$.

Damit kann man prinzipiell das c zu α berechnen. Für große n ist dies aber mit sehr viel Aufwand verbunden.

Lemma 5.1.1 (Asymptotik für $nH(L_n; \rho)$)

Sei

$$D_{n,\rho} := \sum_{k=1}^s \frac{(h_n(k) - n\rho(k))^2}{n\rho(k)} = n \sum_{k=1}^s \rho(k) \left(\frac{L_n(k)}{\rho(k)} - 1 \right)^2.$$

Dann gilt

$$nH(L_n; \rho) - \frac{1}{2}D_{n,\rho} \xrightarrow{n \rightarrow \infty} 0 \quad \text{in } \mathbb{P}_\rho\text{-Wahrscheinlichkeit.}$$

Beweis. Es gilt

$$\begin{aligned} nH(L_n; \rho) - \frac{1}{2}D_{n,\rho} &= n \sum_{k=1}^s \rho(k) \left(\frac{L_n(k)}{\rho(k)} \ln \left(\frac{L_n(k)}{\rho(k)} \right) - \frac{1}{2} \left(\frac{L_n(k)}{\rho(k)} - 1 \right)^2 \right) \\ &\stackrel{(*)}{=} n \sum_{k=1}^s \rho(k) \left(1 - \frac{L_n(k)}{\rho(k)} + \frac{L_n(k)}{\rho(k)} \ln \left(\frac{L_n(k)}{\rho(k)} \right) - \frac{1}{2} \left(\frac{L_n(k)}{\rho(k)} - 1 \right)^2 \right) \\ &=: n \sum_{k=1}^s \rho(k) g(Y_{k,n}) \end{aligned}$$

wobei wir in $(*)$ verwenden, dass $\sum_{k=1}^s \rho(k) = \sum_{k=1}^s L_n(k) = 1$ gilt sowie $Y_{k,n} := \frac{L_n(k)}{\rho(k)}$ und

$$g(x) = 1 - x + x \ln(x) - \frac{1}{2}(x - 1)^2.$$

Dann ist g auf $(0, \infty)$ glatt mit $g(0) = \frac{1}{2}$, $g(1) = 0$, $g'(1) = g''(1) = 0$. Also ist

$$g(1+x) = O(|x|^3) \quad x \searrow 0.$$

Es gilt

$$\begin{aligned} \mathbb{E}_\rho (n(Y_{k,n} - 1)^2) &= n \mathbb{E}_\rho \left[\left(\frac{L_n(k)}{\rho(k)} - 1 \right)^2 \right] = \frac{n}{\rho(k)^2 n^2} \mathbb{E}_\rho (h_n(k) - n\rho(k))^2 \\ &= \frac{1}{\rho(k)^2 n} \underbrace{n \rho(k)(1 - \rho(k))}_{= \mathbb{V}[\text{Bin}(n, \rho(k))]} = \frac{1}{\rho(k)} (1 - \rho(k)) \leq \frac{1}{\rho(k)}, \end{aligned} \quad (**)$$

da $h_n(k) \sim \text{Bin}(n, \rho(k))$. Also folgt für $C > 0$ mit der CHEBYCHEV-Ungleichung (C)

$$\begin{aligned} \mathbb{P}_\rho \left(|Y_{k,n} - 1| \leq \frac{C}{\sqrt{n}} \right) &= 1 - \mathbb{P}_\rho \left(|Y_{k,n} - 1| > \frac{C}{\sqrt{n}} \right) \stackrel{(C)}{\geq} 1 - \frac{\mathbb{E}[|Y_{k,n} - 1|^2]}{\left(\frac{C}{\sqrt{n}} \right)^2} \\ &= 1 - \frac{n \mathbb{E}[|Y_{k,n} - 1|^2]}{C^2} \stackrel{(**)}{\geq} 1 - \frac{1}{\rho(k) C^2} \xrightarrow{C \rightarrow \infty} 1 \end{aligned}$$

gleichmäßig in k und n .

Also gilt auf der Menge $|Y_{k,n} - 1| \leq \frac{C}{\sqrt{n}}$ für alle $j \in \{1, \dots, s\}$

$$\left| nH(L_n; \rho) - \frac{1}{2}D_{n,\rho} \right| \leq n \tilde{C} \left(\frac{C}{\sqrt{n}} \right)^3 = \tilde{C} C^3 \frac{1}{\sqrt{n}} \xrightarrow{n \rightarrow \infty} 0.$$

Seien nun $\delta > 0$ und $\varepsilon > 0$ beliebig. Nach oben gezeigter Konvergenz können wir C so wählen, dass $\mathbb{P}_\rho\left(|Y_{k,n} - 1| \leq \frac{C}{\sqrt{n}}\right) > 1 - \delta$ für jedes $n \in \mathbb{N}$ ist (da obige Konvergenz unabhängig von n war). Nun wählen wir $N \in \mathbb{N}$ so groß, dass $\tilde{C}C^3 \frac{1}{\sqrt{n}} < \varepsilon$ für alle $n > N$. Es gilt nun

$$\begin{aligned}\mathbb{P}_\rho\left(\left|nH(L_n; \rho) - \frac{1}{2}D_{n,\rho}\right| \leq \varepsilon\right) &\geq \mathbb{P}_\rho\left(\left\{\left|nH(L_n; \rho) - \frac{1}{2}D_{n,\rho}\right| \leq \varepsilon\right\} \cap \left\{|Y_{k,n} - 1| \leq \frac{C}{\sqrt{n}}\right\}\right) \\ &= \mathbb{P}_\rho\left(|Y_{k,n} - 1| \leq \frac{C}{\sqrt{n}}\right) > 1 - \delta\end{aligned}$$

und es folgt die Konvergenz in Wahrscheinlichkeit. \square

Lemma 5.1.2 (Verteilung von $D_{n,\rho}$ unter H_0)

Die Verteilung von $D_{n,\rho}$ unter H_0 konvergiert für $n \rightarrow \infty$ gegen eine χ_{s-1}^2 -Verteilung.

Beweis. Der Zufallsvektor $v_n := \left(\frac{h_n(1)-n\rho(1)}{\sqrt{\rho(1)}}, \dots, \frac{h_n(s)-n\rho(s)}{\sqrt{\rho(s)}}\right)^\top$ ist von der Form

$$v_n = \sum_{j=1}^n Z_j \quad \text{mit} \quad Z_j := \left(\frac{\mathbb{1}_{\{X_j=1\}} - \rho(1)}{\sqrt{\rho(1)}}, \dots, \frac{\mathbb{1}_{\{X_j=s\}} - \rho(s)}{\sqrt{\rho(s)}}\right).$$

Da die X_j unabhängig identisch verteilt sind, sind es auch die Z_j . Nach dem **mehrdimensionalen zentralen Grenzwertsatz** konvergiert $\frac{1}{\sqrt{n}}v_n$ in Verteilung (oder: schwach) gegen $\mathcal{N}(0, \Sigma)$, wobei für $k, \ell \in E$

$$\Sigma_{k,\ell} = \text{Cov}((Z_1)_k, (Z_1)_\ell) = \begin{cases} \mathbb{V}(Z_{1,k}) = \frac{1}{\rho(k)}\rho(k)(1-\rho(k)) = 1-\rho(k), & \text{wenn } k = \ell, \\ = \frac{-\rho_k\rho_\ell - \rho_k\rho_\ell + \rho_k\rho_\ell}{\sqrt{\rho(k)\rho(\ell)}} = -\sqrt{\rho(k)\rho(\ell)} & \text{wenn } k \neq \ell \end{cases}$$

Beachte, dass

$$\left\|\frac{1}{\sqrt{n}}v_n\right\|^2 = D_{n,\rho}$$

gilt. Die Matrix Σ ist symmetrisch und positiv semidefinit und somit diagonalisierbar mit nicht-negativen Eigenwerten. Wir zeigen, dass 0 ein Eigenwert zum Eigenvektor $e_s = \sqrt{\rho(1)}\mathbf{1}^\top$ ist. Für alle $k \in E$ gilt

$$\sum_{\ell=1}^s \Sigma_{k,\ell}\sqrt{\rho(\ell)} = \Sigma_{k,k}\sqrt{\rho(k)} + \sum_{\substack{\ell=1 \\ \ell \neq k}}^s \Sigma_{k,\ell}\sqrt{\rho(\ell)} = (1-\rho(k))\sqrt{\rho(k)} - \sum_{\substack{\ell=1 \\ \ell \neq k}}^s \sqrt{\rho(k)\rho(\ell)}\sqrt{\rho(\ell)} = 0.$$

23.06.2022

Ferner ist $\lambda = 1$ ein $s-1$ -facher Eigenwert von Σ , denn es gilt

$$\Sigma - I_s = \begin{pmatrix} -\rho(1) & -\sqrt{\rho(1)\rho(2)} & \dots & -\sqrt{\rho(1)\rho(s)} \\ -\sqrt{\rho(1)\rho(2)} & -\rho(2) & \dots & \vdots \\ \vdots & \dots & \ddots & \vdots \\ -\sqrt{\rho(1)\rho(s)} & \dots & \dots & -\rho(s) \end{pmatrix}.$$

Der Rang von $\Sigma - I_s$ ist eins; dividiert man die k -te Zeile durch $\sqrt{\rho(k)}$, so ist sie gleich $-(\sqrt{\rho(1)}, \dots, \sqrt{\rho(s)})^\top$.

Somit lässt sich Σ als

$$\Sigma = U \begin{pmatrix} I_{s-1} & 0 \\ 0 & 0 \end{pmatrix} U^T,$$

wobei U orthogonal ist. Die letzte Spalte von U ist e_s .

Der Vektor $T_n := U^T V_n$ hat den letzten Eintrag 0, da $\sum_{k=1}^s h_n(k) = \sum_{k=1}^s n\rho(k) = n$ gilt.

Weil U orthogonal ist, gilt $\frac{1}{n}\|T_n\|^2 = \frac{1}{n}\|V_n\|^2 = D_{n,\rho}$. Da $\frac{1}{\sqrt{n}}V_n$ in Verteilung gegen $\mathcal{N}(0, \Sigma)$ konvergiert, konvergiert $\frac{1}{\sqrt{n}}T_n$ gegen eine Normalverteilung mit Erwartungsvektor $(0, \dots, 0)^T$ und Kovarianzmatrix

$$\begin{aligned} \mathbb{E} \left[\frac{1}{\sqrt{n}} T_n \left(\frac{1}{\sqrt{n}} T_n \right)^T \right] &= \mathbb{E} \left[\frac{1}{n} U^T V_n V_n^T U \right] = U^T \mathbb{E} \left[\frac{1}{n} V_n V_n^T \right] U \\ &= U^T \Sigma U = \text{diag}(1, \dots, 1, 0). \end{aligned}$$

Somit konvergiert die Verteilung des Vektors $\frac{1}{\sqrt{n}}\tilde{T}_n \in \mathbb{R}^{s-1}$ (das Tilde bedeutet, dass wir den letzten Eintrag weglassen) gegen $\mathcal{N}(0, I_{s-1})$.

Also konvergiert $D_{n,\rho} = \frac{1}{n}\|T_n\|^2 = \frac{1}{n}\|\tilde{T}_n\|^2$ in Verteilung gegen eine χ_{s-1}^2 -Verteilung. \square

Bemerkung 5.1.3 Damit kann man für vorgegebenes Niveau $\alpha \in (0, 1)$ die Konstante c aus dem LQ-Test approximativ so bestimmen, dass das Niveau ungefähr gleich α ist. \circ

Bemerkung 5.1.4 Der obige Test heißt χ^2 -Anpassungstest (*engl.*: goodness of fit). \circ

χ^2 -
Anpassungstest

Beispiel 5.1.5 (Urnenexperiment mit Zurücklegen / MENDELS Erbsen)

Betrachte $E := \{1, \dots, s\}$ und den Beobachtungsraum $X := E^n$. Dies modelliert s verschiedene Kugeln in einer Urne und n Ziehungen. Wir wählen

$$\Theta := \left\{ \vartheta = (\vartheta(j))_{j=1}^s \in [0, 1]^s : \sum_{j=1}^s \vartheta(j) = 1 \right\},$$

die Menge aller möglichen Verteilungen für den ersten Zug, wobei $\vartheta(k)$ die Wahrscheinlichkeit darstellt, die k -te Kugel zu ziehen.

Wir haben eine Vermutung $\rho \in \Theta$ für die Verteilung und wollen $H_0 : \vartheta = \rho$ gegen $H_1 : \vartheta \neq \rho$ testen. Für $k \in \{1, \dots, s\}$, zählen wir, wie oft wir die k -te Kugel gezogen haben; $h_n(k) := |\{j \in \{1, \dots, n\} : X_j = k\}|$. Wir definieren

$$D_{n,\rho} := \sum_{k=1}^s \frac{(h_n(k) - n\rho(k))^2}{n\rho(k)}.$$

Dann ist $\varphi := \mathbb{1}_{\{D_{n,\rho} > c\}}$ für ein $c \in \mathbb{R}$ der χ^2 -Anpassungstest. Für große n wählen wir $c := \chi_{s-1, 1-\alpha}^2$, also das $(1 - \alpha)$ -Fraktil der χ^2 -Verteilung mit $s - 1$ Freiheitsgraden.

Betrachte zum Beispiel MENDELS Erbsen, ein Experiment zur Vererbungslehre, wobei die Form (rund (A) oder kantig (a)) und die Farbe (gelb (B) oder grün (b)) von Erbsen beobachtet wird.

Die Nullhypothese ist, dass rund und gelb *dominante Merkmale* sind und das Häufigkeitsverhältnis 9:3:3:1 ist.

Wir definiere also $E := \{AB, Ab, aB, ab\}$ und $\mathfrak{X} := \mathbb{E}^n$ sowie $\Theta := \{\vartheta = (\vartheta(k))_{k \in E} : \vartheta_{AB} + \vartheta_{Ab} + \vartheta_{aB} + \vartheta_{ab} = 1\}$ und $\rho := (\frac{9}{16}, \frac{3}{16}, \frac{3}{16}, \frac{1}{16})$.

Für $\alpha = 0.1$ ist $\chi_{3,0.9}^2 = 6.3$. Der zugehörige χ^2 -Anpassungstest ist $\mathbb{1}_{\{D_{n,\rho} > 6.3\}}$.

Wir haben die folgenden $n := 556$ Beobachtungen gesammelt

AB	A b	a B	a b
315	108	101	32

Dann ist

$$D_{n,\rho} = \frac{(315 - 556 \cdot \frac{9}{16})^2}{556 \cdot \frac{9}{16}} + \frac{(108 - 556 \cdot \frac{3}{16})^2}{556 \cdot \frac{3}{16}} + \frac{(101 - 556 \cdot \frac{3}{16})^2}{556 \cdot \frac{3}{16}} + \frac{(32 - 556 \cdot \frac{1}{16})^2}{556 \cdot \frac{1}{16}} = 0.47.$$

Da $D_{n,\rho} = 0.47 < 6.3 = \chi_{3,0.9}^2$ ist, lehnen wir die Nullhypothese nicht ab. \diamond

Frage. Angenommen, wir wählen $E = \mathbb{R}$ anstatt $E = \{1, \dots, s\}$ und F sei eine vorgegebene Verteilungsfunktion auf \mathbb{R} . Wir wollen im Produktmodell die Hypothese F gegen alle anderen Verteilungsfunktionen auf \mathbb{R} testen. Wir können den LQ-Test nicht verwenden, da dieses Modell kein Standardmodell ist (es existiert kein dominierendes Maß μ_0 , sodass alle Wahrscheinlichkeitsmaße absolut stetig bezüglich μ_0 sind). Die Nullhypothese ist, dass F die Verteilungsfunktion ist.

Bemerkung 5.1.6 Eine Möglichkeit, welche wir jedoch nicht verfolgen werden, ist es, \mathbb{R} in disjunkte Intervalle zu zerlegen („Gruppenbildung“) und dann den χ^2 -Test anzuwenden. \circ

Bemerkung 5.1.7 Dieses Problem ist nicht parametrisch. \circ

Die folgende Aussage führt uns zu einem vernünftigen Test.

SATZ 5.1.1: GLIWENKO-CANTELLI

Seien X_1, X_2, \dots unabhängig identisch verteilte reelle Zufallsvariablen mit Verteilungsfunktion F und $F_n(t) := \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{\{X_k \leq t\}}$ für $t \in \mathbb{R}$ die empirische Verteilungsfunktion. Dann konvergiert F_n fast sicher gleichmäßig gegen F .

Beweis. ① **Punktweise Konvergenz** ist klar, denn für festes $t \in \mathbb{R}$ gilt nach dem starken Gesetz der großen Zahlen

$$F_n(t) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{\{X_k \leq t\}} \rightarrow \mathbb{E}[\mathbb{1}_{\{X_1 \leq t\}}] = \mathbb{P}(X_1 \leq t) = F(t) \quad \text{fast sicher.}$$

② **Gleichmäßig Konvergenz.** Für $t \in \mathbb{R}$ gilt

$$\lim_{s \nearrow t} F_n(s) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{X_k < t} \xrightarrow[n \rightarrow \infty]{\text{GGZ}} \mathbb{E}[X_1 < t] = \mathbb{P}(X_1 < t) = \lim_{s \nearrow t} F(s) \quad \text{fast sicher.}$$

Seien $N \in \mathbb{N}$ fest sowie $x_j := \inf \{t \in (-\infty, \infty) : F(t) \geq \frac{j}{N}\}$ für $j \in \{0, \dots, N\}$. Dann gilt

$$-\infty = x_0 \leq x_1 \leq \dots \leq x_N \leq \infty.$$

Es ist nicht klar, dass es eine globale Nullmenge gibt, auf der $F_n \rightarrow F$ punktweise fast sicher außerhalb jener Nullmenge gilt.




Abb. 12: Die Verteilungsfunktion F induziert eine Partition von \mathbb{R} über die $(x_j)_{j=0}^N$.

Dann gilt wegen ①

$$R_n := \max_{j \in \{1, \dots, N\}} (|F_n(x_j) - F(x_j)| + |F_n(x_{j-}) - F(x_{j-})|) \xrightarrow{n \rightarrow \infty} 0 \quad \text{fast sicher,}$$

wobei $G(x-) := \lim_{y \nearrow x} G(y)$ den einseitigen Grenzwert bezeichnet.

Für $x \in (x_{j-1}, x_j)$ gilt, da Verteilungsfunktionen monoton wachsend sind,

$$\begin{aligned} F_n(x) &\leq F_n(x_j-) \leq F(x_{j-}) + R_n \leq F(x) + R_n + \frac{1}{N} \\ F_n(x) &\geq F_n(x_{j-1}) \geq F(x_{j-1}) - R_n \geq F(x) - R_n - \frac{1}{N} \end{aligned}$$

und somit

$$|F_n(x) - F(x)| \leq R_n + \frac{1}{N} \quad \forall x \in (x_{j-1}, x_j).$$

Es folgt

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \leq R_n + \frac{1}{N} \xrightarrow{n \rightarrow \infty} \frac{1}{N}$$

und somit

$$\limsup_{n \rightarrow \infty} \|F_n - F\|_\infty \leq \frac{1}{N} \quad \text{fast sicher.}$$

Da $N \in \mathbb{N}$ beliebig war, folgt die Aussage. \square

Warnung. Sind F und F_n Verteilungsfunktionen und $F_n(t) \xrightarrow{n \rightarrow \infty} F(t)$ für alle $t \in \mathbb{R}$ gilt, so folgt *nicht* $\|F_n - F\|_\infty \rightarrow 0$.

DEFINITION 5.1.8 (KOLMOGOROV-SMIRNOFF TEST)

Ein KOLMOGOROV-SMIRNOFF TEST (oder: KS-Anpassungstest) ist ein Hypothesentest für die Nullhypothese F im n -fachen Produktmodell, welcher die folgende Form hat.

$$\varphi(x) = \begin{cases} 1, & \text{wenn } \|F_n - F\|_\infty > c, \\ 0, & \text{wenn } \|F_n - F\|_\infty < c. \end{cases}$$

Bemerkung 5.1.9 (Berechnung von $\|F_n - F\|_\infty$)

Sind die X_1, \dots, X_n aufsteigend sortiert und F stetig, gilt

$$\|F_n - F\|_\infty = \max_{k \in \{1, \dots, n\}} \left(F(X_k) - \frac{k-1}{n}, \frac{k}{n} - F(X_k) \right),$$

das heißt, der betragsmäßig größte Abstand zwischen F und F_n ist an einer der Sprungstellen der empirischen Verteilungsfunktion, welche die Werte $\left(\frac{j}{n}\right)_{j=0}^n$ annimmt (siehe auch das Lemma unten).

Die Fraktile für c hängen nicht von F ab und können in einer Tabelle nachgeschlagen werden.

Lemma 5.1.10

Ist F stetig, so hängt die Verteilung von $\|F_n - F\|_\infty$ nicht von F ab.




Abb. 13: Eine Verteilungsfunktion und eine empirische Verteilungsfunktion.

Beweis. Sei $\Delta_n := \sup_{t \in \mathbb{R}} |F_n(t) - F(t)|$ für $n \in \mathbb{N}$. Unter der Nullhypothese, dass F stetig ist, sind fast sicher alle x_1, \dots, x_n verschieden. Sei $X_{k:n}$ der k -kleinste Wert, das heißt $X_{1:n} < \dots < X_{n:n}$ mit $X_{k:n} \in \{X_1, \dots, X_n\}$ für $k \in \{1, \dots, n\}$.

Es gilt

$$\Delta_n = \max_{k \in \{1, \dots, n\}} \max \left(\frac{k}{n} - F(X_{k:n}), F(X_{k:n}) - \frac{k-1}{n} \right).$$

Seien $U_k := F(X_k)$ für $k \in \{1, \dots, n\}$. Die sind unabhängig identisch gleichverteilt mit Verteilung (da F stetig ist) $\mathcal{U}([0, 1])$ und es gilt

$$\Delta_n = \max_{k \in \{1, \dots, n\}} \max \left(\frac{k}{n} - U_{k:n}, U_{k:n} - \frac{k-1}{n} \right).$$

Also hängt die Verteilung von Δ_n nicht von F ab. □

Beispiel 5.1.11 (Benzinverbrauch)

Eine zufällige Auswahl von zehn Autos eines bestimmten Typs ergab folgenden Verbrauch in $\ell/100\text{km}$:

10.8 11.3 10.4 9.8 10.0
10.6 11.0 10.5 9.5 11.2

Wir testen zum Niveau $\alpha = 0.05$, ob der Benzinverbrauch $\mathcal{N}_{10,1}$ ist.

Zunächst sortieren wir die Beobachtungen aufsteigend.

k	1	2	3	4	5	6	7	8	9	10
X_k	9.5	9.8	10.0	10.4	10.5	10.6	10.8	11.0	11.2	11.3

Die Verteilungsfunktion von $\mathcal{N}_{10,1}$ ist $F(x) = \Phi(x - 10)$, wobei Φ die Verteilungsfunktion einer Standardnormalverteilung ist. Dann gilt

k	1	2	3	4	5	6	7	8	9	10
$F(X_k)$	0.31	0.42	0.5	0.66	0.69	0.73	0.79	0.84	0.89	0.90
$F(X_k) - \frac{k-1}{n}$	0.31	0.32	0.3	0.36	0.29	0.23	0.19	0.14	0.09	0.00
$\frac{k}{n} - F(X_k)$	-0.21	-0.22	-0.2	-0.26	-0.19	-0.13	-0.09	-0.04	0.01	0.10

Daher ist $\|F_n - F\|_\infty = 0.36$. Aus einer Tabelle erhalten wir $c = 0.41$, da $\|F_n - F\|_\infty < c$ gilt, lehnen wir die Nullhypothese nicht ab. ◇

Somit ist die Verteilung von Δ_n gleich der von

28.06.2022

$$G(t) = \begin{cases} 0, & t \leq 0, \\ t, & 0 \leq t \leq 1, \\ 1, & t \geq 1 \end{cases}$$

statt F und $G_n(t) := \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{U_{k:n} \leq t}$ anstatt $F_n(t)$.

Was ist die asymptotische Verteilung von Δ_n für $n \rightarrow \infty$?

Ohne Beweis. Sei $V_n(t) := \sqrt{n}(G_n(t) - G(t))$ für $t \in [0, 1]$ ein stochastischer Prozess. Es ist klar, dass für festes $t \in [0, 1]$ $\mathbb{E}[V_n(t)] = 0$ sowie $\mathbb{V}[V_n(t)] = (\sqrt{n})^2 \frac{1}{n^2} n t(1-t) = t(1-t)$

$t)$ ($\mathbb{1}_{U_{k:n} \leq t}$ eine $\text{Ber}(t)$ -verteilte Zufallsvariable) gilt. Nach dem zentralen Grenzwertsatz konvergiert $V_n(t)$ in Verteilung (haben wir nicht definiert) gegen $\mathcal{N}(0, t(1-t))$. Unklar ist, ob der Prozess V_n gegen einen einfacheren stochastischen Prozess in Verteilung konvergiert. Man kann zeigen (cf. [3]), dass V_n in Verteilung im Raum $D[0, 1]$ gegen eine **BROWNSCHE BRÜCKE** konvergiert, das heißt gegen einen GAUSS-Prozess auf $[0, 1]$ mit einer Darstellung $V(t) = W(t) - tW(1)$ für $t \in [0, 1]$, wobei $W(t)$ für $t \geq 0$ eine Standard BROWNSCHE Bewegung ist.

Daraus folgt, dass die Verteilung von $\sqrt{n}\Delta_n$ in Verteilung gegen $\sup_{t \in [0, 1]} |V(t)|$ konvergiert. Die Verteilungsfunktion dieser Größe ist

$$\mathbb{P} \left[\sup_{t \in [0, 1]} |V(t)| \leq x \right] = \begin{cases} 0, & x \leq 0, \\ 1 - 2 \sum_{k=1}^{\infty} (-1)^{k+1} e^{-2k^2 x^2}, & x > 0. \end{cases}$$

Damit kann man für vorgegebenes α die Konstante c approximativ so bestimmen, dass der obige Test Niveau α hat.

Bemerkung 5.1.12 Der KS-Test lässt sich so modifizieren, dass damit das „**Zweistichprobenproblem**“ behandelt werden kann: seien X_1, X_2, \dots u.i.v. reellwertig mit Verteilungsfunktion F und empirischer Verteilungsfunktion F_n sowie Y_1, Y_2, \dots u.i.v. reellwertige Zufallsvariablen mit Verteilungsfunktion \tilde{F} und empirischer Verteilungsfunktion \tilde{F}_n . Die Verteilungsfunktionen F und \tilde{F} sind unbekannt. Wir wollen die Nullhypothese $F = \tilde{F}$ gegen die Alternative $F \neq \tilde{F}$ testen. Man wird bei n bzw. m Proben X_1, \dots, X_n sowie Y_1, \dots, Y_m die Nullhypothese ablehnen, wenn $\Delta_{n,m} = \|F_n - \tilde{F}_m\|_{\infty}$ (die Größe ist verteilungsunabhängig wenn F und \tilde{F} stetig sind) groß ist (Literatur: Wikipedia, [3]). \circ

5.2 | χ^2 -Test auf Unabhängigkeit

Das folgende Beispiel kommt aus [2, Bsp. 11.17].

Beispiel 5.2.1 (χ^2 -Test auf Unabhängigkeit)

Wir betrachten zwei „Merkmale“ mit je *endlich* vielen verschiedenen Ausprägungen, z.B. Schulbildung (ungelernt, ..., Uniabschluss) und die Frage, wie stark sich die fragten Personen durch Umweltschadstoffe beeinträchtigt fühlen.

Beeinträchtigung \ Schulbildung	Schulbildung					Σ
	ungelernt				Uni	
gar nicht	212	434	169	79	45	939
etwas	85	245	146	93	69	628
ziemlich	38	85	74	56	48	301
sehr	20	35	30	21	20	126
Σ	355	799	419	249	182	2004

Tabelle 3: Kontingenztafel zur „Umweltfrage“.

Sind die beiden **Merkmale unabhängig**?

Allgemein: Seien $A = \{1, \dots, a\}$, $B := \{1, \dots, b\}$ die möglichen Ausprägungen der beiden Merkmale. Für $E := A \times B$ betrachten wir das Produktmodell $(E^{\otimes \mathbb{N}}, \mathcal{P}(E)^{\otimes \mathbb{N}}, (\vartheta^{\otimes \mathbb{N}})_{\vartheta \in \Theta})$, wobei $\Theta := \{\vartheta = (\vartheta(i, j))_{(i, j) \in E} \in (0, 1)^E : \sum_{(i, j) \in E} \vartheta(i, j) = 1\}$. Für $\vartheta \in \Theta$ seien $\vartheta^A = (\vartheta^A(i))_{i \in A}$ mit $\vartheta^A(i) := \sum_{j=1}^b \vartheta(i, j)$ und ϑ^B analog definiert die **Randverteilungen** von $\vartheta \in \Theta$.

Seien $\Theta_0 := \{\vartheta \in \Theta : \vartheta = \vartheta^A \otimes \vartheta^B\}$ sowie $\Theta_1 := \Theta \setminus \Theta_0$.

Nach n unabhängigen E -wertigen Beobachtungen X_1, \dots, X_n ergibt sich eine „Kontingenztafel“ mit den Einträgen $h_n(i, j) := |\{k \in \{1, \dots, n\} : X_k = (i, j)\}|$ (absolute Häufigkeiten). Die normierten Werte sind $L_n(i, j) := \frac{1}{n} h_n(i, j)$. Ferner definieren wir $L_n^A(i) := \sum_{j=1}^b L_n(i, j)$ und analog für h_n^A sowie analog für B .

Wir werden Θ_0 ablehnen, wenn L_n nicht nah bei $L_n^A \otimes L_n^B$ liegt. Da wir ein Standardmodell vorliegen haben, können wir einen LQ-Test anwenden. Der Likelihoodquotient ist (wegen Stetigkeit in ϑ können wir im Zähler wieder Θ_1 durch Θ ersetzen)

$$\begin{aligned}
 R_n &= \frac{\sup_{\vartheta \in \Theta} \prod_{(i, j) \in E} \vartheta(i, j)^{h_n(i, j)}}{\sup_{\gamma \otimes \beta \in \Theta_0} \prod_{(i, j) \in E} (\gamma(i) \beta(j))^{h_n(i, j)}} = \frac{\sup_{\vartheta \in \Theta} \prod_{(i, j) \in E} \vartheta(i, j)^{h_n(i, j)}}{\sup_{\gamma} \prod_{i \in A} \gamma(i)^{h_n^A(i)} \sup_{\beta} \prod_{j \in B} \beta(j)^{h_n^B(j)}} \\
 &= \frac{\prod_{(i, j) \in E} L_n(i, j)^{h_n(i, j)}}{\prod_{i \in A} L_n^A(i)^{h_n^A(i)} \prod_{j \in B} L_n^B(j)^{h_n^B(j)}} = \prod_{(i, j) \in E} \left(\frac{L_n(i, j)}{L_n^A(i) L_n^B(j)} \right)^{n L_n(i, j)} \\
 &= \exp(n H(L_n; L_n^A \otimes L_n^B)).
 \end{aligned}$$

Ein kleines Problem ist, dass die rechte Seite auch für $\vartheta \in \Theta_0$ von ϑ abhängt. Um ein Niveau $\alpha \in (0, 1)$ zu garantieren, müsste man sicherstellen, dass $\sup_{\beta, \gamma} \mathbb{P}_{\gamma \otimes \beta}(R_n > c) \leq \alpha$ gilt!

Man betrachtet wie beim χ^2 -Anpassungstest die Asymptotik für $n \rightarrow \infty$:

$$\tilde{D}_n := n \sum_{i,j} L_n^A(i) L_n^B(j) \left(\frac{L_n(i,j)}{L_n^A(i) L_n^B(j)} - 1 \right)^2.$$

[2, Satz 11.18] zeigt, dass unter $\rho = \gamma \otimes \beta$ der Wert $nH(L_n; L_n^A \otimes L_n^B)$ „nah“ bei \tilde{D}_n liegt und dass \tilde{D}_n in Verteilung gegen eine $\chi^2_{(a-1)(b-1)}$ -Verteilung konvergiert (das Schätzen der Zähldichte γ „verbraucht“ $a - 1$ Freiheitsgrade, das Schätzen von β $b - 1$. Die Gesamtzahl $ab - 1$ der Freiheitsgrade verringert sich daher um $(a - 1) + (b - 1)$ und es bleiben nur $(a - 1)(b - 1)$ Freiheitsgrade übrig). \diamond

Bemerkung 5.2.2 Beim „Umweltbeispiel“ wird die Nullhypothese bei $\alpha = 0.01$ deutlich abgelehnt [2, S. 307]. \circ

5.3 | Vorzeichen- und Rangtests

Gute Quellen sind [2, Kap. 11.4] sowie [1].

30.06.2022

DEFINITION 5.3.1 (α -QUANTIL, MEDIAN, $\mu(Q)$)

Seien Q ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ und $\alpha \in (0, 1)$. Ein $q \in \mathbb{R}$ ist ein α -Quantil von Q wenn $Q((-\infty, q)) \leq \alpha \leq Q((-\infty, q])$ ist. Ein $\frac{1}{2}$ -Quantil ist der Median von Q . Ferner bezeichne $\mu(Q)$ die Menge aller Mediane von Q .

α -Quantil

DEFINITION 5.3.2 (FRAKTIL)

In der obigen Situation ist das α -Fraktile das $(1 - \alpha)$ -Quantil.

Bemerkung 5.3.3 Die Menge aller α -Quantile von Q ist ein kompaktes nichtleeres Intervall. \circ

Notation. Seien $\mu_{\max}(Q) := \max(\mu(Q))$ und $\mu_{\min}(Q)$ analog definiert.

Beispiel 5.3.4

Beim Werfen eines fairen Würfels ist $\mu(Q) = [3, 4]$. \diamond

DEFINITION 5.3.5 (ORDNUNGSSTATISTIK)

Seien X_1, X_2, \dots, X_n unabhängige reellwertige Zufallsvariablen mit stetigen Verteilungsfunktionen. (Dann sind fast sicher alle X_1, X_2, \dots, X_n verschieden.) Die **Ordnungsstatistik** der X_1, \dots, X_n sind definiert durch $X_{1:n} < X_{2:n} < \dots < X_{n:n}$ mit $X_{k:n} \in \{X_1, \dots, X_n\}$ für $k \in \{1, \dots, n\}$.

Ordnungsstatistik

Notation. Für $\alpha \in (0, 1)$ sei $b_n(\alpha)$ das größte α -Quantil der Binomialverteilung $B_{n, \frac{1}{2}}$.

Wir wollen testen, ob im Produktmodell der Median (welcher viel stabiler ist als der Mittelwert) gleich einer vorgegebenen Zahl μ_0 oder größer als μ_0 (einseitiger Hypothesentest) bzw. gleich μ_0 oder ungleich μ_0 ist (zweiseitiger Hypothesentest).

Bemerkung 5.3.6 Hat die Zufallsvariable X eine „stetige Verteilung“ (das heißt die Verteilungsfunktion ist stetig), so gilt

$$\begin{aligned} \mathbb{P}(X \in \mu(Q)) &= \mathbb{P}(\mu_{\min}(Q) \leq X \leq \mu_{\max}(Q)) \\ &= \mathbb{P}(X \leq \mu_{\max}(Q)) - \mathbb{P}(X \leq \mu_{\min}(Q)) = \frac{1}{2} - \frac{1}{2} = 0. \end{aligned} \quad \circ$$

Den folgenden Satz kann man auch (in ungenauerer Fassung) in [2, Satz 8.19] finden.

SATZ 5.3.1: KONFIDENZINTERVALL FÜR MEDIAN IM PRODUKTMODELL

Seien $n \in \mathbb{N}$, $\alpha \in (0, 1)$ sowie $k = b_n(\frac{\alpha}{2})$. Dann ist $[X_{k:n}, X_{n-k+1:n}]$ im Produktmodell Q^n mit stetigem Q ein Konfidenzintervall für $\mu(Q)$, das heißt $Q^{\otimes n}(\mu(Q) \subset [X_{k:n}, X_{n-k+1:n}]) \geq 1 - \alpha$.

Beweis. Es gilt

$$Q^{\otimes n}(X_{k:n} > \mu_{\min}(Q)) = Q^{\otimes n}\left(\sum_{j=1}^n \mathbb{1}_{\{X_j \leq \mu_{\min}(Q)\}} < k\right) = B_{n, \frac{1}{2}}(\{0, \dots, k-1\}) \leq \frac{\alpha}{2}$$

und ebenso

$$Q^{\otimes n}(X_{n-k+1:n} < \mu_{\max}(Q)) \leq \dots \leq \frac{\alpha}{2},$$

also folgt

$$Q^{\otimes n}(\mu(Q) \in [X_{k:n}, X_{n-k+1:n}]) \geq 1 - \frac{\alpha}{2} - \frac{\alpha}{2} = 1 - \alpha. \quad \square$$

Beispiel 5.3.7 (Vorzeichentest (*engl.* signed test))

Zwei Dünger sollen verglichen werden. Sind beide gleich gut? Eine Alternative ist „Dünger 2 und Dünger 1 sind verschieden“, eine andere ist „Dünger 2 ist besser als Dünger 1“.

Versuchsanordnung. Jedes von n Feldern wird in zwei gleichgroße Teile geteilt und dort Dünger 1 bzw. Dünger 2 verwendet. Die Erträge der Feldern seien $(Y_1, Z_1), \dots, (Y_n, Z_n)$, wobei Y_k der Ertrag auf Feld k mit Dünger 1 und Z_k der Ertrag auf Feld k mit Dünger 2 sind. Da die Felder unterschiedlich sind (z.B. Bodenbeschaffenheit, Mikroklima, ...), nehmen wir *nicht* an, dass die Paare $((Y_k, Z_k))_{k=1}^n$ identisch verteilt sind. Da globale Ereignisse (Hochwasser, Dürre, Sturm, ...) auftreten können, welche alle Felder betreffen, wollen wir *nicht* annehmen, dass die Paare $((Y_k, Z_k))_{k=1}^n$ unabhängig sind.

Als Nullhypothese wählen wir, dass nicht nur Y_k und Z_k für jedes k die selbe Verteilung haben, sondern sogar (Y_k, Z_k) die selbe Verteilung hat wie (Z_k, Y_k) . Weitere Annahmen (unter der Nullhypothese) seien, dass die $X_k := Y_k - Z_k$ stetige Verteilungsfunktionen F_k für $k \in \{1, \dots, n\}$ haben und das

$$I_k := \begin{cases} 1, & X_k > 0 \\ 0, & X_k = 0 \\ -1, & X_k < 0 \end{cases}$$

für $k \in \{1, \dots, n\}$ unabhängig sind. Unter der Nullhypothese hat X_k dieselbe Verteilung wie $-X_k$, somit ist die Menge der Mediane von X_k ein symmetrisches Intervall um die Null für alle $k \in \{1, \dots, n\}$.

Wir lehnen die Nullhypothese ab, wenn im zweiseitigen Fall die Anzahl der Einsen unter den I_1, \dots, I_n stark von $\frac{n}{2}$ abweicht (das heißt $|\sum_{k=1}^n I_k|$ „groß“). Die entspricht einem Test auf Fairness einer Münze beim n -fachen unabhängigen Werfen.

Allgemeiner: Seien X_1, X_2, \dots, X_n reelle Zufallsvariablen. Wir wollen testen, ob alle Verteilungen den Median μ_0 (vorgegebene Zahl) haben (oben ist $\mu = 0$). Die einzigen Annahmen sind, dass alle Verteilungsfunktionen F_k von X_k (müssen nicht gleich sein) stetig sind und

$$I_k := \begin{cases} 1, & X_k > \mu_0, \\ -1, & X_k < \mu_0 \end{cases} \quad \text{für } k \in \{1, \dots, n\} \text{ unter der Nullhypothese unabhängig sind mit}$$

$\mathbb{P}(I_k = 1) = \mathbb{P}(I_k = -1) = \frac{1}{2}$ für alle $k \in \{1, \dots, n\}$. Die Nullhypothese wird abgelehnt, wenn $|\sum_{k=1}^n I_k|$ „verdächtig“ groß ist. Ein Test zum Niveau α lässt sich durch Quantile $b_n(\alpha)$ von $B_{n, \frac{1}{2}}$ bestimmen. \diamond

Wie kann man den Schwellenwert bestimmen?

Rangtests

Ist Dünger 2 besser Dünger 1 oder sind beide gleich gut? Dünger 1 wird auf k Feldern verwendet und Dünger 2 auf ℓ Feldern. Die Erträge seien X_1, \dots, X_k sowie X_{k+1}, \dots, X_n mit $n := k + \ell$. Wir nehmen an, dass X_1, \dots, X_n **unabhängig** sind und dass X_1, \dots, X_k die **Verteilung P** haben und X_{k+1}, \dots, X_n die **Verteilung Q** haben, wobei P und Q **unbekannt aber stetig** sind. Ist Dünger 2 besser, so sind X_{k+1}, \dots, X_n „eher“ größer als X_1, \dots, X_k , das heißt $P \geq Q$.

DEFINITION 5.3.8 (STOCHASTISCH KLEINER)

Seien P und Q Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Dann ist P **stochastisch kleiner** als Q , und wir schreiben $P \leq Q$, wenn $P((c, \infty)) \leq Q((c, \infty))$ für alle $c \in \mathbb{R}$ (oder äquivalent: $P((-\infty, c]) \geq Q((-\infty, c])$ für alle $c \in \mathbb{R}$). Wir schreiben $P < Q$, wenn $P \leq Q$ und $P \neq Q$ ist.

Beispiel 5.3.9 ([2, 11.23])

Ist $m < m'$, so sind $\mathcal{N}(m, v) < \mathcal{N}(m', v)$ und $\Gamma_{a,m} < \Gamma_{a,m'}$ für $a > 0$. ◇

Wir testen die Hypothese $H_0 : P = Q$ gegen die Alternative $H_1 : P < Q$.

05.07.2022

DEFINITION 5.3.10 (RANGSTATISTIK)

Als **Rangstatistik** der Folge X_1, \dots, X_n bezeichnet man die Zufallsvariablen R_1, \dots, R_n mit $R_m := \#\{j \in \{1, \dots, n\} : X_j \leq X_m\} \geq 1$ für $m \in \{1, \dots, n\}$.

Rangstatistik

Beispiel 5.3.11 (Rangstatistik)

Sind $X_2 < X_1 < X_4 < X_3$, so sind $(R_1, R_2, R_3, R_4) = (2, 1, 4, 3)$. ◇

Bemerkung 5.3.12 (Rang- vs. Ordnungsstatistik) Es gilt $X_k = X_{R_k:n}$. ○

Bemerkung 5.3.13 Die Werte $\{R_1, \dots, R_n\}$ sind eine **Permutation** von $\{1, \dots, n\}$. ○

Welche Funktionen der Ränge der X_1, \dots, X_k können wir wählen, um zu entscheiden, ob diese hinreichend „klein“ sind? Wir wählen die **Rangsummen**.

DEFINITION 5.3.14 (RANGSUMMEN W_P, W_Q)

Es seien $W := W_P := R_1 + \dots + R_k$ sowie $W_Q := R_{k+1} + \dots + R_n$.

Nach Bemerkung 5.3.13 gilt $W_P + W_Q = \sum_{j=1}^n j = \frac{1}{2}n(n+1)$. Wir lehnen H_0 ab, wenn W „klein“ ist und sonst nicht.

DEFINITION 5.3.15 (U-STATISTIK)

Die **U -Statistik** ist

 U -Statistik

$$U = U_{k,\ell} := \sum_{m=1}^k \sum_{j=k+1}^n \mathbb{1}_{\{X_m > X_j\}}$$

Lemma 5.3.16 (Rangsumme und U -Statistik)

Es gilt $W = U + \frac{1}{2}k(k+1)$.

Beweis. Ordnet man die ersten X_1, \dots, X_k so um, dass $X_1 < \dots < X_k$, dann ändern sich weder W noch U . Seien also $X_1 < \dots < X_k$. Für die Ränge $R_1 < \dots < R_k$ gilt

$$R_m = m + \#\{j \in \{k+1, \dots, n\} : X_j < X_k\} \quad (33)$$

für $m \in \{1, \dots, k\}$ und somit

$$W = \sum_{m=1}^k R_m \stackrel{(33)}{=} \sum_{m=1}^k m + \underbrace{\sum_{m=1}^k \#\{j \in \{k+1, \dots, n\} : X_j < X_k\}}_{=\sum_{m=1}^k \sum_{j=k+1}^n 1_{\{X_m > X_j\}}} = \frac{1}{2}k(k+1) + U.$$

□

DEFINITION 5.3.17 (MANN-WHITNEY- U -TEST)

Ein Test der Nullhypothese $H_0 : P = Q$ gegen $H_1 : P < Q$ mit Ablehnungsbereich $\{U < c\} = \{W < \frac{1}{2}k(k+1) + c\}$ mit $c \in \{0, \dots, k\ell\}$ heißt **MANN-WHITNEY- U -Test** oder **WILCOXON-Zweistichproben-Rangsummentest**.

Bemerkung 5.3.18 (Randfall $k = \ell = 1$) Ist $k = \ell = 1$, dann ist $U = 1$ genau dann wenn $X_1 > X_2$ und $U = 0$ genau dann wenn $X_1 < X_2$. Unter H_0 ist die Wahrscheinlichkeit $P(U < 1) = P(U = 0) = \frac{1}{2}$ und $P(U < 0) = 0$ sowie $P(U < 2) = 1$.

Sei $\alpha \in (0, \frac{1}{2})$. Dann gilt $P(U < c) \leq \alpha$ nur, wenn $c = 0$ ist. ◯

Wie kann man im Allgemeinen c zu $\alpha \in (0, 1)$ wählen, damit der **MANN-WHITNEY- U -Test** Niveau α hat?

SATZ 5.3.2: U -VERTEILUNG UNTER H_0

Für stetige P und $m \in \{0, \dots, k\ell\}$ gilt $P^{\otimes n}(U = m) = \frac{1}{\binom{n}{k}} N(m; k, \ell)$, wobei $N(m; k, \ell)$ die Anzahl der Partitionen $\sum_{j=1}^k m_j = m$, von m in k aufsteigend geordnete Zahlen $m_1 \leq m_2 \leq \dots \leq m_k$ aus $\{0, \dots, \ell\}$ ist.

Bemerkung 5.3.19 Die Verteilung von U hängt insbesondere nicht von P ab, wenn P stetig ist. ◯

Beweis. (Idee) Sei $R := \{R_1, \dots, R_k\}$ ist eine zufällige k -elementige Teilmenge von $\{1, \dots, n\}$ gleichverteilt (da P stetig ist) auf allen $\binom{n}{k}$ k -elementigen Teilmengen von $\{1, \dots, n\}$. Für ein $r = (r_1, \dots, r_k)$ mit $r_1 < \dots < r_k$ und $r_j \in \{1, \dots, n\}$ sei $m(r) := (m_1(r), \dots, m_k(r))$ mit $m_j(r) := r_j - j$ für $j \in \{1, \dots, k\}$. Dann ist $r \mapsto m(r)$ eine Bijektion zwischen der obigen Menge der r und der Menge aller $\{0, \dots, \ell\}$ -wertigen aufsteigenden Folgen $m_1 \leq m_2 \leq \dots \leq m_k$.

Weiter ist $m_j(r)$ die Anzahl alle Elemente in $\{1, \dots, n\} \setminus \{r_1, \dots, r_k\}$, die kleiner als j sind. Also ist $\sum_{j=1}^k m_j(R) = U$, das heißt $\sum_{j=1}^k m_j(R) = m$ genau dann wenn $U = m$, und das ist die Behauptung. □

Beispiel 5.3.20 (Zum Beweis)

Es bedeute 0, dass eine Realisierung zu der ersten Stichprobe stammt und 1, dass sie aus der zweiten Stichprobe kommt. Unser Ergebnis sei 10001101. Dann sind $k = \ell = 4$ und $n = 8$ sowie $m_1(r) = 0$ und $m_2(r) = 2$, da die zweite Null im Ergebnis an vierter Stelle steht. \diamond

Bemerkung 5.3.21 Also lautet der **MANN-WHITNEY- U -Test** zum Niveau $\alpha \in (0, 1)$: berechne $\frac{1}{\binom{n}{k}} N(m; k, \ell)$ für $m \in \{0, 1, \dots\}$ solange, bis die Summe größer als α ist. Wenn das bei m_0 der Fall ist, dann wähle $c = m_0$. \circ

Für große k und ℓ liefert der folgende Satz einen Test zum approximativen Niveau α :

SATZ 5.3.3: Hoeffding: $U_{k,\ell}^* \rightarrow \mathcal{N}(0, 1)$

Seien X_1, \dots, X_n unabhängig und identisch verteilt mit stetiger Verteilung P . Dann konvergiert $U_{k,\ell}^* := v_{k,\ell}^{-\frac{1}{2}} (U_{k,\ell} - \frac{1}{2}k\ell)$ (der Erwartungswert von $U_{k,\ell}$ ist $\frac{1}{2}k\ell$) in Verteilung gegen $\mathcal{N}(0, 1)$ für $k, \ell \rightarrow \infty$, wobei $v_{k,\ell} := \frac{1}{12}k\ell(k + \ell + 1)$.

Beweis. [2, Satz 12.28]. \square

Beispiel 5.3.22

Um die Verlängerung der Reaktionszeit durch ein bestimmtes Medikament zu untersuchen, wurden 20 Personen einem Reaktionstest unterzogen, von denen 10 zuvor das Medikament eingenommen hatten und die anderen 10 eine Kontrollgruppe bildeten. Es ergaben sich folgende Reaktionszeiten (in Sekunden):

behandelte Gruppe	0.83	0.66	0.94	0.78	0.81	0.60	0.88	0.90	0.79	0.86
Kontrollgruppe	0.64	0.70	0.69	0.80	0.71	0.82	0.62	0.91	0.59	0.63

Es ist Hausaufgabe 12.2 mit einem **MANN-WHITNEY- U -Test** zum Niveau $\alpha := 0.05$ die Hypothese zu testen, dass die Reaktionszeit durch das Medikament nicht beeinflusst wird, gegen die Alternative einer verlängerten Reaktionszeit, und zwar (a) exakt, (b) unter Verwendung der Normalapproximation. \diamond

Bemerkung 5.3.23 (Zusammenhang U -Test \leftrightarrow KS Zweistichprobentest)

Wir haben gesehen, dass der **KOLMOGOROV-SMIRNOFF-Zweistichprobentest** $\Delta_{k,\ell} := \|F_k - \tilde{F}_\ell\|_\infty$, wobei F_k resp. \tilde{F}_ℓ die empirischen Verteilungsfunktionen von X_1, \dots, X_k resp. X_{k+1}, \dots, X_n sind, benutzt wird. Dieses $\Delta_{k,\ell}$ hängt nur von den Ränge von X_1, \dots, X_n ab (die Differenz erreicht ihr Maximum an den Sprungstellen...). Wir modifizieren den **KOLMOGOROV-SMIRNOFF-Zweistichprobentest**, sodass er besser zur Alternative $P < Q$ passt: wähle $\overline{\Delta_{k,\ell}} := \sup_{x \in \mathbb{R}} F_k(x) - \tilde{F}_\ell(x)$, welche wieder eine Funktion der Ränge von X_1, \dots, X_n ist.

Beispiel 5.3.24

Es ist nicht so, dass $\overline{\Delta_{k,\ell}}$ eine Funktion der Rangsumme W ist. Seien zum Beispiel $k = \ell = 3$ sowie

X_1	X_2	X_3	X_4	X_5	X_6	W	$\overline{\Delta_{3,3}}$
1	3	5	2	4	6	9	$\frac{1}{3}$
1	2	6	3	4	5	9	$\frac{2}{3}$

Dann ist W für beide paare von Stichproben (erste und zweite Zeile) gleich, jedoch ist $\overline{\Delta_{3,3}}$ unterschiedlich. \diamond

6 Lineare Modelle und Varianzanalyse

6.1 Einfache lineare Regression

07.07.2020

Exemplarisch betrachten wir die **Wärmeausdehnung eines Metallstabs**. Für vorgegebene Temperaturen t_1, t_2, \dots, t_n wird jeweils die Länge des Metallstabs X_k gemessen.

Wir modellieren die Länge als $X_k = \gamma_0 + \gamma_1 t_k + \sqrt{v} \xi_k$ für $k \in \{1, \dots, n\}$, wobei γ_0 und γ_1 unbekannt sind und geschätzt werden sollen und $v > 0$ ein „Störparameter“ ist. Letztlich sind ξ_1, \dots, ξ_n Zufallsvariablen, welchen den **Messfehler** beschreiben.

Wir müssen nicht annehmen, dass die ξ_k unabhängig, unkorreliert oder identisch verteilt sind, wir nehmen jedoch $\mathbb{E}[\xi_k] = 0$ und $\mathbb{V}[\xi_k] = 1$ an.

Mit $X := (X_1, \dots, X_n)$, $t := (t_1, \dots, t_n)$, $\xi := (\xi_1, \dots, \xi_n)$ und $\mathbf{1} := (1, \dots, 1) \in \mathbb{R}^n$ können wir das Modell knapp als $X = \gamma_0 \mathbf{1} + \gamma_1 t + \sqrt{v} \xi$ schreiben.

Wir wählen das Modell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_{\gamma, v})_{(\gamma, v) \in \mathbb{R}^2 \times (0, \infty)})$ (kein Produktmodell!), wobei $\mathbb{P}_{\gamma, v}$ die Verteilung von $\gamma_0 \mathbf{1} + \gamma_1 t + \sqrt{v} \xi$ hat.

DEFINITION 6.1.1 (PRINZIP DER KLEINSTEN QUADRATE, KQ-SCHÄTZER)

Das **Prinzip der kleinsten Quadrate** („least squares“) wählt $\hat{\gamma} = (\hat{\gamma}_0, \hat{\gamma}_1) \in \mathbb{R}^2$ so, dass der mittlere quadratische Fehler

$$F_{\gamma} := \frac{1}{n} \sum_{k=1}^n (X_k - \gamma_0 - \gamma_1 t_k)^2$$

minimiert wird. Dieses $\hat{\gamma}$ heißt **KQ-Schätzer** (sofern er eindeutig ist).




Abb. 14: Der KQ-Schätzer bestimmt die Regressionsgerade $\hat{\gamma}_0 + t\hat{\gamma}_1$, welche die Daten approximieren soll.

Bemerkung 6.1.2 Sind alle t_k gleich, dann ist die Lösung $\hat{\gamma}$ nicht eindeutig, unter anderem, da dann t und $\mathbf{1}$ linear abhängig sind. Wir nehmen daher an, dass nicht alle t_k gleich sind. ◯

SATZ 6.1.1: KQ-SCHÄTZER FÜR EINFACHE LINEARE REGRESSION

Seien t und $\mathbf{1}$ linear unabhängig sowie $M(y) := \frac{1}{n} \sum_{k=1}^n y_k$ und $V(t) := \frac{1}{n} \sum_{k=1}^n t_k^2 - M(t)^2$ sowie $c(t, y) := \frac{1}{n} \langle t, y \rangle - M(t)M(y)$ für $t, y \in \mathbb{R}^n$. (Wegen $t \neq \lambda \mathbf{1}$ folgt $V(t) > 0$.) Der KQ-Schätzer des obigen Problems $X = \gamma_0 \mathbf{1} + \gamma_1 t + \sqrt{v} \xi$ ist

$$\hat{\gamma}_0 = M(x) - M(t) \frac{c(t, x)}{V(t)} \quad \hat{\gamma}_1 = \frac{c(t, x)}{V(t)}$$

und ist erwartungstreu.

Beweis. Wir erhalten $\hat{\gamma}$ aus dem linearen Gleichungssystem $0 = \frac{\partial}{\partial \gamma_0} F_{\gamma} = \frac{\partial}{\partial \gamma_1} F_{\gamma}$. ◻

Bemerkung 6.1.3 Dieses Modell (und damit die Aussage des Satzes) ist ein Spezialfall des linearen Modells im nächsten Abschnitt, cf. Beispiel 6.3.5. ◯

Bemerkung 6.1.4 Die Menge $L := \{\gamma_0 \mathbf{1} + \gamma_1 t : \gamma_0, \gamma_1 \in \mathbb{R}\} \subset \mathbb{R}^n$ ist ein zweidimensionaler Teilraum, wenn $\mathbf{1}$ und t linear unabhängig sind und sonst ist die Dimension gleich eins. ◯




Abb. 15: Die Regressionsgerade $\hat{\gamma}_0 \mathbf{1} + \hat{\gamma}_1 t$ ist die orthogonale Projektion von X auf L .

Bemerkung 6.1.5 Ist L eindimensional, so existiert die orthogonale Projektion von x auf L und ist eindeutig, aber die Darstellung $\hat{\gamma}_0 \mathbb{1} + \hat{\gamma}_1 t$ ist *nicht* eindeutig. \circ

Beispiel 6.1.6 (Motorleistung) Ein Motor erbrachte bei $n = 8$ Messungen die folgende Leistung (in kW) in Abhängigkeit vom Drehmoment (1000 U / min):

t_k	0.8	1.5	2.5	3.5	4.2	4.7	5.0	5.5
X_k	8.8	14.7	22.8	29.4	38.2	44.1	47.8	51.5

Wir berechnen die Regressionsgerade und schätzen die Leistung für das Drehmoment 4000 U / min.

Es sind

$$M(t) := \frac{1}{8} \sum_{k=1}^8 t_k \approx 3.46 \quad \text{und} \quad M(X) := \frac{1}{8} \sum_{k=1}^8 X_k \approx 32.16$$

sowie

$$V(t) := \frac{1}{8} \sum_{k=1}^8 t_k^2 - M(t)^2 \approx 14.55 - (3.46)^2 \approx 2.56$$

sowie

$$c(t, x) := \frac{1}{n} \sum_{k=1}^8 t_k X_k - M(t)M(x) \approx 134.87 - 3.46 \cdot 32.16 \approx 23.51.$$

Nach Satz 6.1.1 erhalten wir die erwartungstreuen Schätzer

$$\hat{\gamma}_0 := M(x) - M(t) \frac{c(t, x)}{V(t)} \approx 0.34 \quad \hat{\gamma}_1 := \frac{c(t, x)}{V(t)} \approx 9.19,$$

also ist die Regressionsgerade $9.19t + 0.34$. Für das Drehmoment 4000 U / min schätzen wir also eine Leistung von 37.10 kW. \diamond

6.2 | Das lineare Modell

DEFINITION 6.2.1 (LINEARE MODELL)

Seien $s, n \in \mathbb{N}$ mit $s \leq n$. Ein **lineares Modell** für n reellwertige Beobachtungen mit unbekannten **Verschiebungsparameter** $\gamma \in \mathbb{R}^s$ und $v > 0$ besteht aus

lineares Modell

- einer „Design“-Matrix $A \in \mathbb{R}^{n,s}$ mit vollem Rang $s \leq n$,
- einem **Zufallsvektor** $\xi \in \mathbb{R}^n$ („Fehler“) von standardisierten Zufallsvariablen (das heißt $\xi_k \in L^2(\mathbb{R}^n)$, $\mathbb{E}[\xi_k] = 0$ und $\mathbb{E}[\xi_k^2] = 1$ für alle $k \in \{1, \dots, n\}$),
- einem **Beobachtungsvektor** $X := A\gamma + \sqrt{v}\xi \in \mathbb{R}^n$.

Das Modell ist $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_{(\gamma,v)})_{\gamma \in \mathbb{R}^s, v > 0})$, wobei $\mathbb{P}_{(\gamma,v)}$ die Verteilung von $A\gamma + \sqrt{v}\xi$ bezeichnet.

Bemerkung 6.2.2 Es gilt $\mathbb{E}_{(\gamma,v)}[X] = A\gamma$. ◦

Wir wollen einen KQ-Schätzer $\hat{\gamma}$ zu X zu finden (welcher $\frac{1}{n} \sum_{k=1}^n (X_k - A\gamma)^2$ minimiert).

Beispiel 6.2.3 (Lineare Modelle) Die oben besprochene einfache **lineare Regression** ist ein lineares Modell mit $A = (\mathbb{1}, t) \in \mathbb{R}^{n,2}$, das heißt $s = 2$. Auch **polynomielle Regression** $X_k = \sum_{j=0}^d \gamma_j t_k^j + \sqrt{v}\xi_k$ für $k \in \{1, \dots, n\}$ ist ein lineares Modell mit $d = s - 1$ und $A := (1, t, t^2, \dots, t^d) \in \mathbb{R}^{n \times (d+1)}$, wobei $t^k := (t_1^k, \dots, t_n^k)^\top$ für $k \in \{1, \dots, d\}$ ist. Auch ein **Modell mit mehreren Einflussgrößen** $X_k = \gamma_0 \sin(\delta_k \cdot t_k) + \gamma_1 e^{u_k^2} + \gamma_2 \frac{1}{\delta_k^2 + t_k^2 + u_k^2 + 1} + \sqrt{v}\xi_k$ ist ein lineares Modell mit $A = \left(\sin(\delta_k \cdot t_k), e^{u_k^2}, \frac{1}{\delta_k^2 + t_k^2 + u_k^2 + 1} \right)_{k=1}^n$. ◇

Bemerkung 6.2.4 Für die Verteilung von ξ_1, \dots, ξ_n kann man unterschiedliche Annahmen machen, z.B. $\mathcal{N}(0, E_n)$ oder $\xi_1 = \dots = \xi_n$ mit $\mathbb{P}(\xi = 1) = \mathbb{P}(\xi = -1) = \frac{1}{2}$. ◦

Notation. Der Teilraum $L = L(A) := \text{Bild}(A) = \{A\gamma : \gamma \in \mathbb{R}^s\} \subset \mathbb{R}^n$ ist $\text{rang}(A) = s$ -dimensional.

Wie vorher wollen wir X **orthogonal auf L projizieren**. Sei $\pi_L \in \mathbb{R}^{n,n}$ die zugehörigen Projektionsmatrix. Da $\mathcal{A}: \mathbb{R}^s \rightarrow L \subset \mathbb{R}^n$, $x \mapsto Ax$ bijektiv ist, existiert genau ein $\hat{\gamma} \in \mathbb{R}^s$ mit $A\hat{\gamma} = \pi_L X$.

Wie sieht π_L aus und können wir eine Formel für $\hat{\gamma}$ aufschreiben?

Lemma 6.2.5 (KQ-Schätzer für lineare Modelle)

Die Matrix $A^\top A \in \mathbb{R}^{s,s}$ ist invertierbar und $\pi_L = A(A^\top A)^{-1}A^\top$. Die einzige Lösung von $\pi_L X = A\hat{\gamma}$ ist der KQ-Schätzer $\hat{\gamma} = (A^\top A)^{-1}A^\top X$.

Beweis. ① Angenommen, es gibt ein $c \in \mathbb{R}^s$ mit $A^\top A c = 0$. Dann gilt $\|Ac\|^2 = (Ac)^\top Ac = c^\top A^\top A c = 0$ und somit $Ac = 0$. Da A vollen Rang hat, folgt daraus $c = 0$.

② Für $X \in \mathbb{R}^n$ gilt

$$A(A^\top A)^{-1}A^\top X \in L$$

und für $y \in \mathbb{R}^s$ gilt

$$\begin{aligned}\langle X - \pi_L X, Ay \rangle &= \langle X - A(A^\top A)^{-1} A^\top X, Ay \rangle = \langle A^\top X - \underbrace{A^\top A(A^\top A)^{-1} A^\top X}_{= \text{id}_{s,s}}, y \rangle \\ &= \langle \underbrace{A^\top X - A^\top X}_{=0}, y \rangle = 0\end{aligned}$$

und somit $X - \pi_L X \perp L$. Also folgt $A\hat{\gamma} = A(A^\top A)^{-1} A^\top X = \pi_L X$. \square

SATZ 6.2.1: ERWARTUNGSTREUE SCHÄTZER IM LINEAREN MODELL

In der obigen Situation gilt

- ① $\hat{\gamma} = (A^\top A)^{-1} A^\top X$ ist ein erwartungstreuer Schätzer für γ .
- ② Sei τ eine lineare reelle Funktion von γ , also $\tau(\gamma) = c^\top \gamma$ für ein $c \in \mathbb{R}^s$ und alle $\gamma \in \mathbb{R}^s$. Dann ist $T := \langle c, \hat{\gamma} \rangle$ ein erwartungstreuer Schätzer für τ und es gilt $T = a^\top X$ mit $a = A(A^\top A)^{-1} c$.
- ③ Sind zusätzlich die ξ_1, \dots, ξ_n unkorreliert, das heißt $\mathbb{E}_{(\gamma,v)}[\xi_i \xi_j] = 0$ für alle $i, j \in \{1, \dots, n\}$ mit $i \neq j$, dann hat T **minimale Varianz unter allen linearen erwartungstreuen Schätzern** für τ („ T ist **BLUE** - best linear unbiased estimator“).
- ④ Unter den Voraussetzungen von ③ und $n > s$ ist die (korrigierte) **Stichprobenvarianz**

$$V^* := \frac{1}{n-s} |X - \pi_L X|^2 = \frac{1}{n-s} (|X|^2 - |\pi_L X|^2) = \frac{1}{n-s} |X - A\hat{\gamma}|^2$$

ein erwartungstreuer Schätzer für v .

Beweis. ① Es gilt

$$\mathbb{E}_{(\gamma,v)}[\hat{\gamma}] = (A^\top A)^{-1} A^\top \mathbb{E}_{(\gamma,v)}[X] = (A^\top A)^{-1} A^\top A\gamma = \gamma.$$

② Es gilt

$$\mathbb{E}_{(\gamma,v)}[T] = \mathbb{E}_{(\gamma,v)}[c^\top \hat{\gamma}] = c^\top \mathbb{E}_{(\gamma,v)}[\hat{\gamma}] = c^\top \gamma = \tau(\gamma)$$

sowie

$$T = c^\top \hat{\gamma} = c^\top (A^\top A)^{-1} A^\top X = (A(A^\top A)^{-1} c)^\top X = a^\top X.$$

12.07.2022

- ③ Sei $S: (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n)) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ein linearer erwartungstreuer Schätzer für τ . Dann existiert ein $b \in \mathbb{R}^n$ mit $S = \langle b, X \rangle$ und es gilt

$$\begin{aligned}\langle b, A\gamma \rangle &\stackrel{6.2.2}{=} \mathbb{E}_{(\gamma,v)}[b^\top X] = \mathbb{E}_{(\gamma,v)}[S] = \tau(\gamma) \\ &= c^\top \gamma = \mathbb{E}_{(\gamma,v)}[T] = a^\top \mathbb{E}_{(\gamma,v)}[X] = \langle a, A\gamma \rangle\end{aligned}$$

und somit $\langle b - a, A\gamma \rangle = 0$ für alle $\gamma \in \mathbb{R}^s$, also $b - a \perp L$. Da $a \in L$ folgt $a = \pi_L b$. Dann folgt mit dem Satz von PYTHAGORAS $|a| \leq |b|$, genauer $|a| = |\pi_L b| \leq \|\pi_L\| |b| = |b|$, wobei $\|\cdot\|$ die Operatornorm ist (orthogonale Matrizen haben immer Einheitsoperatornorm).

Mit $\vartheta = (\gamma, v)$ gilt

$$\begin{aligned}\mathbb{V}_\vartheta[S] - \mathbb{V}_\vartheta[T] &= \mathbb{E}_\vartheta[|\langle b, X \rangle - \mathbb{E}_\vartheta[\langle b, X \rangle]|^2] - \mathbb{E}_\vartheta[|\langle a, X \rangle - \mathbb{E}_\vartheta[\langle a, X \rangle]|^2] \\ &\stackrel{\mathbb{E}_\vartheta[X] = A\gamma}{=} \mathbb{E}_\vartheta[\langle b, X - A\gamma \rangle^2 - \langle a, X - A\gamma \rangle^2] \\ &= \mathbb{E}_\vartheta[b^\top (X - A\gamma)(X - A\gamma)^\top b - a^\top (X - A\gamma)(X - A\gamma)^\top a] \\ &\stackrel{X - A\gamma = \sqrt{v}\xi}{=} v(b^\top \underbrace{\mathbb{E}_\vartheta[\xi\xi^\top]}_{= \text{id}_n} b - a^\top \mathbb{E}_\vartheta[\xi\xi^\top] a) = v(|b|^2 - |a|^2) \geq 0\end{aligned}$$

(Selber überlegen: allgemeinere Bedingung als Unkorreliertheit unter der die Aussage erhalten bleibt.)

- ④ **Darstellung der Stichprobenvarianz.** Die Formel $|X - \pi_L X|^2 = |X|^2 - |\pi_L X|^2$ folgt direkt aus dem Satz von PYTHAGORAS. Mit Lemma 6.2.5 folgt $|X - \pi_L X|^2 = |X - A\hat{\gamma}|^2$.

Erwartungstreue. Seien v_1, \dots, v_n eine Orthonormalbasis von \mathbb{R}^n , sodass v_1, \dots, v_s eine Orthonormalbasis von L ist. Sei Γ die (orthonormale) Matrix mit den Spalten v_1, \dots, v_n . Dann bildet Γ den Raum $\{x \in \mathbb{R}^n : x_{s+1} = \dots = x_n = 0\}$ bijektiv auf L ab. Die darstellende (bezüglich der Basis v_1, \dots, v_n) Matrix der orthogonalen Projektion auf L ist $M_s := \begin{pmatrix} \text{id}_s & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n,n}$. Daher gilt $\pi_L = \Gamma M_s \Gamma^\top$. Sei $\eta := \Gamma^\top \xi \in \mathbb{R}^n$. Dann gilt

$$\begin{aligned}(n-s)V^* &= |X - \pi_L X|^2 = |\cancel{A\gamma} + \sqrt{v}\xi - \pi_L(\cancel{A\gamma} + \sqrt{v}\xi)|^2 \stackrel{(\star)}{=} v|\xi - \pi_L \xi|^2 \\ &\stackrel{(\dagger)}{=} v|\Gamma^\top(\xi - \pi_L \xi)|^2 = v|\eta - M_s \eta|^2 = v \sum_{k=s+1}^n \eta_k^2,\end{aligned}\tag{\diamond}$$

wobei wir in (\star) benutzen, dass $A\gamma \in L$ und deswegen $\pi_L A\gamma = A\gamma$ und in (\dagger) , dass orthogonale Abbildungen die $|\cdot|$ -Norm erhalten.

Weiter gilt für $k \in \{1, \dots, n\}$

$$\mathbb{E}_\vartheta[\eta_k^2] = \mathbb{E}_\vartheta[\langle v_k, \xi \rangle^2] = v_k \mathbb{E}_\vartheta[\xi\xi^\top] v_k^\top = |v_k|^2 = 1$$

und somit

$$(n-s)\mathbb{E}_\vartheta[V^*] = (n-s)v.$$

□

6.3 | Das lineare Gauß-Modell

Wir nehmen nun zusätzlich an, dass $\xi \mathcal{N}(0, E_n)$ -verteilt ist mit $s \leq n$.

SATZ 6.3.1: VERALLGEMEINERTER SATZ VON STUDENT [2, 12.17]

Im linearen GAUß-Modell gelten (bezüglich $\mathbb{P}_{\gamma, v}$)

① $\hat{\gamma}$ ist $\mathcal{N}(\gamma, v(A^\top A)^{-1})$ -verteilt.

Wenn $s < n$ ist, dann gelten

② $\frac{n-s}{v} V^*$ ist χ_{n-s}^2 -verteilt.

③ $\frac{1}{v} |A(\hat{\gamma} - \gamma)|^2 = \frac{1}{v} |\pi_L X - \mathbb{E}_{(\gamma, v)}[X]|^2$ ist χ_s^2 -verteilt und unabhängig von V^* .

Insbesondere ist $\frac{|A(\hat{\gamma} - \gamma)|^2}{s V^*}$ ist $\mathcal{F}_{s, n-s}$ -verteilt.

④ Ist $H \subset L$ ein Teilraum mit Dimension $r < s$ und ist $A\gamma \in H$, so ist $\frac{1}{v} |\pi_L X - \pi_H X|^2$ χ_{s-r}^2 -verteilt und unabhängig von V^* . Insbesondere ist die FISHER-Statistik

$$F_{H,L} := \frac{\frac{|\pi_L X - \pi_H X|^2}{(s-r)v}}{\frac{(n-s)V^*}{(n-s)v}} = \frac{n-s}{s-r} \frac{|\pi_L X - \pi_H X|^2}{|X - \pi_L X|^2} = \frac{|A\hat{\gamma} - \pi_H X|^2}{(s-r)V^*}$$

$\mathcal{F}_{s-r, n-s}$ -verteilt (wegen ②).

Merke, dass Satz 3.0.2 ② ein Spezialfall (mit $s = 1$, $A = \mathbb{1}$ und somit ist $\hat{\gamma}$ der empirische Mittelwert der X_k) von ① und ② ist.

Beweis. ① Da $X = A\gamma + \sqrt{v}\xi$ gilt, ist $X \mathcal{N}(A\gamma, v \text{id}_n)$ -verteilt. Da $\hat{\gamma} = (A^\top A)^{-1} A^\top X$ eine lineare Transformation von X ist, ist auch $\hat{\gamma}$ normalverteilt mit Erwartungswert $\mathbb{E}_\theta[\hat{\gamma}] = \gamma$. Die Kovarianzmatrix ist

$$\begin{aligned} \mathbb{E}_\theta[(\hat{\gamma} - \gamma)(\hat{\gamma} - \gamma)^\top] &= \mathbb{E}_\theta[(A^\top A)^{-1} A^\top (X - A\gamma)(X - A\gamma)^\top A (A^\top A)^{-1}] \\ &= v \mathbb{E}_\theta[\xi \xi^\top] (A^\top A)^{-1} = v (A^\top A)^{-1}. \end{aligned}$$

② - ④ Sei $H \subset L$ ein Teilraum mit Dimension $r < s$ und v_1, \dots, v_n eine Orthonormalbasis von \mathbb{R}^n mit $\text{span}(v_1, \dots, v_r) = H$ und $\text{span}(v_1, \dots, v_s) = L$. Sei Γ wieder die Matrix mit den Spalten v_1, \dots, v_n und $\eta := \Gamma^\top \xi$. Dann ist $\eta \mathcal{N}(0, \text{id}_n)$ -verteilt. Daraus folgt ② mit (\diamond) und der Definition einer χ_{n-s}^2 -Verteilung.

Wieder gilt $\pi_L = \Gamma M_s \Gamma^\top$ und analog $\pi_H = \Gamma M_r \Gamma^\top$ also folgt, dass

$$|\pi_L \xi - \pi_H \xi|^2 = |\Gamma(M_s - M_r) \Gamma^\top \xi|^2 = |(M_s - M_r) \eta|^2 = \sum_{k=r+1}^s \eta_k^2$$

χ_{s-r}^2 -verteilt und wegen (\diamond) unabhängig von V^* .

Fall 1: $H = \{0\}$. Dann ist $r = 0$, also ist $|\pi_L \xi|^2$ χ_s^2 -verteilt und unabhängig von V^* .

Weiter gilt

$$A(\hat{\gamma} - \gamma) = \pi_L(X - A\gamma) = \pi_L \sqrt{v} \xi = \sqrt{v} \pi_L \xi$$

und somit $\frac{1}{v} |A(\hat{\gamma} - \gamma)|^2 = |\pi_L \xi|^2$, also folgt ③.

Fall 1: $H \neq \{0\}$. Sei $A\gamma \in H$. Dann gilt

$$\begin{aligned}\pi_L X - \pi_H X &= \pi_L(A\gamma + \sqrt{v}\xi) - \pi_H(A\gamma + \sqrt{v}\xi) \\ &= \cancel{A\gamma} + \sqrt{v}\pi_L \xi - \cancel{A\gamma} - \sqrt{v}\pi_H \xi = \sqrt{v}(\pi_L \xi - \pi_H \xi)\end{aligned}$$

also folgt ④. □

Seien im Folgenden $s < n$.

13.07.2022

Korollar 6.3.1 (Konfidenzbereiche im linearen GAUSS-Modell)

Sei $\alpha \in (0, 1)$.

- ① Ein Konfidenzellipsoid für γ zu Irrtumsniveau α ist

$$C(\cdot) = \{\gamma \in \mathbb{R}^s : |A(\gamma - \hat{\gamma})|^2 < s f_{s, n-s; 1-\alpha} V^*\},$$

Man kann $<$ durch \leq ersetzen, da \mathcal{F} eine stetige Verteilung ist.

wobei $f_{s, n-s; 1-\alpha}$ das α -Fraktile (bzw. $(1-\alpha)$ -Quantil) der $\mathcal{F}_{s, n-s}$ -Verteilung ist.

- ② Ein Konfidenzintervall für $\tau(\gamma) = c^T \gamma$, wobei $c \in \mathbb{R}^s$, zum Irrtumsniveau α ist

$$C(\cdot) = [c^T \hat{\gamma} - \delta \sqrt{V^*}, c^T \hat{\gamma} + \delta \sqrt{V^*}],$$

Hier müssen wir das abgeschlossene Intervall wählen, weil die Aussage sonst für $c = 0$ falsch ist.

wobei $\delta = t_{n-s; 1-\frac{\alpha}{2}} \sqrt{c^T (A^T A)^{-1} c}$ und $t_{n-s; 1-\frac{\alpha}{2}}$ das $\frac{\alpha}{2}$ -Fraktile der t_{n-s} -Verteilung ist.

- ③ Sind $q_- := \chi_{n-s; \frac{\alpha}{2}}^2$ und $q_+ := \chi_{n-s; 1-\frac{\alpha}{2}}^2$ die $\frac{\alpha}{2}$ bzw. $1 - \frac{\alpha}{2}$ -Quantile von χ_{n-s}^2 , so ist

$$C(\cdot) = \left((n-s) \frac{V^*}{q_+}, (n-s) \frac{V^*}{q_-} \right)$$

Man kann C durch das entsprechende abgeschlossene Intervall ersetzen, da die χ^2 -Verteilung eine stetige Dichte hat.

ein Konfidenzintervall für v zum Niveau α .

Beweis. ① Folgt aus Satz 6.3.1 ③, denn $\mathbb{P}(\frac{1}{sV^*} |A(\gamma - \hat{\gamma})|^2 < f_{s, n-s; 1-\alpha}) = 1 - \alpha$ nach Definition des Fraktils.

- ② Sei ohne Beschränkung der Allgemeinheit $c \neq 0$, denn für $c = 0$ ist $\tau \equiv 0$ und $C(\cdot) = \{0\}$ offenbar richtig. Nach Satz 6.3.1 ① ist $\hat{\gamma} \mathcal{N}(\gamma, v(A^T A)^{-1})$ -verteilt. Also ist $Z := c^T \hat{\gamma}$ normalverteilt mit $\mathbb{E}_\vartheta[Z] = c^T \mathbb{E}_\vartheta[\hat{\gamma}] = c^T \gamma = \tau(\gamma)$ und

$$\mathbb{E}_\vartheta[(Z - \mathbb{E}_\vartheta[Z])(Z - \mathbb{E}_\vartheta[Z])^T] = c^T \mathbb{E}_\vartheta[(\hat{\gamma} - \gamma)(\hat{\gamma} - \gamma)^T] c \stackrel{6.3.1 \text{ ①}}{=} c^T v(A^T A)^{-1} c.$$

Somit ist $Z \mathcal{N}(c^T \gamma, v c^T (A^T A)^{-1} c)$ -verteilt. Somit ist $Z^* := \frac{Z - \mathbb{E}_\vartheta[Z]}{\sqrt{\mathbb{V}_\vartheta[Z]}} = \frac{c^T(\hat{\gamma} - \gamma)}{\sqrt{v} \sqrt{c^T (A^T A)^{-1} c}}$ standardnormalverteilt. Sind Z^* und V^* unabhängig, dann sind es auch Z^* und $(n -$

$s) \frac{V^*}{v}$, welche χ^2_{n-s} -verteilt ist. Also ist $\frac{Z^*}{\sqrt{\frac{V^*}{v}}}$ t_{n-s} -verteilt. Dann folgt

$$\begin{aligned}
 \mathbb{P}_\vartheta(\tau(\gamma) \in C(\cdot)) &= \mathbb{P}_\vartheta(c^\top \hat{\gamma} - \delta\sqrt{V^*} \leq c^\top \gamma \leq c^\top \hat{\gamma} + \delta\sqrt{V^*}) \\
 &= \mathbb{P}_\vartheta(|c^\top(\hat{\gamma} - \gamma)| \leq \delta\sqrt{V^*}) \\
 &= \mathbb{P}_\vartheta\left(\frac{|Z - \tau(\gamma)|}{\sqrt{V^*}} \leq \delta\right) \\
 &= \mathbb{P}_\vartheta\left(\frac{|Z^*| \sqrt{vc^\top(A^\top A)^{-1}c}}{\sqrt{V^*}} \leq \delta\right) \\
 &= \mathbb{P}_\vartheta\left(\frac{|Z^*|}{\sqrt{\frac{V^*}{v}}} \leq \frac{\delta}{\sqrt{c^\top(A^\top A)^{-1}c}}\right) \\
 &= \mathbb{P}_\vartheta\left(\left|\frac{Z^*}{\sqrt{\frac{V^*}{v}}}\right| \leq t_{n-s;1-\frac{\alpha}{2}}\right) = 1 - \alpha.
 \end{aligned}$$

Es verbleibt, die Unabhängigkeit von Z^* und V^* zu zeigen. Aus (\diamond) folgt $\frac{n-s}{v}V^* = \sum_{k=s+1}^n \eta_k^2$. Es gilt

$$\begin{aligned}
 A\hat{\gamma} &= \pi_L X = \pi_L(A\gamma + \sqrt{v}\xi) = A\gamma + \sqrt{v}\pi_L \xi = A\gamma + \sqrt{v}\Gamma M_s \underbrace{\Gamma^\top \xi}_{=\eta} \\
 &= A\gamma + \sqrt{v}\Gamma(\eta_1, \dots, \eta_s, 0, \dots, 0)^\top.
 \end{aligned}$$

Es tauchen nur deterministische Größen auf, bis auf η_1, \dots, η_s . In V^* tauchen nur $\eta_{s+1}, \dots, \eta_n$ auf, also sind V^* und $A\hat{\gamma}$ unabhängig. Da A bijektiv und bimessbar (messbar und die Umkehrabbildung ist messbar) ist, sind auch $\hat{\gamma}$ und V^* unabhängig. Somit sind Z^* und V^* unabhängig.

③ Einfach. □

Korollar 6.3.2 (Hypothesentests im linearen GAUSS-Modell)

Sei $\alpha \in (0, 1)$.

- ① **t-Test für** $c^\top \gamma = m_0$. Der (zweiseitige) **t-Test** der Hypothese $H_0 : c^\top \gamma = m_0$ gegen $H_1 : c^\top \gamma \neq m_0$ mit Irrtumsniveau α hat den Ablehnungsbereich

$$\left\{ |c^\top \hat{\gamma} - m_0| > t_{n-s;1-\frac{\alpha}{2}} \sqrt{c^\top(A^\top A)^{-1}c\sqrt{V^*}} \right\},$$

und das gilt analog für den einseitigen Test $H_0 : c^\top \gamma \leq m_0$ gegen $H_1 : c^\top \gamma \geq m_0$.

- ② **F-Test von** $H_0 : A\gamma \in H$. Sei $H \subset L$ ein r -dimensionaler Unterraum. Ist $F_{H,L}$ wie in Satz 6.3.1 definiert, so definiert der Ablehnungsbereich

$$\{F_{H,L} > f_{s-r,n-s,1-\alpha}\}$$

einen Test zum Niveau α für die Hypothese $H_0 : A\gamma \in H$ gegen die Alternative $H_1 : A\gamma \notin H$.

- ③ **χ^2 -Test für die Varianz** v . Für $v_0 > 0$ definiert der Ablehnungsbereich

$$\{(n-s)V^* > v_0\chi^2_{n-s;1-\alpha}\}$$

einen Test zum Niveau α für $H_0 : v \leq v_0$ gegen $H_1 : v > v_0$.

Beweis. ① und ② sind klar durch Bemerkung 4.1.11.

③ Sei $0 < v \leq v_0$. Dann gilt

$$\begin{aligned} \mathbb{P}_\vartheta((n-s)V^* > v_0\chi_{n-s;1-\alpha}^2) &= \mathbb{P}_\vartheta\left((n-s)\frac{V^*}{v} > \underbrace{\frac{v_0}{v}}_{\geq 1} \chi_{n-s;1-\alpha}^2\right) \\ &\leq \mathbb{P}_\vartheta\left(\underbrace{(n-s)\frac{V^*}{v}}_{\sim \chi_{n-s}^2} > \chi_{n-s;1-\alpha}^2\right) = \alpha. \end{aligned}$$

□

Beispiel 6.3.3 (Motorleistung (Fortsetzung))

② Wir testen $H_0 : \gamma_1 \geq 10$ zum Niveau $\alpha = 0.05$. Für $H_0 : \binom{0}{1} \cdot \gamma \geq 10$ ist der Ablehnungsbereich $\left\{10 - \hat{\gamma}_1 > t_{6,0.95} \sqrt{\frac{1}{n} \frac{1}{V(t)}} V^*\right\}$, wobei $t_{6,0.95} \approx 1.943$. Es ist $V(t) \approx 2.56$ sowie

$$V^* = \frac{1}{6} \sum_{k=1}^8 (X_k - \gamma_0 - \gamma_1 t_k)^2 \approx 2.5$$

und somit $\sqrt{\frac{1}{n} \frac{1}{V(t)}} V^* \approx 0.35$. Da $10 - \hat{\gamma}_1 > 0.68$, wird H_0 abgelehnt.

③ Wir bestimmen einen Konfidenzbereich für γ_1 zum Irrtumsniveau $\alpha = 0.05$. Der Konfidenzbereich mit $c = (0, 1)^\top$ ist $C(x) = (\hat{\gamma}_2 - \delta\sqrt{V^*}, \hat{\gamma}_1 + \delta\sqrt{V^*})$, wobei $\delta = t_{6,0.975} \sqrt{\frac{1}{n} \frac{1}{V(t)}} \approx 2.447 \cdot 0.02$ ist. Also gilt

$$C(x) = (9.19 - 2.447 \cdot 0.35, 9.19 + 2.447 \cdot 0.35) \approx (8.33, 10.05).$$

◇

Beispiel 6.3.4 (GAUSS-Produktmodell: Mittelwert schätzen)

Seien $s = 1$, $A := \mathbf{1} \in \mathbb{R}^n$ und $\gamma = m \in \mathbb{R}$, dann können wir $X = A\gamma + \sqrt{v}\xi$ schreiben, wobei $\xi \mathcal{N}(0, \text{id}_n)$ -verteilt sind, das heißt $X_k = m + \sqrt{v}\xi_k$ für $k \in \{1, \dots, n\}$ sind unabhängig $\mathcal{N}(m, v)$ -verteilt.

Es gilt $\hat{\gamma} = \hat{m} = (A^\top A)^{-1} A^\top X$. Wegen $A^\top A = n$ folgt $\hat{m} = \frac{1}{n} \sum_{k=1}^n X_k$. Insbesondere ergibt sich aus Korollar 6.3.2 ① ein t -Test (mit $c = 1$) für die Hypothese $H_0 : m = m_0$ gegen die Alternative $H_1 : m \neq m_0$

◇

Beispiel 6.3.5 (Einfache lineare Regression)

Seien $s = 2$ sowie $A = (\mathbf{1}, t) \in \mathbb{R}^{n \times 2}$ für $t \in \mathbb{R}^n$, sodass $\mathbf{1}$ und t linear unabhängig sind. Ferner sei $V(t) := \frac{1}{n} \sum_{k=1}^n t_k^2 - M(t)^2$, wobei $M(t) := \frac{1}{n} \sum_{k=1}^n t_k$. Dann gilt

$$A^\top A = (\mathbf{1}, t)^\top (\mathbf{1}, t) = \begin{pmatrix} n & nM(t) \\ nM(t) & nM(t^2) \end{pmatrix}$$

und daher (cf. [2, Satz 6.1])

$$(A^\top A)^{-1} = \frac{1}{n^2 M(t^2) - n^2 M(t)^2} \begin{pmatrix} nM(t^2) & -nM(t) \\ -nM(t) & n \end{pmatrix} = \frac{1}{n} \frac{1}{V(t)} \begin{pmatrix} M(t^2) & -M(t) \\ -M(t) & 1 \end{pmatrix}$$

also

$$\begin{pmatrix} 0 & 1 \end{pmatrix} (A^\top A)^{-1} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \frac{1}{n} \frac{1}{V(t)}$$

und

$$\hat{\gamma} = (A^T A)^{-1} A^T X = \frac{1}{n} \frac{1}{V(t)} \begin{pmatrix} M(t^2) & -M(t) \\ -M(t) & 1 \end{pmatrix} \begin{pmatrix} \sum_{k=1}^n X_k \\ \sum_{k=1}^n t_k X_k \end{pmatrix} \quad \diamond$$

6.4 | Varianzanalyse

Siehe [2, Kap. 12.4], nicht relevant für die Juli-Prüfung.

19.07.2022

Appendix

A

Wiederholung: Gemeinsame Verteilung und Randverteilungen

25.05.2022

Sind X und Y Zufallsvariablen, so ist die Verteilung von (X, Y) die **gemeinsame Verteilung** und die Verteilung der einzelnen Variablen X und Y sind die **Randverteilungen**.

Aus der gemeinsamen Verteilung von (X, Y) kann man stets eindeutig die Randverteilungen von X und Y bestimmen. Sind die Randverteilungen gegeben, ist die gemeinsame Verteilung nicht eindeutig (bei Unabhängigkeit möglich).

Beispiel A.0.1 (Nichteindeutigkeit der gemeinsamen Verteilung)

Seien X und Y gleichverteilt auf $[0, 1]$. Es gibt viele Möglichkeiten, eine gemeinsame Verteilung zu wählen:

- ist $X(\omega) = Y(\omega)$, so gilt $\mathbb{P}[X \leq s, Y \leq t] = \mathbb{P}[X \leq \min(s, t)] = \min\{s, t\}$ für $s, t \in (0, 1)$.
- ist $X(\omega) = 1 - Y(\omega)$, so ist $\mathbb{P}[X \leq s, Y \leq t] = \mathbb{P}[1 - t \leq X \leq s] = \max\{0, s + t - 1\}$ für $s, t \in (0, 1)$.
- sind X und Y unabhängig, so ist $\mathbb{P}[X \leq s, Y \leq t] = \mathbb{P}[X \leq s]\mathbb{P}[Y \leq t] = st$ für $s, t \in (0, 1)$. \diamond

DEFINITION A.0.2 (RANDVERTEILUNG)

Seien X und Y reelle Zufallsvariablen, deren gemeinsame Verteilung bekannt ist. Die **Randverteilungen** sind

$$\mathbb{P}[X \in A] = \mathbb{P}[(X, Y) \in A \times \mathbb{R}] \quad \text{und} \quad \mathbb{P}[Y \in A] = \mathbb{P}[(X, Y) \in \mathbb{R} \times A].$$

In diskreten Fall (wenn X und Y \mathbb{N} -wertig sind), gilt

$$\mathbb{P}[X = k] = \sum_{j \in \mathbb{N}} \mathbb{P}[X = k, Y = j] \quad \text{und} \quad \mathbb{P}[Y = j] = \sum_{k \in \mathbb{N}} \mathbb{P}[X = k, Y = j].$$

Im absolut stetigen Fall mit gemeinsamer Dichte $f_{(X,Y)}$ gilt

$$f_X(x) = \int_{\mathbb{R}} f_{(X,Y)}(x, y) dy \quad \text{und} \quad f_Y(y) = \int_{\mathbb{R}} f_{(X,Y)}(x, y) dx.$$

Sind X und Y unabhängig, so gilt

$$\mathbb{P}[(X, Y) \in A \times B] = \mathbb{P}[X \in A] \times \mathbb{P}[Y \in B].$$

Wiederholung: Satz von BAYES und bedingte Verteilung

Für $A, B \subset \Omega$ mit $\mathbb{P}[A] > 0$ und $\mathbb{P}[B] > 0$ gilt

$$\mathbb{P}[A | B] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]} = \frac{\mathbb{P}[B | A]\mathbb{P}[A]}{\mathbb{P}[B]}.$$

Ist $\bigcup_{j \in I} A_j = \Omega$ eine Zerlegung, gilt auch

$$\mathbb{P}[A_k | B] = \frac{\mathbb{P}[B | A_k] \mathbb{P}[A_k]}{\sum_{j \in I} \mathbb{P}[B | A_j] \mathbb{P}[A_j]}.$$

Für Zufallsvariablen X und Y ist

$$\mathbb{P}[Y \in A | X \in B] = \frac{\mathbb{P}[Y \in A, X \in B]}{\mathbb{P}[X \in B]}$$

sozusagen der Quotient aus der gemeinsamen Verteilung und der Randverteilung.

Nimmt die diskrete Zufallsvariable Y die Werte $(y_i)_{i \in I}$ an, so gilt $(\sum_{i \in I} \mathbb{P}[Y = y_i] = 1$ und)

$$\mathbb{P}[Y = y_i | X \in B] = \frac{\mathbb{P}[X \in B | Y = y_i] \mathbb{P}[Y = y_i]}{\sum_{j \in I} \mathbb{P}[X \in B | Y = y_j] \mathbb{P}[Y = y_j]}.$$

Sind X und Y absolut stetig bezüglich des LEBESGUE-Maßes, so ist die **bedingte Dichte von X gegeben Y**

$$f_{X|Y}(x | y) := \frac{f_{(X,Y)}(x, y)}{f_Y(y)},$$

also sozusagen der Quotient der gemeinsamen Dichte und der Randdichte. Analog zum Satz von BAYES folgt

$$f_{X|Y}(x | y) = \frac{f_{Y|X}(y | x) f_X(x)}{\int_{\mathbb{R}} f_{Y|X}(y | z) f_X(z) dz}.$$

B

Wiederholung: Bedingte Wahrscheinlichkeit und Erwartungswert

Was ist $\mathbb{E}[X | Y] := \mathbb{E}[X | \sigma(Y)]$?

Wenn Y diskret ist, existieren $(p_i)_{i \in I}$ mit $\mathbb{P}(Y = y_i) > 0$ für alle $i \in I$ und $\sum_{i \in I} \mathbb{P}(Y = y_i) = 1$. Dann gilt $\mathbb{E}[X | Y](\omega) = \mathbb{E}[X | Y = y_i]$ wenn $Y(\omega) = y_i$.

Beispiel B.0.1 (Münzwurf)

Wir werfen eine faire Münze unabhängig. Seien Y das Ergebnis des ersten Wurfes und X die Anzahl der Versuch bis zum ersten Mal Kopf. Dann ist

$$\mathbb{E}[X | Y](\omega) = \begin{cases} 1, & \text{wenn } Y(\omega) = \text{Kopf,} \\ 1 + \mathbb{E}[X] = 3, & \text{wenn } Y(\omega) = \text{Zahl.} \end{cases}$$

◇

DEFINITION B.0.2 (BEDINGTE ERWARTUNG)

Seien $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, $G \subset \mathcal{F}$ eine σ -Algebra und $X \in L^1(\Omega)$. Die Zufallsvariable X_0 sodass gilt

- X_0 ist G -messbar,
- $\mathbb{E}[X_0 \mathbb{1}_A] = \mathbb{E}[X \mathbb{1}_A]$ für alle $A \in G$,

heißt **bedingte Erwartung von X gegeben G** und wir schreiben $X_0 = \mathbb{E}[X | G]$.

bedingte
Erwartung

Lemma B.0.3 (Eigenschaften der bedingten Erwartung)

- ① **Linearität:** $\mathbb{E}[aX + bY | G] = a \mathbb{E}[X | G] + b \mathbb{E}[Y | G]$,
- ② **Bekanntes rausziehen:** ist X G -messbar, so gilt $\mathbb{E}[XY | G] = X \cdot \mathbb{E}[Y | G]$,
- ③ **Unabhängigkeit:** sind X und Y unabhängig, so gilt $\mathbb{E}[X | \sigma(Y)] = \mathbb{E}[X]$,
- ④ **Konstanten:** ist $X = a \in \mathbb{R}$, dann ist $\mathbb{E}[X | G] = a$
- ⑤ **Monotonie:** ist $X \leq Y$, dann ist $\mathbb{E}[X | Y] \leq \mathbb{E}[Y | G]$.
- ⑥ **JENSENSche Ungleichung:** ist $f: \mathbb{R} \rightarrow \mathbb{R}$ konvex und $f(X) \in L^1$, dann gilt $f(\mathbb{E}[X | G]) \leq \mathbb{E}[f(X) | G]$.
- ⑦ **Turmeigenschaft:** Seien $H, G \subset \mathcal{F}$ σ -Algebren mit $H \subset G$, dann gilt

$$\mathbb{E}[\mathbb{E}[X | H] | G] = \mathbb{E}[\mathbb{E}[X | G] | H] = \mathbb{E}[X | H]$$

und insbesondere $\mathbb{E}[\mathbb{E}[X | G]] = \mathbb{E}[X]$.

Beispiel B.0.4 (Zweimaliger Würfelwurf)

Wir werfen zwei mal einen fairen Würfel. Seien X_j für $j \in \{1, 2\}$ das Ergebnis des j -ten Wurfs. Dann gilt

$$\mathbb{E}[X_1 + X_2 | X_1] \stackrel{\textcircled{1}}{=} \mathbb{E}[X_1 | X_1] + \mathbb{E}[X_2 | X_1] \stackrel{\textcircled{2}}{=} X_1 + \mathbb{E}[X_2] \stackrel{\textcircled{3}}{=} X_1 + \frac{7}{2}. \quad (34)$$

Der Erwartungswert der erwarteten Augensumme bei Kenntnis des ersten Wurfs ist somit

$$\mathbb{E}[\mathbb{E}[X_1 + X_2 \mid X_1]] \stackrel{(34)}{=} \mathbb{E}\left[X_1 + \frac{7}{2}\right] = 7 = \mathbb{E}[X_1 + X_2]. \quad \diamond$$

Letztlich ist $\mathbb{P}_\vartheta[A \mid \mathcal{B}]$ eine Zufallsvariable auf \mathfrak{X} und es gilt $\mathbb{P}_\vartheta[X \in A \mid \sigma(T)] = \mathbb{E}_\vartheta[\mathbb{1}_A(X) \mid \sigma(T)]$ beziehungsweise

$$\mathbb{P}_\vartheta[A \mid \sigma(T)] = \mathbb{E}_\vartheta[\mathbb{1}_A \mid \sigma(T)].$$

Übersicht: Modelle, Schätzer und deren Eigenschaften

	\mathfrak{X}	$\rho(x, \vartheta)$	τ	$T_n(x)$	\mathbb{E} -treu	UMVU	M Reg.	M exp.	T reg.	$T = ML$	Suff.	Vollst.	Konsist.
BERNOULLI	$\{0, 1\}$	$\vartheta^{n\hat{\mu}}(1 - \vartheta)^{1-n\hat{\mu}}$	$\text{id}_{[0,1]}$	$\hat{\mu}$	✓	✓	✗	✓, $\Theta = (0, 1)$	✓	✓	✓	✓	✓
Binomial	$\{0, \dots, n\}$	$\binom{n}{x}\vartheta^x(1 - \vartheta)^{n-x}$	$\text{id}_{[0,1]}$	$\frac{1}{n}x$	✓	✓	✗	✓, $\Theta = (0, 1)$	✓	✓	✓	✓	✓
Hypergeo.	$\{0, \dots, n\}$	$\frac{\binom{\vartheta}{x}\binom{N-\vartheta}{n-x}}{\binom{N}{n}} \mathbb{1}_{x \leq \vartheta}$	$\text{id}_{\{0, \dots, N\}}$	$x \frac{N}{n}$	✓		✗	✗	/	✗			
			$\text{id}_{\{0, \dots, N\}}$	$\begin{cases} N, & x = n \\ x \lfloor \frac{N+1}{n} \rfloor, & \text{sonst} \end{cases}$			✗	✗	/	✓			
POISSON	\mathbb{N}_0	$e^{-\vartheta} \frac{\vartheta^x}{x!}$	$\text{id}_{(0, \infty)}$	$\hat{\mu}$	✓	✓	✓	✓	✓	✓	✓	✓	✓
			$e^{-3\vartheta}$	$(-2)^x$	✓		✓			/			
Geometrisch	$\mathbb{N}_{>0}$	$\vartheta(1 - \vartheta)^{x-1}$	$\text{id}_{[0,1]}$	$\frac{1}{x}$	✗		✗		/	✓			
	\mathbb{N}_0	$\vartheta(1 - \vartheta)^{n\hat{\mu}}$	$\text{id}_{[0,1]}$	$\hat{\mu}$							✓		
Game show	$[0, \infty)$	$\mathcal{U}_{[0, \vartheta]}$	$\text{id}_{(0, \infty)}$	$x_{(n)}$	✗	✗	✗	✗	/	✓			✓
				$\frac{n+1}{n}x_{(n)}$	✓	✓							✓
				$2\hat{\mu}$	✓		✗	✗	/	✗			✓
				$e \left(\prod_{k=1}^n x_k \right)^{\frac{1}{n}}$	✓								✓
Exponentiell	$(0, \infty)$	$\vartheta e^{-\vartheta x}$	$\frac{1}{\text{id}_{(0, \infty)}}$	$\hat{\mu}$	✓	✓	✓	✓	✓	/			✓
			id	$\frac{1}{\hat{\mu}}$	✗					✓			
Verschob. Exp.	\mathbb{R}	$e^{\vartheta-x} \mathbb{1}_{[\vartheta, \infty)}(x)$	$\text{id}_{\mathbb{R}}$	$x_{(1)}$	✗	✗	✗	✗		✓			✓
GAUSS I	\mathbb{R}	$\mathcal{N}_{m, \vartheta}$	$\sqrt{\text{id}_{(0, \infty)}}$	$\sqrt{\frac{\pi}{2}} \frac{1}{n} \sum_{k=1}^n x_k - m $	✓				✓	/			
			$\text{id}_{(0, \infty)}$	$\frac{1}{n} \sum_{k=1}^n (x_k - m)^2$	✓	✓	✓	✓	✓	✓	✓	✓	
GAUSS II	\mathbb{R}	\mathcal{N}_{ϑ}	$\text{id}_{\mathbb{R} \times (0, \infty)}$	$(\hat{\mu}, \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2)$	✗	✓	✓	(✓)		✓			
		$n > 1$	$\text{id}_{\mathbb{R} \times (0, \infty)}$	$(\hat{\mu}, \frac{1}{n-1} \sum_{k=1}^n (x_k - \hat{\mu})^2)$	✓	✓	✓	(✓)		✗			
GAUSS III	\mathbb{R}	$\mathcal{N}_{\vartheta, \sigma^2}$	$\text{id}_{\mathbb{R}}$	$\hat{\mu}$	✓	✓	✓	✓	✓	✓	✓	✓	✓
Gleichverteilung	\mathbb{R}	$\mathcal{U}_{[\vartheta - \frac{1}{2}, \vartheta + \frac{1}{2}]}$	$\text{id}_{\mathbb{R}}$	$\frac{1}{2} (x_{(1)} + x_{(n)})$	✓	✗	✗	✗	/	✓			
			$\text{id}_{\mathbb{R}}$	$\hat{\mu}$	✓	✗	✗	✗	/	✓			✓
LAPLACE	\mathbb{R}	$\frac{1}{2} e^{\vartheta-x}$	$\text{id}_{\mathbb{R}}$	$\text{Median}(x_1, \dots, x_{n=2m})$	✓	✓	✓	✓	✓	✓	✓	✓	
Pareto	$[k, \infty)$	$z \mapsto \vartheta k^{\vartheta} z^{-\vartheta-1}$	$\text{id}_{(0, \infty)}$	$\left(\frac{1}{n} \sum_{j=1}^n \ln(x_j) - \ln(k) \right)^{-1}$	✗	✗	✓	✗	✗?	✓			

Tabelle 4: Überblick über die statistischen Standardmodelle $M = (\mathfrak{X}, \mathcal{F}, (\mathbb{P}_{\vartheta})_{\vartheta \in \Theta})$ mit Kenngröße τ und Schätzer T für τ . Wir betrachten meist das n -fache Produktmodell von M für $n \geq 1$. Für diskrete Modelle ist $\mathcal{F} = \mathcal{P}(\mathfrak{X})$ und für stetige $\mathcal{F} = \mathcal{B}(\mathfrak{X})$. Letztlich ist $\hat{\mu} := \frac{1}{n} \sum_{k=1}^n x_k$ der empirische Mittelwert. Ist M exponentiell bezüglich T , so sind M und T regulär und T ist UMVU, suffizient und vollständig.

Index

A

a-posteriori Verteilung	46
a-priori Verteilung	46
Ablehnungsbereich	63
absolut stetig	10
asymptotisch erwartungstreu	8

B

BAYES-Schätzer	48
bedingte Erwartung	104
bester Schätzer	17
bester Test	65
Betaverteilung	59
Bias	3

C

χ^2 -Anpassungstest	78
χ^2 -Verteilung	60

E

empirische Varianz	13, 38, 61, 94
empirische Verteilungsfunktion	5
empirischer Mittelwert	4, 6, 13, 38, 61
erwartungstreu	3
exponentielles Modell	24

F

Fehler erster Art	63
Fehler zweiter Art	63
FISHER-Information	20
FISHER-Verteilung	61

G

Gammaverteilung	59
Gütefunktion	63

K

Konfidenzbereich	53
------------------------	----

konsistent	38
------------------	----

L

Likelihood-Quotient	66
Likelihoodfunktion	10
lineares Modell	93
Loglikelihoodfunktion	11

M

Maximum-a-posteriori-Schätzer	51
Maximum-Likelihood-Schätzer	10

N

Nullhypothese	63
---------------------	----

O

Ordnungsstatistik	85
-------------------------	----

P

Produktmodell	4
---------------------	---

Q

Quantil	85
---------------	----

R

Rangstatistik	87
regulär	19, 21
relative Entropie	41
Risiko	3

S

Schätzer	3
Scorefunktion	20
Standardmodell	10
Statistik	3
statistisches Modell	3
STUDENT t -Verteilung	61
suffizient	29

INDEX

T

Test 63

U

U-Statistik 87

unimodal 42

unverfälscht 65

V

vollständig 34

W

wachsende Likelihoodquotienten 69

Literatur

- [1] Breiman, Leo: [Statistics: with a View Toward Applications](https://books.google.de/books?id=xJsZAQAAIAAJ). Houghton Mifflin, 1973, ISBN 9780395042328. <https://books.google.de/books?id=xJsZAQAAIAAJ>.
- [2] Georgii, Hans Otto: [Stochastik](https://doi.org/10.1515/9783110215274). de Gruyter, 3. Auflage, 2007. <https://doi.org/10.1515/9783110215274>.
- [3] Rüschemdorf, Ludger: [Mathematische Statistik](https://doi.org/10.1007/978-3-642-41997-3), Band 62 der Reihe [Masterclass](#). Springer Spektrum Berlin, Heidelberg, 1. Auflage, 2014. <https://doi.org/10.1007/978-3-642-41997-3>.
- [4] Scheutnow, Michael: [Wahrscheinlichkeitstheorie I Skript](#).