



TECHNISCHE UNIVERSITÄT BERLIN

SKRIPT ZUR VORLESUNG, ÜBUNG UND  
TUTORIUM

# Wahrscheinlichkeitstheorie I

gelesen von Prof. Dr. Wilhelm Stannat im  
Sommersemester 2019




Abb. 1: Würfel. [Quelle:Wiki]

---

# INHALTSVERZEICHNIS

<b>SECTION</b>	<b>MATHEMATISCHE MODELLIERUNG VON ZUFALLSEXPERIMENTEN</b>	<b>SEITE 1</b>
	1.1 Axiomatischer Aufbau der Wahrscheinlichkeitstheorie . . . . .	1
	1.2 Diskrete Wahrscheinlichkeitsräume . . . . .	6
	1.3 Stetige Wahrscheinlichkeitsräume . . . . .	11
<b>SECTION</b>	<b>BEDINGTE WAHRSCHEINLICHKEIT UND UNABHÄNGIGKEIT</b>	<b>SEITE 13</b>
	2.1 Bedingte Wahrscheinlichkeit . . . . .	13
	2.2 Unabhängigkeit . . . . .	17
	2.3 Produktwahrscheinlichkeitsräume . . . . .	19
<b>SECTION</b>	<b>ZUFALLSVARIABLEN UND VERTEILUNGEN</b>	<b>SEITE 22</b>
	3.1 Grundlegende Konzepte . . . . .	22
	3.2 Diskrete Verteilungen . . . . .	26
	3.3 Stetige Verteilung . . . . .	32
	3.4 Gemeinsame Verteilung und Unabhängigkeit von Zufallsvariablen . . . . .	34
	3.5 Erwartungswert und Varianz reellwertiger Zufallsvariablen . . . . .	36
<b>SECTION</b>	<b>ERZEUGENDEN &amp; CHARAKTERISTISCHE FUNKTIONEN</b>	<b>SEITE 41</b>
	4.1 Erzeugenden Funktionen . . . . .	41
	4.2 Charakteristische Funktionen . . . . .	45
<b>SECTION</b>	<b>GESETZE DER GROSSEN ZAHLEN</b>	<b>SEITE 47</b>
	5.1 MARKOVsche Ungleichung . . . . .	47
	5.2 Das schwache Gesetz der großen Zahlen . . . . .	48
	5.3 Das starke Gesetz der großen Zahlen . . . . .	49

---

<b>SECTION</b>	<b>DER ZENTRALE GRENZWERTSATZ</b>	<b>SEITE 52</b>
<b>SECTION</b>	<b>MULTIVARIATE VERTEILUNGEN</b>	<b>SEITE 53</b>
	7.1 Die Multivariate Normalverteilung.....	54
<b>SECTION</b>	<b>MARKOV-KETTEN</b>	<b>SEITE 57</b>
	8.1 Irreduzibilität .....	61
	8.2 Stationäre Verteilungen.....	64
	8.3 Der Konvergenzsatz für MARKOV-Ketten auf endlichen Zustands- räumen.....	68
<b>SECTION</b>	<b>APPENDIX</b>	<b>SEITE 71</b>
	A.1 Maßtheoretische Grundlagen.....	71
	A.2 Rechnungen.....	76
	A.3 Übersicht über die Verteilungen .....	82
	A.4 Nützliche Identitäten .....	83
	A.5 Klausuraufgaben .....	84

Mitschrift von Viktor Glombik.

Zuletzt geändert am 9. Oktober 2020.

# Mathematische Modellierung von Zufallsexperimenten

## 1.1 Axiomatischer Aufbau der Wahrscheinlichkeitstheorie

Unter einem **Zufallsexperiment** versteht man einen zeitlich und örtlich festgelegten Vorgang mit **unbestimmtem Ausgang**. Beispiele hierfür sind

- Werfen eines Würfels oder einer Münze,
- zufälliges Ziehen von Kugeln aus einer Urne,
- Kartenspiele,
- Wahlergebnis der nächsten Europawahl,
- Temperatur auf dem Alexanderplatz am 11. April 2019, 12:00,
- Lebensdauern.

### DEFINITION 1.1.1 (ERGEBNIS, ERGEBNISRAUM)

Die Gesamtheit aller möglichen Ausgänge eines Zufallsexperiments heißt **Ergebnisraum**. Seine Elemente heißen **Ergebnisse** und stellen einen möglichen Ausgang des Zufallsexperiments dar.

11.04.2019:  
Zufallsexperiment

Ergebnisraum

### Beispiel 1.1.2 (diskrete und kontinuierliche Ergebnisräume)

Beim  $k$ -maligen Würfeln ist der Ergebnisraum  $\Omega := \{1, \dots, 6\}^k$ , es gilt  $|\Omega| = 6^k$ . Bei der Temperatur an einem bestimmten Ort zu einer festgelegten Zeit bietet sich  $\Omega := [10, 30]$  an.  $\diamond$

### DEFINITION 1.1.3 ((ELEMENTAR)EREIGNIS)

Teilmengen  $A \subset \Omega$  heißen **Ereignisse**. Die Gesamtheit der Ereignisse ist somit  $\mathcal{P}(\Omega)$ . Wir nennen  $\Omega$  das **sichere** und  $\emptyset$  das **unmögliche Ereignis**. Die Menge  $\{\omega\}$  nennt man **Elementarereignis**.

Ereignis

Elementarereignis

**Bemerkung 1.1.4** Elementarereignisse sind keine Ergebnisse!

**Beispiel 1.1.5 (Ereignisse)** Die Menge  $\{1, 3, 5\}$  bezeichnet das Ereignis „ungerade Augenzahl“, die Menge  $[40, \infty)$  eine hohe Temperatur.  $\diamond$

Der Satz A.1.1 zeigt, dass es im Allgemeinen unmöglich ist, jedem Ereignis  $A \in \mathcal{P}(\Omega)$  in konsistenter Weise eine Wahrscheinlichkeit zuzuordnen. Deshalb schränkt man sich auf kleinere Mengensysteme  $\mathcal{A} \subset \mathcal{P}(\Omega)$  ein,

Seien $(A_k)_{k=1}^n \subset \mathcal{P}(\Omega)$ Ereignisse.	
Sprache der Ereignisse	Mengenschreibweise
$\bigcup_{k=1}^n A_k$	mind. ein $A_k$ tritt ein
$\bigcap_{k=1}^n A_k$	alle $A_k$ treten ein
$A^c$	$A$ tritt nicht ein
$A \subset B$	$A$ impliziert $B$

Abb. 2: Mengenoperation auf Ereignissen

welche unter den in Abb. 2 genannten Mengenoperationen abgeschlossen sind, die  $\sigma$ -Algebren.

## Wahrscheinlichkeiten

Wir wollen für jedes messbare Ereignis  $A \in \mathcal{A}$  eine Wahrscheinlichkeit  $\mathbb{P}(A) \in [0, 1]$  festlegen, welche ein Maß dafür sein soll, dass  $A$  eintritt; tritt  $A$  niemals (sicher) ein, so setzt man  $\mathbb{P}(A) = 0$  ( $= 1$ ). Insbesondere gilt  $\mathbb{P}(\emptyset) = 0$  und  $\mathbb{P}(\Omega) = 1$ .

Zusätzlich soll für disjunkte Ereignisse  $A$  und  $B$

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) \quad (\text{Additivität})$$

gelten. Daraus folgt unmittelbar für eine Familie  $(A_k)_{k=1}^n$  paarweise disjunkter Ereignisse

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n \mathbb{P}(A_k). \quad (\text{endliche Additivität})$$

Gilt für jede abzählbare Familie paarweise disjunkter Ereignisse  $(A_k)_{k \in \mathbb{N}}$

$$\mathbb{P}\left(\bigcup_{k \in \mathbb{N}} A_k\right) = \sum_{k \in \mathbb{N}} \mathbb{P}(A_k), \quad (\text{abzählbare / } \sigma\text{-Additivität})$$

so heißt  $\mathbb{P}$  Wahrscheinlichkeitsmaß:

### DEFINITION 1.1.6 (KOLMOGOROVSCHE AXIOME, 1933)

Sei  $(\Omega, \mathcal{A})$  ein **Messraum**. Eine Abbildung  $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$  heißt **Wahrscheinlichkeitsmaß** auf  $\mathcal{A}$ , falls sie normiert und  $\sigma$ -additiv ist.

**Bemerkung** Ein Wahrscheinlichkeitsmaß kann als Verallgemeinerung der relativen Häufigkeit gesehen werden. [Mehr dazu im anderen Skript, todo]

### DEFINITION 1.1.7 (WAHRSCHEINLICHKEITSRAUM)

Sei  $\Omega$  eine nichtleere Menge,  $\mathcal{A}$  eine  $\sigma$ -Algebra auf  $\Omega$  und  $\mathbb{P}$  ein **Wahrscheinlichkeitsmaß** auf  $\mathcal{A}$ . Dann heißt das Tripel  $(\Omega, \mathcal{A}, \mathbb{P})$  **Wahrscheinlichkeitsraum**.

Sei im Folgenden  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum.

### DEFINITION 1.1.8 (STETIGKEIT VON MASSEN)

Seien  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum,  $(A_k)_{k \in \mathbb{N}} \subset \mathcal{A}$  und  $A \in \mathcal{A}$ .

$\sigma$ -Algebren

$$\begin{aligned} \mu(\text{Kreis}) &= \mu(\text{Kreis}_1) + \mu(\text{Kreis}_2) \\ &\quad + \mu(\text{Kreis}_3) \\ \mu(\text{Rechteck}) &= \mu(\text{Rechteck}_1) + \mu(\text{Rechteck}_2) \\ &\quad + \mu(\text{Rechteck}_3) + \dots \end{aligned}$$

Abb. 3: endliche und abzählbare Additivität  
[Quelle: Wiki]

Messraum

Wahrscheinlichkeitsmaß

Wahrscheinlichkeitsraum

Gilt  $A_1 \subset A_2 \subset \dots$  und  $A = \bigcup_{n \in \mathbb{N}} A_n$ , so folgt  $\mathbb{P}(A_n) \xrightarrow{n \rightarrow \infty} \mathbb{P}(A)$  ( $\sigma$ -stetig von unten).

Gilt  $A_1 \supset A_2 \supset \dots$ ,  $\mathbb{P}(A_1) < \infty$  und  $A = \bigcap_{k \in \mathbb{N}} A_k$ , so folgt  $\mathbb{P}(A_n) \xrightarrow{n \rightarrow \infty} \mathbb{P}(A)$  ( $\sigma$ -stetig von oben).

### Lemma 1.1.9 (Eigenschaften von $\mathbb{P}$ )

Jedes Wahrscheinlichkeitsmaß ist endlich additiv, monoton, subadditiv und stetig von oben / unten. Es gilt  $\mathbb{P}(\emptyset) = 0$  und  $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ .

### Beispiel 1.1.10 (Erste Wahrscheinlichkeiten: Würfeln)

Beim einmaligen (zweimaligen) fairen Würfeln ist jede der sechs (36) möglichen Augenzahlen gleich wahrscheinlich.

Man setzt daher  $\mathbb{P}(\{\omega\}) := \frac{1}{6}$  ( $:= \frac{1}{36}$ ) für  $\omega \in \Omega := \{1, \dots, 6\}^{(2)}$ . Die Wahrscheinlichkeit, eine ungerade Zahl zu Würfeln ist  $3 \cdot \frac{1}{6} = \frac{1}{2}$  und, dass die Augensumme größer als zehn ist,  $3 \cdot \frac{1}{36} = \frac{1}{12}$ .  $\diamond$




Abb. 4: Wahrscheinlichkeitsverteilung beim zweimaligen fairen Würfeln.

### Satz 1.1.1: EINSCHLUSS-AUSSCHLUSS-PRINZIP

Für  $(A_k)_{k=1}^n \subset \mathcal{A}$  gilt die **Siebformel von SYLVESTER**:

$$\begin{aligned} \mathbb{P}\left(\bigcup_{k=1}^n A_k\right) &= \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I} A_k\right) \\ &= \sum_{j=1}^n (-1)^{j+1} \sum_{1 \leq i_1 \leq \dots \leq i_j \leq n} \mathbb{P}\left(\bigcap_{k=1}^j A_{i_k}\right) \end{aligned}$$

**Beweis.** Wir beweisen mittels vollständiger Induktion über  $n \in \mathbb{N}_{>1}$ .

Induktionsanfang:  $n = 2$ . Da  $A_1 \cup A_2 = A_1 \sqcup (A_2 \setminus A_1)$  und  $A_2 = (A_2 \setminus A_1) \sqcup (A_2 \cap A_1)$  disjunkte Zerlegungen sind, gilt aufgrund der **Additivität**

$$\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2 \setminus A_1) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2).$$

Induktionsschritt:  $n \rightarrow n + 1$ . Es gilt

$$\begin{aligned} \mathbb{P}\left(\bigcup_{k=1}^{n+1} A_k\right) &= \mathbb{P}\left(\bigcup_{k=1}^n A_k\right) + \mathbb{P}(A_{n+1}) - \mathbb{P}\left(\left(\bigcup_{k=1}^n A_k\right) \cap A_{n+1}\right) \\ &= \mathbb{P}\left(\bigcup_{k=1}^n A_k\right) + \mathbb{P}(A_{n+1}) - \mathbb{P}\left(\bigcup_{k=1}^n (A_k \cap A_{n+1})\right). \end{aligned}$$

Nach Induktionsannahme gilt

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I} A_k\right)$$




Abb. 5: Visualisierung der Formel von SYLVESTER für  $n = 3$ . [Quelle: Wiki]

und

$$\begin{aligned} \mathbb{P}\left(\bigcup_{k=1}^n (A_k \cap A_{n+1})\right) &= \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I} (A_k \cap A_{n+1})\right) \\ &= \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I \cup \{n+1\}} A_k\right). \end{aligned}$$

Einsetzen ergibt

$$\begin{aligned} \mathbb{P}\left(\bigcup_{k=1}^{n+1} A_k\right) &= \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I} A_k\right) + \mathbb{P}(A_{n+1}) \\ &\quad - \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I \cup \{n+1\}} A_k\right) \\ &= ?? \\ &= \sum_{\substack{I \subset \{1, \dots, n+1\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I} A_k\right). \quad \square \end{aligned}$$

**Bemerkung (V)** Der Satz gilt sogar für **endliche Inhalte**  $\mathbb{P}$  auf **Ring**en.

### Beispiel 1.1.11 (Anwendung: Fixpunktfreie Permutation)

Es treffen sich  $n \in \mathbb{N}$  Studenten und legen ihre Jacken auf einen Haufen. Vor dem Heimweg nimmt jeder zufällig eine Jacke. Wie groß ist die Wahrscheinlichkeit, mindestens einer der Studenten seine eigene Jacke bekommt?

Sei  $\mathcal{N} := \{1, \dots, n\}$ . Wir wählen den Wahrscheinlichkeitsraum

$$\Omega := \{(\varphi(k))_{k \in \mathcal{N}} : \varphi : \mathcal{N} \rightarrow \mathcal{N} \text{ bijektiv}\}, \quad \mathcal{A} := \mathcal{P}(\Omega)$$

und die Gleichverteilung  $\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$ ,  $A \mapsto \frac{|A|}{|\Omega|}$ . Dann gilt  $|\Omega| = n!$ .

Definiere nun für  $i \in \mathcal{N}$  die Ereignisse

$$A_i := \{\text{Student } i \text{ geht mit seiner Jacke nach Hause}\} = \{\varphi(i) = i\}$$

Nach dem obigen Satz gilt (vgl. Abb. 2) ist die Wahrscheinlichkeit, dass mindestens einer der Studenten seine eigene Jacke bekommt,

$$\begin{aligned} \mathbb{P}\left(\bigcup_{i \in \mathcal{N}} A_i\right) &= \sum_{\substack{I \subset \{1, \dots, n\} \\ I \neq \emptyset}} (-1)^{|I|-1} \mathbb{P}\left(\bigcap_{k \in I} A_k\right) \\ &\stackrel{(*)}{=} \sum_{j=1}^n (-1)^{j-1} \binom{n}{j} \mathbb{P}\left(\bigcap_{k=1}^j A_k\right) \\ &= \sum_{j=1}^n (-1)^{j-1} \binom{n}{j} \prod_{k=1}^j \frac{1}{(n-k+1)} \\ &= \sum_{j=1}^n \frac{(-1)^{j-1}}{j!} \xrightarrow{n \rightarrow \infty} 1 - \frac{1}{e} \approx 63.21\%, \end{aligned}$$




Abb. 6: Die linken Wahrscheinlichkeiten für  $n \leq 12$ . [Quelle: WolframAlpha]

wobei wir in  $(\star)$  benutzen, dass die Wahrscheinlichkeiten aller Schnittmengen mit derselben Anzahl an Teilmengen gleich sind.  $\diamond$



## 1.2 Diskrete Wahrscheinlichkeitsräume

Ist  $\Omega$  höchstens abzählbar also diskret, so ist jede Teilmenge

diskret

$$A := \{\omega_1, \dots\} = \bigcup_{n \in \mathbb{N}} \{\omega_n\} \subset \Omega$$

abzählbar und somit eine abzählbare Vereinigung von Elementarereignissen. Deswegen ist für diskrete Wahrscheinlichkeitsräume deren Potenzmenge die natürliche  $\sigma$ -Algebra.

Für ein Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $\Omega$  kann man

$$\mathbb{P}(A) = \sum_{n \in \mathbb{N}} \mathbb{P}(\{\omega_n\}) = \sum_{\omega \in A} \mathbb{P}(\{\omega\}).$$

als absolut konvergente Reihe darstellen.

### DEFINITION 1.2.1 (ZÄHLDICHTE, ENGL.: PMF)

Sei  $\Omega$  diskret. Eine Funktion  $p : \Omega \rightarrow [0, 1]$  mit der Eigenschaft

engl.: probability mass function

$$\sum_{\omega \in \Omega} p(\omega) = 1. \quad (1)$$

heißt Zähl-dichte bzw. Wahrscheinlichkeitsfunktion.

Zähl-dichte

Durch

$$p : \Omega \rightarrow [0, 1], \omega \mapsto \mathbb{P}(\{\omega\})$$

erhalten wir aus  $\mathbb{P}$  eine Zähl-dichte auf  $\Omega$ . Eine einfache Methode zur Konstruktion von Wahrscheinlichkeitsmaßen auf diskreten Wahrscheinlichkeitsräumen mittels Funktionen mit Eigenschaft (1) liefert der

### SATZ 1.2.1: 1-1-BEZIEHUNG ZWISCHEN ZÄHLDICHTEN UND WAHRSCHEINLICHKEITSMASSEN

Seien  $\Omega$  diskret und  $p$  eine Zähl-dichte. Dann definiert

$$\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1], A \mapsto \sum_{\omega \in A} p(\omega)$$

ein Wahrscheinlichkeitsmaß auf  $\mathcal{P}(\Omega)$  und heißt Verteilung auf  $\Omega$ .

**Beweis.** Die Nichtnegativität und Normiertheit sind klar, also bleibt nur die  $\sigma$ -Additivität nachzuweisen. Seien

$$(A_n := (\omega_{nk})_{k=1}^{|A_n|+1})_{n \in \mathbb{N}} \subset \mathcal{P}(\Omega)$$

paarweise disjunkt. Dann ist

$$\{\omega_{nk} : n \in \mathbb{N}, k \in \{1, \dots, |A_n| + 1\}\}$$

eine Aufzählung aller Elemente von  $A := \bigcup_{n \in \mathbb{N}} A_n$ , wobei jedes Element aus  $A$  genau einmal aufgezählt wird, da die Ereignisse  $A_n$  paarweise disjunkt sind. Dann folgt

$$\mathbb{P}(A) = \sum_{\omega \in A} p(\omega) = \sum_{n \in \mathbb{N}} \sum_{k=1}^{|A_n|+1} p(\omega_{nk}) = \sum_{n \in \mathbb{N}} \sum_{\omega \in A_n} p(\omega) = \sum_{n \in \mathbb{N}} \mathbb{P}(A_n). \quad \square$$

Zur vollständigen Beschreibung des Wahrscheinlichkeitsraums genügt also *im diskreten Fall* die Angabe von  $(\Omega, p)$ .

**Beispiel 1.2.2 (*n*-facher Münzwurf)** Für  $\mathcal{N} := \{1, \dots, n\}$  wählen wir

$$\Omega := \{(i_k)_{k \in \mathcal{N}} : i_j \in \{0, 1\}, j \in \mathcal{N}\} = \{0, 1\}^n,$$

wobei wir 0 als Kopf und 1 als Zahl interpretieren. Da alle Ergebnisse gleich wahrscheinlich sind, setzen wir

$$p(\omega) = \frac{1}{|\Omega|} = 2^{-n}.$$

Für  $k \in \mathcal{N}$  ist die Wahrscheinlichkeit im  $k$ -ten Wurf Kopf zu werfen durch

$$\frac{|\{(i_1, \dots, i_{k-1}, 0, i_{k+1}, \dots, i_n) : i_j \in \{0, 1\}, j \in \mathcal{N}\}|}{2^n} = \frac{2^{n-1}}{2^n} = \frac{1}{2}$$

gegeben.  $\diamond$

Das obige Beispiel ist Spezialfall eines

### DEFINITION 1.2.3 (LAPLACE-WAHRSCHEINLICHKEITSRAUM)

Sei  $\Omega$  endlich. Dann heißt das durch  $\mathbb{P}(A) = \frac{|A|}{|\Omega|}$  definierte Wahrscheinlichkeitsmaß auf  $\mathcal{P}(\Omega)$  **Gleichverteilung** auf  $\Omega$ .

(Man sagt,  $\mathbb{P}$  werde durch die Zähldichte  $p : \Omega \rightarrow [0, 1]$ ,  $\omega \mapsto \frac{1}{|\Omega|}$  induziert.)

Die Berechnung von  $\mathbb{P}(A)$  führt auf **Abzählprobleme**, deren wichtigste Vertreter wir anhand einfacher Urnenmodelle illustrieren:

### Beispiel 1.2.4 (Abzählprobleme mit Urnen)

Eine Urne enthält mit den Zahlen  $1, \dots, n$  beschriftete Kugeln, von denen wir  $k \leq n$  ziehen. Sei  $\mathcal{N} := \{1, \dots, n\}$ .

① **in Reihenfolge mit Zurücklegen.** Wir setzen

$$\Omega := \{(x_1, \dots, x_k) \subset \mathcal{N}^k\}.$$

Dann gilt  $|\Omega| = n^k$ .

② **in Reihenfolge ohne Zurücklegen.** Wir setzen

$$\Omega := \{(x_1, \dots, x_k) \subset \mathcal{N}^k, x_i \neq x_j \text{ für } i \neq j\}.$$




Abb. 7: Zähldichte einer diskreten Gleichverteilung. [Quelle: Wiki]

**Gleichverteilung**

**Abzählproblem**

Dann gilt

$$|\Omega| = n \cdot (n-1) \cdot \dots \cdot (n-k+1) = \frac{n!}{(n-k)!}.$$

Für  $k = n$  erhält man den Spezialfall  $|\Omega| = n!$ , welche also die Anzahl aller **Permutationen** von  $\mathcal{N}$  angibt.

Permutationen

③ **ohne Reihenfolge mit Zurücklegen.** Wir setzen

$$\Omega := \{\{x_1, \dots, x_k\} \subset \mathcal{N}^k, x_i \neq x_j \text{ für } i \neq j\}.$$

Im Unterschied zum Ziehen unter Beachtung der Reihenfolge werden alle  $k!$  Stück  $k$ -Tupel, welche zu der selben Menge an Kugeln führen, zu einem Elementarereignis zusammengefasst. Also gilt

$$|\Omega| = \frac{1}{k!} \frac{n!}{(n-k)!} =: \binom{n}{k},$$

was genau der Anzahl aller  $k$ -elementigen Teilmengen einer  $n$ -elementigen Grundmenge entspricht.

Eine alternative Darstellung von  $\Omega$  erhält man, da es unter allen  $k$ -Tupeln, welche zur selben Menge führen, genau eines gibt, in welchem die Elemente ihrer Größe nach geordnet sind:

$$\Omega = \{(x_1, \dots, x_k) \subset \mathcal{N}^k, x_i < x_{i+1} \forall i \in \{1, \dots, k-1\}\}.$$

④ **ohne Reihenfolge ohne Zurücklegen.**

Analog zum vorherigen Fall ordnen wir wieder die Nummern der gezogenen Kugeln der Größe nach an:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(k)} \quad (2)$$

wobei wegen des Zurücklegens Kugeln mehrfach gezogen werden können. Durch den (bijektiven) Übergang von  $x_{(i)}$  zu  $x_{(i)} + i - 1$  erhält man aus (2) eine streng monoton aufsteigende Folge

$$x_{(1)} \leq x_{(2)} + 1 \leq x_{(3)} + 2 \leq \dots \leq x_{(k)} + k - 1.$$

Wir erhalten also

$$\Omega := \{(x_1, \dots, x_k) : \subset \{1, \dots, n+k-1\}^k, x_i < x_{i+1} \forall i \in \{1, \dots, k-1\}\}$$

und somit nach ③  $|\Omega| = \binom{n+k-1}{k}$ .

[König-Skript] Alternativ kann man die Formel auch so herleiten: *Wie viele Möglichkeiten gibt es,  $k$  ununterscheidbare Murmeln auf  $n$  Zellen zu verteilen?* Seien die  $k$  Murmeln in einer Reihe gelegt. Sie in  $n$  Zellen einzuteilen ist äquivalent dazu,  $n-1$  Trennwände zwischen die  $k$  Murmeln zu setzen. Dadurch erhalten wir eine Reihe von  $n+k-1$  Objekten, und nach ③ gibt es  $\binom{n+k-1}{n}$  Möglichkeiten, diese anzuordnen.  $\diamond$




Abb. 8: Graphen der verschiedenen Urnenmodelle (stetig fortgesetzt).

Eine Anwendung ist der

### SATZ 1.2.2: BINOMISCHER LEHRSATZ

Für Elemente  $x, y$  eines kommutativen unitären Rings gilt

$$(x + y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}, \quad n \in \mathbb{N}.$$

**Beweis.** Schreibe  $(x + y)^n = \prod_{k=1}^n (x_k + y_k)$  mit  $x_i = x$  und  $y_i = y$ . Beim Ausmultiplizieren tritt der Term  $x^k y^{n-k}$  immer dann auf wenn in  $k$  Klammern der Faktor  $x_i$  und in  $n - k$  Klammern der Faktor  $y_i$  gewählt wird, also nach ③ in  $\binom{n}{k}$  Fällen.  $\square$

### Korollar 1.2.5

Es gilt  $\sum_{k=0}^n \binom{n}{k} = 2^n$ ,  $\sum_{k=0}^n (-1)^k \binom{n}{k} = 0$  und  $\sum_{k=0}^n k \binom{n}{k} = n2^{n-1}$ .

### Beispiel 1.2.6 (Anwendung Abzählprobleme: Paar Schuhe)

In einem Karton befinden sich  $n$  Paar Schuhe. Man nimmt zufällig  $r \leq n$  Schuhe heraus. Wie groß ist die Wahrscheinlichkeit  $\mathbb{P}_n^{(r)}(p)$ , dass darunter genau  $p \in \{1, \dots, \lfloor \frac{r}{2} \rfloor\}$  Paare sind?

Wir betrachten ein Abzählproblem ohne Reihenfolge und ohne Zurücklegen über dem Ereignisraum  $\Omega := \{x_1, y_1, \dots, x_n, y_n\}$ , in welchem sich  $n$  Paar Schuhe  $(x_i, y_i)$  befinden. Somit ist  $|\Omega| = \binom{2n}{r}$ . Wir betrachten die Möglichkeiten genau  $p$  aus  $n$  Paare zu ziehen, also  $\binom{n}{p}$ . Somit blieben uns dann  $n - p$  Paare, die es möglich wären zu ziehen. Da wir jedoch kein weiteres ziehen wollen, betrachten wir dann  $\binom{n-p}{r-2p}$  Möglichkeiten kein weiteres zu ziehen. Zuallerletzt muss noch beachtet werden, dass wir für jedes Paar, die Möglichkeit linker Schuh oder rechter Schuh, als  $2^{r-2p}$  Kombinationsmöglichkeiten haben. Somit gilt

$$\mathbb{P}_n^{(r)}(p) = \frac{\binom{n}{p} \binom{n-p}{r-2p} 2^{r-2p}}{\binom{2n}{r}}. \quad \diamond$$

### Beispiel 1.2.7 (Geburtstags-Paradox)

Man fragt zufällig  $n \in \mathbb{N}_{\geq 2}$  Studenten nach ihrem Geburtstag. Wie groß ist die Wahrscheinlichkeit  $\wp_n$ , dass mindestens zwei der angesprochenen Studenten am gleichen Tag Geburtstag haben?

Wir benutzen das Gegenereignis  $\hat{\wp}$ : jeder Student hat an einem anderen Tag Geburtstag: Für den ersten Studenten ist die Wahrscheinlichkeit, mit keinem der vorherigen Studenten einen Geburtstag zu teilen, genau eins. Für den zweiten Studenten ist die Wahrscheinlichkeit an dem Geburtstag des vorherigen Studenten Geburtstag zu haben,  $\frac{364}{365}$ . Somit erhalten wir  $\hat{\wp} = 1 \cdot \frac{364}{365} \cdot \frac{363}{365} \cdot \dots \cdot \frac{364-n}{365}$ , also  $\wp_n = 1 - \prod_{k=0}^{n-1} \left(1 - \frac{k}{365}\right)$ . Somit gilt schon  $\wp_{23} > 0.5$ .  $\diamond$

### Beispiel 1.2.8 (Multiple-Choice Test)

Ein Student legt einen multiple-choice Test mit 20 Fragen ab und wählt bei jeder Frage zufällig eine der  $k \in \mathbb{N}$  vorgeschlagenen Antworten, von denen nur eine richtig ist. Für jede richtige Antwort erhält der Student einen Punkt. Wie groß ist die Wahrscheinlichkeit, dass der Student am Ende genau  $\ell \in \mathbb{N}$  Punkte hat?




Abb. 9: Die Funktionen  $\mathbb{P}_{15}^{(r)}(p)$  für  $r \in \{8, 6, 10\} \cong \{f, g, h\}$ .




Abb. 10: [Quelle: Wiki]

Ist die Antwort falsch (Wahrscheinlichkeit  $\frac{k-1}{k}$ ) so erhält der Student Null Punkte, mit einer Wahrscheinlichkeit von  $\frac{1}{k}$  die richtige Antwort und somit einen Punkt. Wir wählen also den diskreten Wahrscheinlichkeitsraum mit  $\Omega := \{0, 1\}^{20}$  und  $\mathcal{F} := \mathcal{P}(\Omega)$ . Somit gilt für ein  $\omega \in \Omega$

$$\mathbb{P}(\{\omega\}) := p(\omega) = \left(\frac{1}{k}\right)^{\sum_{j=1}^{20} \omega_j} \left(\frac{k-1}{k}\right)^{20 - \sum_{j=1}^{20} \omega_j} = \frac{(k-1)^{20 - \sum_{j=1}^{20} \omega_j}}{k^{20}}.$$

Für  $S_\ell := \{\omega \in \Omega : \sum_{j=1}^{20} \omega_j = \ell\}$  gilt somit

$$\mathbb{P}(S_\ell) = \sum_{\omega \in S_\ell} p(\omega) = |S_\ell| \frac{(k-1)^{20-\ell}}{k^{20}} = \binom{20}{\ell} \frac{(k-1)^{20-\ell}}{k^{20}}. \quad \diamond$$

### Beispiel 1.2.9 (Multinomialkoeffizient)

Sei  $n \in \mathbb{N}$  und  $A$  eine  $n$ -elementige Menge. Sei weiter  $n_1, \dots, n_k \in \mathbb{N}$  mit  $\sum_{\ell=1}^k n_\ell = n$ , für  $k \in \mathbb{N}_{\leq n}$ . Wie viele verschiedene Möglichkeiten gibt es, die Menge  $A$  in  $k$  disjunkte Teilmengen  $A_j$  der Größe  $n_1, \dots, n_k$  zu unterteilen, wobei wir davon ausgehen, dass  $n_i \neq n_j$  für  $i \neq j$  gilt?

Wir setzen  $\mathcal{N}_1$  als die Anzahl der Möglichkeiten, aus  $A$   $n_1$  Kugeln auszuwählen. Dann gilt  $\mathcal{N}_1 = \binom{n}{n_1}$ . Analog setzen wir  $\mathcal{N}_2$  als die Anzahl der Möglichkeiten, aus  $A \setminus A_1$   $n_2$  Kugeln auszuwählen. Dann gilt  $\mathcal{N}_2 = \binom{n-n_1}{n_2}$ .

Also ist Wahrscheinlichkeit gegeben durch

$$\begin{aligned} \prod_{j=1}^k \binom{n - \sum_{k=1}^{j-1} n_k}{n_j} &= \binom{n}{n_1} \cdot \binom{n-n_1}{n_2} \cdot \binom{n-(n_1+n_2)}{n_3} \cdot \dots \cdot \binom{n_k+n_{k-1}}{n_k} \cdot 1 \\ &= \frac{n!}{(n_1!)(n-n_1)!} \cdot \frac{(n-n_1)!}{(n_2!)(n-(n_1+n_2))!} \cdot \dots \cdot \frac{(n_k+n_{k-1})!}{(n_{k-1}!)(n_k!)} = \frac{n!}{\prod_{j=1}^k (n_j!)} \end{aligned}$$

### Beispiel 1.2.10 (Vier Asse)

Wir betrachten ein Standard-52-Kartenspiel. Jede Position einer Karte im Deck ist gleich wahrscheinlich. Wie groß ist die Wahrscheinlichkeit, dass genau vier Asse hintereinander zu finden sind?

Wir haben

$$\Omega := \{(\omega_1, \dots, \omega_{52}) : \omega_i \in \{1, \dots, 52\}, \omega_i \neq \omega_j \text{ } \forall i \neq j\}, \quad \mathcal{F} := \mathcal{P}(\Omega).$$

Und wählen als Wahrscheinlichkeitsmaß  $\mathbb{P}$  die Gleichverteilung. Ohne Beschränkung der Allgemeinheit seien die vier Asse  $\{1, 2, 3, 4\}$ .

Wir setzen

$$A := \{\omega \in \Omega : \exists k \leq 49 : \{k, k+1, k+2, k+3\} = \{1, 2, 3, 4\}\}. \quad \diamond$$

Da es 49 Möglichkeiten für die Position der vier Asse gibt, die auf 4! Weisen permutiert werden können und für die verbleibenden Karten 48! Permutation möglich sind, gilt  $|A| = 49 \cdot 4! \cdot 48! = 49! \cdot 4!$ . Oder auch (vgl. 1.2.9)  $49 \cdot \frac{1}{48! \cdot 4!}$ .

## 1.3 Stetige Wahrscheinlichkeitsräume

Für viele Zufallsexperimente kann der Ergebnisraum nicht diskret gewählt werden, bei anderen ergibt er sich natürlicherweise bei unendlichen Wiederholungen von diskreten Zufallsexperimenten.

### Beispiel 1.3.1 ( $\infty$ -facher Münzwurf)

Der überabzählbare Ergebnisraum ist  $\Omega := \{0, 1\}^{\mathbb{N}}$ . Wir können die ersten  $n$  Münzwürfe  $\{\omega_1, \dots, \omega_n\}$  als Teilmenge von  $\Omega$  auffassen, indem wir die zugehörige **Zylindermenge**

$$\{\omega_1, \dots, \omega_n\} \times \{0, 1\} \times \{0, 1\} \times \dots$$

betrachten. ◇

Gibt es eine Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $\mathcal{P}(\Omega)$ , sodass für jede solche Zylindermenge

$$\mathbb{P}(\{\omega_1, \dots, \omega_n\} \times \{0, 1\} \times \{0, 1\} \times \dots) = 2^{-n} \quad (3)$$

gilt, also dass die Wahrscheinlichkeit eines Ereignisses, welche nur von den ersten  $n$  Würfeln abhängt, gerade der Wahrscheinlichkeit dieses Ereignisses bezüglich des in Beispiel 1.2.2 betrachteten Wahrscheinlichkeitsmaßes für  $n$  faire Münzwürfe entspricht? Nach Satz A.1.1 ist die Antwort Nein.

Der Ausweg besteht in der Verkleinerung der Ereignissysteme auf eine  $\sigma$ -Algebra, welche strikt kleiner als die Potenzmenge ist, aber immer noch alle von endlich vielen Münzwürfen erzeugten Zylindermengen enthält. Es existiert ein Wahrscheinlichkeitsmaß mit der Eigenschaft (3) auf diesem Mengensystem.

### DEFINITION 1.3.2 (BOREL- $\sigma$ -ALGEBRA)

Sei

$$\mathcal{C} := \left\{ (a, b] := \prod_{k=1}^n (a_k, b_k] : a = (a_k)_{k=1}^n, b = (b_k)_{k=1}^n \right\},$$

wobei  $-\infty \leq a_i \leq b_i < \infty$  für alle  $i \in \{1, \dots, n\}$  gelten soll. Dann ist  $\sigma(\mathcal{C}) =: \mathcal{B}(\mathbb{R}^d)$  die **BOREL- $\sigma$ -Algebra**.

**BOREL- $\sigma$ -Algebra**

**Bemerkung 1.3.3** Es gilt  $\mathcal{B}(\mathbb{R}^d) \subsetneq \mathcal{P}(\mathbb{R}^d)$ .  $\mathcal{B}(\mathbb{R}^d)$  enthält u.a. alle offenen, abgeschlossenen und kompakten Teilmengen des  $\mathbb{R}^d$ .

An die Stelle der Zähldichte tritt im stetigen Fall eine

**DEFINITION 1.3.4 (DICHTe (ENGL. PDF))**

Ein integrierbare Funktion  $f : \mathbb{R}^d \rightarrow [0, \infty)$  heißt **Dichte**, wenn  $\int_{\mathbb{R}^d} f(x) dx = 1$  gilt.

**Dichte***engl. probability density function***SATZ 1.3.1: KONTINUIERLICHES ANALOGON ZU 1.2.1**

Sei  $f$  eine **Dichte** auf  $\mathbb{R}^d$ . Dann definiert

$$\mathbb{P} : \mathcal{B}(\mathbb{R}^d) \rightarrow \mathbb{R}, A \mapsto \int_A f(x) dx$$

ein **Wahrscheinlichkeitsmaß** auf  $\mathcal{B}(\mathbb{R}^d)$ .

**DEFINITION 1.3.5 (GLEICHVERTEILUNG IM  $\mathbb{R}^d$ )**

Sei  $\Omega \in \mathcal{B}(\mathbb{R}^d)$  endlich. Das zu der Dichte  $\frac{\mathbb{1}_\Omega}{|\Omega|}$  gehörende Wahrscheinlichkeitsmaß auf  $\Omega$  heißt **Gleichverteilung** auf  $\Omega$ .

**Gleichverteilung**

Es gilt  $\mathbb{P}(A) = \frac{|A|}{|\Omega|}$  für alle  $A \in \mathcal{B}(\mathbb{R})$ . Insbesondere ist die Dichte der **Gleichverteilung** auf  $[a, b]$  durch  $\frac{\mathbb{1}_{[a,b]}}{\prod_{k=1}^d (b_k - a_k)}$  gegeben.

**Gleichverteilung****Beispiel 1.3.6 (BETRANDSches Paradox)**

**TODO.** nicht so wichtig, vgl. zweite Übung.

◇

## Bedingte Wahrscheinlichkeit und Unabhängigkeit

### 2.1 Bedingte Wahrscheinlichkeit

Sind über den Ausgang eines Zufallsexperiments bereits Informationen verfügbar, ändern sich die Wahrscheinlichkeiten.

Sei im Folgenden  $(\Omega, \mathcal{A}, \mathbb{P})$  stets ein Wahrscheinlichkeitsraum.

#### Beispiel 2.1.1 (Bedingte Wahrscheinlichkeit beim Würfeln)

Nach Beispiel 1.1.10 ist die Wahrscheinlichkeit mit zwei fairen Würfeln die Augensumme größer als 10 zu würfeln,  $\frac{1}{12}$ .

Wie ändert sich die Wahrscheinlichkeiten, wenn zuerst eine sechs gewürfelt wird? Für den zweiten Wurf gibt es sechs gleichwahrscheinliche Möglichkeiten, von denen zwei das Gewünschte erreichen. Somit ist die Wahrscheinlichkeit unter dieser Annahme gegeben durch

$$\begin{aligned} \mathbb{P}(\text{Augensumme} > 10 \mid \text{1. Wurf } 6) &= \frac{\mathbb{P}(\text{Augensumme} > 10, \text{1. Wurf } 6)}{\mathbb{P}(\text{1. Wurf } 6)} \\ &= \frac{\frac{2}{36}}{\frac{6}{36}} = \frac{1}{3}. \end{aligned} \quad \diamond$$

Die obige Notation erklären wir mit der folgenden

#### DEFINITION 2.1.2 (BEDINGTE WAHRSCHEINLICHKEIT)

Seien  $A, B \in \mathcal{A}$  Ereignisse. Dann heißt

$$\mathbb{P}(A \mid B) := \begin{cases} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, & \text{für } \mathbb{P}(B) > 0, \\ 0, & \text{für } \mathbb{P}(B) = 0. \end{cases}$$

die **bedingte Wahrscheinlichkeit** von  $A$  gegeben  $B$ .

**bedingte Wahrscheinlichkeit**

#### Korollar 2.1.3 (Eigenschaften bedingter Wahrscheinlichkeiten)

Seien  $A, B \in \mathcal{A}$ . Dann gilt

- $B \subset A \implies \mathbb{P}(A \mid B) = 1$  für  $\mathbb{P}(B) > 0$ ,
- $\mathbb{P}(A \mid B) = 0$  für  $A \cap B = \emptyset$ .
- $\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B)$  für alle  $B \in \mathcal{A}$  und  $\mathbb{P}(A) = 1$ .



**SATZ 2.1.1: BEDINGTES WAHRSCHEINLICHKEITSMASS**

Seien  $B \in \mathcal{A}$  mit  $\mathbb{P}(B) > 0$  und  $\tilde{\mathbb{P}} : \mathcal{A} \rightarrow [0, 1]$ ,  $A \mapsto \mathbb{P}(A \mid B)$ .  
Dann ist  $(\Omega, \mathcal{A}, \tilde{\mathbb{P}})$  ein Wahrscheinlichkeitsraum.

**Beweis.** Die Nichtnegativität und Wohldefiniert folgt direkt aus den entsprechenden Eigenschaften von  $\mathbb{P}$ . Aus der Existenz eines  $A \in \mathcal{A}$  mit  $\tilde{\mathbb{P}}(\mathcal{A}) > 1$  folgt  $\mathbb{P}(A \cap B) > \mathbb{P}(B)$ , was im Widerspruch zu der Monotonie von  $\mathbb{P}$  steht.

Sei nun  $(A_k)_{k \in \mathbb{N}} \subset \mathcal{A}$  eine paarweise disjunkte Familie. Dann ist auch  $(A_k \cap B)_{k \in \mathbb{N}} \subset \mathcal{A}$  eine paarweise disjunkte Familie und aufgrund der  $\sigma$ -Additivität von  $\mathbb{P}$  (\*) gilt für  $A \in \mathcal{A}$

$$\tilde{\mathbb{P}}(A) = \frac{\mathbb{P}(\bigcup_{k \in \mathbb{N}} A_k \cap B)}{\mathbb{P}(B)} \stackrel{(*)}{=} \frac{\sum_{k \in \mathbb{N}} \mathbb{P}(A_k \cap B)}{\mathbb{P}(B)} = \sum_{k \in \mathbb{N}} \tilde{\mathbb{P}}(A_k). \quad \square$$

**Beispiel 2.1.4 (Bedingte LAPLACE Wahrscheinlichkeit)**

Seien  $\Omega$  endlich,  $\mathbb{P}$  die Gleichverteilung auf  $\Omega$  und  $B \neq \emptyset$ . Dann ist die bedingte LAPLACE-Wahrscheinlichkeit die Gleichverteilung auf  $B$ :

$$\mathbb{P}(A \mid B) = \frac{\frac{|A \cap B|}{|\Omega|}}{\frac{|B|}{|\Omega|}} = \frac{|A \cap B|}{|B|}. \quad \diamond$$

**Beispiel 2.1.5 (Verkehrsunfälle)**

Seien die Ereignisse  $U :=$  „Unfall“,  $M :=$  „Versicherter männlich“ und  $W :=$  „Versicherte weiblich“ definiert und die Wahrscheinlichkeiten  $\mathbb{P}(U \mid W) = 0.002$ ,  $\mathbb{P}(U \mid M) = 0.005$  sowie  $\mathbb{P}(W) = 0.4 = 1 - \mathbb{P}(M)$  gegeben. Dann gilt

$$\begin{aligned} \mathbb{P}(U) &= \mathbb{P}(U, W) + \mathbb{P}(U, M) \stackrel{2.1.2}{=} \mathbb{P}(U \mid W) \mathbb{P}(W) + \mathbb{P}(U \mid M) \mathbb{P}(M) \\ &= 0.002 \cdot 0.4 + 0.005 \cdot 0.6 = 0.0038. \end{aligned} \quad \diamond$$

Die Berechnung dieser „totalen“ Wahrscheinlichkeit für einen Arbeitsunfall ist ein Spezialfall des folgenden

**SATZ 2.1.2: VON DER TOTALEN WAHRSCHEINLICHKEIT**

Seien  $A \in \mathcal{A}$  und  $(B_n)_{n \in \mathbb{N}} \subset \mathcal{A}$  eine paarweise disjunkte Familie mit  $A \subset \bigcup_{n \in \mathbb{N}} B_n$ . Dann gilt

$$\mathbb{P}(A) = \sum_{n \in \mathbb{N}} \mathbb{P}(A \mid B_n) \cdot \mathbb{P}(B_n) = \sum_{n \in \mathbb{N}} \mathbb{P}(A \cap B_n).$$

**Beweis.** Für  $\mathbb{P}(B_n) > 0$  folgt  $\mathbb{P}(A | B_n) \mathbb{P}(B_n) = \mathbb{P}(A \cap B_n)$  (\*) aus der Definition. Für  $\mathbb{P}(B_n) = 0$  folgt, da  $\mathbb{P}(A \cap B_n) \leq \mathbb{P}(B_n) = 0$  mit der Monotonie auch (\*). Somit gilt

$$\sum_{n \in \mathbb{N}} \mathbb{P}(A | B_n) \mathbb{P}(B_n) = \sum_{n \in \mathbb{N}} \mathbb{P}(A \cap B_n) \stackrel{1.1.9}{=} \mathbb{P}\left(A \cap \bigcup_{n \in \mathbb{N}} B_n\right) = \mathbb{P}(A). \square$$

**Beispiel 2.1.6 (Aus  $\mathbb{P}(U)$  die W-keit  $\mathbb{P}(M | U)$  berechnen)**

Es gilt

$$\mathbb{P}(M | U) = \frac{\mathbb{P}(M, U)}{\mathbb{P}(U)} = \frac{\mathbb{P}(U | M) \mathbb{P}(M)}{\mathbb{P}(U)} = \frac{0.005 \cdot 0.6}{0.0038} = 0.789. \quad \diamond$$

Der folgende Satz verallgemeinert die Rechnung aus dem letzten Beispiel.

### SATZ 2.1.3: BAYES (1763)

Unter den Voraussetzungen von Satz 2.1.2 und  $P(A) > 0$  gilt

$$\mathbb{P}(B_n | A) = \frac{\mathbb{P}(A | B_n) \cdot \mathbb{P}(B_n)}{\sum_{k \in \mathbb{N}} \mathbb{P}(A | B_k) \mathbb{P}(B_k)} \left( = \frac{\mathbb{P}(A \cap B_n)}{\sum_{k \in \mathbb{N}} \mathbb{P}(A \cap B_k)} \right).$$

**Beweis.** Aus Satz 2.1.2 folgt  $P(A) = \sum_{k \in \mathbb{N}} P(A | B_k) \cdot P(B_k)$  und somit

$$\begin{aligned} \mathbb{P}(B_n | A) &= \frac{\mathbb{P}(B_n \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \cap B_n)}{\mathbb{P}(B_n)} \cdot \frac{\mathbb{P}(B_n)}{\mathbb{P}(A)} \\ &= \frac{\mathbb{P}(A | B_n) \cdot \mathbb{P}(B_n)}{\sum_{k \in \mathbb{N}} \mathbb{P}(A | B_k) \mathbb{P}(B_k)}. \end{aligned} \quad \square$$

**Beispiel 2.1.7 (Anwendung: Das Ziegenproblem)**

In einer Gameshow gibt es drei Türen, hinter zwei stehen Ziegen, hinter der anderen ein Sportwagen. Wir dürfen eine Tür wählen und behalten, was dahinter ist. Wir wählen eine Tür. Anstatt unsere Tür zu öffnen, öffnet der Moderator eine andere und es kommt eine Ziege zum Vorschein. Uns wird angeboten, die Tür zu wechseln, sollten wir das tun?

Zusätzliche Annahmen: Die Position des Sportwagens ist zufällig gemäß der Gleichverteilung auf die drei Türen verteilt. Der Moderator weiß, wo der Sportwagen ist. Wählt der Kandidat eine Tür mit dem Sportwagen, so wählt er gleichverteilt eine andere Tür.

Sei  $A_i :=$  "Der Sportwagen ist hinter Tür  $i$ " für  $i \in \{1, 2, 3\}$ . Dann gilt  $\bigcup_{k=1}^3 A_k =: \Omega$ . Ohne Einschränkung wählt der Kandidat Tür eins und der Moderator Tür zwei. Sei  $B :=$  "Moderator öffnet Tür mit Ziege"  $\subset \Omega$ .

Da der Moderator gleichverteilt wählt, wenn wir den Sportwagen gewählt haben, gilt  $\mathbb{P}(B | A_1) = \frac{1}{2}$ . Der Moderator wähle die Tür mit der anderen Ziege, wenn wir eine gewählt haben, es gilt  $\mathbb{P}(B | A_2) = 0$  und  $\mathbb{P}(B | A_3) = 1$ .




Abb. 11: Darstellung von des Satzes von BAYES für  $n = 1$  mit Entscheidungsbäumen.  
[Quelle: Wiki]

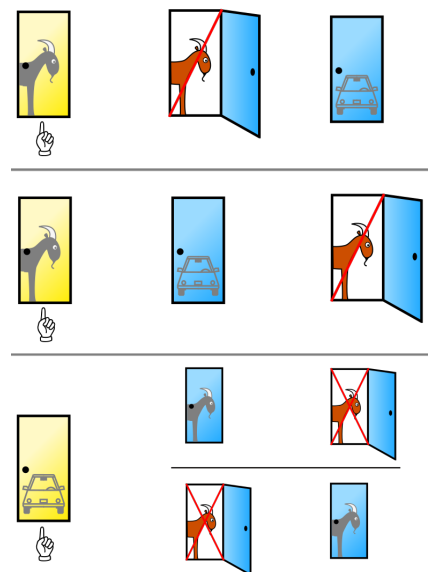


Abb. 12: [Quelle: Wiki]

Also ist die Gewinnchance ohne Wechsel  $P(A_1) = \frac{1}{3}$  und mit

$$\mathbb{P}(A_3 | B) = \frac{\mathbb{P}(B | A_3) \mathbb{P}(A_3)}{\sum_{k=1}^3 \mathbb{P}(B | A_k) \mathbb{P}(A_k)} = \frac{1 \cdot \frac{1}{3}}{\frac{1}{2} \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3}} = \frac{2}{3}$$

mit der Formel von BAYES. Es ist also sinnvoll, zu wechseln.  $\diamond$

Weitere Anwendung: Ruinprobleme. **TODO**

### Beispiel 2.1.8 (Falsch-Positive)

Angenommen, 5‰ der Bevölkerung haben eine Krankheit  $K$ . Ein Test zeigt bei 99% der Erkrankten eine positive Reaktion (P):  $\mathbb{P}(P | K) = 0.99$ , allerdings zeigt er bei 2 % der Gesunden eine positive Reaktion:  $\mathbb{P}(P | K^c) = 0.02$ .

Die Formel von BAYES liefert mit  $B_1 := K$  und  $B_2 := K^c$

$$\begin{aligned} \mathbb{P}(K | P) &= \frac{\mathbb{P}(P | K) \mathbb{P}(K)}{\mathbb{P}(P | K) \cdot \mathbb{P}(K) + \mathbb{P}(P | K^c) \mathbb{P}(K^c)} \\ &= \frac{0.99 \cdot 0.005}{0.99 \cdot 0.005 + 0.02 \cdot 0.995} \approx 0.2 \end{aligned}$$

Also ist in nur zwei von zehn positiven Tests die getestet Person wirklich erkrankt.  $\diamond$




Abb. 13: Von 479 positiv getesteten sind nur 99 (knapp jeder fünfte) wirklich erkrankt. [Quelle: selber]

## 2.2 Unabhängigkeit

### DEFINITION 2.2.1 (STOCHASTISCHE UNABHÄNGIGKEIT)

Eine Familie von Ereignissen  $(A_i)_{i \in I}$  heißt **stochastisch unabhängig** wenn für alle endlichen nichtleeren Teilmengen  $J \subset I$  gilt

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j). \quad (4)$$

### Gegenbeispiel 2.2.2 (Vollständig $\iff$ paarweise unabhängig)

Seien  $A \in \mathcal{A}$  mit  $\mathbb{P}(A) \in (0, 1)$  und  $n \in \mathbb{N}_{>2}$ . Definiere  $A_1 = \dots = A_{n-1} := A$  und  $A_n = \emptyset$ . Dann gilt  $\mathbb{P}(\bigcap_{k \in \mathbb{N}} A_k) = \mathbb{P}(A)^{n-1} \cdot \mathbb{P}(A_n) = 0$  aber

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A) \neq \mathbb{P}(A)^2 = \mathbb{P}(A_1) \mathbb{P}(A_2).$$

Definiere  $A :=$  „1. Wurf Zahl“,  $B :=$  „2. Wurf Zahl“ und  $C :=$  „1. und 2. Wurf gleich“. Es gilt  $\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}$  und  $\mathbb{P}(A \cap B) = \mathbb{P}(A \cap C) = \mathbb{P}(B \cap C) = \frac{1}{4}$  aber  $\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \mathbb{P}(A) \mathbb{P}(B) \mathbb{P}(C)$ .  $\diamond$

### SATZ 2.2.1: UNABHÄNGIGKEIT ENDLICHER FAMILIEN

Die Familie  $(A_k)_{k=1}^n$  ist genau dann unabhängig, wenn für jede Wahl von  $B_k \in \{A_k, A_k^c\}$ ,  $k \in \{1, \dots, n\}$

$$\mathbb{P}\left(\bigcap_{k=1}^n B_k\right) = \prod_{k=1}^n \mathbb{P}(B_k)$$

gilt.

**Beweis.** „ $\implies$ “: Wir führen eine vollständige Induktion über  $m := |\{i \in \{1, \dots, n\} : B_i = A_i\}|$ .

Induktionsanfang:  $m = 0$ . Für  $m = 0$  gilt  $B_i = A_i$  für alle  $i \in \{1, \dots, n\}$ .

Induktionsannahme: Ist  $m := |\{i \in \{1, \dots, n\} : B_i = A_i\}|$ , so sind die Ereignisse  $(B_k)_{k=1}^n$  unabhängig.

Induktionsschritt:  $n \rightarrow n + 1$ . Durch Umnummerierung können wir  $B_1 = A_1^c$  annehmen. Nach Annahme sind die Ereignisse  $A_1, B_2, \dots, B_n$  unabhängig, also gilt für eine nichtleere Teilmenge  $J \subset \{2, \dots, n\}$

$$\mathbb{P}\left(\bigcap_{j \in J} B_j\right) = \prod_{j \in J} \mathbb{P}(B_j) \quad \text{und} \quad \mathbb{P}\left(A_1 \cap \bigcap_{j \in J} B_j\right) = \mathbb{P}(A_1) \prod_{j \in J} \mathbb{P}(B_j).$$

stochastisch unabhängig




Abb. 14: Wahrscheinlichkeiten beim zweimaligen fairen Münzwurf. [Quelle: selbst]

Mit einer Verallgemeinerung von (5) folgt durch Umstellen

$$\begin{aligned}\mathbb{P}\left(\bigcap_{j \in J \cup \{1\}} B_j\right) &= \mathbb{P}\left(\bigcap_{j \in J} B_j\right) - \mathbb{P}\left(A_1 \cap \bigcap_{j \in J} B_j\right) \\ &= \prod_{j \in J} \mathbb{P}(B_j) - \mathbb{P}(A_1) \prod_{j \in J} \mathbb{P}(B_j) \\ &= (1 - \mathbb{P}(A_1)) \prod_{j \in J} \mathbb{P}(B_j) = \mathbb{P}(B_1) \prod_{j \in J} \mathbb{P}(B_j).\end{aligned}$$

„ $\Leftarrow$ “: Nach Annahme gilt

$$\mathbb{P}\left(\bigcap_{k=1}^n B_k\right) = \prod_{k=1}^n \mathbb{P}(B_k) \quad \text{und} \quad \mathbb{P}\left(\bigcap_{k=2}^n B_k \cap B_1^c\right) = \prod_{k=2}^n \mathbb{P}(B_k) \cdot \mathbb{P}(B_1^c)$$

Addition ergibt

$$\prod_{k=1}^n \mathbb{P}(B_k) + \prod_{k=2}^n \mathbb{P}(B_k) \cdot \mathbb{P}(B_1^c) = \prod_{k=2}^n \mathbb{P}(B_k) [\mathbb{P}(B_1) + \mathbb{P}(B_1^c)] = \prod_{k=2}^n \mathbb{P}(B_k).$$

Aufgrund von

$$\bigcap_{k=2}^n B_k = \bigcap_{k=2}^n B_k \cap (B_1 \cup B_1^c) = \left(\bigcap_{k=1}^n B_k\right) \cup \left(\bigcap_{k=2}^n B_k \cap B_1^c\right), \quad (5)$$

wobei die letzte Vereinigung aufgrund von  $B_1 \cap B_1^c$  disjunkt ist, folgt

$$\mathbb{P}\left(\bigcap_{k=2}^n B_k\right) = \prod_{k=2}^n \mathbb{P}(B_k).$$

Somit erhält man die Produktformel für Durchschnitte von  $n-1$  Mengen und iterativ für  $\binom{n}{k}_{k=1}^{n-2}$  Mengen.  $\square$

### Beispiel 2.2.3 („Kopf“ im $k$ -ten von $n$ Würfeln)

Betrachte beim  $n$ -maligen Wurf einer fairen Münze die Familie der Ereignisse  $(A_k := \text{„}k\text{-ter Wurf Kopf“})_{k=1}^n$ . Sie ist unabhängig, denn für jede Wahl  $B_k \in \{A_k, A_k^c\}$

$$\mathbb{P}\left(\bigcap_{k=1}^n B_k\right) = 2^{-n} = \prod_{k=1}^n \mathbb{P}(B_k). \quad \diamond$$

Der  $n$ -malige Münzwurf ist ein Spezialfall für die unabhängige Hintereinanderausführung von Teilexperimenten, welche im nächsten Kapitel betrachtet werden.

## 2.3 Produktwahrscheinlichkeitsräume

### DEFINITION 2.3.1 (PRODUKTRAUM UND -MASS)

Seien  $((\Omega_k, \mathbb{P}_k))_{k=1}^n$  diskrete Wahrscheinlichkeitsräume,

$$\Omega := \prod_{k=1}^n \Omega_k \text{ und } \mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1], A \mapsto \sum_{\substack{\omega := \{\omega_1, \dots, \omega_n\} \\ \omega \in A}} \prod_{k=1}^n \mathbb{P}_k(\{\omega_k\})$$

Dann heißt  $(\Omega, \mathbb{P})$  **Produktraum** und  $\mathbb{P} := \bigotimes_{k=1}^n \mathbb{P}_k$  **Produktmaß**.

Produktmaß

### Korollar 2.3.2 (Zylindermengen)

Für **Zylindermengen**  $A := \prod_{k=1}^n A_k \in \mathcal{P}(\Omega)$  mit  $A_k \in \Omega_k$  gilt

$$\begin{aligned} \mathbb{P}(A) &= \sum_{\omega \in A} \mathbb{P}(\{\omega\}) = \sum_{\omega_1 \in A_1} \dots \sum_{\omega_n \in A_n} \prod_{k=1}^n \mathbb{P}_k(\{\omega_k\}) \\ &= \sum_{\omega_1 \in A_1} \dots \sum_{\omega_{n-1} \in A_{n-1}} \prod_{k=1}^{n-1} \mathbb{P}_k(\{\omega_k\}) \mathbb{P}_n(A_n) = \dots = \prod_{k=1}^n \mathbb{P}_k(A_k). \end{aligned}$$

### Beispiel 2.3.3 ( $n$ -maliger Münzwurf als Produktraum)

Der  $n$ -malige Münzwurf  $(\Omega, \mathbb{P})$  ist der **Produktraum** der Wahrscheinlichkeitsräume  $\Omega_i := \{0, 1\}$  mit  $\mathbb{P}(\{0\}) = \mathbb{P}(\{1\}) = \frac{1}{2}$  für  $i \in \{1, \dots, n\}$ .  $\diamond$

Produktraum

Eine Verallgemeinerung ist das

### DEFINITION 2.3.4 (BERNOULLI-EXPERIMENT)

Seien  $p \in [0, 1]$ ,  $n \in \mathbb{N}$  und  $\Omega := \{0, 1\}$ . Ein durch  $\Omega := \prod_{i=1}^n \Omega_i$  und das Produkt der Wahrscheinlichkeitsmaße  $\mathbb{P}_i(\{1\}) = p = 1 - \mathbb{P}_i(\{0\})$  für  $i \in \{1, \dots, n\}$  über  $\Omega$  beschriebene Zufallsexperiment heißt **BERNOULLI-Experiment** der **Länge**  $n$  mit **Erfolgswahrscheinlichkeit**  $p$ .

BERNOULLI-Experiment

### Lemma 2.3.5 ( $\prod_{k=1}^n \text{LAPLACE} = \text{LAPLACE}$ )

Endliche Produkte LAPLACE-Wahrscheinlichkeitsräume sind LAPLACE-Wahrscheinlichkeitsräume.

**Beweis.** Seien  $(\Omega_k)_{k=1}^n$  eine Familie nichtleere endlicher Mengen und  $\mathbb{P}_k$  die Gleichverteilung auf  $\Omega_k$  für  $k \in \{1, \dots, n\}$ . Dann gilt für das Produktmaß

$$\mathbb{P}(\{\omega_1, \dots, \omega_n\}) = \prod_{k=1}^n \mathbb{P}_k(\{\omega_k\}) = \prod_{k=1}^n \frac{1}{|\Omega_k|} = \frac{1}{|\prod_{k=1}^n \Omega_k|}.$$

Also ist das Produktmaß  $\mathbb{P} = \bigotimes_{k=1}^n \mathbb{P}_k$  die Gleichverteilung auf  $\prod_{k=1}^n \Omega_k$ .  $\square$

Der folgende Satz formalisiert die Intuition, dass der Produktraum die **unabhängige** Hintereinanderausführung von Zufallsexperimenten entspricht.

**SATZ 2.3.1**

Seien  $(A_i \in \mathcal{P}(\Omega_i))_{i=1}^n$  Ereignisse. Die Ereignisse im Produktraum, welche nur von Ereignis  $A_i$  im  $i$ -ten Zufallsexperiment abhängen

$$A_i^{(i)} := \{\omega = (\omega_1, \dots, \omega_n) \in \Omega : \omega_i \in A_i\} = \prod_{k=1}^{i-1} \Omega_k \times A_i \times \prod_{k=i+1}^n \Omega_k$$

sind unabhängig.

**Beweis.** Aufgrund von  $(A_i^{(i)})^c = \prod_{k=1}^{i-1} \Omega_k \times A_i^c \times \prod_{k=i+1}^n \Omega_k$  genügt es für die Anwendung von Satz 2.2.1

$$\mathbb{P} \left( \bigcap_{k=1}^n A_k^{(k)} \right) = \prod_{k=1}^n \mathbb{P} \left( A_k^{(k)} \right)$$

für beliebige  $A_k \in \mathcal{P}(\Omega_k)$  zu zeigen. Aus Korollar 2.3.2  $(\star)$  folgt

$$\begin{aligned} \mathbb{P} \left( \bigcap_{k=1}^n A_k^{(k)} \right) &\stackrel{\text{Def.}}{=} \mathbb{P} \left( \bigcap_{k=1}^n \prod_{j=1}^{i-1} \Omega_j \times A_k \times \prod_{j=i+1}^n \Omega_j \right) = \mathbb{P} \left( \prod_{k=1}^n A_k \right) \\ &\stackrel{(\star)}{=} \prod_{k=1}^n \mathbb{P} \left( A_k \right) = \prod_{k=1}^n \mathbb{P} \left( \prod_{j=1}^{i-1} \Omega_j \times A_k \times \prod_{j=i+1}^n \Omega_j \right) \\ &= \prod_{k=1}^n \mathbb{P} \left( A_k^{(k)} \right). \quad \square \end{aligned}$$

**Bemerkung 2.3.6 (kontinuierliche Produkträume)**

Analog kann man auf Familien von beliebigen Wahrscheinlichkeitsräumen  $(\Omega_k, \mathcal{A}_k, \mathbb{P}_k)_{k=1}^n$  das Produkt  $(\Omega, \mathcal{A}, \mathbb{P}) := (\prod_{k=1}^n \Omega_k, \otimes_{k=1}^n \mathcal{A}_k, \otimes_{k=1}^n \mathbb{P}_k)$  definieren. Sei  $A := \prod_{k=1}^n A_k$  mit  $A_k \in \mathcal{A}_k$  ein Zylindermenge. Dann ist  $\mathcal{A}$  die kleinste  $\sigma$ -Algebra, welche von allen Zylindermengen erzeugt wird und  $\mathbb{P}$  das eindeutig bestimmte Wahrscheinlichkeitsmaß ist, für das  $\mathbb{P}(\prod_{k=1}^n A_k) = \prod_{k=1}^n \mathbb{P}(A_k)$  gilt.

**Lemma 2.3.7 (Produktmaße und -dichten)**

Sind  $(f_i : \mathbb{R} \rightarrow [0, \infty))_{i=1}^n$  Dichten auf  $\mathbb{R}$  und  $\mathbb{P}_i(A) := \int_A f_i(x) dx$  für  $A \in \mathcal{B}(\mathbb{R})$  die zugehörigen Wahrscheinlichkeitsmaße auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , so ist

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, (x_1, \dots, x_n) \mapsto \prod_{k=1}^n f_k(x_k)$$

eine Dichte auf  $\mathbb{R}^n$  und das zugehörige Wahrscheinlichkeitsmaß

$$\mathbb{P} : \mathcal{B}(\mathbb{R}^n) \rightarrow [0, 1], A \mapsto \int_A f(x) dx$$

genau das Produktmaß von  $(P_i)_{i=1}^n$ .

**Beweis.** Für Zylindermengen  $A := \prod_{k=1}^n A_k$  gilt

$$\mathbb{P}(A) = \int_{\prod_{k=1}^n A_k} f(x) \, dx = \int_{A_1} f_1(x_1) \, dx_1 \cdots \int_{A_n} f_n(x_n) \, dx_n = \prod_{k=1}^n \mathbb{P}_k(A_k)$$

und das beendet den Beweis?? **WARUM GENÜGT ES, FÜR DEN ZYLINDER-FALL ZU ZEIGEN??**  $\square$

**Bemerkung 2.3.8 (diskreter Fall)**

Aus dem Lemma folgt analog für den diskreten Fall, dass für endliche BOREL-Mengen  $(\Omega_i)_{i=1}^n \subset \mathbb{R}$  und die Gleichverteilung  $\mathbb{P}_i(A_i) = \frac{|A_i|}{|\Omega_i|}$  auf  $\Omega_i$  das zugehörige Produktmaß  $\mathbb{P} = \bigotimes_{k=1}^n \mathbb{P}_k$  die Gleichverteilung auf  $\prod_{k=1}^n \Omega_k$  ist.



### 3.1 Grundlegende Konzepte

Anstatt einzelne Ergebnisse  $\omega \in \Omega$  ist man häufig nur am Wert  $X(\omega)$  einer **Messgröße**  $X$  interessiert, z.B. Temperatur oder Aktienkurs.

Messgröße

Seien im Folgenden  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $(E, \mathcal{E})$  ein Messraum.

#### DEFINITION 3.1.1 (ZUFALLSVARIABLE(VEKTOR), REALISIERUNG)

- Eine Abbildung  $X : \Omega \rightarrow E$  heißt **Zufallsvariable**, wenn

Zufallsvariable

$$\{X \in B\} := X^{-1}(B) := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A} \quad (6)$$

für alle  $B \in \mathcal{E}$  gilt.

- Der Wert  $X(\omega)$  heißt **Realisierung** von  $X$  zum Ergebnis  $\omega$ .
- Ist  $(E, \mathcal{E}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , so heißt  $X$  **reellwertig** und für  $(E, \mathcal{E}) = (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$   $d$ -dimensionaler **Zufallsvektor**.

Realisierung

Zufallsvektor

**Bemerkung 3.1.2 (Notation)** Es hat sich durchgesetzt,  $\mathbb{P}(X \in B)$  anstatt  $\mathbb{P}(\{X \in B\})$ ,  $\mathbb{P}(X \in A, Y \in B)$  anstatt  $\mathbb{P}(\{X \in A\} \cap \{Y \in B\})$  usw. zu schreiben.

#### Lemma 3.1.3 (Zufallsvariablen)

- Ist  $\Omega$  diskret, so ist jede Abbildung  $X : \Omega \rightarrow E$  eine Zufallsvariable.
- Für jedes  $A \in \mathcal{A}$  definiert die **Indikatorfunktion**  $\mathbb{1}_A$  eine Zufallsvariable.
- Sind  $X_1, \dots, X_n$  reellwertige Zufallsvariablen und ist  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  BOREL-messbar, so ist auch  $f(X_1, \dots, X_n)$  wieder eine Zufallsvariable. Insbesondere sind Summen, Produkte etc. reellwertiger Zufallsvariablen reellwertige Zufallsvariablen.

Indikatorfunktion

#### DEFINITION 3.1.4 (VERTEILUNG)

Sei  $X : \Omega \rightarrow E$  eine Zufallsvariable. Dann nennt man

$$\mu := \mathbb{P} \circ X^{-1} = \mathbb{P}_X : \mathcal{E} \rightarrow \mathbb{R}, \quad B \mapsto \mathbb{P}(X \in B)$$

**Verteilung** von  $X$  und schreibt  $X \sim \mu$ .

Verteilung

**SATZ 3.1.1:**  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_X)$  WAHRSCHEINLICHKEITSRAUM

Die Verteilung (einer Zufallsvariable) ist ein Wahrscheinlichkeitsmaß.

**Beweis.** Da  $X$  ein Zufallsvariable ist, gilt  $\{X \in B\} \in \mathcal{A}$  für alle  $B \in \mathcal{E}$ , somit ist  $\mathbb{P}_X$  wohldefiniert. Weil  $\mathbb{P}$  nichtnegativ und normiert ist, ist es auch  $\mathbb{P}_X$ . Es bleibt nur noch die  $\sigma$ -Additivität zu zeigen. Sei  $(B_n)_{n \in \mathbb{N}} \subset \mathcal{E}$  eine paarweise disjunkte Folge, dann ist die Urbildfolge  $(\{X \in B_n\})_{n \in \mathbb{N}} \subset \mathcal{A}$  auch paarweise disjunkt. Aus der  $\sigma$ -Additivität von  $\mathbb{P}$  ( $\dagger$ ) und da Urbilder auch unter Vereinigungen invariant ( $\star$ ) sind, gilt

$$\begin{aligned} \mathbb{P}_X \left( \bigcup_{n \in \mathbb{N}} B_n \right) &= \mathbb{P} \left( X \in \bigcup_{n \in \mathbb{N}} B_n \right) \stackrel{(\star)}{=} \mathbb{P} \left( \bigcup_{n \in \mathbb{N}} \{X \in B_n\} \right) \\ &\stackrel{(\dagger)}{=} \sum_{n \in \mathbb{N}} \mathbb{P}(X \in B_n) = \sum_{n \in \mathbb{N}} \mathbb{P}_X(B_n). \end{aligned} \quad \square$$

**Diskrete Zufallsvariablen und Verteilungen**

Die Verteilung einer diskreten Zufallsvariablen  $X$  wird vollständig durch die zugehörige **Zähldichte**

$$p_X : E \rightarrow [0, 1], \quad b \mapsto \mathbb{P}(X = b)$$

beschrieben. Dies gilt auch, wenn nur das Bild  $X(\Omega)$  diskret ist.

**Beispiel 3.1.5 (Zähldichte beim zweimaligen Würfeln)**

Beim zweimaligen fairen Würfeln sei  $X : \Omega \rightarrow \{2, \dots, 12\}$  die Augensumme. Dann gilt

$$p_X : \{2, \dots, 12\} \rightarrow [0, 1], \quad b \mapsto \mathbb{P}(\{(k, \ell) \in \Omega : k + \ell = b\}). \quad \diamond$$




Abb. 15: Ein **Stabdiagramm** der Wahrscheinlichkeiten.

**Reellwertige Zufallsvariablen und Verteilungen**
**DEFINITION 3.1.6 (VERTEILUNGSFUNKTION (CDF))**

Sei  $X$  eine reellwertige Zufallsvariable. Dann heißt

$$F_X : \mathbb{R} \rightarrow [0, 1], \quad x \mapsto \mathbb{P}(X \leq x) = \mathbb{P}_X((-\infty, x])$$

**Verteilungsfunktion** von  $X$ .

engl.: *cummulative distribution function*

**Verteilungsfunktion**

**DEFINITION 3.1.7 (ENTARTETE ZUFALLSVARIABLE)**

Eine Zufallsvariable, welche nur einen Wert  $c \in \mathbb{R}$  annimmt, heißt **deterministisch** oder entartet, da ihr Wert vom Ausgang des Zufallsexperiments unabhängig ist. Es gilt  $F_X(x) = \mathbb{1}_{x \geq c}(x)$ .

deterministisch

**Lemma 3.1.8 (Eigenschaften der diskreten Verteilungsfunktion)**

Sei  $X$  eine diskrete Zufallsvariable und  $F_X$  ihre Verteilungsfunktion. Dann gilt

- ①  $F_X$  ist eine **stückweise konstante** monoton wachsende **Treppenfunktion** mit Werte zwischen Null und Eins.
- ② Ihre **Sprungstellen** sind genau diejenigen Werte  $x$ , sodass  $\mathbb{P}(X = x) > 0$  gilt. Die Höhe der Sprungstellen ist  $\mathbb{P}(X = x)$ .

**Beweis.** Das folgt aus der Darstellung

$$F_X(x) = \sum_{y \leq x} \mathbb{P}_X(\{y\}) = \sum_{y \leq x} \mathbb{P}(X = y). \quad \square$$

**Beispiel 3.1.9 (Verteilungsfunktion der Gleichverteilung)**

Ist  $X$  gleichverteilt auf  $[a, b]$ , schreibt man  $X \sim \mathcal{U}([a, b])$  und es gilt für  $x \in \mathbb{R}$  nach Beispiel 1.3.5

$$F_X(x) = \mathbb{P}_X((-\infty, x]) = \frac{|(-\infty, x] \cap [a, b]|}{|[a, b]|} = \frac{x - a}{b - a} \cdot \mathbb{1}_{[a, b]} + \mathbb{1}_{x \geq b}. \quad \diamond$$




Abb. 16: Verteilungsfunktion der diskreten Gleichverteilung. [Quelle: Wiki]

**SATZ 3.1.2: EIGENSCHAFTEN DER KONTINUIERLICHEN VERTEILUNGSFUNKTION**

Sei  $X$  eine reellwertige Zufallsvariable. Dann gilt

- ①  $F_X$  ist monoton wachsend.
- ②  $F_X$  ist rechtsstetig.
- ③  $F \in [0, 1]$ ,  $F(-\infty+) = 0$ ,  $F(\infty-) = 1$ .

**Bemerkung 3.1.10 (Verteilungsfunktion  $\iff$  W-Maß)**

Alternativ kann man eine Verteilungsfunktion auch genau über die oben genannten Eigenschaften definieren und dann zeigen, dass zu jeder Verteilungsfunktion  $F$  genau ein Wahrscheinlichkeitsmaß  $\mathbb{P}(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  existiert, sodass  $\mathbb{P}((-\infty, x]) = F(x)$  gilt.

Ebenfalls kann man zu jeder Verteilungsfunktion  $F$  einen Wahrscheinlichkeitsraum und eine reellwertige Zufallsvariable konstruieren, deren Verteilungsfunktion mit  $F$  übereinstimmt.

Daraus folgt

**Lemma 3.1.11**

*Eine Verteilung ist durch die Angabe ihrer Verteilungsfunktion eindeutig bestimmt: Sind  $X$  und  $Y$  zwei reellwertige Zufallsvariablen mit  $F_X = F_Y$ , so folgt  $P_X = P_Y$ .*

also insbesondere: gilt  $F_\mu = F_\nu$  für zwei Wahrscheinlichkeitsmaße  $\mu$  und  $\nu$  auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  so folgt  $\mu \equiv \nu$ .

**Lemma 3.1.12**

*Eine Verteilungsfunktion  $F_X$  von  $X$  ist genau dann stetig in  $x$  wenn  $\mathbb{P}(X = x) = 0$  gilt.*

**Beweis.** Leicht, vgl. HA V Aufg 4  $\Leftarrow$  . □

Ist  $f : \mathbb{R} \rightarrow [0, \infty)$  eine Dichte, so ist die Funktion

$$F : \mathbb{R} \rightarrow [0, 1], \quad x \mapsto \int_{-\infty}^x f(y) \, dy \quad (7)$$

eine Verteilungsfunktion. Das motiviert die

**DEFINITION 3.1.13 (ABSOLUTSTETIGE VERTEILUNGSFUNKT.)**

Jede Verteilungsfunktion  $F$ , für die eine Dichte existiert, sodass (7) gilt, heißt **absolutstetige Verteilungsfunktion**.

absolutstetige Verteilungsfunktion

Ist  $X$  eine Zufallsvariable mit absolutstetiger Verteilungsfunktion  $F_X$  und zugehöriger Dichte  $f_X$ , so folgt aus (7) für alle  $B \in \mathcal{B}(\mathbb{R})$

$$\mathbb{P}(X \in B) = \int_B f_X(y) \, dy. \quad (8)$$

## 3.2 Diskrete Verteilungen

### BERNOULLI-Verteilung

Die Verteilung der **Indikatorfunktion**  $\mathbb{1}_A$  des Ereignisses  $A \in \mathcal{A}$  nimmt zwei Werte an. Wir interpretieren das Ereignis  $\{\mathbb{1}_A = 1\} = A$  als Erfolg und bezeichnen  $p := \mathbb{P}(X = 1) = \mathbb{P}(A)$  als **Erfolgswahrscheinlichkeit**. Für die Wahrscheinlichkeit des Misserfolgs gilt  $\mathbb{P}(X = 0) \stackrel{1.1.9}{=} 1 - p$ .

#### DEFINITION 3.2.1 (BERNOULLI-VERTEILUNG/EXPERIMENT)

Sei  $p \in [0, 1]$ . Das durch die Zähldichte

$$\{0, 1\} \rightarrow [0, 1], \quad 1 \mapsto p, \quad 0 \mapsto 1 - p$$

definierte Wahrscheinlichkeitsmaß auf  $\{0, 1\}$  heißt **BERNOULLI-Verteilung zu  $p$**  und wird mit  $\text{Ber}(p)$  bezeichnet. Zufallsexperimente mit nur zwei Ausgängen nennt man **BERNOULLI-Experimente**.

#### Beispiel 3.2.2 (BERNOULLI-Experimente)

Beim Werfen einer Münze, dem Geschlecht eines Neugeborenen oder dem Ziehen einer Kugel aus einer Urne mit zwei verschiedenen Arten von Kugeln handelt es sich um **BERNOULLI-Experimente**.  $\diamond$

### Binomialverteilung

Seien  $(X_k \sim \text{Ber}(p))_{k=1}^n$  unabhängige Zufallsvariablen und  $p \in [0, 1]$ . Die Zufallsvariable  $S_n := \sum_{k=1}^n S_k \in \{0, \dots, n\}$  zählt die **Gesamtanzahl der Erfolge**. Dann gilt für  $k \in \mathbb{N}$

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1 - p)^{n-k},$$

da  $\binom{n}{k}$  die Anzahl der  $n$ -Tupel mit  $k$  Einsen und  $n - k$  Nullen ist.

#### DEFINITION 3.2.3 (BINOMIALVERTEILUNG)

Sei  $n \in \mathbb{N}$  und  $p \in [0, 1]$ . Das durch die Zähldichte

$$b(\cdot, n, p) : \{0, \dots, n\} \rightarrow [0, 1], \quad k \mapsto \binom{n}{k} p^k (1 - p)^{n-k}$$

definierte Wahrscheinlichkeitsmaß auf  $\{0, \dots, n\}$  heißt **Binomialverteilung zu  $n$  und  $p$**  und wird mit  $\text{Bin}(n, p)$  bezeichnet.




Abb. 17: unnamed figure

**BERNOULLI-Verteilung zu  $p$**   
**BERNOULLI-Experimente**






Abb. 18: unnamed figure



**Binomialverteilung zu  $n$  und  $p$**

Abb. 19: unnamed figure



## Geometrische Verteilung

Seien  $(X_k \sim \text{Ber}(p))_{k \in \mathbb{N}}$  unabhängige Zufallsvariablen mit  $p > 0$ . Die **Wartezeit auf den ersten Erfolg** definieren wir als  $T := \min_{X_k=1} k$ . Wir erhalten für  $k \in \mathbb{N}$

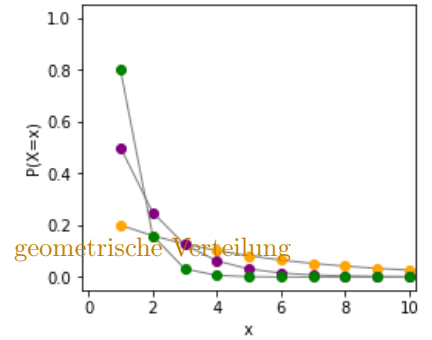
$$\begin{aligned} \mathbb{P}(T = k) &= \mathbb{P}((X_n = 0)_{n=0}^{k-1}, X_k = 1) \\ &= \prod_{n=0}^{k-1} \mathbb{P}(X_n = 0) \cdot \mathbb{P}(X_k = 1) = (1-p)^{k-1}p. \end{aligned}$$

### DEFINITION 3.2.4 (GEOMETRISCHE VERTEILUNG)

Sei  $p \in (0, 1]$ . Das durch die Zähldichte

$$\mathbb{N} \rightarrow [0, 1], \quad k \mapsto (1-p)^{k-1}p$$

definierte Wahrscheinlichkeitsmaß auf  $\mathbb{N}$  heißt **geometrische Verteilung zu  $p$**  und wird mit  $\text{Geo}(p)$  bezeichnet.



Ihre wohl wichtigste Eigenschaft ist die

### SATZ 3.2.1: GEDÄCHTNISLOSIGKEIT

- ① Sei  $T$  geometrisch verteilt. Dann gilt für alle  $k \geq 2, n \in \mathbb{N}$

$$\mathbb{P}(T \geq n+k-1 \mid T \geq n) = \mathbb{P}(T \geq k) \quad (9)$$

- ② Ist  $T : \Omega \rightarrow \mathbb{N}$  eine Zufallsvariable mit Eigenschaft (9), so ist sie geometrisch verteilt.

**Beweis.** ① Sei  $T$  geometrisch verteilt. Dann gilt für  $m \in \mathbb{N}$

$$\begin{aligned} \mathbb{P}(T \geq m) &= \sum_{k=m}^{\infty} \mathbb{P}(T = k) = \sum_{k=m}^{\infty} (1-p)^{k-1}p \\ &= (1-p)^{m-1} \cdot p \cdot \sum_{k=0}^{\infty} (1-p)^k \\ &= (1-p)^{m-1} \cdot p \cdot \frac{1}{1-(1-p)} = (1-p)^{m-1} \end{aligned}$$

und somit

$$\begin{aligned} \mathbb{P}(T \geq k-1+n \mid T \geq n) &= \frac{\mathbb{P}(T \geq k-1+n)}{\mathbb{P}(T \geq n)} = \frac{(1-p)^{k-1+n-1}}{(1-p)^{n-1}} \\ &= (1-p)^{k-1} = \mathbb{P}(T \geq k). \end{aligned}$$

- ② Da  $\mathbb{P}(T \geq k) = \mathbb{P}(T > k-1)$  gilt, ist (9) äquivalent zu

$$\mathbb{P}(T \geq k+n \mid T > n) = \mathbb{P}(T > k). \quad (10)$$

Abb. 21: Die geometrische Verteilung für  $p \in \{0.2, 0.5, 0.8\}$ .

Setzt man  $n = 2$  in (10) ein, so erhält man

$$\mathbb{P}(T \geq k + 2 \mid T > 2) = \mathbb{P}(T > k) \quad \forall k \in \mathbb{N}.$$

Nach Definition der bedingten Wahrscheinlichkeit  $(\star)$  gilt nun

$$\begin{aligned} \mathbb{P}(T > k + 1) &= \mathbb{P}(T \geq k + 2) \stackrel{(\star)}{=} \mathbb{P}(T \geq k + 2 \mid T > 2) \underbrace{\mathbb{P}(T > 2)}_{>0} \\ &\stackrel{(10)}{=} \mathbb{P}(T > k) \mathbb{P}(T > 2) = \mathbb{P}(T \geq k + 1) \mathbb{P}(T > 2) \\ &\stackrel{(\star)}{=} \mathbb{P}(T \geq k + 1 \mid T > 2) \mathbb{P}(T > 2)^2 \\ &\stackrel{(10)}{=} \mathbb{P}(T \geq k - 1) \mathbb{P}(T > 2)^2. \end{aligned}$$

Iteration ergibt  $\mathbb{P}(T > k + 1) = \mathbb{P}(T > 2)^{k+1}$   $(\star)$  für alle  $k \in \mathbb{N}_0$ .

Mit  $q := \mathbb{P}(T > 2)$  folgt

$$\mathbb{P}(T = k) = \mathbb{P}(T > k - 1) - \mathbb{P}(T > k) = q^{k-1} - q^k = q^{k-1}(1 - q).$$

Nun bleibt noch  $q < 1$  zu zeigen. Wir nehmen an, dass  $q = 1$  gilt.

Durch Umstellen folgt mit  $(\star)$   $\mathbb{P}(T > k + 1) = 1$  für alle  $k \in \mathbb{N}_0$

und somit  $\mathbb{P}(T \leq k + 1) = 0$  bzw.  $\mathbb{P}(T \leq n) = 0$  für alle  $n \in \mathbb{N}$ . Mit

der Stetigkeit von Maßen folgt

$$\mathbb{P}(T \in \mathbb{N}) = \lim_{n \rightarrow \infty} \mathbb{P}(T \leq n) = 0,$$

was ein Widerspruch zu  $\mathbb{P}(T \in \mathbb{N}) = 1$  darstellt.  $\square$

### Beispiel 3.2.5

Seien  $W := (\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X, Y : W \rightarrow (\mathbb{N}, \mathcal{P}(\mathbb{N}))$  zwei unabhängige Zufallsvariablen mit  $X, Y \sim \text{Geo}(p)$  für  $p \in (0, 1]$ . Dann gilt  $\min(X, Y) \sim \text{Geo}(1 - q^2)$  für  $q := p - 1$ . (vgl. A.2.5). Bestimmen Sie die Verteilung von  $Z := \min(X, Y)$ .  $\diamond$

## Negative Binomialverteilung

Als Verallgemeinerung der geometrischen Verteilung können wir für jedes  $n \geq 1$  die Wartezeit auf den  $n$ -ten Erfolg

$$T_n := \min_{\sum_{j=1}^k X_j = n} k \in \mathbb{N}_{\geq n}$$

betrachten. Für die Verteilung ergibt sich analog zu den obigen Überlegungen für  $k \geq n$

$$\mathbb{P}(T_n = k) = \binom{k-1}{n-1} (1-p)^{k-n} p^n$$

**DEFINITION 3.2.6 (NEGATIVE BINOMIALVERTEILUNG)**

Sei  $p \in (0, 1]$  und  $n \in \mathbb{N}$ . Das durch die Zähldichte

$$\mathbb{N}_{\geq n} \rightarrow [0, 1], \quad k \mapsto \binom{k-1}{n-1} (1-p)^{k-n} p^n$$

definierte Wahrscheinlichkeitsmaß auf  $\mathbb{N}_{\geq n}$  heißt **negative Binomialverteilung** zu den Parametern  $n$  und  $p$ .

negative Binomialverteilung

## POISSON-Verteilung

**DEFINITION 3.2.7 (POISSON-VERTEILUNG)**

Sei  $\lambda > 0$ . Das durch die Zähldichte

$$\pi_\lambda : \mathbb{N}_0 \rightarrow [0, 1], \quad k \mapsto e^{-\lambda} \frac{\lambda^k}{k!}$$

definierte Wahrscheinlichkeitsmaß auf  $\mathbb{N}_0$  heißt **POISSON-Verteilung** zu  $\lambda$  und wird mit  $\text{Poiss}(\lambda)$  bezeichnet.

Der nächste Satz zeigt, dass die POISSON-Verteilung sich als Näherung der Binomialverteilung für große  $n$  und kleiner  $p$  (genauer: kleine  $np^2$ ) eignet. Eine näherungsweise Berechnung von Wahrscheinlichkeiten gewisser Ereignisse mit Hilfe einer POISSON-Verteilung ist immer dann gerechtfertigt, wenn es sich um seltene Ereignisse handelt.

**SATZ 3.2.2: POISSONSCHER GRENZWERTSATZ**

Sei  $(p_n)_{n \in \mathbb{N}} \subset [0, 1]$  eine Folge von Erfolgsparametern mit  $np_n \xrightarrow{n \rightarrow \infty} \lambda > 0$ . Dann gilt für alle  $k \in \mathbb{N}_0$

$$b(k; n, p_n) \xrightarrow{n \rightarrow \infty} \pi_\lambda(k).$$

**Beweis.** Es gilt

$$\begin{aligned} b(k; n, p_n) &= \binom{n}{k} p_n^k (1 - p_n)^{n-k} \\ &= \frac{1}{k!} \cdot \underbrace{\frac{n}{n}}_{=1} \cdot \underbrace{\frac{n-1}{n}}_{\rightarrow 1} \cdots \underbrace{\frac{n-k+1}{n}}_{\rightarrow 1} \underbrace{(np_n)^k}_{\rightarrow \lambda^k} \underbrace{\left(1 - \frac{np_n}{n}\right)^{n-k}}_{\sim \left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}} \\ &\xrightarrow{n \rightarrow \infty} \frac{\lambda^k}{k!} e^{-\lambda} = \pi_\lambda(k). \quad \square \end{aligned}$$





Abb. 22: von Wiki





### Hypergeometrische Verteilung

Sei ein Grundmenge  $\Omega$  mit  $|\Omega| = N$ , von denen  $K$  Elemente die Eigenschaft  $E$  besitzen. Es werde  $n$ -mal ohne Zurücklegen gezogen. Sei  $X$  die Zufallsvariable, welche die Anzahl der gezogenen Elemente mit Eigenschaft  $E$  angibt.

#### Beispiel 3.2.8 (Hochrechnungen)

Wir wollen die Anzahl der Fische in einem See,  $N$ , schätzen. Wir markieren zunächst  $K$  Fische rot. Danach ziehe man  $n \leq N$  Fische. Dann ist  $X$  die Anzahl der markierten Fische aus dieser Stichprobe und  $\tilde{N} := \frac{nK}{X}$  ist eine natürliche Schätzung für  $N$ , da  $\frac{X}{n} \sim \frac{K}{N}$  gilt.

Fall 1:  $\frac{n}{N}$  ist klein. Dann gibt es keinen großen Unterschied zwischen Ziehen mit und ohne Zurücklegen. Deswegen können wir die Verteilung von  $X$  durch  $\text{Bin}(n, \frac{K}{N})$  approximieren, also  $\mathbb{P}(X = k) \approx b(k; n, \frac{K}{N})$ . Dies sieht man so: Für  $N, K_N \rightarrow \infty$  mit  $p_N := \frac{K_N}{N} \xrightarrow{N \rightarrow \infty} p$  gilt mit  $K = K_N$

$$\begin{aligned} \mathbb{P}(X = k) &= \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} = \binom{n}{k} \frac{K!}{(K-k)!} \frac{(N-K)!}{((N-K)-(n-k))!} \frac{(N-n)!}{N!} \\ &= \binom{n}{k} \prod_{\ell=N-K-n-k+1}^K \frac{\ell}{N} \cdot \prod_{\ell=N-n+1}^N \frac{N}{\ell} \xrightarrow{N \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} \end{aligned}$$

Fall 2:  $\frac{n}{N}$  ist groß. Dann muss man die Verteilung von  $X$  exakt berechnen: für  $k \in \{0, \dots, n\}$  gilt die obige Formel.  $\diamond$

#### DEFINITION 3.2.9 (HYPERGEOMETRISCHE VERTEILUNG)

Seien  $K, n \leq N$ . Das durch die Zähldichte

$$\text{Hyp}(\cdot; n, N, k) : \{0, \dots, n\} \rightarrow [0, 1], \quad k \mapsto \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$$

definierte Wahrscheinlichkeitsmaß auf  $\{0, \dots, n\}$  heißt **Hypergeometrische Verteilung** und wird mit  $\text{Hyp}(n, N, k)$  bezeichnet.




Abb. 24: Wahrscheinlichkeitsfunktion der hypergeometrischen Verteilung für  $k = 20$ ;  $N = 20, n = 30$  (blau),  $N = 50, n = 60$  (grün) und  $N = 20, n = 60$  (rot)

Hypergeometrische Verteilung

Es ergibt sich die folgende Übersicht diskreter Verteilungen:

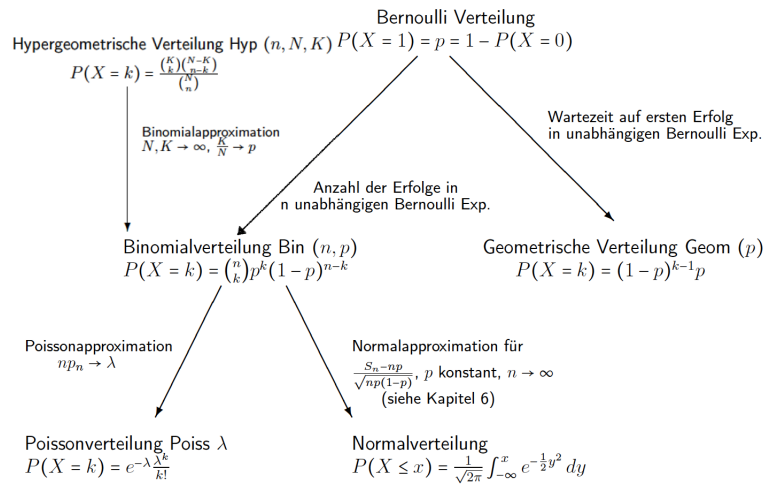


Abb. 25: Übersicht über die diskreten Verteilungsfunktionen und ihre Approximationsmöglichkeiten.

### 3.3 Stetige Verteilung

#### DEFINITION 3.3.1 (GLEICHVERTEILUNG)

Für  $a < b$  heißt eine Zufallsvariable mit Dichte  $f := \frac{1}{b-a} \mathbb{1}_{[a,b]}$  und Verteilungsfunktion ist  $\frac{x-a}{b-a} \cdot \mathbb{1}_{[a,b]} + \mathbb{1}_{x \geq b}$  gleichverteilt auf  $[a, b]$ .

#### DEFINITION 3.3.2 (EXPONENTIALVERTEILUNG)

Für  $\lambda > 0$  heißt die zu der Dichte  $f_\lambda(x) := \lambda e^{-\lambda x} \mathbb{1}_{x \geq 0}$  zugehörige Verteilung,  $F(x) := 1 - e^{-\lambda x} \mathbb{1}_{x \geq 0}$ , **Exponentialverteilung** zum Parameter  $\lambda$  und wird  $\text{Exp}(\lambda)$  bezeichnet.

Die Exponentialverteilung ist das stetige Analogon der geometrischen Verteilung, dementsprechend verwendet man die Exponentialverteilung zur Modellierung stetig verteilter Wartezeiten.

#### Beispiel 3.3.3 (Vielfache / Summen der Exponentialverteilung)

Sei  $X \sim \exp(\vartheta)$  für  $\vartheta > 0$ . Für  $a > 0$  gilt  $aX \sim \exp\left(\frac{\vartheta}{a}\right)$  (vgl. A.2.2).  $\diamond$

#### SATZ 3.3.1: EXPONENTIALVERTEILUNG GEDÄCHTNISLOS

- ① Sei  $T$  exponentialverteilt. Dann gilt für alle  $s > 0$  und  $t > 0$

$$\mathbb{P}(T > s + t \mid T > t) = \mathbb{P}(T > s) \quad (11)$$

- ② Ist  $T$  eine nichtnegative Zufallsvariable mit den Eigenschaften (11) und  $\mathbb{P}(T > 0) > 0$ , so ist  $T$  exponentialverteilt.


**Beweis.** ① Sei  $T$  exponentialverteilt mit Parameter  $\lambda > 0$  und  $F$  die zugehörige Verteilungsfunktion. Dann gilt  $\mathbb{P}(T > t) \stackrel{1.1.9}{=} 1 - F(t) = e^{-\lambda t}$  für  $t > 0$  und somit

$$\mathbb{P}(T > s+t \mid T > t) = \frac{\mathbb{P}(T > s+t)}{\mathbb{P}(T > t)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda t}} = e^{-\lambda s} = \mathbb{P}(T > s).$$

- ② Sei  $T$  eine nichtnegative Zufallsvariable mit der Eigenschaft (11),  $F$  ihr Verteilungsfunktion und  $\bar{F} := 1 - F$ . Dann folgt für  $t, s > 0$

$$\begin{aligned} \bar{F}(t+s) &= \mathbb{P}(T > s+t) = \mathbb{P}(T > s+t \mid T > t) \mathbb{P}(T > t) \\ &\stackrel{(11)}{=} \mathbb{P}(T > s) \mathbb{P}(T > t) = \bar{F}(t) \bar{F}(s). \end{aligned} \quad (12)$$

Aus Analysis I folgt, dass jede **strikt positive rechtsstetige Funktion**, welche der **Funktionalgleichung** (12) genügt, von der Form  $\bar{F}(t) = e^{-\lambda t}$  für ein  $\lambda \in \mathbb{R}$  ist. (★) Da  $\bar{F}(t) \xrightarrow{t \rightarrow \infty} 0$  gilt, folgt  $\lambda > 0$ . Somit ist  $T$  exponentialverteilt.



Exponentialverteilung

Abb. 26: Die Dichte der Exponentialverteilung [Quelle: Wiki]

( $\star$ ): Induktiv folgt aus (12)  $\bar{F}(1/n) = \bar{F}(1)^n$ , also  $F(1) = \bar{F}(1/n)^{1/n}$ . Da  $\bar{F}(1/n) > 0$  und  $\bar{F}(1) \in (0, 1]$ , existiert ein  $\lambda \in \mathbb{R}$  mit  $\bar{F}(1) = e^{-\lambda}$ . Ähnlich folgt  $\bar{F}(1) = \bar{F}(p/q)^{p/q}$  für alle  $p, q \in \mathbb{Z}$  und somit  $\bar{F}(t) = e^{-\lambda t}$  für  $t \in \mathbb{Q}$ . Aufgrund der Rechtsstetigkeit folgt  $\bar{F}(t) = e^{-\lambda t}$  für  $t \in \mathbb{R}$ .  $\square$

Analog zum diskreten Fall können wir auch die Familie der Exponentialverteilungen in eine Familie allgemeinerer Wartezeitenverteilungen einbetten:

**DEFINITION 3.3.4 ( $\Gamma$ -VERTEILUNG)**

Die zu der Dichte  $f(x) := \frac{\lambda^\vartheta}{\Gamma(\vartheta)} x^{\vartheta-1} e^{-\lambda x} \mathbf{1}_{x>0}(x)$  für  $\lambda, \vartheta > 0$  gehörende Verteilung heißt  **$\Gamma$ -Verteilung**  $\Gamma_{\vartheta, \lambda}$ .

Hierbei ist  $\Gamma(\vartheta) := \int_0^\infty x^{\vartheta-1} e^{-x} dx$  für  $\vartheta > 0$  die  **$\Gamma$ -Funktion**. Insbesondere gilt  $\text{Exp}(\lambda) = \Gamma_{1, \lambda}$ .

Die Summe  $n$  unabhängig  $\text{Exp}(\lambda)$ -verteilter Wartezeiten ist  $\Gamma_{n, \lambda}$ -verteilt (siehe Beispiel 3.30) **TODO**.

**DEFINITION 3.3.5 (NORMALVERTEILUNG)**

Die für  $m \in \mathbb{R}$  und  $\sigma > 0$  zu der  $f_{m, \sigma^2}(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x-m)^2}{\sigma^2}\right)$  gehörenden Verteilung heißt **Normalverteilung**  $\mathcal{N}(m, \sigma^2)$  mit **Mittel**  $m$  und **Varianz**  $\sigma^2$ .

**Bemerkung 3.3.6** Für  $m = 0$  und  $\sigma^2$  spricht man von der **Standard-normalverteilung**. Es gilt  $X \sim \mathcal{N}(m, \sigma^2) \implies \frac{X-m}{\sigma} \sim \mathcal{N}(0, 1)$ .

**Beispiel 3.3.7 ( $(aX + b) \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$ )**

Seien  $X \sim \mathcal{N}(\mu, \sigma^2)$ ,  $\sigma > 0$ ,  $a \in \mathbb{R} \setminus \{0\}$  und  $b \in \mathbb{R}$ . Dann ist  $(aX + b) \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$  (vgl. A.2.3).  $\diamond$

**Beispiel 3.3.8 (Summe von Normalverteilungen)**

Seien  $X_i : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  unabhängige Zufallsvariablen mit  $X_i \sim \mathcal{N}(m_i, \sigma_i^2)$  mit  $m_i \in \mathbb{R}$  und  $\sigma_i > 0$  für  $i \in \{1, 2\}$ . Dann gilt  $Z := X_1 + X_2 \sim \mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$ . (vgl. A.2.4)  $\diamond$

**$\Gamma$ -Verteilung**




Abb. 27: Die bei Null zentrierte ( $m = 0$ ) Normalverteilung für  $\sigma \in \{0.5, 1, 2\}$ . **Normalverteilung**

**Varianz**

## 3.4 Gemeinsame Verteilung und Unabhängigkeit von Zufallsvariablen.

Sei im Folgenden immer  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum.

### DEFINITION 3.4.1 (UNABHÄNGIGE ZUFALLSVARIABLEN)

Die  $((E_k, \mathcal{E}_k))_{k=1}^n$ -wertige Zufallsvariablen  $(X_k)_{k=1}^n$  heißen **(stochastisch) unabhängig**, falls für alle Teilmengen  $B_i \in \mathcal{E}_i$  die Ereignisse  $(\{X_k \in B_k\})_{k=1}^n$  (stochastisch) unabhängig sind.

(stochastisch) unabhängig

### Korollar 3.4.2 (Produktformel)

Die obigen Zufallsvariablen sind (vgl. 2.2.1) genau dann unabhängig, wenn  $\mathbb{P}((X_k \in B_k)_{k=1}^n) = \prod_{k=1}^n \mathbb{P}(X_k \in B_k)$  für alle  $(B_k \in \mathcal{E}_k)_{k=1}^n$  gilt.

### Lemma 3.4.3 (Unabhängigkeit transformationsinvariant)

Sind  $(f_k : (E_k, \mathcal{E}_k) \rightarrow (D_k, \mathcal{D}_k))_{k=1}^n$  messbare Abbildungen, so sind die transformierten Zufallsvariablen  $(f_k(X_k))_{k=1}^n$  unabhängig.

**Beweis.** Aufgrund der Messbarkeit der Transformationen gilt  $f^{-1}(B_i) \in \mathcal{E}_i$  für alle  $B_i \in \mathcal{D}_i$  für alle  $i \in \{1, \dots, n\}$ . Aufgrund der Unabhängigkeit von  $(X_k)_{k=1}^n$  sind auch  $(\{X_k \in f_k^{-1}(B_k)\})_{k=1}^n$  stochastisch unabhängig. Aus  $\{X_k \in f_k^{-1}(B_k)\} = \{f_k(X_k) \in B_k\}$  folgt die Unabhängigkeit.  $\square$

Wir wollen die Unabhängigkeit von Zufallsvariablen mittels ihrer Verteilungen charakterisieren.

### DEFINITION 3.4.4 (GEMEINSAME VERTEILUNG)

Seien  $(X_k)_{k=1}^n$   $((E_k, \mathcal{E}_k))_{k=1}^n$ -wertige Zufallsvariablen und  $E := \prod_{k=1}^n \mathcal{E}_k$  und  $\mathcal{E} := \bigotimes_{k=1}^n \mathcal{E}_k$  und

$$\mathbb{X} := (X_k)_{k=1}^n : \Omega \rightarrow E, \omega \mapsto ((X_k(\omega))_{k=1}^n).$$

Dann heißt die Verteilung

$$\mathbb{P}_{\mathbb{X}} : \mathcal{E} \rightarrow [0, 1], B \mapsto \mathbb{P}(\mathbb{X} \in B) = \mathbb{P}((X_1, \dots, X_n) \in B)$$

**gemeinsame Verteilung** von  $(X_k)_{k=1}^n$ .

gemeinsame Verteilung

**Bemerkung 3.4.5** Für Zylindermengen  $B := \prod_{k=1}^n B_k \in \mathcal{E}$  gilt insbesondere  $\mathbb{P}_{\mathbb{X}}(B) = \mathbb{P}((X_k \in B_k)_{k=1}^n)$ .

## Gemeinsame Verteilung und Unabhängigkeit diskreter Zufallsvariablen

Seien  $(X_k)_{k=1}^n$   $E_i$ -wertige Zufallsvariablen, wobei die  $E_i$  höchstens abzählbar sind. Dann ist auch  $\mathbb{X} := (X_k)_{k=1}^n$  eine  $E := \prod_{k=1}^n E_k$ -wertige Zufallsvariable, wobei  $E$  höchstens abzählbar ist. Daher ist die gemeinsame Verteilung der  $(X_k)_{k=1}^n$  eindeutig durch ihre Zähldichte

$$p_{\mathbb{X}} : E \rightarrow [0, 1], \quad ((e_k)_{k=1}^n) = \mathbb{P}((X_k = e_k)_{k=1}^n)$$

bestimmt.

### SATZ 3.4.1: UNABHÄNGIG MIT GEMEINS. VERTEILUNG

Unter den obigen Bedingungen sind die folgenden Aussage äquivalent.

- ①  $(X_k)_{k=1}^n$  sind unabhängig.
- ② Es gilt  $\mathbb{P}((X_k = e_k)_{k=1}^n) = \prod_{k=1}^n \mathbb{P}(X_k = e_k)$  für alle  $(e_k)_{k=1}^n \in E$ .
- ③ Es gilt  $p_{\mathbb{X}}((e_k)_{k=1}^n) = \prod_{k=1}^n p_{X_k}(e_k)$  für alle  $(e_k)_{k=1}^n \in E$ .

**Beweis.** Wir zeigen nur ②  $\implies$  ①. Seien  $(B_k \subset E_k)_{k=1}^n$ ,  $B := \prod_{k=1}^n B_k$  und  $e := ((e_k)_{k=1}^n)$ . Dann gilt

$$\begin{aligned} \mathbb{P}((X_k \in B_k)_{k=1}^n) &= \sum_{e \in B} \mathbb{P}((X_k = e_k)_{k=1}^n) = \sum_{e \in B} \prod_{k=1}^n \mathbb{P}(X_k = e_k) \\ &= \prod_{k=1}^n \sum_{e_k \in B_k} \mathbb{P}(X_k = e_k) = \prod_{k=1}^n \mathbb{P}(X_k \in B_k). \quad \square \end{aligned}$$

### Beispiel 3.4.6 (BERNOULLI-Experimente)

Seien  $(A_n)_{n \in \mathbb{N}}$  eine Folge unabhängiger Ereignisse mit  $\mathbb{P}(A_n) = p$  und  $X_n := \mathbb{1}_{A_n}$  der Ausgang des  $n$ -ten Versuchs. Dann ist  $(X_n)_{n \in \mathbb{N}}$  eine Folge unabhängiger  $\{0, 1\}$ -wertiger Zufallsvariablen, denn für alle  $(i_k)_{k=1}^n \in \{0, 1\}$  gilt

$$\mathbb{P}((X_k = i_k)_{k=1}^n) = \mathbb{P}\left(\bigcap_{k=1}^n A_k^{(i_k)}\right) = \prod_{k=1}^n \mathbb{P}(A_k^{(i_k)}) = \prod_{k=1}^n \mathbb{P}(X_k = i_k),$$

wobei  $A_j^{(i_j)} = A_j \mathbb{1}_{i_j=0} + A_j^c \mathbb{1}_{i_j=1}$  ist. Wir haben benutzt, dass nach Satz 2.2.1 mit  $(A_k)_{k=1}^n$  auch die Ereignisse  $(A_k^{(i_k)})_{k=1}^n$  unabhängig sind.

Für die Zähldichte der gemeinsamen Verteilung der  $\mathbb{X} := (X_k)_{k=1}^n$  gilt

$$p_{\mathbb{X}}((i_k)_{k=1}^n) = p^{\sum_{j=1}^n i_j} (1-p)^{\sum_{j=1}^n 1-i_j}$$

Es stimmt also mit dem Produkt der Wahrscheinlichkeitsmaße  $(\mathbb{P}_j(1) = p = 1 - \mathbb{P}_j(\{0\}))_{j=1}^n$  (vgl. 2.3.4) überein.  $\diamond$

## 3.5 Erwartungswert und Varianz reellwertiger Zufallsvariablen

Erwartungswert und Varianz sind die beiden wichtigsten Kennzahlen einer Zufallsvariablen.

### Erwartungswert diskreter Zufallsvariablen

#### DEFINITION 3.5.1 (DISKRETER ERWARTUNGSWERT)

Sei  $X$  eine diskrete Zufallsvariable mit Werten  $x_n \in \mathbb{R}$  für  $n \in \mathbb{N}$ .

- Ist  $x_n \geq 0$  für alle  $n \in \mathbb{N}$ , so heißt

$$\mathbb{E}[X] := \sum_{n \in \mathbb{N}_0} x_n \mathbb{P}(X = x_n) \in [0, \infty]$$

der Erwartungswert von  $X$ .

- Der Erwartungswert von  $X$  existiert, wenn  $\mathbb{E}[|X|] < \infty$  gilt.

Erwartungswert

**Bemerkung 3.5.2** Der Erwartungswert ist das mit den Wahrscheinlichkeiten gewichtete Mittel der Funktionswerte und lässt sich daher als Schwerpunkt von  $X$  interpretieren. Der Erwartungswert hängt nur von der Verteilung und nicht der Zufallsvariablen ab.

#### Beispiel 3.5.3 (Erste Erwartungswerte)

- Für den fairen Münzwurf gilt  $\mathbb{E}[X] = 0 \cdot \mathbb{P}(X = 0) + 1 \cdot \mathbb{P}(X = 1) = \frac{1}{2}$ .
- Beim Würfeln gilt  $\mathbb{E}[X] = \sum_{k=1}^6 \frac{k}{6} = \frac{7}{2}$ .
- Für  $A \in \mathcal{A}$  gilt  $\mathbb{E}[\mathbb{1}_A] = 0 \cdot \mathbb{P}(A^c) + 1 \cdot \mathbb{P}(A) = \mathbb{P}(A)$ .  $\diamond$

#### Lemma 3.5.4 (Rechenregeln für Erwartungswert)

Seien  $X$  und  $Y$  beliebige diskrete Zufallsvariablen, deren Erwartungswert existieren. Dann gilt

$$\mathbb{E}[aX + Y] = a \mathbb{E}[X] + \mathbb{E}[Y] \quad \forall a, b \in \mathbb{R} \quad (\text{Linearität})$$

$$X \geq 0 \implies \mathbb{E}[X] \geq 0 \quad (\text{Nichtnegativität})$$

$$|\mathbb{E}[X]| \leq \mathbb{E}[|X|] \quad (\triangle \neq)$$

Ferner gilt für eine beliebige (messbar???) Funktion  $h: \mathbb{R} \rightarrow \mathbb{R}$  der **Transformationssatz**:

Transformationssatz

$$\mathbb{E}(h(X)) = \sum_{n \in \mathbb{N}_0} h(x_n) \mathbb{P}(X = x_n)$$

Aus der Linearität und Nichtnegativität folgt die Monotonie des Erwartungswerts.

**SATZ 3.5.1: ERWARTUNGSWERT UND UNABHÄNGIGKEIT**

Seien  $(X_k)_{k=1}^n$  unabhängige diskrete Zufallsvariablen, deren Erwartungswerte existieren. Dann existiert der Erwartungswert von  $X := \prod_{k=1}^n X_k$  und es gilt  $\mathbb{E}[X] = \prod_{k=1}^n \mathbb{E}[X_k]$ .

**Beweis.** Für  $k \in \{1, \dots, n\}$  seien  $x_{\ell}^k$  die Werte Zufallsvariablen  $X_k$  und  $\ell \in \mathbb{N}$ . Dann gilt

$$\begin{aligned} \mathbb{E}[|X|] &= \sum_{\ell_1, \dots, \ell_n} \left| \prod_{k=1}^n x_{\ell_k}^k \right| \mathbb{P}((X_k = x_{\ell_k}^k)_{k=1}^n) \\ &\stackrel{(*)}{=} \sum_{\ell_1, \dots, \ell_n} \left| \prod_{k=1}^n x_{\ell_k}^k \right| \prod_{k=1}^n \mathbb{P}(X_k = x_{\ell_k}^k) = \sum_{\ell_1, \dots, \ell_n} \prod_{k=1}^n |x_{\ell_k}^k| \mathbb{P}(X_k = x_{\ell_k}^k) \\ &= \prod_{k=1}^n \sum_{\ell_1, \dots, \ell_n} |x_{\ell_k}^k| \mathbb{P}(X_k = x_{\ell_k}^k) = \prod_{k=1}^n \mathbb{E}[|X_k|] < \infty, \end{aligned}$$

wobei wir in  $(*)$  die Unabhängigkeit nutzen. Also existiert  $\mathbb{E}[X]$  und Wiederholung derselben Rechnung ohne den Betrag beweist die Behauptung.  $\square$

**Beispiel 3.5.5**

- Sind  $(X_k)_{k=1}^n$  unabhängig BERNOULLI-verteilt mit Erfolgswahrscheinlichkeit  $p$ , so gilt  $\mathbb{E}[X_k] = p$  für alle  $k \in \{1, \dots, n\}$ . Insbesondere gilt  $\mathbb{E}[S_n] = \sum_{k=1}^n \mathbb{E}[X_k] = np$  für  $S_n := \sum_{k=1}^n X_k \sim \text{Bin}(n, p)$ .

Aus dem Transformationssatz folgt für  $\alpha \in \mathbb{R}$  und alle  $k \in \{1, \dots, n\}$

$$\mathbb{E}[\exp(\alpha X_k)] = e^0 \mathbb{P}(X_k = 0) + e^\alpha \mathbb{P}(X_k = 1) = (1 - p) + pe^\alpha$$

und somit

$$\begin{aligned} \mathbb{E}[\exp(\alpha S_n)] &= \mathbb{E} \left[ \prod_{k=1}^n \exp(\alpha X_k) \right] = \prod_{k=1}^n \mathbb{E}[\exp(\alpha X_k)] \\ &= (1 - p + pe^\alpha)^n. \end{aligned}$$

- Ähnlich zu oben folgt  $\mathbb{E}[X] = \lambda$  und  $\mathbb{E}[\exp(\alpha X)] = \exp(-\lambda(1 - e^\alpha))$  für  $X \sim \text{Pois}(\lambda)$ .  $\diamond$

**Erwartungswert reellwertiger Zufallsvariablen**



**DEFINITION 3.5.6 (ALLGEMEINER ERWARTUNGSWERT)**

Sei  $X$  eine Zufallsvariable. Dann nennen wir

$$\mathbb{E}[X] := \int_{\Omega} X \, d\mathbb{P} \quad \text{falls} \quad \int_{\Omega} |X| \, d\mathbb{P} < \infty$$

Erwartungswert von  $X$ .

**Bemerkung 3.5.7** Das Lemma 3.5.4 (vgl. Transformationssatz und der Satz 3.5.1) übertragen sich auf den reellwertigen Fall.

Die Konstruktion des Bildmaßes  $d\mathbb{P}$  wird im Anhang (vgl. A.1.4) ausgeführt.

**Beispiel 3.5.8**

- Sei  $X \sim \mathcal{U}([a, b])$ . Dann existiert der Erwartungswert und ist gleich  $\int_a^b \frac{x \, dx}{b-a} = \frac{a+b}{2}$ , also der Mittelpunkt des Intervalls.
  - Ist  $X \sim \text{Exp}(\lambda)$ , so existiert der Erwartungswert und ist gleich  $\lambda^{-1}$ .
  - Ist  $X \sim \mathcal{N}(0, 1)$  so existiert der Erwartungswert und ist gleich Null.
- Aus Bemerkung 3.3.6 folgt  $\mathbb{E}[X] = m$  für  $X \sim \mathcal{N}(m, \sigma^2)$ .  $\diamond$

**Varianz reellwertiger Zufallsvariablen**

Seien im folgenden alle Zufallsvariablen stets reellwertig.

**DEFINITION 3.5.9 (MOMENTE)**

Seien  $X$  eine Zufallsvariable und  $p \in \mathbb{N}$ . Dann heißt  $\mathbb{E}[X^p]$  das **p-te Moment** von  $X$ .

p-te Moment

**SATZ 3.5.2: CAUCHY-BUNJAKOWSKI-SCHWARZ**

Seien  $X$  und  $Y$  quadratintegrierbare Zufallsvariablen. Dann gilt  $\mathbb{E}[|XY|] < \infty$  und

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2] \mathbb{E}[Y^2]}.$$

**Beweis.** Aus der binomischen Formel folgt  $|XY| \leq \frac{X^2}{2} + \frac{Y^2}{2}$  und somit  $\mathbb{E}[|XY|] < \infty$ . Seien o.B.d.A. ( $\mathbb{E}[X^2] > 0$  oder)  $\mathbb{E}[Y^2] > 0$  und definiere  $\alpha := \frac{\mathbb{E}[XY]}{\mathbb{E}[Y^2]}$ . Dann gilt

$$0 \leq \mathbb{E}[(X - \alpha Y)^2] = \mathbb{E}[X^2] - 2\alpha \mathbb{E}[XY] + \alpha^2 \mathbb{E}[Y^2] = \mathbb{E}[X^2] - \frac{\mathbb{E}[XY]^2}{\mathbb{E}[Y^2]},$$

woraus durch Ziehen der Wurzel die Behauptung folgt.  $\square$

**DEFINITION 3.5.10 (VARIANZ)**

Sei  $X$  eine Zufallsvariable mit  $|\mathbb{E}[X]| < \infty$ . Dann heißt die **mittlere quadratische Abweichung** von  $X$  um ihren Erwartungswert

$$\text{Var}[X] := \mathbb{E}[(X - \mathbb{E}[X])^2] \in [0, \infty]$$

**Varianz** von  $X$ .

**Varianz**

**Bemerkung 3.5.11**

Aus Satz 3.5.2 folgt insbesondere  $\text{Var}[X] < \infty \iff \mathbb{E}[X^2] < \infty$ .

**DEFINITION 3.5.12 (STANDARDABWEICHUNG)**

Die Zahl  $S[X] := \sqrt{\text{Var}[X]}$  heißt **Standardabweichung** von  $X$ .

**Standardabweichung**

**DEFINITION 3.5.13 (KOVARIANZ, UNKORRELIERTHEIT)**

Seien  $X$  und  $Y$  quadratintegrierbare Zufallsvariablen. Dann heißt

$$\text{Cov}[X, Y] := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

die **Kovarianz** von  $X$  und  $Y$ . Gilt  $\text{Cov}(X, Y) = 0$  so heißen  $X$  und  $Y$  **unkorreliert**.

**Kovarianz**

**SATZ 3.5.3: RECHENREGELN FÜR VARIANZEN**

Seien  $X, Y$  und  $(X_k)_{k=1}^n$  quadratintegrierbare Zufallsvariablen.

- Es gilt

$$\text{Var}[aX + b] = a^2 \text{Var}[X] \quad \text{und} \quad (\text{lokale Invarianz})$$

$$\text{Cov}[aX + b, cY + d] = ac \text{Cov}(X, Y) \quad \forall a, b, c, d \in \mathbb{R}$$

$$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2 \quad \text{und} \quad (\text{Verschiebungssatz})$$

$$\text{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

- Die Kovarianz ist eine positiv semidefinite symmetrische Bilinearform.
- **Identität von BIENAYMÉ (B)**. Sind  $(X_k)_{k=1}^n$  paarweise unkorreliert, so folgt  $\text{Var}[\sum_{k=1}^n X_k] = \sum_{k=1}^n \text{Var}(X_k)$ .
- Sind  $X$  und  $Y$  unabhängig, so sind sie unkorreliert.

**Beweis.** Leichtes Rechnen. □

**Gegenbeispiel 3.5.14 (Unkorreliert  $\implies$  unabhängig)**

Seien  $A_1, A_2 \subset A_3$  disjunkt mit  $0 < \mathbb{P}(A_1) = \mathbb{P}(A_2) < \mathbb{P}(A_3) < 1$ . Dann

sind die Zufallsvariablen  $X := \mathbb{1}_{A_1} - \mathbb{1}_{A_2}$  und  $Y := \mathbb{1}_{A_3}$  unkorreliert, da

$$XY = \mathbb{1}_{A_1 \cap A_3} - \mathbb{1}_{A_2 \cap A_3} = \mathbb{1}_{A_1} - \mathbb{1}_{A_2} = X$$

sowie  $\mathbb{E}[X] = \mathbb{P}(A_1) - \mathbb{P}(A_2) = 0$  und somit

$$\text{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[X] - \mathbb{E}[X]\mathbb{E}[Y] = 0$$

gilt, aber nicht unabhängig, da

$$\begin{aligned}\mathbb{P}(X = 1, Y = 1) &= \mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_1) \\ &\neq \mathbb{P}(A_1)\mathbb{P}(A_3) = \mathbb{P}(X = 1)\mathbb{P}(Y = 1)\end{aligned}$$

gilt. ◇

**Beispiel 3.5.15 (Varianzen der wichtigen Verteilungen)**

- Für  $(X_k \sim \text{Ber}(p))_{k=1}^n$  gilt  $\text{Var}[S_n] = \sum_{k=1}^n \text{Var}[X_1] = np(1-p)$  für  $S_n := \sum_{k=1}^n X_k \sim \text{Bin}(n, p)$ .
- Für  $X \sim \text{Pois}(\lambda)$  gilt  $\mathbb{E}[X^2] = \lambda^2 + \lambda$  und somit  $\text{Var}[X] = \lambda$ .
- Sei  $X \sim \text{Exp}(\lambda)$ . Induktiv erhält man mit partieller Integration  $\mathbb{E}[X^k] = \frac{k!}{\lambda^k}$  und somit  $\text{Var}[X] = \lambda^{-2}$ .
- Sei  $X \sim \mathcal{N}(0, 1)$ . Dann gilt  $\mathbb{E}[X^2] = 1$  und somit  $\text{Var}[X] = 1$ . Sei nun  $X \sim \mathcal{N}(m, \sigma^2)$ . Nach Bemerkung 3.3.6 folgt  $\text{Var}[X] = \sigma^2$ . ◇

## Erzeugenden & charakteristische Funktionen

### 4.1 Erzeugenden Funktionen

#### DEFINITION 4.1.1 (ERZEUGENDEN FUNKTION, ENGL. PGF)

Seien  $X$  eine diskrete Zufallsvariable mit Werten in  $\mathbb{N}_0$  und  $p_n := \mathbb{P}(X = n)$  für  $n \in \mathbb{N}$  die **Zähldichte** der zugehörigen **Verteilung**.

- Dann heißt

$$\mathcal{G}_X : [0, 1] \rightarrow [0, 1], \quad s \mapsto \mathbb{E}[s^X] \stackrel{3.5.4}{=} \sum_{n=0}^{\infty} p_n s^n.$$

**erzeugende Funktion** von  $X$ .

- Ist  $\mathbb{P} = (p_n)_{n \in \mathbb{N}_0}$  eine beliebige **Verteilung** auf  $\mathbb{N}_0$ , so heißt  $\mathcal{G}(s) := \sum_{n=0}^{\infty} p_n s^n$  **erzeugenden Funktion** von  $\mathbb{P}$ .

*probability generating function*

Allgemeiner ist der Definitionsbereich von  $\mathcal{G}_X$  der Konvergenzradius der Potenzreihe.

**erzeugende Funktion**

**Bemerkung** Die Potenzreihe ist wohldefiniert, da

$$\sum_{n \in \mathbb{N}_0} |p_n s^n| \leq \sum_{n \in \mathbb{N}_0} p_n |s|^n \leq \sum_{n \in \mathbb{N}_0} p_n = 1$$

gilt.

#### Lemma 4.1.2

Die erzeugenden Funktion ist für  $|s| < 1$  gliedweise differenzierbar mit

$$\frac{\mathcal{G}^{(n)}(0)}{n!} = p_n.$$

#### Korollar 4.1.3 ( $\mathbb{P} \iff \mathcal{G}$ )

Jede Verteilung  $\mathbb{P} = (p_n)_{n \in \mathbb{N}_0}$  ist eindeutig durch ihre erzeugenden Funktion bestimmt.

#### Beispiel 4.1.4 (erzeugenden Funktionen wichtiger Verteilungen)

- Für  $\text{Bin}(n, p)$  gilt  $\mathcal{G}(s) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} s^k \stackrel{1.2.2}{=} (sp + 1 - p)^n$ .
- Sind  $X \sim \text{Bin}(n, p)$  und  $Y \sim \text{Bin}(m, p)$  unabhängige Zufallsvariablen für  $n, m \in \mathbb{N}$  und  $p \in [0, 1]$ . So gilt  $\mathcal{G}_{X+Y}(t) = (tp + 1 - p)^{n+m}$ , also  $X + Y \sim \text{Bin}(n + m, p)$  (s. A.2.6).
- Für  $\text{Geo}(p)$  gilt  $\mathcal{G}(s) = \frac{ps}{1-(1-p)s}$  mit der geometrischen Reihe.

- Seien  $X, Y \sim \text{Geo}(p)$  unabhängige Zufallsvariablen mit  $p \in (0, 1)$ .  
Dann gilt  $\mathcal{G}_{X+Y} = \sum_{k=0}^{\infty} \binom{n}{k} t^k p^k (1-p)^{n-k}$  und somit  $\mathbb{P}(X+Y = n) = p^2(n-1)(1-p)^{n-2}$  für alle  $n \in \mathbb{N}_{>1}$ .
- Für  $\text{Pois}(\lambda)$  gilt  $\mathcal{G}(s) = \sum_{k \in \mathbb{N}_0} e^{-\lambda} \frac{\lambda^k}{k!} s^k = e^{\lambda(s-1)}$ .  $\diamond$

**Bemerkung (Notation)** Wir schreiben  $F(a \pm) := \lim_{x \rightarrow a \pm} F(x)$ .

**Lemma 4.1.5 (Grenzwertsatz von ABEL)**

Sei  $A := \sum_{n \in \mathbb{N}_0} a_n$  eine konvergente Reihe reeller Zahlen. Dann konvergiert die Potenzreihe  $f(x) := \sum_{n \in \mathbb{N}_0} a_n x^n$  auf  $[0, 1]$  und die Funktion  $f(x)$  ist stetig auf  $[0, 1]$  mit  $f(1) = A$ .

**SATZ 4.1.1: MOMENTENBERECHNUNG**

( $X$  diskret?)

- ① Es gilt  $\mathbb{E}[X] = \mathcal{G}'_X(1-)$ .
- ② Ist  $\mathcal{G}'_X(1-) < \infty$ , so gilt

$$\text{Var}[X] = \mathcal{G}''_X(1-) + \mathcal{G}'_X(1-)(1 - \mathcal{G}'_X(1-)).$$

**Beweis.** ① Für  $|s| < 1$  ist  $\mathcal{G}'_X(s) = \sum_{n \in \mathbb{N}} np_n s^{n-1}$ . Für  $\mathbb{E}[X] = \infty$  ist die Identität klar, sonst folgt sie aus dem Satz von ABEL.

② Für  $|s| < 1$  gilt

$$\mathcal{G}''_X(s) = \sum_{n=2}^{\infty} n(n-1)p_n s^{n-2} = \underbrace{\sum_{n \in \mathbb{N}} n^2 p_n s^{n-2}}_{=: \mathfrak{S}_1(s)} - \underbrace{\sum_{n \in \mathbb{N}} np_n s^{n-2}}_{=: \mathfrak{S}_2(s)}.$$

Ist  $\mathcal{G}'_X(1-) < \infty$  so folgt

$$\lim_{s \nearrow 1} \mathfrak{S}_2(s) = \lim_{s \nearrow 1} \frac{\mathcal{G}'_X(s)}{s} = \mathcal{G}'_X(1-) = \mathbb{E}[X]$$

und analog zu ①

$$\lim_{s \nearrow 1} \mathfrak{S}_1(s) = \sum_{n \in \mathbb{N}} n^2 p_n = \mathbb{E}[X^2]$$

und somit

$$\begin{aligned} \text{Var}[X] &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \lim_{s \nearrow 1} \mathcal{G}''_X(s) + \frac{\mathcal{G}'_X(s)}{s} - \mathcal{G}'_X(s)^2 \\ &= \mathcal{G}''_X(1-) + \mathcal{G}'_X(1-)(1 - \mathcal{G}'_X(1-)). \end{aligned} \quad \square$$

**Beispiel 4.1.6 (Momentenberechnung)**

- Aus dem letzten Beispiel wissen wir, dass für  $X \sim \text{Bin}(n, p)$  die erzeugende Funktion  $\mathcal{G}_X$  ein Polynom und somit überall differenzierbar ist. Aus dem Satz 4.1.1 folgt  $\mathbb{E}[X] = np$  und  $\text{Var}[X] = np(1-p)$ .

- Für  $X \sim \text{Poiss}(\lambda)$  eine global konvergente Potenzreihe und somit differenzierbar. Somit folgt  $\mathbb{E}[X] = \lambda = \lambda^2 + \lambda(1 - \lambda) = \text{Var}[X]$ .  $\diamond$

**SATZ 4.1.2: TODO**

Seien  $(X_k)_{k=1}^n$  unabhängige  $\mathbb{N}_0$ -wertige Zufallsvariablen und  $S_n := \sum_{k=1}^n X_k$ . Dann gilt für  $|s| < 1$

$$\mathcal{G}_{S_n}(s) = \prod_{k=1}^n \mathcal{G}_{X_k}(s)$$

**Beweis.** Da  $(X_k)_{k=1}^n$  unabhängig sind, ist es nach ... auch  $(s^{X_k})_{k=1}^n$  für beliebige  $s \in \mathbb{R}$ . Nach Satz 3.33 (!!!) gilt

$$\mathcal{G}_{S_n}(s) = \mathbb{E} \left[ s^{\sum_{k=1}^n X_k} \right] = \mathbb{E} \left[ \prod_{k=1}^n s^{X_k} \right] = \prod_{k=1}^n \mathbb{E} [s^{X_k}] = \prod_{k=1}^n \mathcal{G}_{X_k}(s). \quad \square$$

**Beispiel 4.1.7 (Anwendung auf BERNOULLI-Experimente)**

Seien  $(Y_k \sim \text{Ber}(p))_{k=1}^n$  unabhängig. Dann gilt  $X := \sum_{k=1}^n Y_k \sim B(n, p)$ . Mit dem obigen Satz können wir unser Ergebnis aus Beispiel 4.1.4 verifizieren:  $\mathcal{G}_X(s) = \prod_{k=1}^n \mathcal{G}_{Y_k}(s) = (sp + 1 - p)^n$ .  $\diamond$

**SATZ 4.1.3: KONVERGENZSATZ FÜR CH. FUNKTIONEN**

Seien  $(P_n = (p_k^{(n)})_{k \in \mathbb{N}_0})_{n \in \mathbb{N}_0}$  eine Folge von Verteilungen auf  $\mathbb{N}_0$  mit erzeugenden Funktionen  $(\mathcal{G}_n)_{n \in \mathbb{N}_0}$ . Dann sind die beiden folgenden Aussage äquivalent.

- Der Grenzwert  $p_k := \lim_{n \rightarrow \infty} p_k^{(n)}$  existiert für alle  $k \in \mathbb{N}_0$ .
- Der Grenzwert  $\mathcal{G}(s) := \lim_{n \rightarrow \infty} \mathcal{G}_n(s)$  existiert für alle  $|s| < 1$ .

In diesem Fall gilt  $p_k \geq 0$  für  $k \geq 0$  mit  $\sum_{k \in \mathbb{N}_0} p_k \leq 1$  und  $\mathcal{G}(s) = \sum_{k \in \mathbb{N}_0} p_k s^k$ .

**Beweis. TODO.**  $\square$

Das folgende Beispiel zeigt, dass im Allgemeinen  $\mathfrak{P} := \sum_{k \in \mathbb{N}_0} p_k < 1$  gilt, dass also die Grenzverteilung ein **defektes Wahrscheinlichkeitsmaß** auf  $\mathbb{N}_0$  ist:  $p_k^{(n)} = \mathbf{1}_{k=n}$ . Dann gilt  $p_k^{(n)} \xrightarrow{n \rightarrow \infty} 0 =: p_k$  für  $k \in \mathbb{N}_0$  also sogar  $\mathfrak{P} = 0$ . Im Falle von  $\mathfrak{P} = 1$  gilt in der Situation des obigen Satzes  $\mathcal{G}(s) = \lim_{n \rightarrow \infty} \mathcal{G}_n(s)$  für  $|s| \leq 1$ .

**Beispiel 4.1.8 (Anwendung: POISSONScher Grenzwertsatz)**

Sei  $(p_n)_{n \in \mathbb{N}}$  eine Folge von Erfolgsparametern mit  $np_n \xrightarrow{n \rightarrow \infty} \lambda > 0$  und  $(\mathcal{G}_n(s) := (sp_n + 1 - p_n)^n)_{n \in \mathbb{N}_0}$  die erzeugenden Funktion der Binomial-

verteilung  $\text{Bin}(n, p)$ . Dann folgt mit  $\lambda_n := np_n$

$$\mathcal{G}_n(s) = (sp_n + 1 - p_n)^n = \left(1 - (1 - s)\frac{\lambda_n}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{(s-1)\lambda},$$

da  $(1 - (1 - s)\frac{\lambda}{n})^n \xrightarrow{n \rightarrow \infty} e^{(s-1)\lambda}$  für alle  $\lambda \in \mathbb{R}$  und

$$\lim_{n \rightarrow \infty} \left| \left(1 - (1 - s)\frac{\lambda_n}{n}\right)^n - \left(1 - (1 - s)\frac{\lambda}{n}\right)^n \right| \leq \lim_{n \rightarrow \infty} |1 - s| |\lambda_n - \lambda| = 0$$

gilt. Die letzte Ungleichung sieht man so ein: Seien  $a := 1 - (1 - s)\frac{\lambda_n}{n}$  und  $b := 1 - (1 - s)\frac{\lambda}{n}$ . Aufgrund von  $s \in [0, 1]$  gilt  $a, b \in [0, 1]$  für große  $n \in \mathbb{N}$ . Nun gilt

$$\begin{aligned} |a^n - b^n| &= \left| \sum_{k=1}^n a^k b^{n-k} - \sum_{k=0}^{n-1} a^k b^{n-k} \right| = \left| \sum_{k=0}^{n-1} a^{k+1} b^{n-1-k} - \sum_{k=0}^{n-1} a^k b^{n-k} \right| \\ &= \left| \sum_{k=0}^{n-1} \underbrace{a^k b^{n-1-k}}_{<1} \right| |a - b| \leq n|a - b| = n|1 - s| \left| \frac{\lambda_n - \lambda}{n} \right|. \end{aligned}$$

**Warum ist das eine Anwendung des Satzes?**

◇

## 4.2 Charakteristische Funktionen



### Vorbetrachtung

Die Funktion  $\mathcal{G}(s) = \sum_{n \in \mathbb{N}_0} p_n s^n$  ist analytisch in  $|s| < 1$  und kann stetig auf dem Rand fortgesetzt werden, (vgl. Satz von ABEL).

Nach komplexer Analysis ist  $\mathcal{G}$  durch seine Randwerte  $\chi_X(t) := \mathcal{G}(e^{it})$  für  $t \in \mathbb{R}$  eindeutig bestimmt.

### DEFINITION 4.2.1 (CHARAKTERISTISCHE FUNKTION)

Sei  $X$  eine reellwertige Zufallsvariable. Dann heißt die Funktion

$$\chi_X : \mathbb{R} \rightarrow \mathbb{C}, \quad t \mapsto \mathbb{E}[\exp(itX)]$$

charakteristische Funktion von  $X$ .

charakteristische Funktion

### Korollar 4.2.2 (Eigenschaften der charakteristischen Funktion)

Sei  $X$  eine reellwertige Zufallsvariable und  $\chi$  ihre charakteristische Funktion. Dann gilt

- $\chi(0) = 1$  und  $|\chi(t)| \stackrel{L\ 3.5.4}{\leq} \mathbb{E}[|\exp(itX)|] = 1$ .
- Ist  $X$  diskret (stetig) verteilt mit den Werten  $x_n$  (Dichte  $f$ ), so gilt

$$\chi_X(t) = \sum_n \mathbb{P}(X = x_n) e^{itx_n} \quad \left( = \int_{\mathbb{R}} e^{itx} f(x) dx \right).$$

den Integralausdruck bezeichnet man als **FOURIER-Transformierte** von  $f$ .

- Die charakteristische Funktion bestimmt die Verteilung einer Zufallsvariablen eindeutig, es gilt  $\chi_X = \chi_Y \iff F_X = F_Y$ .
- Besitzt  $X$  endliches für  $n \in \mathbb{N}_0$   $n$ -tes Moment, so folgt  $\mathbb{E}[X^n] = i^{-n} \chi_X^{(n)}(0)$  (vgl. Satz 4.1.1).
- Seien  $(X_k)_{k=1}^n$  unabhängige Zufallsvariablen. Dann gilt für  $t \in \mathbb{R}$  (vgl. Satz 4.1.2)

$$\chi_{(\sum_{k=0}^n X_k)}(t) = \prod_{k=1}^n \chi_{X_k}(t).$$

- Seien  $X, (X_k)_{k \in \mathbb{N}}$  Zufallsvariablen. Dann sind die beiden folgenden Aussagen äquivalent: (1)  $F_{X_n}(x) \xrightarrow{n \rightarrow \infty} F_X(x)$  für alle Stetigkeitspunkte  $x$  von  $F$  und (2)  $\chi_{X_n}(t) \xrightarrow{n \rightarrow \infty} \chi_X(t)$  für alle  $t \in \mathbb{R}$  (vgl. Satz 4.1.3).

### Beispiel 4.2.3 (Charakteristische Funktion wichtiger Verteilungen)

- Ist  $X \sim \text{Ber}(p)$ , so gilt

$$\chi_X(t) = \mathbb{E}[e^{itX}] = e^{it \cdot 0}(1-p) + e^{it}p = (1-p) + e^{it}p =: B.$$



- Ist  $X \sim \text{Bin}(n, p)$ , so gilt  $\chi_X(t) = \sum_{k=0}^n e^{itk} \binom{n}{k} p^k (1-p)^{n-k} = B^n$ .
- Ist  $X \sim \mathcal{N}(0, 1)$ , so gilt  $\chi_X = e^{-\frac{t^2}{2}}$ . Also folgt für  $Y \sim \mathcal{N}(m, \sigma)^2$   
 $\chi_Y = \exp\left(itm - \frac{(t\sigma)^2}{2}\right)$ . (s. A.2.7)  $\diamond$

**Lemma 4.2.4 (Linearkombinationen von Normalverteilungen)**

Seien  $(X_k \sim \mathcal{N}(m_k, \sigma_k^2))_{k=1}^n$  unabhängig und  $(\alpha_k)_{k=1}^n \subset \mathbb{R}$ . Dann gilt  
 $Z := \sum_{k=1}^n \alpha_k X_k \sim \mathcal{N}(m, \sigma^2)$  mit  $m := \langle \alpha, m \rangle := \sum_{k=1}^n \alpha_k m_k$  und  
 $\sigma^2 := \sum_{k=1}^n \alpha_k^2 \sigma_k^2$ .

**Beweis.** Es gilt

$$\begin{aligned} \chi_Z(t) &= \mathbb{E} \left[ \exp \left( it \sum_{k=1}^n \alpha_k X_k \right) \right] \stackrel{\text{L}}{=} \prod_{k=1}^n \mathbb{E}[\exp(it\alpha_k X_k)] \\ &\stackrel{(\otimes)}{=} \prod_{k=1}^n \exp \left( it\alpha_k m_k - \sigma_k^2 \frac{(t\alpha_k)^2}{2} \right) \\ &= \exp \left( \sum_{k=1}^n \alpha_k m_k - \left( \sum_{k=1}^n \alpha_k^2 \sigma_k^2 \right) \frac{t^2}{2} \right) = \exp \left( itm - \frac{(t\sigma)^2}{2} \right), \end{aligned}$$

wobei wir in  $(\otimes)$  Lemma 3.4.3 benutzt haben. Aufgrund der Eindeutigkeit der charakteristischen Funktion folgt die Behauptung.  $\square$

## 5.1 MARKOVsche Ungleichung

## SATZ 5.1.1: MARKOVSCHE UNGLEICHUNG

Seien  $X$  eine reellwertige Zufallsvariable und  $\Phi : \mathbb{R} \rightarrow [0, \infty)$  monoton wachsend. Dann gilt

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[\Phi(X)]}{\Phi(a)}$$

für alle  $a \in \mathbb{R}$  mit  $\Phi(a) > 0$ .

**Beweis.** Sei  $a \in \mathbb{R}$ . Dann  $\Phi$  monoton wachsend ist, folgt  $\Phi(X(\omega)) < \Phi(a)$  aus  $X(\Omega) \geq a$  für alle  $\omega \in \Omega$ . Das impliziert (Notation aus (6))

$$\{X \geq a\} \subset \{\Phi(X) \geq \Phi(a)\} \implies \mathbb{P}(X \geq a) \leq \mathbb{P}(\Phi(X) \geq \Phi(a)). \quad (13)$$

Nun folgt

$$\begin{aligned} \Phi(a) \mathbb{P}(X \geq a) &\stackrel{(13)}{\leq} \Phi(a) \mathbb{P}(\Phi(X) \geq \Phi(a)) \stackrel{\substack{3.5.3 \\ (L)}}{\leq} \mathbb{E}[\Phi(a) \mathbb{1}_{\{\Phi(X) \geq \Phi(a)\}}] \\ &\stackrel{(M)}{\leq} \mathbb{E}[\Phi(X) \mathbb{1}_{\{\Phi(X) \geq \Phi(a)\}}] \stackrel{(M)}{\leq} \mathbb{E}[\Phi(X)] \end{aligned}$$

Da  $\Phi(a) > 0$  ist, folgt die Behauptung durch Umstellen.  $\square$

**Korollar 5.1.1 (CHEBYSHEV'sche Ungleichung)**

Für  $p \in [1, \infty)$  betrachte die monoton wachsende Funktion  $\Phi(t) := t^p \mathbb{1}_{t>0}(t)$ . Also folgt für alle  $a > 0$

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \frac{\mathbb{E}[|X - \mathbb{E}[X]|^p]}{a^p}$$

Der Spezialfall  $p = 2$

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \frac{\text{Var}[X]}{a^2}$$

heißt **CHEBYSHEV'sche Ungleichung**.

*CHEBYSHEV'sche Ungleichung*

**Korollar 5.1.2 (Generische CHERNOFF-Schranke)**

Für  $\Phi(t) := e^{\lambda t}$  mit  $\lambda > 0$  folgt für alle  $a \in \mathbb{R}$

$$\mathbb{P}(X - \mathbb{E}[X] \geq a) \leq e^{-\lambda a} \mathbb{E}[\exp(\lambda(X - \mathbb{E}[X]))].$$

## 5.2 Das schwache Gesetz der großen Zahlen

### DEFINITION 5.2.1 (STOCHASTISCHE KONVERGENZ)

Seien  $X, (X_k)_{k \in \mathbb{N}}$  Zufallsvariablen. Die Folge  $(X_k)_{k \in \mathbb{N}}$  **konvergiert in Wahrscheinlichkeit** gegen  $X$ , wenn für alle  $\varepsilon > 0$

$$\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

gilt und schreiben  $X_n \xrightarrow{\mathbb{P}} X$ .

### SATZ 5.2.1: SCHWACHES GESETZ DER GROSSEN ZAHLEN

Sei  $(X_n)_{n \in \mathbb{N}}$  eine Folge unkorrelierter identische verteilter Zufallsvariablen mit endlicher Varianz. Dann gilt

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X_1].$$

**Beweis.** Sei  $m := \mathbb{E}[X_1]$  und  $\varepsilon > 0$ . Dann gilt  $\mathbb{E}\left[\frac{1}{n} \sum_{k=1}^n X_k\right] = m$  und

$$\begin{aligned} \mathbb{P}\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - m\right| > \varepsilon\right) &\stackrel{5.1.1}{\leq} \frac{1}{\varepsilon^2} \operatorname{Var}\left[\frac{1}{n} \sum_{k=1}^n X_k\right] \\ &\stackrel{(B)}{=} \frac{1}{(\varepsilon n)^2} \sum_{k=1}^n \operatorname{Var}[X_k] \\ &\stackrel{\text{i.v.}}{=} \frac{1}{\varepsilon^2 \cdot n} \operatorname{Var}[X_1] \xrightarrow{n \rightarrow \infty} 0. \quad \square \end{aligned}$$

### Beispiel 5.2.2 (empirisches $\rightarrow$ theoretisches Mittel)

Seien  $(X_n \sim \operatorname{Ber}(p))_{n \in \mathbb{N}}$  unabhängig. Dann gilt  $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{\mathbb{P}} p$ .  $\diamond$

### SATZ 5.2.2: SCHWACHES GGZ (VERALLGEMEINERUNG)

Sei  $(X_k)_{k=1}^n$  eine Familie paarweise unkorrelierter Zufallsvariablen mit endlicher Varianz. Gilt

$$\frac{1}{n^2} \sum_{k=1}^n \operatorname{Var}[X_k] \xrightarrow{n \rightarrow \infty} 0,$$

so folgt

$$\frac{1}{n} \sum_{k=1}^n (X_k - \mathbb{E}[X_k]) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0.$$

**Beweis.** Für  $\varepsilon > 0$  gilt

$$\begin{aligned} \mathbb{P}\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \mathbb{E}[X_k]\right| > \varepsilon\right) &\leq \frac{1}{\varepsilon^2} \operatorname{Var}\left[\frac{1}{n} \sum_{k=1}^n X_k\right] \\ &= \frac{1}{(\varepsilon n)^2} \sum_{k=1}^n \operatorname{Var}[X_k] \xrightarrow{n \rightarrow \infty} 0. \quad \square \end{aligned}$$


## 5.3 Das starke Gesetz der großen Zahlen

Wir betrachten eine Folge fairer Münzwürfe  $(X_k)_{k \in \mathbb{N}}$  (u.i.v) mit  $\mathbb{P}(X_k = 0) = \mathbb{P}(X_k = 1) = 0.5$ . Nach dem schwachen Gesetz der großen Zahlen gilt für  $S_n := \sum_{k=1}^n X_k$

$$\frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X_1] = 0.5.$$

Betrachten wir nun eine Folge von Realisierungen  $(X_k(\omega))_{k \in \mathbb{N}}$  der Münzwürfe erhalten wir das nebenstehende Verhalten für die Folge der relativen Häufigkeiten. Für ein „typisches“  $\omega$  sollte als  $\frac{S_n}{n}(\omega) \rightarrow 0.5$  gelten.

Daher benötigen wir den stärkeren Konvergenzbegriff der



### DEFINITION 5.3.1 (FAST SICHERE KONVERGENZ)

Seien  $X$  und  $(X_k)_{k \in \mathbb{N}}$  Zufallsvariablen auf  $(\Omega, \mathcal{A}, \mathbb{P})$ . Die Folge  $(X_n)_{n \in \mathbb{N}}$  konvergiert  $\mathbb{P}$ -fast sicher gegen  $X$  falls

$$X_n \xrightarrow{\text{f.s.}} X : \Longleftrightarrow X = \lim_{n \rightarrow \infty} X_n : \Longleftrightarrow \mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

### SATZ 5.3.1: F.S.E UND STOCHASTISCHE KONVERGENZ

Fast sichere Konvergenz impliziert stochastische Konvergenz.

**Beweis.** Seien  $\varepsilon > 0$  und

$$B_N := \{|X_n(\omega) - X(\omega)| < \varepsilon \ \forall n \geq N\}.$$

Die  $B_N$  sind aufsteigend und es gilt

$$B := \bigcup_{N \in \mathbb{N}} B_N \supset \{X_n(\omega) \xrightarrow{n \rightarrow \infty} X(\omega)\} =: A$$

Nach Annahme folgt  $\mathbb{P}(A) = 1$  und somit  $\mathbb{P}(B) = 1$ . Aufgrund der Stetigkeit von  $\mathbb{P}$  von unten folgt

$$\mathbb{P}(B_N) \xrightarrow{N \rightarrow \infty} 1$$

und somit

$$\lim_{N \rightarrow \infty} \mathbb{P}(\{|X_N(\omega) - X(\omega)| \geq \varepsilon\}) \leq \lim_{N \rightarrow \infty} \mathbb{P}(B_N^c) = 0. \quad \square$$

### Gegenbeispiel 5.3.2 (stochastische $\implies$ f.s. Konvergenz)

Wir betrachten den Wahrscheinlichkeitsraum mit  $\Omega := [0, 1]$ ,  $\mathcal{A} := \mathcal{B}([0, 1])$  und der Gleichverteilung  $\mathbb{P}$ . Seien

$$c_n := \sum_{k=1}^n \frac{1}{k} \quad \text{und} \quad A_n := \{\omega : [c_{n-1} \bmod 1, c_n \bmod 1]\}.$$

Für  $\varepsilon \in (0, 1)$  folgt

$$\mathbb{P}(\mathbb{1}_{A_n} \geq \varepsilon) \stackrel{?}{=} \mathbb{P}(A_n) = \frac{1}{n} \xrightarrow{n \rightarrow \infty} 0.$$

Somit gilt  $\mathbb{1}_{A_n} \xrightarrow[n \rightarrow \infty]{f.s.} 0$ . Andererseits gilt für alle  $\omega \in (0, 1)$  **Warum??**

$$\limsup_{n \rightarrow \infty} \mathbb{1}_{A_n}(\omega) = 1 \neq 0 = \liminf_{n \rightarrow \infty} \mathbb{1}_{A_n}(\omega). \quad \diamond$$

### DEFINITION 5.3.3 (lim sup UND lim inf VON MENGEN)

Sei  $(A_n)_{n \in \mathbb{N}} \subset \mathcal{A}$  eine Folge von Ereignissen. Wir definieren

$$\limsup_{n \rightarrow \infty} A_n := \bigcap_{n \in \mathbb{N}} \bigcup_{k=n}^{\infty} A_k = \{\omega \in A_k \text{ für } \infty \text{ viele } k\}$$

$$\liminf_{n \rightarrow \infty} A_n := \bigcup_{n \in \mathbb{N}} \bigcap_{k=n}^{\infty} A_k = \{\omega \in A_k \text{ für alle bis auf endlich viele } k\}$$

### SATZ 5.3.2: BOREL-CANTELLI

Für  $(A_n)_{n \in \mathbb{N}} \subset \mathcal{A}$  gilt

- ① aus  $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) < \infty$  folgt  $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 0$ .
- ② Sind die Ereignisse  $(A_n)_{n \in \mathbb{N}}$  unabhängig, so folgt  $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 1$  aus  $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \infty$ .

**Beweis.** ① Aus  $\bigcup_{k \geq n} A_k \searrow \bigcap_{n \in \mathbb{N}} \bigcup_{k \geq n} A_k$  für  $n \rightarrow \infty$  folgt aus der  $\sigma$ -Stetigkeit von oben von  $\mathbb{P}$

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcup_{k \geq n} A_k\right) \leq \lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k) = 0.$$

- ② Es genügt zu zeigen, dass für alle  $n \in \mathbb{N}$

$$\mathbb{P}\left(\bigcup_{k \geq n} A_k\right) = 1 \quad \text{bzw.} \quad \mathbb{P}\left(\bigcap_{k \geq n} A_k^c\right) = 0$$

gilt. Für alle  $\alpha \in \mathbb{R}$  gilt (TAYLOR!)  $1 - \alpha \leq e^{-\alpha}$  und somit

$$\begin{aligned} \mathbb{P}\left(\bigcap_{k \geq n} A_k^c\right) &= \lim_{m \rightarrow \infty} \mathbb{P}\left(\bigcap_{k=n}^m A_k^c\right) = \lim_{m \rightarrow \infty} \prod_{k=n}^m \mathbb{P}(A_k^c) \\ &= \lim_{m \rightarrow \infty} \prod_{k=n}^m (1 - \mathbb{P}(A_k)) \leq \lim_{m \rightarrow \infty} \prod_{k=n}^m e^{-\mathbb{P}(A_k)} \\ &= \lim_{m \rightarrow \infty} \exp\left(-\sum_{k=n}^m \mathbb{P}(A_k)\right) = 0, \end{aligned}$$

weil die Exponentialfunktion stetig ist.  $\square$

**Korollar 5.3.4 (Bank-Klausur 2014 / 02)**

Seien  $(X_n \sim \text{Ber}(p_n))_{n \in \mathbb{N}}$  unabhängig mit  $p_n \in [0, 1]$  für alle  $n \in \mathbb{N}$ .

Dann gilt  $\sum_{n \in \mathbb{N}} p_n < \infty$  genau dann wenn  $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}\text{-f.s.}} 0$  gilt.

**Beweis.** " $\implies$ ": Definiere  $A_n := \{X_n = 1\}$ . Dann gilt  $\mathbb{P}(A_n) = p_n$ . Aus dem Lemma von BOREL-CANTELLI folgt  $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 0$  und somit

$$1 = \mathbb{P}((\limsup_{n \rightarrow \infty} A_n)^c) = \mathbb{P}(\liminf_{n \rightarrow \infty} A_n^c) = \mathbb{P}(X_n = 0 \text{ für schließlich alle } n).$$

" $\impliedby$ ": Angenommen  $\sum_{k \in \mathbb{N}} p_n = \infty$ . Aus dem Lemma von BOREL-CANTELLI folgt  $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 1$ , was ein Widerspruch zur Voraussetzung ist.  $\square$

**Lemma 5.3.5 (schnelle stochastische Konvergenz)**

Gilt für alle  $\varepsilon > 0$  schnelle stochastische Konvergenz gegen 0

$$\sum_{n \in \mathbb{N}} \mathbb{P}(|X_n| \geq \varepsilon) < \infty$$

so folgt fast sichere Konvergenz gegen 0

$$\mathbb{P}(\{X_n(\omega) \rightarrow 0\}) = 1.$$

**Beweis.** Fehlt.  $\square$

**SATZ 5.3.3: STARKES GGZ (KOLMOGOROV, 1930)**

Sei  $(X_k)_{k \in \mathbb{N}}$  u.i.v. mit endlichem Erwartungswert. Dann gilt

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{\text{f.s.}} \mathbb{E}[X_1]$$

Unter den obigen Voraussetzungen gilt insbesondere das schwache GGZ.

bla

# Multivariate Verteilungen

## DEFINITION 7.0.1 (MULTIVARIATE KENNGRÖSSEN)

Sei  $\mathbb{X}$  ein  $n$ -dim. Zufallsvektor. Dann ist  $\mathbb{E}[\mathbb{X}] := ((\mathbb{E}(X_k))_{k=1}^n)^T$  der **multivariate Erwartungswert**. Die Varianz verallgemeinert die **Kovarianzmatrix**

$$\text{Cov}(\mathbb{X}, \mathbb{X}) := (\text{Cov}(X_i, X_j))_{1 \leq i, j \leq n} = \mathbb{E}[(X - \mathbb{E}[X]) \cdot (\mathbb{X} - \mathbb{E}[X])^T]$$

und

$$\chi_{\mathbb{X}} : \mathbb{R}^n \rightarrow \mathbb{R}, \lambda \mapsto \mathbb{E}[\exp(i \langle \lambda, \mathbb{X} \rangle)]$$

die **charakteristische Funktion**.

Erwartungswert

Kovarianzmatrix

charakteristische Funktion

## Lemma 7.0.2 (Eigenschaften von $\text{Cov}(\mathbb{X}, \mathbb{X})$ )

Die Kovarianzmatrix ist positiv **semidefinit**, **symmetrisch** und genau dann eine Diagonalmatrix wenn die Komponenten  $(X_k)_{k=1}^n$  paarweise unkorreliert sind.

*semidefinit, symmetrisch*

**Beweis.** Für beliebige  $(\lambda_k)_{k=1}^n$  gilt

$$\begin{aligned} \langle \lambda, \text{Cov}(\mathbb{X}, \mathbb{X}) \lambda \rangle &= \sum_{i,j=1}^n \lambda_i \text{Cov}(X_i, X_j) \lambda_j \\ &\stackrel{\text{Def.}}{=} \sum_{i,j=1}^n \lambda_i \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] \lambda_j \\ &\stackrel{(\text{L})}{=} \mathbb{E} \left[ \left( \sum_{k=1}^n \lambda_k (X_k - \mathbb{E}[X_k]) \right)^2 \right] \geq 0. \quad \square \end{aligned}$$

**Bemerkung 7.0.3** Die (gemeinsame) Verteilung ist eindeutig durch ihre charakteristische Funktion bestimmt.



## 7.1 Die Multivariate Normalverteilung

### DEFINITION 7.1.1 (*n*-DIM. STANDARDNORMALVERTEILUNG)

Ein Zufallsvektor  $\mathbb{X} = ((X_k)_{k=1}^n)^T$  heißt **standardnormalverteilt**, wenn  $X_k \sim \mathcal{N}(0, 1)$  gilt und diese unabhängig sind.

Nach Satz ... (3.26) besitzt  $\mathbb{X}$  die (gemeinsame) Dichte

$$f_{\mathbb{X}} : \mathbb{R}^d \rightarrow \mathbb{R}, (x_1, \dots, x_n) \mapsto \prod_{k=1}^n \frac{\exp\left(-\frac{x_k^2}{2}\right)}{\sqrt{2\pi}} = \frac{\exp\left(-\frac{|x|^2}{2}\right)}{(2\pi)^{\frac{n}{4}}}.$$

### Korollar 7.1.2 (Eigenschaften der *n*-dim. SNV)

Ist  $\mathbb{X}$  standardnormalverteilt, so gilt  $\text{Cov}(\mathbb{X}, \mathbb{X}) = \mathbb{E}_n$  und

$$\chi_{\mathbb{X}} : \mathbb{R} \rightarrow \mathbb{R}, \lambda \mapsto \mathbb{E}[\exp(i \langle \lambda, \mathbb{X} \rangle)] = \prod_{k=1}^n e^{-\frac{\lambda_k^2}{2}} = e^{-\frac{|\lambda|^2}{2}}.$$

**Beweis.** Für  $i \neq j \in \{0, \dots, n\}$  gilt  $\mathbb{E}[X_i] = \mathbb{E}[X_j] = 0$  und somit

$$\text{Cov}[X_i, X_j] \stackrel{\text{Def.}}{=} \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] \stackrel{\text{unabh.}}{=} \mathbb{E}[X_i] \mathbb{E}[X_j] = 0.$$

Für  $i = j$  gilt  $\text{Cov}[X_i, X_j] = \text{Var}[X_i] = 1^2 = 1$ . □

### DEFINITION 7.1.3 (*n*-DIM. NORMALVERTEILUNG)

Ein *n*-dim. Zufallsvektor  $\mathbb{X}$  heißt **normalverteilt**, wenn

$$\mathbb{X} = A \mathbb{Y} + m \quad \text{mit } A \in \mathbb{R}^{n \times k}, m \in \mathbb{R}^n, \mathbb{Y} \in \mathbb{R}^k, \mathbb{Y} \sim \mathcal{N}(0, 1)$$

gilt.

### Korollar 7.1.4 (Eigenschaften der *n*-dim. NV)

Es gilt  $\mathbb{E}[\mathbb{X}] = m$ ,  $\text{Cov}[\mathbb{X}, \mathbb{X}] = AA^T$  und  $\chi_{\mathbb{X}}(\lambda) = \exp\left(i \langle \lambda, m \rangle - \frac{\langle \lambda, \Sigma^2 \lambda \rangle}{2}\right)$ .

**Beweis.** Es gilt

$$\mathbb{E}[\mathbb{X}] = A \underbrace{\mathbb{E}[\mathbb{Y}]}_{=0} + m = m$$

und

$$\begin{aligned} \text{Cov}[\mathbb{X}, \mathbb{X}] &= \mathbb{E}[(\mathbb{X} - \mathbb{E}[\mathbb{X}])(\mathbb{X} - \mathbb{E}[\mathbb{X}])^T] = \mathbb{E}[(A \mathbb{Y})(A \mathbb{Y})^T] \\ &= A \mathbb{E}[\mathbb{Y} \mathbb{Y}^T] A^T = AA^T =: \Sigma^2. \end{aligned}$$

Ferner gilt für  $\lambda \in \mathbb{R}$

$$\begin{aligned} \chi_{\mathbb{X}}(\lambda) &= \mathbb{E}[\exp(i \langle \lambda, A \mathbb{Y} + m \rangle)] = \mathbb{E}[\exp(i \langle \lambda, m \rangle + i \langle A^T \lambda, \mathbb{Y} \rangle)] \\ &= \exp\left(i \langle \lambda, m \rangle - \frac{|A^T \lambda|^2}{2}\right) = \exp\left(i \langle \lambda, m \rangle - \frac{\langle \lambda, \Sigma^2 \lambda \rangle}{2}\right). \end{aligned} \quad \square$$

**DEFINITION 7.1.5 (MULTIVARIATE VERTEILUNG DER NV)**

Sei  $\mathbb{X}$  normalverteilt. Die Verteilung von  $\mathbb{X}$  heißt mehrdimensionale Normalverteilung mit **Mittelwert(vektor)**  $m$  und Kovarianzmatrix  $\Sigma^2$ . Man schreibt  $\mathbb{X} \sim \mathcal{N}(m, \Sigma^2)$ .

**Korollar 7.1.6 (Eigenschaften der  $n$ -dim. Verteilung der NV)**

*Affin lineare Transformationen nver Zufallsvektoren sind nv.*

**Beweis.** Seien  $\mathbb{X} = A\mathbb{Y} + m$  wie oben,  $B \in \mathbb{R}^{\ell \times n}$ ,  $d \in \mathbb{R}^\ell$  und  $\mathbb{W} := B\mathbb{X} + d$ . Dann gilt  $\mathbb{E}[\mathbb{W}] = B\mathbb{E}[\mathbb{X}] + d = Bm + d$  und  $\text{Cov}(\mathbb{W}, \mathbb{W}) = B\text{Cov}(\mathbb{X}, \mathbb{X})B^T = B\Sigma^2B^T$ .  $\square$

**SATZ 7.1.1: DICHTEN DER  $n$ -DIM. NV**

Ist  $\mathbb{X}$  ein  $k$ -dimensionaler Zufallsvektor mit charakteristische Funktion  $\chi_{\mathbb{X}}(\lambda) = \exp\left(i\langle \lambda, m \rangle - \frac{\langle \lambda, \Sigma^2 \lambda \rangle}{2}\right)$ , wobei  $m \in \mathbb{R}^n$  und  $\Sigma^2 \in \mathbb{R}^{n \times n}$  symmetrisch positiv semidefinit ist, dann besitzt die Normalverteilung  $\mathcal{N}(m, \Sigma^2)$  die  $n$ -dimensionale Dichte

$$f_{m, \Sigma^2} : \mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto \frac{\exp\left(-\frac{1}{2}\langle x - m, (\Sigma^2)^{-1}(x - m) \rangle\right)}{(2\pi)^{\frac{n}{2}}}$$

**Beweis.** Symmetrische Matrizen sind orthonormal diagonalisierbar; es existiert eine orthonormale Matrix  $U \in \mathbb{R}^{n \times n}$  und Zahlen  $(\sigma_k^2 \geq 0)_{k=1}^n$  (nichtnegative Eigenwerte von  $\Sigma^2$ ), sodass

$$U^T \Sigma^2 U = \text{diag}((\sigma_k^2)_{k=1}^n),$$

gilt. Für den Zufallsvektor  $\mathbb{Y} := U^T(\mathbb{X} - m)$  folgt dann

$$\begin{aligned} \chi_{\mathbb{Y}}(\lambda) &= \mathbb{E}[\exp(\langle U\lambda, \mathbb{X} - m \rangle)] \\ &= \exp\left(-i\langle U\lambda, m \rangle + i\langle U\lambda, m \rangle - \frac{1}{2}\langle U\lambda, \Sigma^2 U\lambda \rangle\right) \\ &= \exp\left(-\frac{1}{2}\langle U\lambda, \Sigma^2 U\lambda \rangle\right) = \exp\left(-\frac{1}{2}\sum_{k=1}^n \lambda_k^2 \sigma_k^2\right), \end{aligned}$$

d.h. die Komponenten  $(Y_k)_{k=1}^n$  sind unabhängig  $\mathcal{N}(0, \sigma_k^2)$ -verteilt. Gilt  $\sigma_k^2 > 0$  für alle  $k \in \{1, \dots, n\}$ , so ist  $\Sigma^2$  positiv definit und  $\mathcal{N}(m, \Sigma^2)$  besitzt eine  $n$ -dimensionale Dichte  $f_{m, \Sigma^2}$ : Für  $B \in \mathbb{R}^n$  gilt

$$\begin{aligned} \mathbb{P}(\mathbb{X} \in B) &= \mathbb{P}(U\mathbb{Y} + m \in B) = \mathbb{P}(\mathbb{Y} \in U^T(B - m)) \\ &\stackrel{\text{ref 3.26}}{=} \int_{U^T(B - m)} \prod_{k=1}^n \frac{\exp\left(-\frac{y_k^2}{2\sigma_k^2}\right)}{\sqrt{2\pi\sigma_k^2}} dy_n \dots dy_1 \\ &= \int_B \frac{\exp\left(-\frac{1}{2}\sum_{k=1}^n \frac{(U^T(x - m)_k)^2}{\sigma_k^2}\right)}{(2\pi)^{\frac{n}{2}} \sqrt{\det(\Sigma^2)}} dx_n \dots dx_1, \end{aligned}$$

Abb. 28: Für  $\sigma_k^2 = 0$  ist  $\chi(t) = e^{-\sigma_k^2 \frac{t^2}{2}} = 1$  die charakteristische Funktion des DIRAC-Maßes  $\delta_0$ , die man als Grenzfall der Normalverteilung  $\mathcal{N}(0, \sigma_k^2)$  für  $\sigma_k^2 \searrow 0$  auffassen kann.

wobei wir für die letzte Gleichheit  $\prod_{k=1}^n \sigma_k^2 = \det(\Sigma^2)$  und

$$\int f(y) \, dy_n \dots dy_1 = \int f(U^T(x - m)) \, dx_n \dots dx_1$$

verwenden. Man sagt, dass  $x = Uy + m$  mit Umkehrabbildung  $y = U^T(x - m)$  maßerhaltene Transformationen sind. Da

$$U \operatorname{diag} \left( (\sigma_k^{-2})_{k=1}^n \right) U^T = \Sigma^{-2}$$

folgt

$$\mathbb{P}(X \in B) = \frac{\exp \left( -\frac{1}{2} \langle x - m, (\Sigma^2)^{-1} (x - m) \rangle \right)}{(2\pi)^{\frac{n}{2}}}. \quad \square$$

**Beispiel 8.0.1 (Irrfahrt auf  $\mathbb{Z}$ )**

Seien  $(Y_k \sim \text{Ber}(p))_{k=1}^n$  unabhängig und  $p \in (0, 1)$ . Dann sind auch  $(X_k := 2Y_k - 1)_{k=1}^n$  unabhängig mit

$$\mathbb{P}(X_k = 1) = p \quad \text{und} \quad \mathbb{P}(X_k = -1) = 1 - p =: q$$

Definiere  $S_n := \sum_{k=1}^n X_k$  und  $S_0 := 0$ .

Wir können  $S_n$  als eine **Irrfahrt**, d.h. zufällige Bewegung eines Teilchens auf  $\mathbb{Z}$ , auffassen. Gegeben die **Position**  $S_n$  zur **Zeit**  $n$  ergibt sich der nächste Schritt zur Position  $S_{n+1}$  aus dem **Inkrement**  $X_{n+1}$ . Die Position  $S_{n+1}$  hängt nur von  $S_n$  und  $X_{n+1}$  ab und nicht von  $(S_k)_{k=1}^n$ , das Teilchen ist **gedächtnislos** (vgl. (14) und (15)).  $\diamond$

14.06.19

Irrfahrt




Abb. 29: TODO

**DEFINITION 8.0.2 (STOCHASTISCHE MATRIX)**

Sei  $I$  eine nichtleere höchstens abzählbare Menge. Eine Matrix  $P := (p_{ij})_{i,j \in I}$  heißt **stochastische Matrix** oder **Übergangsmatrix**

$$p_{ij} \in [0, 1] \quad \forall i, j \in I \quad \text{und} \quad \sum_{j \in I} p_{ij} = 1 \quad \forall i \in I$$

Die Komponenten  $p_{i,j}$  heißen **Übergangswahrscheinlichkeiten**.

stochastische Matrix

**DEFINITION 8.0.3 (MARKOV-KETTE (A. A. MARKOV, 1906))**


Seien  $I$  wie oben und  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum.

- Eine Folge  $(X_k)_{k \in \mathbb{N}_0}$   $I$ -wertiger Zufallsvariablen heißt (zeitlich homogene) **MARKOV-Kette** mit **Übergangsmatrix**  $P$ , wenn für alle  $n \in \mathbb{N}_0$  und  $(i_k)_{k=0}^{n+1} \subset I$  mit  $\mathbb{P}((X_k = i_k)_{k=0}^n) > 0$  gilt

$$\mathbb{P}(X_{n+1} = i_{n+1} \mid (X_k = i_k)_{k=0}^n) = p_{i_n, i_{n+1}}. \quad (14)$$

- $I$  heißt **Zustandsraum** der MARKOV-Kette.
- Die **Startverteilung**  $\nu$  einer MARKOV-Kette ist das durch  $(\nu_i := \mathbb{P}(X_0 = i))_{i \in I}$  auf  $I$  definierte Wahrscheinlichkeitsmaß (also die Verteilung  $\mathbb{P}_{X_0}$  von  $X_0$  unter  $\mathbb{P}$ ).
- Ist  $\nu$  auf einen Punkt konzentriert (d.h.  $\nu_i = 1$  für ein  $i \in I$ ), so schreibt man  $P_i$  statt  $P$  und sagt, dass die MARKOV-Kette in  $i$  startet.

MARKOV-Kette



### SATZ 8.0.1: MARKOV-EIGENSCHAFT

Für eine MARKOV-Kette  $(X_n)_{n \in \mathbb{N}_0}$  mit Startverteilung  $\nu$  gilt

- ① Für alle  $n \in \mathbb{N}_0$  und alle  $(i_k)_{k=0}^n$  gilt

$$\mathbb{P}((X_k = i_k)_{k=0}^n) = \nu_0 \prod_{k=0}^{n-1} p_{i_k, i_{k+1}}.$$

- ② Seien  $n, m \in \mathbb{N}_0$ ,  $i_n \in I$  und  $A \subset I^n, B \subset I^m$ . Ist

$$\mathbb{P}((X_k)_{k=0}^{n-1} \in A, X_n = i_n) > 0,$$

so gilt die **MARKOV-Eigenschaft**

$$\begin{aligned} \mathbb{P}((X_k)_{k=n+1}^{n+m} \in B \mid (X_k)_{k=0}^{n-1} \in A, X_n = i_n) \\ = \mathbb{P}((X_k)_{k=n+1}^{n+m} \in B \mid X_n = i_n), \end{aligned} \quad (15)$$

die Zukunft hängt nicht von Vergangenheit, sondern nur von Gegenwart ab.

MARKOV-Eigenschaft

**Beweis.** ① Mit Induktion über  $n \in \mathbb{N}_0$ . Der Induktionsanfang folgt aus der Definition der Startverteilung.

Induktionsschritt Es gilt

$$\begin{aligned} \mathbb{P}((X_k = i_k)_{k=0}^{n+1}) &= \mathbb{P}(X_{n+1} = i_{n+1} \mid (X_k = i_k)_{k=0}^n) \mathbb{P}((X_k = i_k)_{k=0}^n) \\ &\stackrel{(14)}{=} p_{i_n, i_{n+1}} \mathbb{P}((X_k = i_k)_{k=0}^n) \stackrel{\text{IS}}{=} \nu_{i_0} \prod_{k=0}^n p_{i_k, i_{k+1}} \end{aligned}$$

- ② Seien  $\tilde{A} := \{(i_k)_{k=0}^{n-1} \in A\}$  und  $\tilde{B} := \{(i_k)_{k=n+1}^{n+m} \in B\}$ . Dann gilt

$$\begin{aligned} \mathbb{P}(((X_k)_{k=0}^{n-1}, X_n = i_n, (X_k)_{k=n+1}^{n+m} \in B)) \\ = \sum_{\tilde{A}} \sum_{\tilde{B}} \mathbb{P}((X_k)_{k=0}^{n+m}) \stackrel{\text{①}}{=} \sum_{\tilde{A}} \sum_{\tilde{B}} \nu_{i_0} \prod_{k=0}^{n+m-1} p_{i_k, i_{k+1}} \\ = \left( \sum_{\tilde{A}} \nu_{i_0} \prod_{k=0}^{n-1} p_{i_k, i_{k+1}} \right) \left( \sum_{\tilde{B}} \prod_{k=n}^{n+m-1} p_{i_k, i_{k+1}} \right) \\ \stackrel{\text{①}}{=} \mathbb{P}((X_k)_{k=0}^{n-1} \in A, X_n = i_n) \left( \sum_{\tilde{B}} \prod_{k=n}^{n+m-1} p_{i_k, i_{k+1}} \right) \end{aligned}$$

Folglich gilt

$$\mathbb{P}((X_k)_{k=n+1}^{n+m} \in B \mid (X_k)_{k=0}^{n-1} \in A, X_n = i_n) = \sum_{\tilde{B}} \prod_{k=n}^{n+m-1} p_{i_k, i_{k+1}}$$

unabhängig von  $A$ . Insbesondere gilt

$$\begin{aligned} & \mathbb{P}((X_k)_{k=n+1}^{n+m} \in B \mid (X_k)_{k=0}^{n-1} \in A, X_n = i_n) \\ &= \mathbb{P}((X_k)_{k=n+1}^{n+m} \in B \mid \underbrace{(X_k)_{k=0}^{n-1} \in I^n}_{\text{immer wahr}}, X_n = i_n) \\ &= \mathbb{P}((X_k)_{k=n+1}^{n+m} \in B \mid X_n = i_n) \end{aligned} \quad \square$$

20.06.19

#### DEFINITION 8.0.4 (ZEITLICH INHOMOGENE MARKOV-KETTE)

Als Verallgemeinerung kann man die Übergangsmatrix von der Zeit abhängen lassen und erhält eine Familie  $P^{(n)} = (p_{i,j}^{(n)})_{i,j}$  für  $n \in \mathbb{N}_0$  von Übergangsmatrizen. Nach Satz 8.0.1 gilt

$$\mathbb{P}((X_k)_{k=0}^n = i_k) = \nu_{i_0} \prod_{k=0}^{n-1} p_{i_k, i_{k+1}}^{(k)} \quad (16)$$

Eine Folge  $(X_k)_{k \in \mathbb{N}}$   $I$ -wertiger Zufallsvariablen, welche (16) erfüllt, erfüllt die MARKOV-Eigenschaft (15) und heißt **zeitliche inhomogene MARKOV-Kette**.

zeitliche inhomogene  
MARKOV-Kette

#### SATZ 8.0.2: EXISTENZ EINER MARKOV-KETTE

Sei  $P$  eine stochastische Matrix,  $\nu$  ein Wahrscheinlichkeitsmaß auf  $I$  und  $N \in \mathbb{N}$ . Dann existiert ein diskreter Wahrscheinlichkeitsraum  $(\Omega, \mathbb{P}_\nu)$  und Abbildungen  $(X_i : \Omega \rightarrow I)_{0 \leq i \leq N}$ , sodass  $(X_k)_{k=0}^N$  eine homogene MARKOV-Kette mit Startverteilung  $\nu$  und Übergangsmatrix  $P$  ist.

Beweis. TODO

□

#### Lemma 8.0.5 (U.i.d Zufallsvariablen sind MARKOV-Kette)

Seien  $X := (X_k)_{k=0}^N$  u.i.d.  $I$ -wertige Zufallsvariablen. Dann ist  $X$  eine zeitlich homogene MARKOV-Kette mit Übergangsmatrix  $p_{i,j} = p_j := \mathbb{P}(X_0 = j)$  für  $j \in I$ .

**Beweis.** Für  $(i_k)_{k=0}^{n+1}$  mit  $\mathbb{P}((X_k)_{k=0}^n = i_k) > 0$  gilt

$$\begin{aligned} \mathbb{P}(X_{n+1} = i_{n+1} \mid (X_k)_{k=0}^n = i_k) &\stackrel{2.1.2}{=} \frac{\mathbb{P}((X_k)_{k=0}^{n+1} = i_k)}{\mathbb{P}((X_k)_{k=0}^n = i_k)} = \frac{\prod_{k=0}^{n+1} \mathbb{P}(X_k = i_k)}{\prod_{k=0}^n \mathbb{P}(X_k = i_k)} \\ &= \mathbb{P}(X_{n+1} = i_{n+1}). \end{aligned} \quad \square$$

**Beispiel 8.0.6 (Irrfahrt auf  $\mathbb{Z}^d$ )** Wir können die Situation aus 8.0.1 verallgemeinern, indem wir eine beliebige ganze Zahl als Startpunkt

zulassen. Die Übergangsmatrix ist durch  $p_{i,j} := p \cdot \mathbb{1}_{j=i+1} + q \cdot \mathbb{1}_{j=i-1}$  gegeben.

Eine weitere Möglichkeit ist, die **Irrfahrt** auf  $d > 1$  Dimensionen zu verallgemeinern. Die Übergangsmatrix ist durch  $\frac{1}{2d} \mathbb{1}_{\sum_{k=1}^d |i_k - j_k| = 1}$  gegeben.  $\diamond$

### Beispiel 8.0.7 (MARKOV-Ketten mit verschiedenen Rändern)

Sei  $\{0, 1, \dots, b\}$  der Zustandsraum für  $b \in \mathbb{N}_{>0}$ .

Eine MARKOV-Kette mit Übergangsmatrix wie in Beispiel 8.0.6 für  $i \in \{0, \dots, b-1\}$ ,  $p_{0,0} = p_{b,b} = 1$  und  $p_{0,j} = p_{b,j} = 0$  für  $j \in \{0, \dots, b-1\}$  besitzt einen **absorbierenden Rand**.

Eine MARKOV-Kette mit Übergangsmatrix wie in Beispiel 8.0.6 für  $i \in \{0, \dots, b-1\}$  und  $p_{0,1} = p_{b,b-1} = 1$  besitzt einen **reflektierenden Rand**.  $\diamond$

### Beispiel 8.0.8 (EHRENFEST-Modell)

Seien  $n$  Kugeln auf zwei Schachteln verteilt, davon  $k$  in der linken und  $n - k$  in der rechten. In jedem Schritt wird zufällig einer der Kugeln gezogen und in die jeweils andere Schachtel gelegt. Der Zustandsraum (für die Anzahl der Kugeln in der linken Schachtel) ist  $\{0, \dots, n\}$  und die Übergangsmatrix durch

$$p_{i,j} = \begin{cases} \frac{i}{n}, & \text{wenn } i = j + 1, i \in \{1, \dots, n\}, \\ \frac{n-i}{i}, & \text{wenn } i = j - 1, i \in \{0, \dots, n-1\}, \\ 0, & \text{sonst.} \end{cases} \quad \diamond$$





Abb. 31: Irrfahrt auf  $\mathbb{Z}^2$  4[Quelle: Stannat Skript]



**reflektierenden Rand**  
Abb. 32: Eine MARKOV-Kette mit absorbierendem Rand. [Quelle: Wiki]




Abb. 33: Ehrenfest Modell [Quelle: Stannat Skript]

## 8.1 Irreduzibilität

Das folgende Lemma zeigt, dass die Einträge  $p_{i,j}^{(n)}$  der Matrix  $P^n$  die  $n$ -Schritt Übergangswahrscheinlichkeiten der MARKOV-Kette sind.

### Lemma 8.1.1 ( $n$ -Schritt Übergangswahrscheinlichkeiten)

Für  $m, n \in \mathbb{N}_0$  und  $i, j \in I$  mit  $P(X_m = i) > 0$  gilt

$$\mathbb{P}(X_{m+n} = j \mid X_m = i) = p_{i,j}^{(n)}.$$

**Beweis.** Mittels vollständiger Induktion über  $n \in \mathbb{N}$ .

Induktionsschritt. Sei  $\mathcal{K} := \{k \in I : \mathbb{P}(X_{m+1} = k, X_m = i) > 0\}$ .

$$\begin{aligned} \mathbb{P}(X_{n+m}) &\stackrel{2.1.2}{=} \frac{\mathbb{P}(X_{m+n+1} = j, X_m = i)}{\mathbb{P}(X_m = i)} \\ &\stackrel{?}{=} \sum_{\mathcal{K}} \frac{\mathbb{P}(X_{m+n+1} = j, X_{m+1} = k, X_m = i)}{\mathbb{P}(X_{m+1} = k, X_m = i)} \cdot \frac{\mathbb{P}(X_{m+1} = k, X_m = i)}{\mathbb{P}(X_m = i)} \\ &\stackrel{2.1.2}{=} \sum_{\mathcal{K}} \mathbb{P}(X_{m+n+1} = j \mid X_{m+1} = k, X_m = i) \cdot \mathbb{P}(X_{m+1} = k \mid X_m = i) \\ &\stackrel{(15)}{=} \sum_{\mathcal{K}} \mathbb{P}(X_{m+n+1} = j \mid X_{m+1} = k) p_{i,k} = \sum_{k \in I} p_{k,j}^{(n)} p_{i,k} = p_{i,j}^{(n+1)}, \end{aligned}$$

wobei wir in der vorletzten Gleichung verwendet haben, dass

$$\mathbb{P}(X_{m+1} = k, X_m = i) = \underbrace{\mathbb{P}(X_{m+1} = k \mid X_m = i)}_{=p_{i,k}} \underbrace{\mathbb{P}(X_m = i)}_{>0} > 0$$

genau dann gilt, wenn  $p_{i,k} > 0$  ist.  $\square$

### Beispiel 8.1.2 (CHAPMAN-KOLMOGOROV Gleichung)

Seien  $m, n \in \mathbb{N}_0$  und  $i, j \in I$ . Aus der Assoziativität des Matrizenprodukts folgt die **CHAPMAN-KOLMOGOROV Gleichung**

$$p_{i,j}^{(n+m)} = \sum_{k \in I} p_{i,k}^{(m)} p_{k,j}^{(n)}$$

und daraus

$$p_{i,j}^{(n+m)} \geq p_{i,k}^{(m)} p_{k,j}^{(n)} \quad (17)$$

für alle  $k \in I$ .  $\diamond$

Seien im Folgenden stets  $P$  eine Übergangsmatrix auf  $I$  und  $i, j \in I$ .

### DEFINITION 8.1.3 (ERREICHBARKEIT ( $i \rightsquigarrow j$ ))

Existiert ein  $n \in \mathbb{N}_0$  mit  $p_{i,j}^{(n)} > 0$ , so heißt  $j$  **von  $i$  aus erreichbar**.

von  $i$  aus erreichbar

### Korollar 8.1.4 ( $\rightsquigarrow$ ist eine Quasiordnung)

Die Relation  $\rightsquigarrow$  ist reflexiv, transitiv aber nicht symmetrisch.



**Beweis.** Reflexivität: Da  $P^0 = E_I$  ist, gilt  $p_{ii}^{(0)} = 1$  für alle  $i \in I$ .

Transitivität: Gilt  $i \rightsquigarrow j$  und  $j \rightsquigarrow k$  so folgt nach Definition die Existenz von  $m, n \in \mathbb{N}$  mit  $p_{i,j}^{(m)}, p_{j,k}^{(n)} > 0$ . Aus (17) folgt  $p_{i,k}^{(m+n)} > p_{i,j}^{(m)} p_{j,k}^{(n)} > 0$ .

Symmetrie: Betrachte die eindimensionale Irrfahrt mit absorbierendem Rand. Die Randpunkte sind von allen inneren Punkten aus erreichbar aber nicht umgekehrt.  $\square$

#### DEFINITION 8.1.5 (ÄQUIVALENTE ZUSTÄNDE)

Die Zustände  $i, j$  sind **äquivalent** ( $i \rightsquigarrow j$ ), wenn  $i \rightsquigarrow j \rightsquigarrow i$  gilt. Wir schreiben  $A \rightsquigarrow B$  wenn Zustände  $i \in A$  und  $j \in B$  mit  $i \rightsquigarrow j$  existieren.

äquivalent

#### Korollar 8.1.6 ( $\rightsquigarrow$ ist eine Äquivalenzrelation)

$\rightsquigarrow$  ist eine Äquivalenzrelation auf  $I$ . Die Notation  $A \rightsquigarrow B$  für Äquivalenzklassen  $A, B$  ist unabhängig von den Repräsentanten  $i \rightsquigarrow j$ .

**Beweis.** Die erste Aussage folgt direkt aus Korollar 8.1.4. **TODO:** zweite Aussage.  $\square$

#### DEFINITION 8.1.7 (IRREDUZIBILITÄT)

$P$  (und jede zugehörige MARKOV-Kette) heißt **irreduzibel**, wenn je zwei Elemente aus  $I$  äquivalent sind.

irreduzibel

#### Beispiel 8.1.8 (eindimensionale Irrfahrt ist irreduzibel)

Die eindimensionale Irrfahrt ist irreduzibel, denn für  $i < j$  gilt

$$p_{i,j}^{(j-i)} = \mathbb{P}(S_{j-i} = j \mid S_0 = i) = p^{j-i} > 0$$

und analog für  $j < i$

$$p_{i,j}^{(i-j)} = \mathbb{P}(S_{i-j} = j \mid S_0 = i) = q^{i-j} > 0.$$

Aus der Irreduzibilität folgt direkt, dass die symmetrische einfache Irrfahrt keine absorbierenden Zustände besitzt.  $\diamond$

#### DEFINITION 8.1.9 (ABGESCHLOSSENHEIT)

Eine nichtleere Menge  $J \subset I$  heißt **abgeschlossen**, falls keine Zustände  $j \in J$  und  $i \in I \setminus J$  existieren, sodass  $j \rightsquigarrow i$  gilt.

abgeschlossen

#### Beispiel 8.1.10 (Äquivalenzklassen der $\mathbb{Z}$ -Irrfahrt mit abs. Rand)

Eine eindimensionale Irrfahrt mit absorbierendem Rand besitzt drei Äquivalenzklassen:  $\{0\}$ ,  $\{b\}$  (beide abg.) und  $\{1, \dots, b-1\}$  (nicht abg.).  $\diamond$


**Beispiel 8.1.11 (Äquivalenzklassen am Übergangsgraph)**

Anhand dem jeder MARKOV-Kette mit endlichem Zustandsraum zuordenbaren Übergangsgraphen sind Äquivalenzklassen oft leichter zu erkennen:

Sei  $I := \{1, 2, 3, 4\}$  und

$$P := \begin{pmatrix} \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ 1 & 0 & 0 & 0 \\ \frac{1}{3} & \frac{1}{3} & 0 & \frac{1}{3} \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Die drei Äquivalenzklassen sind  $\{1, 2\}$ ,  $\{3\}$  und  $\{4\}$ , da 3 nicht von 1 aus erreichbar ist und 3 nicht von 4. Der Zustand 4 ist absorbierend.  $\diamond$



## 8.2 Stationäre Verteilungen

### DEFINITION 8.2.1 (STATIONÄRE MARKOV-KETTE)

Eine MARKOV-Kette  $(X_n)_{n \in \mathbb{N}_0}$  heißt **stationär**, falls für beliebige  $m \in \mathbb{N}$  und  $r \in \mathbb{N}_0$  die Zufallsvektoren  $(X_k)_{k=0}^r$  und  $(X_k)_{k=m}^{m+r}$  dieselbe Verteilung besitzen.

stationär

### Korollar 8.2.2 (Rückrichtung von Lemma 8.0.5 (?))

Für eine stationäre MARKOV-Kette sind insbesondere die einzelnen Zufallsvariablen identisch verteilt.

### Lemma 8.2.3 (Charakterisierung stationären MARKOV-Ketten)

Eine MARKOV-Kette  $(X_n)_{n \in \mathbb{N}_0}$  mit Anfangsverteilung  $\nu$  und Übergangsmatrix  $P$  über  $I$  ist genau dann stationär, wenn

$$\sum_{j \in I} \nu_j p_{j,i} = \nu_i$$

für alle  $i \in I$  gilt.

**Beweis.** „ $\implies$ “: Sei  $(X_n)_{n \in \mathbb{N}_0}$  stationär. Dann besitzen insbesondere  $X_0$  und  $X_1$  die selben Verteilung  $\nu$ . Nach Satz 8.0.1 folgt

$$\begin{aligned} \nu_i &\stackrel{\text{Def.}}{=} \mathbb{P}(X_0 = i) \stackrel{(\text{i.v.})}{=} \mathbb{P}(X_1 = i) \stackrel{(2.1.2)}{=} \sum_{j \in I} \mathbb{P}(X_1 = i, X_0 = j) \\ &\stackrel{(2.1.2)}{=} \sum_{j \in I} \mathbb{P}(X_1 = i \mid X_0 = j) \mathbb{P}(X_0 = j) \stackrel{\text{Def.}}{=} \sum_{j \in I} p_{j,i} \nu_j. \end{aligned}$$

„ $\impliedby$ “: Sei  $\sum_{j \in I} \nu_j p_{j,i} = \nu_i$  für alle  $i \in I$ . Nach Satz 8.0.1 gilt

$$\mathbb{P}((X_k = i_k)_{k=0}^r) = \nu_{i_0} \prod_{k=0}^{r-1} p_{i_k, i_{k+1}} \quad (18)$$

sowie

$$\begin{aligned} \mathbb{P}((X_{m+k} = i_k)_{k=0}^r) &= \sum_{(j_k)_{k=0}^{m-1} \in I} \mathbb{P}((X_k = j_k)_{k=0}^{m-1}, (X_k = i_k)_{k=0}^r) \\ &= \sum_{(j_k)_{k=0}^{m-1} \in I} \nu_{j_0} \prod_{k=0}^{m-1} p_{j_k, j_{k+1}} \cdot i_0 \cdot \prod_{k=0}^{r-1} p_{i_k, i_{k+1}} \\ &\quad \prod_{k=0}^{r-1} p_{i_k, i_{k+1}} \cdot \left( \sum_{(j_k)_{k=0}^{m-1} \in I} \nu_{j_0} \prod_{k=0}^{m-2} p_{j_k, j_{k+1}} \cdot p_{j_{m-1}, i_0} \right). \end{aligned} \quad (19)$$

Nach Annahme gilt nun

$$\begin{aligned}
 \sum_{(j_k)_{k=0}^{m-1} \in I} \nu_{j_0} \prod_{k=0}^{m-2} p_{j_k, j_{k+1}} \cdot p_{j_{m-1}, i_0} &= \sum_{(j_k)_{k=m-1}^1 \in I} \underbrace{\left( \sum_{j_0 \in I} \nu_{j_0} p_{j_0, j_1} \right)}_{= \nu_{j_1}} \cdot \prod_{k=1}^{m-2} p_{j_k, j_{k+1}} \cdot p_{j_{m-1}, i_0} \\
 &= \sum_{(j_k)_{k=m-1}^1 \in I} \nu_{j_1} \cdot \prod_{k=1}^{m-2} p_{j_k, j_{k+1}} \cdot p_{j_{m-1}, i_0} \\
 &= \dots = \nu_{i_0}.
 \end{aligned}$$

Einsetzen in (19) ergibt

$$\mathbb{P}((X_{k+m} = i_k)_{k=0}^r) = \nu_{i_0} \prod_{k=0}^{r-1} p_{i_k, i_{k+1}} \stackrel{(18)}{=} \mathbb{P}((X_k = i_k)_{k=0}^r) \quad \square$$

#### DEFINITION 8.2.4 (STATIONÄRE VERTEILUNG)

Eine Wahrscheinlichkeitsverteilung  $\nu$  auf einem Zustandsraum  $I$  heißt **stationär** (invariant) bezüglich der Übergangsmatrix  $P$ , wenn

**stationär**

$$\sum_{j \in I} \nu_j p_{j,i} = \nu_i \quad \forall i \in I. \quad (20)$$

#### Korollar 8.2.5 (Charakterisierung st. Verteilungen)

Die stationären Verteilungen sind genau die **nichtnegativen Eigenvektoren von  $P^T$  zum Eigenwert 1**, deren **Komponentensumme 1** beträgt.

#### Beispiel 8.2.6 (stationären Verteilungen der Irrfahrt)

Betrachte die Irrfahrt für  $p \in (0, 1)$  und  $q := 1 - p$ . auf

- $I := \{0, \dots, b\}$  mit absorbierendem Rand. Beim Lösen des Gleichungssystems

$$\begin{cases} \nu_0 + q\nu_1 = \nu_0, & p\nu_{b-3} + q\nu_{b-1} = \nu_{b-2}, \\ q\nu_2 = \nu_1, & p\nu_{b-2} = \nu_{b-1}, \\ p\nu_1 + q\nu_3 = \nu_2, & p\nu_{b-1} + \nu_b + \nu_b \\ \vdots \end{cases}$$

erhält man sukzessive  $\nu_1 = \dots = \nu_{n-1} = 0$ . Man erhält die **einparametrische Schar stationärer Verteilung**

$$(\nu_\gamma := (\gamma, 0, \dots, 0, 1 - \gamma))_{\gamma \in [0,1]}$$

- $I := \mathbb{N}_0$  mit Reflexion in 0. Wir erhalten das Gleichungssystem

$$\begin{cases} q\nu_1 = \nu_0, \\ \nu_0 + q\nu_2 = \nu_1, \\ p\nu_{k-1} + q\nu_{k+1} = \nu_k. \end{cases} \implies \begin{cases} \nu_1 - \nu_0 = \frac{p}{q}\nu_0, \\ \nu_2 - \nu_1 = \frac{p}{q}(\nu_1 - \nu_0) - \nu_0, \\ \nu_{k+1} - \nu_k = \frac{p}{q}(\nu_k - \nu_{k-1}), \quad k > 1 \end{cases}$$

Mit  $\gamma := \nu$  und  $j := \frac{p}{1}$  folgt

$$\begin{cases} \nu_1 - \nu_0 = j\gamma, \\ \nu_2 - \nu_1 = j^2\gamma - \gamma, \\ \nu_{k+1} - \nu_k = j^{k+1}\gamma - j^{k-1}\gamma, \quad k \geq 1. \end{cases}$$

Für  $k \geq 1$  impliziert das  $\nu_k = j^k\gamma + j^{k-1}\gamma$ . Also ist

- $\gamma > 0$ , da sonst  $\nu \equiv 0$  kein Wahrscheinlichkeitsmaß wäre,
- $p < q$ , da sonst  $\nu_k \geq \gamma$  für alle  $k \in \mathbb{N}$  also  $\sum_{k \in \mathbb{N}} \nu_k = \infty \neq 1$  gelten würde, eine Widerspruch dazu, dass  $\nu$  ein Wahrscheinlichkeitsmaß ist.

Unter diesen Bedingung gilt mit Indexverschiebung

$$1 = \sum k = 0^\infty \nu_k = 2\gamma \sum_{k=0}^{\infty} j^k = \frac{2\gamma}{1-j} \implies \gamma = \frac{1-j}{2}.$$

Damit ist die stationäre Verteilung durch

$$\nu_k = \frac{1}{2} \begin{cases} 1-j, & k=0, \\ j^{k-1} - j^{k+1}, & k \geq 1 \end{cases}$$

gegeben.

Im Allgemeinen existiert somit nicht immer eine stationäre Verteilung und auch wenn sie existiert, muss sie nicht eindeutig sein.  $\diamond$

### SATZ 8.2.1: ENDLICHE MK BESITZT ST. VERTEILUNG

Sei  $I$  endlich. Dann besitzt jede MARKOV-Kette auch  $I$  mindestens eine stationäre Verteilung.

**Beweis.** Seien o.B.d.A.  $I := \{1, \dots, N\}$  und  $P$  die Übergangsmatrix einer MARKOV-Kette auf  $I$ . Die Menge der Wahrscheinlichkeitsmaße auf  $I$  können wir mit dem  $N-1$ -dimensionalen **Simplex**

$$\Delta_N := \left\{ (\nu_k)_{k=1}^N \in \mathbb{R}^N : \nu_j \geq 0, \sum_{k=1}^N \nu_k = 1 \right\}$$

identifizieren. Sei nun  $\nu^{(0)}$  eine beliebige Startverteilung und  $\nu^{(n)} := \nu^{(0)} P^n$  für  $n \geq 1$ .

Dann ist auch das **CESARO-Mittel**  $\pi^{(n)} := \frac{1}{n} \sum_{k=0}^{n-1} \nu^{(k)}$  eine Wahrscheinlichkeitsmaß auf  $I$ , da Linearkombinationen von Maßen mit nichtnegativen Koeffizienten wieder Maße sind.

Nach dem **Satz von BOLZANO-WEIERSTRASS** besitzt die Folge  $(\pi^{(n)})_{n \in \mathbb{N}}$  eine konvergente Teilfolge  $(\pi^{(n_k)})_{k \in \mathbb{N}}$ , welche gegen  $\pi$  konvergiert. Auf-

grund der **Abgeschlossenheit von  $\Delta_N$**  ist  $\pi \in \Delta_N$  ein Wahrscheinlichkeitsmaß auf  $I$ . Aus

$$\pi^{(n_k)} P = \frac{1}{n_k} \sum_{k=0}^{n_k-1} \nu^{(0)} P^{k+1} = \frac{1}{n_k} \sum_{k=1}^{n_k} \nu^{(0)} P^k = \pi^{(n_k)} + \frac{\nu^{n_k} - \nu^{(0)}}{n_k} \quad (21)$$

folgt

$$\pi P \stackrel{\text{Def.}}{=} \lim_{k \rightarrow \infty} \lim_{k \rightarrow \infty} \pi^{(n_k)} P \stackrel{(21)}{=} \lim_{k \rightarrow \infty} \lim_{k \rightarrow \infty} \pi^{(n_k)} + \frac{\nu^{n_k} - \nu^{(0)}}{n_k} = \pi$$

und somit die Invarianz von  $\pi$ . □

## 8.3 Der KonvergenzsatZ für MARKOV-Ketten auf endlichen Zustandsräumen

### SATZ 8.3.1: KONVERGENZSATZ FÜR ENDLICHEN MARKOV-KETTEN

Sei  $(X_n)_{n \in \mathbb{N}_0}$  eine MARKOV-Kette auf einem endlichem Zustandsraum  $I$  mit Übergangsmatrix  $P$ . Existiert ein  $r \in \mathbb{N}$ , sodass die Matrix  $P^r$  mindestens eine Spalte mit strikt positiven Einträgen besitzt, gilt

- ① Für beliebige  $i, j \in I$  existieren die von  $i$  unabhängigen Grenzwerte

$$\lim_{n \rightarrow \infty} p_{i,j}^{(n)} = \nu_j.$$

- ②  $\nu = (\nu_i)_{i \in I}$  ist die einzige stationäre Verteilung von  $(X_n)_{n \in \mathbb{N}_0}$ .

**Beweis.** Sehr lang. □

Wir untersuchen nun, was die Voraussetzung an die Positivität einer Spalte von  $P^r$  konkret bedeutet.

#### DEFINITION 8.3.1 ((UN)WESENTLICHE ZUSTÄNDE)

Ein Zustand  $i$  heißt **wesentlich**, falls aus  $i \rightsquigarrow j$  stets  $j \rightsquigarrow i$  folgt.

wesentlich

#### Lemma 8.3.2 (Äquivalente Zustände auch (un)wesentlich)

Aus der (Un)wesentlichkeit von  $i \in I$  folgt die (Un)wesentlichkeit aller äquivalenten Zustände.

**Beweis.** Sei  $i$  wesentlich und  $j$  zu  $i$  äquivalent. Angenommen, es gilt  $j \rightsquigarrow k$ . Aus  $i \rightsquigarrow j$  und  $j \rightsquigarrow k$  folgt  $i \rightsquigarrow k$  und damit  $k \rightsquigarrow i$ , weil  $i$  wesentlich ist. Aus  $j \rightsquigarrow i$  folgt deshalb  $k \rightsquigarrow j$ . □

Die Einschränkung der Übergangsmatrix  $P$  auf eine wesentliche Klasse  $W \subset I$ ,  $P^W$ , ist wieder eine Übergangsmatrix, d.h. die Zeilensummen sind 1, denn für alle  $i \in W$  und  $j \notin W$  gilt  $p_{i,j} = 0$ . Insbesondere ist die Einschränkung irreduzibel.

Lemma 8.3.2 liefert eine Zerlegung des Zustandsraums  $I$  in wesentliche (Äquivalenz)Klassen  $(K_i)_{i=1}^{\omega}$  und unwesentliche Klassen  $(K_i)_{i=\omega+1}^{\omega+n}$ . Die Übergangsmatrix kann nach entsprechender Nummerierung der Zustände

auf folgenden Gestalt transformiert werden:

$$P = \left[ \begin{array}{ccc|ccc} P_{11} & & 0 & & & \\ & \ddots & & & 0 & \\ 0 & & P_{\omega,\omega} & & & \\ \hline & & & P_{\omega+1,\omega+1} & & * \\ & * & & & \ddots & \\ & & & * & & P_{\omega+n,\omega+n} \end{array} \right]$$

Dabei sind  $P_{\ell,\ell}$  die zu den Klassen  $K_\ell$  gehörenden Teilmatrizen. Insbesondere sind die Teilmatrizen  $(P_{\ell,\ell})_{\ell=1}^\omega$  zu den wesentlichen Klassen stochastisch und somit sind alle weiteren Elemente in der oberen Hälfte der Matrix 0. Die Teilmatrizen  $(P_{\ell,\ell})_{\ell=\omega+1}^{\omega+n}$  zu den unwesentlichen Klassen sind nicht stochastisch und daher können die mit \* markierten Einträge von Null verschieden sein.

### Beispiel 8.3.3 (Motivation: Periodizität vs. Konvergenzsatz)

Für die Beurteilung des Langzeitverhaltens der MARKOV-Kette zu erfassen genügt es nicht, irreduzible Ketten einer wesentlichen Klasse zu betrachten: Seien  $I := \{1, 2\}$  und  $P := \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ , welche irreduzibel ist. Es gilt  $P^{2k+1} = P$  und  $P^{2k} = E_2$  für  $k \in \mathbb{N}_0$ .

Es sind also weder die Voraussetzungen noch die Aussagen des Konvergenzsatzes 8.3.1 erfüllt.  $\diamond$

### DEFINITION 8.3.4 (PERIODE VON MARKOV-KETTEN)

Sei  $i \in I$ . Die Zahl  $d_i := \text{ggT}\{n \in \mathbb{N} : p_{i,i}^{(n)} > 0\}$  heißt Periode von  $i$ . Der Zustand heißt aperiodisch, wenn  $d_i = 1$  gilt.

Haben alle Zustände der MARKOV-Kette Periode eins, so heißt diese aperiodisch. Haben alle Zustände dieselbe Periode  $d > 1$ , so heißt die MARKOV-Kette periodisch mit Periode  $d$ .

### Lemma 8.3.5 (Äquivalente Zustände teilen Periode)

Seien  $i$  und  $j$  äquivalente Zustände. Dann folgt  $d_i = d_j$ .

**Beweis.** Nach Voraussetzung existieren  $k, \ell \in \mathbb{N}$  mit  $p_{i,j}^{(k)}, p_{i,j}^{(\ell)} > 0$ . Sei  $\Lambda_i := \{m \in \mathbb{N} : p_{i,i}^{(m)} > 0\}$ .

Dann folgt für  $n \in \Lambda_j$

$$p_{i,i}^{(n+d_i(k+\ell))} \stackrel{(17)}{\geq} p_{i,j}^{(k)} p_{j,j}^{(n)} p_{j,i}^{(\ell)} \cdot \prod_{c=1}^{d_i-1} p_{i,j}^{(k)} p_{i,j}^{(\ell)} > 0.$$

Also gilt  $n + d_i(k + \ell) \in \Lambda_i$  und somit  $d_i \mid n$ . Da dies für alle  $n \in \Lambda_j$  gilt, gilt  $d_i \mid d_j$  und somit  $d_i \leq d_j$ . Analog zeigt man  $d_j \leq d_i$ .  $\square$



**Lemma 8.3.6**

*Gilt  $d = \text{ggT}\{(n_k)_{k \in \mathbb{N}}\}$ , so existieren  $K, L \in \mathbb{N}$  sodass für jedes  $\ell \geq L$  Zahlen  $c_k \in \mathbb{N}$  und Indizes existieren, sodass  $\ell d = \sum_{k=1}^K c_k n_k$  gilt.*

**Beweis.** Nicht relevant. □

**SATZ 8.3.2**

Sei  $(X_n)_{n \in \mathbb{N}_0}$  eine irreduzible aperiodische MARKOV-Kette mit endlichem Zustandsraum  $I$ . Dann existiert ein  $r \in \mathbb{N}$ , sodass alle Elemente der Matrix  $P^r$  strikt positiv sind.

**Bemerkung** Insbesondere sind die Voraussetzungen des Konvergenzsatzes erfüllt und die MARKOV-Kette konvergent.

## A.1 Maßtheoretische Grundlagen

 $\sigma$ -Algebren, Inhalte und (Prä)maße

vgl. erste Übung




Abb. 34: Quelle: arbeitsbuch achim klenke glaub ich

## Konstruktion von Maßen und Eindeigkeitsatz

vgl. zweite Übung

## Satz von VITALI

## SATZ A.1.1: VITALI, 1905

Hier Satz 1.15

Beweis. TODO

□

## Konstruktion des Integrals

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X : \Omega \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  eine Zufallsvariable. Gilt  $\mathbb{E}(|X|) < \infty$ , man sagt  $\mathbb{E}(X)$  „existiert“, was zu äquivalent zu  $X \in L^1(\Omega, \mathcal{P})$  ist, setzt man

$$\mathbb{E}[X] := \int_{\Omega} X(\omega) d\mathbb{P}(\omega)$$

Konstruktion des Bildmaßes  $d\mathbb{P}$ .

- ① Sei  $A \in \mathcal{F}$  und  $X := \mathbb{1}_A$ . Dann definieren wir

$$\mathbb{E}[\mathbb{1}_A] := \int_A d\mathbb{P} = \mathbb{P}(A).$$

- ② Sei  $X := \sum_{k=1}^n \alpha_k \mathbb{1}_{A_k}$  eine **einfache Funktion**, wobei  $\alpha_k \geq 0$  und  $A_k \in \mathcal{F}$  für alle  $k \in \{1, \dots, n\}$  paarweise disjunkt sein sollen und  $\Omega = \bigsqcup_{k=1}^n A_k$  gilt. Dann gilt (oder Definition??)

$$\mathbb{E}[X] = \sum_{k=1}^n \alpha_k \mathbb{P}(A_k).$$

- ③ Sei  $X$  eine nichtnegative Zufallsvariable. Dann existiert eine Folge einfacher Zufallsvariablen  $(x_n)_{n \in \mathbb{N}}$  so dass  $x_n(\omega) \nearrow^{n \rightarrow \infty} X(\omega)$  für alle  $\omega \in \Omega$  gilt. So eine Folge ist z.B. durch  $x_n(\omega) := k2^{-n} \mathbb{1}_{[k2^{-n}, (k+1)2^{-n}]}$  gegeben. Dann definieren wir

$$\mathbb{E}(X) := \lim_{n \rightarrow \infty} \mathbb{E}[x_n] = \sup_{n \in \mathbb{N}} \mathbb{E}[x_n].$$

- ④ Zerlegung in Positiv- und Negativteil.

**Transformationssatz für Maße** Seien  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum  $X : \Omega \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  eine Zufallsvariable und  $h : \mathbb{R} \rightarrow \mathbb{R}$  messbar. Dann gilt

$$\int_{X^{-1}(A)} h(X) d\mathbb{P} = \int_A h(z) d\mathbb{P}_X(z) = \int_{\mathbb{R}} h(z) f_X(z) d(\lambda(z)),$$

wobei die letzte Gleichheit nur gilt, wenn  $X$  eine Dichte  $f_X$  besitzt.

Diskrete Zufallsvariablen sind nur ein Spezialfall: Ist  $X$  diskret mit Werten in  $I$  und eine Zähldichte  $p_k = \mathbb{P}(X = k)$  für  $k \in I$  gegeben, so ist

$$\mathbb{E}[X] = \sum_{k \in I} k \cdot \mathbb{P}(X = k) \quad \text{und} \quad \text{Var}[X] = \sum_{k \in I} (k - \mathbb{E}[X])^2 \mathbb{P}(X = k)$$

## Beweis des Transformationssatzes

**SATZ A.1.2: TRANSFORMATIONSSATZ, VERSION I**

Sei  $h : (\mathbb{R}, \mathcal{B}(\mathbb{R})) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  eine messbare Funktion.

(a) Dann gilt

$$\mathbb{E}[h(X)] \stackrel{\text{Def.}}{=} \int_{\Omega} h(X) d\mathbb{P} = \int_{\mathbb{R}} h(x) \mathbb{P}_X(dx),$$

wobei  $\mathbb{P}_X := \mathbb{P} \circ X^{-1}$  das **Bildmaß** von  $X$  auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  ist.

(b) Hat  $X$  (bzw.  $\mathbb{P}_X$ ) eine Dichte  $f_X$ , so gilt

$$\int_{\mathbb{R}} h(x) \mathbb{P}_X(dx) = \int_{\mathbb{R}} f_X(x) h(x) dx.$$

**Bildmaß**

**Beispiel A.1.1 ( $k$ -tes Moment der Exponentialverteilung)**

Sei  $X \sim \text{Exp}(\lambda)$  für  $\lambda > 0$  ein exponentialverteilte Zufallsvariable. Dann gilt für alle  $k \in \mathbb{N}$

$$\mathbb{E}[X^k] = \int_{\Omega} X^k d\mathbb{P} \stackrel{(a)}{=} \int_{\mathbb{R}} x^k \mathbb{P}_X(dx) \stackrel{(b)}{=} \int_{\mathbb{R}^+} x^k \cdot \lambda \cdot e^{-\lambda} dx = k! \cdot \lambda^{-k},$$

wobei man das Integral über  $k$ -fache partielle Integration bzw. über vollständige Induktion ausrechnet.  $\diamond$

**Bemerkung A.1.2** Der Erwartungswert  $\mathbb{E}[X]$  hängt also nur von der Verteilung, nicht von der Abbildung  $X$  selbst ab!

**Beweis.** Wir führen eine **maßtheoretische Induktion** über  $h$ :

① Sei  $h := \mathbb{1}_A$  für  $A \in \mathcal{B}(\mathbb{R})$ .

(a) Dann gilt  $h(X) = \mathbb{1}_A(X) = \mathbb{1}_{X \in A}$  ( $\dagger$ ) und somit

$$\begin{aligned} \mathbb{E}[h(X)] &\stackrel{\text{Def.}}{=} \int_{\Omega} h(X) d\mathbb{P} \stackrel{(\dagger)}{=} \int_{\Omega} \mathbb{1}_{X \in A} d\mathbb{P} = \mathbb{P}(X \in A) = \mathbb{P}_X(A) \\ &= \int_{\mathbb{R}} \mathbb{1}_A(x) \mathbb{P}(dx) = \int_{\mathbb{R}} h(x) \mathbb{P}(dx). \end{aligned}$$

(b) Es gilt

$$\mathbb{E}[h(X)] \stackrel{(a)}{=} \mathbb{P}(X \in A) = \int_A f_X(x) dx = \int_{\mathbb{R}} h(x) f_X(x) dx.$$

② Sei  $n \in \mathbb{N}$ ,  $\alpha_k \geq 0$  und  $A_k \in \mathcal{B}(\mathbb{R})$  paarweise disjunkt für alle  $k \in \{1, \dots, n\}$  und  $h := \sum_{k=1}^n \alpha_k \mathbb{1}_{A_k}$ . Dann ist  $h$  und somit auch  $h \circ X$  messbar.

(a) Dann gilt

$$\begin{aligned} \mathbb{E}[h(X)] &= \int_{\Omega} \sum_{k=1}^n \alpha_k \mathbb{1}_{A_k}(X) d\mathbb{P} \stackrel{\text{L}}{=} \sum_{k=1}^n \alpha_k \int_{\Omega} \mathbb{1}_{A_k}(X) d\mathbb{P} \\ &\stackrel{(a)}{\stackrel{\text{L}}{=}} \sum_{k=1}^n \alpha_k \int_{\mathbb{R}} \mathbb{1}_{A_k}(x) \mathbb{P}_X(dx) = \int_{\mathbb{R}} h(x) \mathbb{P}_X(dx) \end{aligned}$$

(b) und

$$\begin{aligned}\mathbb{E}[h(X)] &\stackrel{(a)}{=} \int_{\mathbb{R}} h(x) \mathcal{P}_X(dx) \stackrel{L}{=} \sum_{k=1}^n \alpha_k \int_{\Omega} \mathbb{1}_{A_k}(X) \mathbb{P}_X(dx) \\ &= \sum_{k=1}^n \alpha_k \int_{\mathbb{R}} \mathbb{1}_{A_k}(x) f_X(x) dx \stackrel{L}{=} \int_{\mathbb{R}} h(x) f_X(x) dx.\end{aligned}$$

- ③ Sie  $h : \mathbb{R} \rightarrow \mathbb{R}$  nichtnegativ und messbar. Dann existiert  $(h_n : \mathbb{R} \rightarrow \mathbb{R})_{n \in \mathbb{N}}$  eine punktweise monoton wachsenden Folge einfacher Funktionen mit  $h_n(x) \nearrow h(x)$  für alle  $x \in \mathbb{R}$ . Dann ist  $(h_n(X) : \Omega \rightarrow \mathbb{R})_{n \in \mathbb{N}}$  eine monoton wachsende Folge nichtnegativer Elementarfunktionen und es gilt  $h_n(X(\omega)) \nearrow h(X(\omega))$  für alle  $\omega \in \Omega$ .

(a) Dann gilt

$$\begin{aligned}\int_{\Omega} h(X) d\mathbb{P} &\stackrel{\text{Def.}}{=} \lim_{n \rightarrow \infty} \int_{\Omega} h_n(X) d\mathbb{P} \stackrel{2}{=} \lim_{n \rightarrow \infty} \int_{\mathbb{R}} h_n(x) \mathbb{P}_X(dx) \\ &\stackrel{\text{Def.}}{=} \int_{\mathbb{R}} h(x) \mathbb{P}_X(dx)\end{aligned}$$

(b) und

$$\begin{aligned}\mathbb{E}[h(X)] &\stackrel{(a)}{=} \int_{\mathbb{R}} h(x) \mathbb{P}_X(dx) \stackrel{\text{Def.}}{=} \lim_{n \rightarrow \infty} \int_{\mathbb{R}} h_n(x) \mathbb{P}_X(dx) \\ &\stackrel{2}{=} \lim_{n \rightarrow \infty} \int_{\mathbb{R}} h_n(x) f_X(x) dx \stackrel{\text{Def.}}{=} \int_{\mathbb{R}} h(x) f_X(x) dx.\end{aligned}$$

- ④ Sei  $h : (\mathbb{R}, \mathcal{B}(\mathbb{R})) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  eine messbare Funktion. Falls definiert, gilt  $h = h^+ - h^-$ .

(a) Dann gilt

$$\begin{aligned}\mathbb{E}[h(X)] &\stackrel{L}{=} \mathbb{E}[h^+(X)] - \mathbb{E}[h^-(X)] \\ &\stackrel{\text{Def.}}{=} \int_{\mathbb{R}} h^+(x) \mathbb{P}_X(dx) - \int_{\mathbb{R}} h^-(x) \mathbb{P}_X(dx) \\ &\stackrel{3}{=} \int_{\mathbb{R}} h(x) \mathbb{P}_X(dx).\end{aligned}$$

(b) und

$$\begin{aligned}\mathbb{E}[h(X)] &\stackrel{(a)}{=} \int_{\mathbb{R}} h^+(x) \mathbb{P}_X(dx) - \int_{\mathbb{R}} h^-(x) \mathbb{P}_X(dx) \\ &\stackrel{3}{=} \int_{\mathbb{R}} h^+(x) f_X(x) dx - \int_{\mathbb{R}} h^-(x) f_X(x) dx \\ &\stackrel{L}{=} \int_{\mathbb{R}} h(x) f_X(x) dx. \quad \square\end{aligned}$$

Das geht natürlich allgemeiner:

**SATZ A.1.3: TRANSFORMATIONSSATZ, VERSION 2**

Seien  $:= (F, \mathcal{F}, \mu)$  und  $\tilde{G} := (G, \mathcal{G}, \nu)$  Maßräume,  $f : \tilde{F} \rightarrow \tilde{G}$  und  $g : \tilde{G} \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  messbar und  $g \in L^1(\tilde{G})$ . Dann gilt

$$\int_G g \, d\nu = \int_F g \circ f \, d\mu,$$

falls  $\nu = \mu \circ f$ , d.h.  $\nu(A) = \mu(f \in A)^a$  für alle  $A \in \mathcal{G}$ .

<sup>a</sup>vgl. absolutstetiges Maß und Satz von RADON-NYKODYM.

Bei uns war  $f := X$ ,  $\tilde{F} := (\Omega, \mathcal{A}, \mathbb{P})$ ,  $g := h$  und  $\tilde{G} := (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_X)$ . Besitzt  $\nu$  eine Dichte, d.h. eine messbare Funktion  $f_\nu : G \rightarrow [0, \infty)$  sodass

$$\nu(A) = \int_G \mathbb{1}_A(x) f_\nu(x) \, dx$$

für alle  $A \in \mathcal{G}$  gilt, so folgt

$$\int_G g \, d\nu = \int_G g f_\nu \, d\lambda(x), \text{ d.h. } \int_G g(x) \nu(dx) = \int_G g(x) f_\nu(x) \, dx.$$

**Bemerkung A.1.3** Seien  $G, G' \subset \mathbb{R}$  offene Teilmengen,  $f : G \rightarrow G'$  ein  $\mathcal{C}^1$ -Diffeomorphismus und  $\lambda_G := \lambda|_G$ . Dann gilt

$\mathcal{C}^1$ -Diffeomorphismus

$$\lambda_G(\{x \in \mathbb{R} : f^{-1} \in A\}) = \int_A |\det(Df(x))| \lambda_G(dx). \quad (22)$$

Sei nun  $g : \mathbb{R} \rightarrow \mathbb{R}$  messbar. Dann gilt

$$\begin{aligned} \int_{\mathbb{R}} g(x) \lambda_G(dx) &= \int_R g(f \circ f^{-1}(x)) \lambda_{G'}(dx) = \int_R (g \circ f)(f^{-1}(x)) \lambda_{G'}(dx) \\ &\stackrel{\text{A.1.2}}{=} \int_R (g \circ f)(x) (\lambda_{G'} \circ (f^{-1})^{-1})(dx) \\ &\stackrel{(22)}{=} \int_R (g \circ f)(x) |\det(Df(x))| \lambda_G(dx). \end{aligned}$$

## A.2 Rechnungen

### Beispiel A.2.1 (Aus der Übersicht 35)

- ① Sei  $X \sim \text{Ber}(p)$ . Dann gilt mit dem Transformationssatz (T)

$$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2 \stackrel{(T)}{=} (p \cdot 1^2 + (1-p) \cdot 0^2) - p^2 = p(1-p).$$

Ferner gilt für das  $k$ -te Moment

$$\mathbb{E}[X^k] \stackrel{(T)}{=} p \cdot 1^k + (1-p) \cdot 0^k = p.$$

Ferner gilt

$$\mathcal{G}_X(s) = \sum_{n \in \mathbb{N}_0} \mathbb{P}(X = n) s^n = \mathbb{P}(X = 0) \cdot 1 + \mathbb{P}(X = 1) s^1 = 1 - p + ps.$$

- ② Sei  $X \sim \text{Geo}(p)$  für  $p \in (0, 1]$ . Dann gilt mit der Ableitung der geometrischen Reihe

$$\mathbb{E}[X] = \sum_{k \in \mathbb{N}} k \mathbb{P}(X = k) = p \sum_{k \in \mathbb{N}} k(1-p)^{k-1} = \frac{p}{(1 - (1-p))^2} = \frac{1}{p}.$$

Nun gilt  $\sum_{k \in \mathbb{N}} kx^k = \frac{x}{(1-x)^2}$  und somit  $\sum_{k \in \mathbb{N}} k^2 x^{k-1} = \frac{x+1}{(1-x)^3}$  und somit

$$\begin{aligned} \text{Var}[X] &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \stackrel{(T)}{=} p \sum_{k \in \mathbb{N}} k^2 (1-p)^{k-1} - \frac{1}{p^2} \\ &= \frac{p(2-p)}{(1 - (1-p))^3} - \frac{1}{p^2} = \frac{2-p-1}{p^2} = \frac{1-p}{p^2}. \end{aligned}$$

Ferner gilt

$$\begin{aligned} \chi_X(t) &= \sum_{n \in \mathbb{N}} \mathbb{P}(X = n) e^{itn} = p \cdot \sum_{n \in \mathbb{N}} (1-p)^{n-1} e^{itn} \\ &= \frac{p}{1-p} \sum_{n \in \mathbb{N}} ((1-p)e^{it})^n = \frac{p}{1-p} \frac{\cancel{(1-p)} e^{it}}{\cancel{1-p} 1 - (1-p)e^{it}} \\ &= \frac{p \cdot e^{it}}{1 - (1-p)e^{it}} \end{aligned}$$

- ③ Sei  $X \sim \text{N Bin.}$  Es gilt

$$\begin{aligned} \binom{-n}{k} &= \frac{(-n)(-n-1) \cdots (-n-k+1)}{k!} \\ &= (-1)^k \frac{n(n+1) \cdots (n+k-1)}{k!} \\ &= (-1)^k \frac{(n+k-1)!}{k!(n-1)!} = (-1)^k \binom{n+k-1}{k} \end{aligned}$$

und somit mit  $q := 1 - p$

$$\begin{aligned}
 \mathbb{E}[X] &= \sum_{k=n}^{\infty} k \binom{k-1}{n-1} q^{k-n} p^n \\
 &= p^n \sum_{k \in \mathbb{N}_0} (k+n) \binom{k+n-1}{n-1} q^k \\
 &= p^n \sum_{k \in \mathbb{N}_0} (k+n) \binom{k+n-1}{k} q^k \\
 &= p^n \sum_{k \in \mathbb{N}_0} (k+n) \frac{(k+n-1)!}{k!(n-1)!} q^k \\
 &= n \cdot p^n \sum_{k \in \mathbb{N}_0} \frac{(k+n)!}{k!n!} q^k = n \cdot p^n \sum_{k \in \mathbb{N}_0} \binom{k+n}{k} q^k \\
 &= n \cdot p^n \sum_{k \in \mathbb{N}_0} \binom{-(n+1)}{k} (p-1)^k = \frac{n \cdot p^n}{(1+p-1)^{n+1}} = \frac{n}{p}.
 \end{aligned}$$

Alternativ kann man  $X = \sum_{k=1}^n G_k$  schreiben, wobei  $(G_k \sim \text{Geo}(p))_{k=1}^n$  u.i.d verteilt sind. Dann gilt  $\mathbb{E}[X] \stackrel{(L)}{=} \sum_{k=1}^n \mathbb{E}[G_k] = \frac{n}{p}$ .

Todo varianz: [here](#)

④ Sei  $N \sim \text{Pois}(\lambda)$ . Dann gilt

$$\begin{aligned}
 \chi_N(t) &= \sum_{k=0}^{\infty} e^{itk} \mathcal{P}(N=k) = \sum_{k=0}^{\infty} e^{itk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda \cdot e^{it})^k}{k!} \\
 &= e^{-\lambda} \exp(\lambda \cdot e^{it}) = \exp(\lambda(e^{it} - 1)).
 \end{aligned}$$

⑤ Sei  $X \sim \text{Hyp}(K, n, N)$ . Es gilt

$$k \binom{n}{k} = k \frac{n!}{k!(n-k)!} = \frac{n(n-1)!}{(k-1)!(n-1-(k-1))!} = n \binom{n-1}{k-1}. \quad (23)$$

Daraus folgt

$$\begin{aligned}
 \mathbb{E}[X] &= \sum_{k=0}^n k \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} = \sum_{k=0}^n \frac{K \binom{K-1}{k-1} \binom{(N-1)-(K-1)}{(n-1)-(k-1)}}{\frac{N}{n} \binom{N-1}{n-1}} \\
 &= \frac{nK}{N} \sum_{k=0}^n \underbrace{\frac{\binom{K-1}{k-1} \binom{(N-1)-(K-1)}{(n-1)-(k-1)}}{\binom{N-1}{n-1}}}_{\substack{\mathbb{P}(\hat{X}=k), \\ \hat{X} \sim \text{Hyp}(K-1, n-1, N-1)}} \stackrel{(1)}{=} \frac{nK}{N}
 \end{aligned}$$

Eine Modifikation von (23) ergibt

$$k(k-1) \binom{n}{k} = n(k-1) \binom{n-1}{k-1} = n(n-1) \binom{n-2}{k-2}.$$

und analog zu oben findet man

$$\mathbb{E}[X(X-1)] = \frac{n(n-1)K(K-1)}{N(N-1)}$$

und induktiv

$$\mathbb{E}[X(X-1) \dots (X-k+1)] = \prod_{j=0}^{k-1} \frac{(n-j)(K-j)}{(N-j)}$$



Somit gilt

$$\begin{aligned}\operatorname{Var}[X] &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mathbb{E}[X(X-1) + X] - \mathbb{E}[X]^2 \\ &= \mathbb{E}[X(X-1)] + \mathbb{E}[X](1 - \mathbb{E}[X]) \\ &= \frac{K(K-1)n(n-1)}{N(N-1)} + \frac{Kn}{N} \left(1 - \frac{Kn}{N}\right) \\ &= \frac{Kn(N-K)(N-n)}{N^2(N-1)}.\end{aligned}$$

⑥ Sei  $X \sim \mathcal{U}([a, b])$ . Dann gilt

$$\mathbb{E}[X^k] \stackrel{(T)}{=} \frac{1}{b-a} \int_a^b x^k dx = \frac{b^{k+1} - a^{k+1}}{(k+1)(b-a)} \stackrel{4.1.8}{=} \frac{1}{k+1} \sum_{j=0}^k a^j b^{k-j}.$$

Ferner gilt

$$\operatorname{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{1}{3}(a^2 + ab + b^2) - \frac{a^2 + 2ab + b^2}{2} = \frac{(b-a)^2}{12}.$$

Hausaufgabe 8.2(b): Nach der EULERSche Formel  $e^{ix} = \cos(x) + i \sin(x)$  (\*) gilt

$$\begin{aligned}\chi_X(t) &= \int_{\mathbb{R}} \exp(itx) f(x) dx = \int_{\mathbb{R}} \exp(itx) \mathbb{1}_{(a,b)}(x) dx \\ &= \int_a^b \exp(itx) dx \stackrel{(*)}{=} \int_a^b \cos(tx) dx + i \cdot \int_a^b \sin(tx) dx \\ &= \frac{\sin(tb) - \sin(ta)}{t} + \frac{i(-\cos(tb) + \cos(ta))}{t} \\ &= \frac{-i(\cos(tb) + i \sin(tb))}{t} + \frac{i(\cos(ta) + i \sin(ta))}{t} \\ &\stackrel{(*)}{=} \frac{i(e^{ita} - e^{-itb})}{t}.\end{aligned}$$

Im vor-vorletzten Term kann man sehen, dass das Ergebnis genau dann reellwertig ist, wenn  $-\cos(tb) + \cos(ta) = 0$  für alle  $t \in \mathbb{R}$  gilt, also wenn  $a = -b$  ist, da  $a \neq b$  ist. Also ist  $\chi_X(t)$  für alle Paare  $(a, -a) \in \mathbb{R}^2$  reellwertig.  $\diamond$

### Beispiel A.2.2 (aus Beispiel 3.3.3)

Sei  $W := (\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X : W \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  eine Zufallsvariable. Zeigen Sie mit Hilfe der Dichte von  $X$ :

① Sei  $X \sim \exp(\vartheta)$  für  $\vartheta > 0$  und sei  $a > 0$ , dann ist  $aX \sim \exp\left(\frac{\vartheta}{a}\right)$ .

**Beweis.** Für  $t \geq 0$  gilt

$$\mathbb{P}(aX \leq t) = \mathbb{P}\left(X \leq \frac{t}{a}\right) = 1 - e^{-\vartheta \frac{t}{a}} = 1 - e^{-\frac{\vartheta}{a}t}. \quad \square$$

- ② Sei  $\lambda > 0$  und  $X \sim \exp(\lambda)$ . Bestimmen Sie die Verteilung von  $Y := \sum_{k=1}^{\infty} k \mathbb{1}_{[k-1, k)}(X)$ .

**Lösung:** Weil  $\text{Im}(Y) = \mathbb{N}$  ist, ist  $Y$  diskret, es gilt  $Y : W \rightarrow (\mathbb{N}, \mathcal{P}(\mathbb{N}))$ . Es gilt

$$\begin{aligned} \mathbb{P}(Y = n) &= \mathbb{P}(x \in [n-1, n)) = \int_{n-1}^n \lambda e^{-\lambda t} dt \\ &= e^{-\lambda(n-1)} - e^{-\lambda n} = (e^\lambda - 1)e^{-n\lambda}. \end{aligned} \quad \diamond$$

**Beispiel A.2.3 (aus Beispiel 3.3.7)** Für o.B.d.A  $a > 0$  und der Substitution  $\varphi(t) := \frac{t-b}{a}$  gilt

$$\begin{aligned} F_{aX+b}(t) &= \mathbb{P}(aX + b \leq t) = \mathbb{P}\left(x \leq \frac{t-b}{a}\right) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\frac{t-b}{a}} \exp\left(-\frac{(s-\mu)^2}{2\sigma^2}\right) ds \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\varphi(t)} \exp\left(-\frac{(\varphi(s)-\mu)^2}{2\sigma^2}\right) \cdot \frac{1}{a} ds \\ &= \frac{1}{\sqrt{2\pi\sigma^2 a^2}} \int_{-\infty}^t \exp\left(-\frac{\left(\frac{s-n}{a}-\mu\right)^2}{2\sigma^2}\right) ds \\ &= \frac{1}{\sqrt{2\pi\sigma^2 a^2}} \int_{-\infty}^t \exp\left(-\frac{(s-(b+a\mu))^2}{2s^2\sigma^2}\right) ds. \end{aligned} \quad \diamond$$

**Beispiel A.2.4 (aus Beispiel 3.3.8)**

Seien  $X_i : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  unabhängige Zufallsvariablen mit  $X_i \sim \mathcal{N}(m_i, \sigma_i^2)$  mit  $m_i \in \mathbb{R}$  und  $\sigma_i > 0$  für  $i \in \{1, 2\}$ . Zeigen Sie, dass  $Z := X_1 + X_2 \sim \mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$ .

**Beweis.** Seien  $\tilde{X}_i := X_i - m_i \sim \mathcal{N}(0, \sigma_i^2)$  für  $i \in \{1, 2\}$  und  $\tilde{Z} := \tilde{X}_1 + \tilde{X}_2$ .

Dann gilt

$$f_{\tilde{Z}}(z) = \int_{\mathbb{R}} f_{\tilde{X}_1}(x) \cdot f_{\tilde{X}_2}(z-x) dx = \frac{1}{2\pi\sigma_1\sigma_2} \int_{\mathbb{R}} \exp\left(-\frac{1}{2} \left(\frac{x^2}{\sigma_1^2} + \frac{(z-x)^2}{\sigma_2^2}\right)\right) dx.$$

Nun gilt

$$\begin{aligned} \frac{x^2}{2\sigma_1^2} + \frac{(z-x)^2}{2\sigma_2^2} &= \frac{x^2(\sigma_1^2 + \sigma_2^2)}{\sigma_1^2\sigma_2^2} - \frac{2xz}{\sigma_2^2} + \frac{z^2}{\sigma_2^2} \\ &= \frac{x^2(\sigma_1^2 + \sigma_2^2)}{\sigma_1^2\sigma_2^2} - \frac{2xz}{\sigma_2^2} + \frac{z^2\sigma_1^2}{\sigma_2^2(\sigma_1^2 + \sigma_2^2)} - \frac{z^2\sigma_1^2}{\sigma_2^2(\sigma_1^2 + \sigma_2^2)} + \frac{z^2}{\sigma_2^2} \\ &= \left( \underbrace{\frac{x\sqrt{\sigma_1^2 + \sigma_2^2}}{\sigma_1\sigma_2} - \frac{z\sigma_1}{\sigma_2\sqrt{\sigma_1^2 + \sigma_2^2}}}_{=: u =: \varphi(x)} \right)^2 + \frac{z^2}{\sigma_1^2 + \sigma_2^2}. \end{aligned}$$

Dann gilt

$$\begin{aligned} f_{\tilde{Z}}(z) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2} \frac{z^2}{\sigma_1^2 + \sigma_2^2}\right) \frac{\sigma_1\sigma_2}{\sqrt{\sigma_1^2 + \sigma_2^2}} \int_{\mathbb{R}} e^{-\frac{u^2}{2}} du \\ &= \frac{1}{2\pi} \exp\left(-\frac{1}{2} \frac{z^2}{\sigma_1^2 + \sigma_2^2}\right) \frac{1}{\sqrt{\sigma_1^2 + \sigma_2^2}} \sqrt{2\pi} \\ &= \frac{1}{\sqrt{2\pi\sigma_1^2 + \sigma_2^2}} \exp\left(-\frac{1}{2} \frac{z^2}{\sigma_1^2 + \sigma_2^2}\right) \sim \mathcal{N}(0, \sigma_1^2 + \sigma_2^2) \end{aligned}$$

und daher  $Z = \tilde{Z} + m_1 + m_2 \sim \mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$ .  $\square$

### Beispiel A.2.5 (aus Beispiel 3.2.5)

Sei  $W := (\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X, Y : W \rightarrow (\mathbb{N}, \mathcal{P}(\mathbb{N}))$  zwei unabhängige Zufallsvariablen mit  $X \sim \text{Geo}(p)$  und  $Y \sim \text{Geo}(y)$  für  $p \in (0, 1]$ . Bestimmen Sie die Verteilung von  $Z := \min(X, Y)$ .

**Lösung:** Es gilt

$$\mathbb{P}(Z \geq n) = \mathbb{P}(X \geq n) \mathbb{P}(Y \geq n),$$

weil  $X$  und  $Y$  unabhängig voneinander sind. Ferner gilt

$$\begin{aligned} \mathbb{P}(X \geq n) &= \sum_{k=n}^{\infty} (1-p)^{k-1} \cdot p = p(1-p)^{n-1} \sum_{k=0}^{\infty} (1-p)^k \\ &= p(1-p)^{n-1} \frac{1}{1-(1-p)} = (1-p)^{n-1} \end{aligned}$$

Also gilt

$$\begin{aligned} \mathbb{P}(Z = n) &= \mathbb{P}(Z \geq n) - \mathbb{P}(Z \geq n+1) = ((1-p)^{n-1})^2 - ((1-p)^n)^2 \\ &= ((1-p)^2)^{n-1} (1 - (1-p)^2) \end{aligned}$$

und somit  $Z \sim \text{Geo}(1-p^2)$  für  $q := 1-p$ .  $\diamond$

### Beispiel A.2.6 (Aus Beispiel 4.1.4)

Seien  $X \sim \text{Bin}(n, p)$  und  $Y \sim \text{Bin}(m, p)$  unabhängige Zufallsvariablen für  $n, m \in \mathbb{N}$  und  $p \in [0, 1]$ . Berechnen Sie die erzeugende Funktion von  $X + Y$ .

**Lösung:** Mit dem binomischen Lehrsatz und  $\binom{n}{k} = 0$  für  $k > n$  gilt

$$\mathcal{G}_X(t) = \sum_{k=0}^{\infty} \binom{n}{k} t^k p^k (1-p)^{n-k} = \sum_{k=0}^n \binom{n}{k} (tp)^k (1-p)^{n-k} = (tp+1-p)^n$$

Da  $X$  und  $Y$  unabhängig sind, folgt

$$\mathcal{G}_{X+Y}(t) = \mathcal{G}_X(t) \mathcal{G}_Y(t) = (tp+1-p)^n (tp+1-p)^m = (tp+1-p)^{n+m}.$$

Also gilt  $X + Y \sim \text{Bin}(n+m, p)$ .

Seien  $X, Y \sim \text{Geo}(p)$  zwei unabhängige Zufallsvariablen mit  $p \in (0, 1)$ . Berechnen Sie die erzeugende Funktion der Zufallsvariablen  $S := X + Y$  und  $\mathbb{P}(S = n)$  für alle  $n \in \mathbb{N}$ .

**Lösung:** Aus der Vorlesung ist  $\mathcal{G}_X(t) = \mathcal{G}_Y(t) = \frac{pt}{1-(1-p)t}$  bekannt. Weil  $X$  und  $Y$  unabhängig sind, gilt

$$\begin{aligned}\mathcal{G}_{X+Y}(t) &= \frac{p^2 t^2}{(1-(1-p)t)^2} \stackrel{(*)}{=} \sum_{k=0}^{\infty} p^2 t^2 (k+1) ((1-p)t)^k \\ &= \sum_{k=2}^{\infty} p^2 (k-1) (1-p)^{k-2} t^k = \sum_{k=0}^{\infty} p^2 (k-1) (1-p)^{k-2} t^k,\end{aligned}$$

da  $\mathbb{P}(X+Y=0) = \mathbb{P}(X+Y=1) = 0$  ist, gilt

$$\mathbb{P}(X+Y=n) = p^2 (n-1) (1-p)^{n-2}$$

für  $n \geq 2$ . Die Gleichheit  $(*)$  folgt aus Differenzieren der geometrischen Reihe.  $\diamond$

#### Beispiel A.2.7 (Ch. Fkt. der Normalverteilung (vgl. 4.2.3))

Betrachte zunächst  $X \sim \mathcal{N}(0, 1)$ , da dann  $Y := \sigma X + m \sim \mathcal{N}(m, \sigma^2)$  und somit

$$\chi_Y(t) = \mathbb{E}[e^{itY}] = \mathbb{E}[e^{itm} e^{i\sigma X}] = e^{itm} \mathbb{E}[e^{i\sigma X}] = e^{itm} \chi_X(\sigma t)$$

gilt. Nach  $e^{ix} = \cos(x) + i \sin(x)$  gilt

$$\begin{aligned}\mathbb{E}[e^{itX}] &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itz} e^{-\frac{z^2}{2}} dz \\ &= \frac{1}{\sqrt{2\pi}} \left( \int_{\mathbb{R}} \cos(tz) e^{-\frac{z^2}{2}} dz + i \underbrace{\int_{\mathbb{R}} \sin(tz) e^{-\frac{z^2}{2}} dz}_{=0 \text{ weil } \sin \text{ ungerade}} \right).\end{aligned}$$

Aus dem Differentiationslemma folgt mit partieller Integration

$$\begin{aligned}\chi'_X(t) &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \frac{d}{dt} \cos(tz) e^{-\frac{z^2}{2}} dz = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \sin(tz) (-z) e^{-\frac{z^2}{2}} dz \\ &= \frac{1}{\sqrt{2\pi}} \left( \underbrace{\left[ \sin(tz) e^{-\frac{z^2}{2}} \right]_{z=-\infty}^{\infty}}_{=0} - \int_{\mathbb{R}} t \cos(tz) e^{-\frac{z^2}{2}} dz \right) = -t \chi_X(t).\end{aligned}$$

Also löst  $\chi_X(t)$  die Differentialgleichung  $\chi_X(t)' = -t \chi_X(t)$  zum Anfangswert  $\chi_X(0) = 1$ . Daraus folgt  $\chi_X(t) = e^{-\frac{t^2}{2}}$ . Also ist bis auf einen Faktor die Dichte ihre eigene charakteristische Funktion und somit ein Fixpunkt der **FOURIER-Transformation**.

**TODO:** das geht auch einfacher mit quadratischer Ergänzung und der Translationsinvarianz des Integrals  $\diamond$

## A.3 Übersicht über die Verteilungen

	Def.-menge	(Zähl)Dichte	Verteilungsfkt.	$\mathbb{E}$	$\mathbb{E}[\cdot^k]$	Var	ch. Funktion	erz. Fkt.
Bernoulli	$\{0, 1\}$	$1 - p \cdot \mathbb{1}_0$	$\mathbb{1}_{[0, \infty)} - p \mathbb{1}_{[0, 1]}$	$p$	$p$	$pq$	$q + pe^{it}$	$q + pt$
	$\{0, \dots, n\}$	$\binom{n}{k} p^k q^{n-k}$		$np$		$npq$	$(q + pe^{it})^n$	$(sp + q)^n$
	$\mathbb{N}$	$q^k p$	$1 - q^k$	$\frac{1}{p}$		$\frac{q}{p^2}$	$\frac{p \cdot e^{it}}{1 - qe^{it}}$	$\frac{ps}{1 - q^s}$
Binomial	$\mathbb{N}_{\geq n}$	$\binom{k-1}{n-1} q^{k-n} p^n$		$\frac{n}{p}$		$\frac{nq}{p^2}$		
Poisson	$\mathbb{N}_0$	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$		$\lambda$		$\lambda$	$\exp(\lambda(e^{it} - 1))$	$e^{\lambda(s-1)}$
Hypergeometrisch	$\{0, \dots, n\}$	$\frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$		$\frac{nK}{N}$		$\frac{K n (N-K) (N-n)}{N^2 (N-1)}$		
Normal	$\mathbb{R}$	$\frac{\mathbb{1}_{[a, b]}}{b - a}$	$\frac{x - a}{b - a} \mathbb{1}_{[a, b)} + \mathbb{1}_{[b, \infty)}$	$\frac{a + b}{2}$	$\frac{\sum_{j=0}^k a^j b^{k-j}}{k + 1}$	$\frac{(b - a)^2}{12}$	$\frac{i(e^{ita} - e^{-itb})}{t}$	
	$\mathbb{R}$	$\lambda e^{-\lambda x} \mathbb{1}_{[0, \infty)}(x)$	$1 - e^{-\lambda x} \mathbb{1}_{[0, \infty)}$	$\lambda^{-1}$	$\frac{k!}{\lambda^k}$	$\lambda^{-2}$		
	$\mathbb{R}$	$\frac{\lambda^\vartheta x^{\vartheta-1} e^{-\lambda x}}{\Gamma(\vartheta)} \mathbb{1}_{[0, \infty)}(x)$		$\frac{\vartheta}{\lambda}$				
Normal	$\mathbb{R}$	$\frac{\exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)}{\sqrt{2\pi\sigma^2}}$		$m$		$\sigma^2$	$\exp\left(itm - \frac{(t\sigma)^2}{2}\right)$	

enngrößen wichtiger Verteilungen. Hierbei ist  $q := 1 - p$ .

## A.4 Nützliche Identitäten

### Kombinatorik / Binomialkoeffizient

$$k \binom{n}{k} = n \binom{n-1}{k-1} \text{ und } \binom{n}{k} = \binom{n}{n-k}$$

### Geometrische Reihe und ihre Verwandte

Sei  $|x| < 1$ . Dann gilt  $\sum_{k \in \mathbb{N}_0} x^k = \frac{1}{1-x}$ ,  $\sum_{k \in \mathbb{N}} x^k = \frac{x}{1-x}$ ,  $\sum_{n \in \mathbb{N}_0} kx^k = \frac{x}{(1-x)^2}$ ,  $\sum_{n \in \mathbb{N}_0} kx^{k-1} = \frac{1}{(1-x)^2}$ ,  $\sum_{n \in \mathbb{N}_0} k^2 x^{k-1} = \frac{x+1}{(1-x)^3}$ .

## A.5 Klausuraufgaben

Deuschel 2018 Probe Sei  $X$  eine  $\mathbb{R}^d$ -wertige Zufallsvariable mit Verteilungsfunktion  $\mathbb{P}_X$  und charakteristischer Funktion  $\varphi_X$ . Zeigen Sie die Äquivalenz der folgenden Aussagen

- ①  $\mathbb{P}_X = \mathbb{P}_{-X}$ .
- ②  $\varphi_X = \varphi_{-X}$ .
- ③  $\varphi_X(t) = \mathbb{E}[\cos(\langle t, X \rangle)]$  für  $t \in \mathbb{R}^d$ .
- ④  $\varphi_X$  ist reell.

**Beweis.** (c)  $\implies$  (d). Nach Definition gilt

$$\begin{aligned}\varphi_X(t) &\stackrel{\text{Def.}}{=} \mathbb{E}[\exp(i \langle t, X \rangle)] \\ &\stackrel{\text{L}}{=} \mathbb{E}[\cos(\langle t, X \rangle)] + i \mathbb{E}[\sin(\langle t, X \rangle)] \stackrel{!}{=} \mathbb{E}[\cos(\langle t, X \rangle)].\end{aligned}$$

Somit gilt  $i \mathbb{E}[\sin(\langle t, X \rangle)] = 0$ .

(d)  $\implies$  (b). Für alle  $a, b \in \mathbb{R}$  gilt

$$\varphi_{aX+b}(t) = e^{itb} \varphi_X(at) \quad \text{und} \quad \varphi_X(-t) = \overline{\varphi_X(t)}.$$

Damit folgt

$$\varphi_{-X}(t) = \varphi_X(-t) = \overline{\varphi_X(t)}$$

(b)  $\implies$  (c): Nach Definition muss

$$\mathbb{E}[\cos(\langle t, X \rangle)] + i \mathbb{E}[\sin(\langle t, X \rangle)] = \mathbb{E}[\cos(\langle t, -X \rangle)] + i \mathbb{E}[\sin(\langle t, -X \rangle)]$$

gelten. Nach den Eigenschaften des Standardskalarproduktes ist das äquivalent zu

$$\mathbb{E}[\cos(\langle t, X \rangle)] + i \mathbb{E}[\sin(\langle t, X \rangle)] = \mathbb{E}[\cos(\langle t, X \rangle)] - i \mathbb{E}[\sin(\langle t, X \rangle)]$$

Das impliziert

$$i \mathbb{E}[\sin(\langle t, X \rangle)] = -i \mathbb{E}[\sin(\langle t, X \rangle)] \implies i \mathbb{E}[\sin(\langle t, X \rangle)] = 0$$

und somit folgt die Behauptung.  $\square$

Deuschel 2018 Probe Seien  $X$  und  $Y$  i.i.d verteilte reellwertige Zufallsvariablen und  $\ln(X) \sim \text{Exp}(1)$ . Bestimmen Sie die Verteilungsfunktion von  $Z := XY$ .

**Lösung: Here's the solution using convolution:** Let  $\overline{X} := \ln(X)$  and  $\overline{Y}$  analogously. We can now calculate the PDF of  $\ln(XY) =$

$\bar{X} + \bar{Y}$  using convolution: For  $x \geq 0$  we have

$$f_{\ln(XY)}(x) = f_{\bar{X}} * f_{\bar{Y}} = \int_{-\infty}^{\infty} f_{\bar{X}}(y) f_{\bar{Y}}(x-y) dy = \int_0^x e^{-y} e^{y-x} dy = \int_0^x e^{-x} dy = x e^{-x}$$

and  $f_{\ln(XY)}(x) = 0$  otherwise. Therefore, for  $x \geq 0$  we have

$$P(\ln(XY) \leq x) = \int_{-\infty}^x f_{\ln(XY)}(y) dy = \int_0^x y e^{-y} dy = 1 - e^{-x}(x+1).$$

For  $z \geq 1$  this implies

$$P(XY \leq z) = 1 - \frac{1 + \ln(z)}{z}.$$

and  $P(XY \leq z) = 0$  for  $z \leq 1$ .

**Zweite Lösung.** Since  $\ln(X) \sim \text{Exp}(1)$ , for all  $k \geq 0$  we have

$$\mathbb{P}(X \leq e^k) = \mathbb{P}(\ln(X) \leq k) = 1 - e^{-k}$$

By substitution we obtain

$$\mathbb{P}(X \leq a) = 1 - \frac{1}{a}.$$

for all  $a \geq 1$ . We can now obtain the density function by calculating

the derivative:  $f_X(x) = \frac{1}{x^2}$ .

Now, for  $z \geq 1$  we have

$$\begin{aligned} \mathbb{P}(XY \leq z) &= \int_1^{\infty} 1_{(-\infty, z]}(x, y) d\mathbb{P}(x, y) = \int_1^{\infty} \int_{\mathbb{R}^+} 1_{(1, \frac{z}{y})}(x) d\mathbb{P}_X d\mathbb{P}_Y \\ &= \int_1^z \int_{\mathbb{R}^+} 1_{(1, \frac{z}{y})}(x) \frac{1}{x^2} \frac{1}{y^2} dx dy \\ &= \int_1^z \frac{1}{y^2} \left[ \int_1^{\frac{z}{y}} \frac{1}{x^2} dx \right] dy \\ &= \int_1^z \frac{1}{y^2} \left( 1 - \frac{y}{z} \right) dy = 1 - \frac{1 + \ln(z)}{z}. \end{aligned}$$

**Dritte Lösung mit regulärer bedingter Verteilung** Für  $x > 0$  gilt

$$\begin{aligned} \mathcal{P}(\ln(XY) \leq x) &= \mathcal{P}(\ln(X) + \ln(Y) \leq x) = \int_0^{\infty} \mathcal{P}(\ln(X) + \ln(Y) \leq x \mid Y = y) f_Y(y) dy \\ &= \int_0^{\infty} \mathcal{P}(\ln(X) \leq x - y) f_Y(y) dy = \int_0^x (1 - e^{y-x}) e^{-y} dy \\ &= \int_0^x e^{-y} - e^{-x} dy = 1 - e^{-x}(1+x). \end{aligned}$$

Daraus folgt für  $z > 1$

$$\mathcal{P}(Z \leq z) = \mathcal{P}(\ln(Z) \leq \ln(z)) = 1 - e^{-\ln(z)}(1 + \ln(z)) = 1 - \frac{\ln(z) + 1}{z}.$$

Für  $z \leq 1$  gilt  $\mathcal{P}(Z \leq z) = 0$ .

- ① **Ideen:** Die ZVen  $Y_k$  sind Bernoulli-verteilt zum Parameter  $p_k := \mathbb{P}(X_k \leq t)$  und somit unabhängig und identisch verteilt. (Eigentlich nicht identisch weil  $p_k$  sich ändert, oder??) Somit gilt  $\mathbb{E}[Y_1] = p$



und  $\text{Var}[Y_1] = p(1-p)$ . Die Verteilungsfunktion einer  $\text{Ber}(p)$ -verteilten Zufallsvariable durch  $F(t) = \mathbb{1}_{[0,\infty)}(t) - p \mathbb{1}_{[0,1)}(t)$  gegeben ist, impliziert  $F(t) \in \{0, 1\}$ , dass  $p \in \{0, 1\}$  gilt und somit  $X \in \{0, 1\}$ .

Ferner gilt  $S_n \sim \text{Bin}(n, p)$ . Nach Poissonschem Approximationssatz konvergieren eine Folge binomial-Zähldichten punktweise gegen die Zähldichte der Exponentialverteilung zum Parameter  $\lambda := \lim_{n \rightarrow \infty} np_n$ .

Scheutzwow, 07/17 Entscheiden Sie, welche der folgenden Aussagen immer wahr sind.

- ① Aus  $\mathbb{E}[X^6] < \infty$  folgt auch  $\mathbb{E}[X^4] < \infty$ .

**Stimmt. Ansatz 1:** Da jeder Wahrscheinlichkeitsraum  $\Omega$  endlich ist, gilt  $L^q(\Omega) \subset L^p(\Omega)$  für alle  $1 \leq p \leq q \leq \infty$ .

**Ansatz 2:** Es gilt  $X^4 \leq X^6 + 1$ .

- ② Sind  $Z_1$  und  $Z_2$  exponentialverteilte Zufallsvariablen, so ist  $Z := \min_{j=1}^2 Z_j$  auch exponentialverteilt.

**Stimmt.** Seien  $Z_1, Z_2 \sim \text{Exp}(\lambda)$  für ein  $\lambda > 0$ . Dann gilt für  $x \geq 0$

$$\begin{aligned} \mathbb{P}(Z \leq x) &= \sum_{k=1}^2 \binom{2}{k} (1 - e^{-\lambda x})^k (e^{-\lambda x})^{2-k} \\ &= 2e^{-\lambda x} - 2e^{-2\lambda x} + 1 - 2e^{-\lambda x} + e^{-2\lambda x} = 1 - e^{-2\lambda x} \end{aligned}$$

und somit  $Z \sim \text{Exp}(2\lambda)$ .

**Was macht man für  $(Z_k \sim \text{Exp}(\lambda_k))_{k \in \mathbb{N}}$ ???**

- ③ Ist  $X + Y$  eine int'bare Zufallsvariable, so ist  $\mathbb{E}[|X + Y|] < \infty$ .

**Stimmt**, da  $Z$  eine integrierbare Zufallsvariable ist, wenn ihr Erwartungswert existiert, also folgt die Aussage aus der Definition 3.5.1.

- ④ Es ist nicht möglich, dass  $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}\text{-f.s.}} 0$  und  $\mathbb{E}[X_n] \xrightarrow[n \rightarrow \infty]{} \infty$ .

**todp.**

- ⑤ Sind  $X$  und  $Y$  unkorreliert, so sind sie unabhängig.

**Falsch**, siehe Gegenbeispiel 3.5.14.

Scheutzwow, 07/17 Sei  $f(x) := c \cdot \ln(1 - \frac{x}{2})$  für  $c \in \mathbb{R}$ .

- ① Für welche  $c \in \mathbb{R}$  ist  $f$  eine erzeugende Funktion?

**Lösung.** Assuming that  $X$  is a non-negative integer random

variable, we can use that

$$\mathbb{P}(X = k) = \frac{G_X^{(k)}(0)}{k!}.$$

These probability mass values must sum to one, which imposes a constraint on the PGF, which we can use to find the constant  $c$ . Now, substituting your specified PGF you get:

$$G_X^{(k)}(z) = c \cdot \left(\frac{d}{dz}\right)^k \ln(1-z/2) = \begin{cases} c \cdot \ln(1-z/2), & \text{for } k = 0, \\ -c \cdot (k-1)! \cdot (2-z)^{-k}, & \text{for } k > 0, \end{cases}$$

which gives the mass function:

$$\mathbb{P}(X = k) = \frac{G_X^{(k)}(0)}{k!} = \begin{cases} 0, & \text{for } k = 0, \\ -(c/k) \cdot 2^{-k}, & \text{for } k > 0. \end{cases}$$

The constraint equation therefore reduces to:

$$1 = \sum_{k=0}^{\infty} \mathbb{P}(X = k) = -c \cdot \sum_{k=1}^{\infty} \frac{1}{k \cdot 2^k} = -c \cdot \ln(2).$$

From this constraint we have  $c = -\ln(2)$  so your PGF is:

$$G_X(z) = -\frac{\ln(1-\frac{z}{2})}{\ln(2)} = 1 - \frac{\ln(2-z)}{\ln(2)},$$

and the corresponding probability mass function is:

$$p_X(k) \equiv \mathbb{P}(X = k) = \frac{1}{\ln(2)} \cdot \frac{1}{k \cdot 2^k} \quad \text{for all } k \in \mathbb{N}.$$

- ② Sei  $X_c$  eine Zufallsvariable mit der von  $f$  erzeugten Verteilung. Bestimmen Sie  $\mathbb{E}[X_c]$  und  $\mathbb{P}(X_c = 1)$ .

**Lösung.** TODO

- ③ Geben Sie die Verteilungsfunktion von  $X_c$  an.

**Lösung.** TODO

Scheutzwow, 07/17 Seien  $X, Y \sim \text{Exp}(\lambda)$  u.i.v. mit  $\lambda > 0$ .

- ① Bestimmen Sie die Dichte von  $Z := X + Y$ .

**Lösung.** Seien  $f_X$  und  $f_Y$  die Dichten von  $X$  bzw.  $Y$ . Dann

gilt für  $x \in \mathbb{R}$

$$\begin{aligned} f_Z(x) &= (f_X * f_Y)(x) = \int_{\mathbb{R}} f_X(x-y) f_Y(y) \, dy \\ &= \int_{\mathbb{R}} \lambda e^{-\lambda(x-y)} \mathbb{1}_{[0,\infty)}(x-y) \cdot \lambda e^{-\lambda y} \mathbb{1}_{[0,\infty)}(y) \, dy \\ &= \lambda^2 \int_0^x e^{-\lambda(x-y)} \cdot e^{-\lambda y} \, dy \cdot \mathbb{1}_{[0,\infty)}(x) = \lambda^2 \int_0^x e^{-\lambda x} \, dy \cdot \mathbb{1}_{[0,\infty)}(x) \\ &= \underline{\underline{\lambda^2 x \cdot e^{-\lambda x} \cdot \mathbb{1}_{[0,\infty)}(x)}}. \end{aligned}$$

② Bestimmen Sie die Verteilung von  $(X, Z)$ .

③ Berechnen Sie  $\mathbb{E}[X \mid Z]$ .

Scheutzwow 07/17 Seien  $X, Y$  unabhängig und identisch stetig gleichverteilt auf  $[0, a]$  für  $a > 0$ . Bestimmen Sie die Dichte, Verteilungsfunktion, den Erwartungswert und die Varianz von  $Z := X + Y$ .

**Lösung.**

① Die Dichte bestimmen wir wie oben mit Faltung: Für  $x \in \mathbb{R}$  gilt

$$\begin{aligned} \int_{\mathbb{R}} f_X(x-y) f_Y(y) \, dy &= \frac{1}{(a-0)^2} \int_{\mathbb{R}} \mathbb{1}_{[0,a]}(x-y) \mathbb{1}_{[0,a]}(y) \, dy \\ &= \frac{1}{a^2} \int_0^a 1 \, dy \cdot \mathbb{1}_{[0,2a]}(x) = \frac{\mathbb{1}_{[0,2a]}(x)}{a} \end{aligned}$$

② **TODO**

2016 Erstklausur Seien  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $A, B, C \in \mathcal{A}$ . Zeigen Sie, dass gilt

① Sind  $A \cap B$  und  $C$  unabhängig und  $\mathbb{P}(B) > 0$ , so folgt

$$\mathbb{P}(A \cap C \mid B) = \mathbb{P}(A \mid B) \mathbb{P}(C) \quad (24)$$

**Beweis.** Nach Definition gilt

$$\begin{aligned} \mathbb{P}(A \cap C \mid B) &\stackrel{\text{Def.}}{=} \frac{\mathbb{P}(A \cap C \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}((A \cap B) \cap C)}{\mathbb{P}(B)} \\ &\stackrel{\text{unabh.}}{=} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \cdot \mathbb{P}(C) \stackrel{\text{Def.}}{=} \mathbb{P}(A \mid B) \mathbb{P}(C). \quad \square \end{aligned}$$

② Die Gleichung (24) gilt auch, falls statt Unabhängigkeit  $\mathbb{P}(C) = 1$  gilt.

**Beweis.** Wir müssen den Schritt, den wir oben mit der Unabhängigkeit begründet haben, nur anderweitig begründen.

Dafür zeigen wir das für  $\mathbb{P}(C) \in (0, 1)$  und  $\mathbb{P}(D) = 1$  gilt

$$\mathbb{P}(C \cap D) = \mathbb{P}(C) \mathbb{P}(D).$$

Dies folgt direkt aus  $\mathbb{P}(D \mid C) = \mathbb{P}(D) = 1$ .  $\square$

- ③ Es gelte  $\mathbb{P}(A \mid B) = \mathbb{P}(A \mid B^c)$  und  $\mathbb{P}(B) \in (0, 1)$ . Dann sind  $A$  und  $B$  unabhängig.

**Beweis.** Aus dem Satz über die totale Wahrscheinlichkeit folgt

$$\begin{aligned}\mathbb{P}(A) &= \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c) = \mathbb{P}(A \mid B) \mathbb{P}(B) + \mathbb{P}(A \mid B^c) \mathbb{P}(B^c) \\ &= \mathbb{P}(A \mid B) (\mathbb{P}(B) + \mathbb{P}(B^c)) = \mathbb{P}(A \mid B).\end{aligned}$$

und somit die Behauptung.  $\square$

2016 Erstklausur Seien  $(X_n \sim \text{Exp}(\frac{1}{n}))_{n \in \mathbb{N}}$  Zufallsvariablen.

- ① Berechnen Sie die Verteilungsfunktion  $F_n$  der  $Y_n := \frac{X_n}{2n+1}$ .

**Lösung:** Für  $x \in \mathbb{R}$  gilt

$$\begin{aligned}\mathbb{P}(Y_n \leq x) &= \mathbb{P}(X_n \leq x(2n+1)) = 1 - e^{-\frac{2n+1}{n}x} \mathbb{1}_{[0, \infty)}(x(2n+1)) \\ &= 1 - e^{-\frac{2n+1}{n}x} \mathbb{1}_{[0, \infty)}(x)\end{aligned}$$

- ② Bestimmen Sie für alle  $x \in \mathbb{R}$  den punktweise Grenzwert  $F(x) := \lim_{n \rightarrow \infty} F_n$ .

**Lösung.** Aufgrund der Stetigkeit der Exponentialfunktion gilt für  $x \geq 0$

$$F(x) = \lim_{n \rightarrow \infty} F_n(x) = 1 - \exp\left(\lim_{n \rightarrow \infty} -\frac{2n+1}{n}x\right) = 1 - e^{-2x}$$

und  $F(x) \equiv 0$  auf  $(-\infty, 0)$ .

- ③ die Funktion  $F$  ist die Verteilungsfunktion einer Zufallsvariable  $Y$ . Um welche Verteilung handelt es sich und was können sie über die Konvergenz der Folge  $(Y_n)_{n \in \mathbb{N}}$  aussagen?

**Lösung.** Die Funktion  $F$  ist die Verteilungsfunktion einer  $\text{Exp}(2)$ -verteilten Zufallsvariable.

**TODO:zweiter Teil.**

2016 Erstklausur Peter will nach der Vorlesung mit dem Bus nach Hause fahren. Dazu kann er den Bus  $A$  oder den Bus  $B$  nehmen. Die Wartezeiten auf die Busse können durch unabhängig auf dem Intervall  $[0, 10]$  gleichverteilte Zufallsvariablen  $X$  und  $Y$  beschrieben werden.

- ① Bestimmen Sie die Verteilungsfunktionen von  $Z_1 := \max(X, Y)$  und  $Z_2 := \min(X, Y)$ .

**Lösung.** Für  $x \in [0, 10]$  gilt mit dem binomischen Lehrsatz

$$\mathbb{P}(Z_1 \leq x) = 1 - (1 - \mathbb{P}(X \leq x))^2 = 1 - \left(1 - \frac{x}{10}\right)^2 = \frac{x}{5} - \frac{x^2}{100}.$$

und  $\mathbb{P}(Z_1 \leq x) = 0$  für  $x < 0$  sowie  $\mathbb{P}(Z_1 \leq x) = 1$  für  $x > 10$ .

Ferner gilt

$$\mathbb{P}(Z_2 \leq x) = \mathbb{P}(X \leq x)^2 = \frac{x^2}{100}$$

und  $\mathbb{P}(Z_2 \leq x) = 0$  für  $x < 0$  sowie  $\mathbb{P}(Z_2 \leq x) = 1$  für  $x > 10$ .

- ② Wie groß ist die Wahrscheinlichkeit, dass Peter länger als zwei Minuten auf einen Bus warten muss?

**Lösung.** Aus den obigen Rechnungen ergibt sich sofort

$$\mathbb{P}(Z_2 > 2) = 1 - \mathbb{P}(Z_2 \leq 2) = 1 - \frac{4}{100} = \frac{24}{25}.$$

- ③ Peter kommt zur Haltestelle und wird dort für fünf Minuten abgelenkt. Wie hoch ist die Wahrscheinlichkeit, dass er beide Busse verpasst hat?

**Lösung.** Aus ① ergibt sich

$$\mathbb{P}(Z_1 \leq 5) = \frac{5}{5} - \frac{25}{100} = \frac{3}{4}.$$


- ④ Zeigen Sie, dass die Dichte von  $(X, Y)$  durch

$$f_{Z_2}(z) = \frac{1}{5} \left(1 - \frac{z}{10}\right) \mathbb{1}_{[0,10]}(z)$$

gegeben ist.

- ⑤ Geben Sie die gemeinsame Dichte und die gemeinsame Verteilung des Zufallsvektors  $(X, Y)$  an.

Erstklausur 2016 Betrachte den folgenden Übergangsgraphen einer MARKOV-Kette.



- ① Geben Sie die Übergangsmatrix  $P$  an.

**Lösung.** Es gilt

$$P := \begin{pmatrix} 1-p & p & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ 0 & p & 0 & 1-p \\ 0 & 0 & \frac{1}{2} & \frac{1}{2} \end{pmatrix}.$$

- ② Bestimmen Sie alle Äquivalenzklassen mit ihrer wechselseitigen Erreichbarkeit in Abhängigkeit von  $p$ .

**Lösung.** Fall 1:  $p = 0$ . Die Klassen sind  $\{1\}, \{2\}, \{3\}, \{4\}$  und nur  $\{2\}$  ist abgeschlossen.

Fall 2:  $p \in (0, 1)$ . Die einzige Klasse ist  $\{1, 2, 3, 4\}$  und sie ist abgeschlossen.

Fall 1:  $p = 1$ . Die Klassen sind  $\{1, 2, 3\}$  und  $\{4\}$  und nur letztere ist abgeschlossen.

- ③ Sei nun  $p = 0$ . Welche Zustände sind (un)wesentlich?

**Lösung.**  $\{1\}, \{3\}$  und  $\{4\}$  sind wesentlich,  $\{2\}$  ist unwesentlich.

- ④ Bestimmen Sie alle stationären Verteilungen der MARKOV-Kette.

**Lösung.** Da die stationären Verteilungen genau die Eigenvektoren von  $P^T$  zum Eigenwert 1 und Komponentensumme 1 sind, lösen wir

$$\begin{pmatrix} 1-p & \frac{1}{2} & 0 & 0 \\ p & 0 & p & 0 \\ 0 & \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 0 & 1-p & \frac{1}{2} \end{pmatrix} \begin{pmatrix} \gamma \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} \gamma \\ x_2 \\ x_3 \\ x_4 \end{pmatrix}$$

Wir erhalten

$$\begin{aligned} \text{I: } (1-p)\gamma + \frac{x_2}{2} &= \gamma \implies x_2 = 2p\gamma, \\ \text{IV: } (1-p)x_3 + \frac{x_4}{2} &= x_4 \implies x_4 = 2(1-p)x_3 \end{aligned}$$

und somit aus III

$$x_2 + x_4 = 2x_3 \implies p\gamma + (1-p)x_3 = x_3 \implies x_3 = \gamma$$

Da die Komponentensumme 1 ergeben muss, erhalten wir

$$1 \stackrel{!}{=} \gamma + x_2 + x_3 + x_4 = 2\gamma + 2p\gamma + 2(1-p)\gamma = 4\gamma$$

also  $\gamma = \frac{1}{4}$  und somit ist die einzige stationäre Verteilung durch

$$\left( \frac{1}{4}, \frac{p}{2}, \frac{1}{4}, \frac{1-p}{2} \right)$$

gegeben.

Bank, 2014/2 Kreuzen Sie alle wahren Aussagen an.

- ① Seien  $X$  und  $Y$  zwei unabhängige integrierbare Zufallsvariablen auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{A}, \mathbb{P})$  mit Dichten  $f_X$  und  $f_Y$  bezüglich des LEBESGUE-Maßes. Dann gilt

- ①  $X^2$  und  $\sqrt{|Y|}$  sind unabhängig.

**Stimmt.** Dies folgt daraus, dass  $x \mapsto x^2$  und  $x \mapsto \sqrt{|x|}$  messbare Abbildungen sind.

- ②  $\mathbb{E}[X \cdot \mathbb{1}_{\{Y \leq 0\}}] = \mathbb{E}[X] - \mathbb{E}[X] \mathbb{P}(Y > 0)$ .

**Stimmt.** Es gilt  $\mathbb{E}[\mathbb{1}_A] = \mathbb{P}(A)$  und somit

$$\begin{aligned} \mathbb{E}[X] - \mathbb{E}[X] \mathbb{P}(Y > 0) &= \mathbb{E}[X](1 - \mathbb{P}(Y > 0)) = \mathbb{E}[X] \mathbb{P}(Y \leq 0) \\ &= \mathbb{E}[X] \mathbb{E}[\mathbb{1}_{\{Y \leq 0\}}] = \mathbb{E}[X \cdot \mathbb{1}_{\{Y \leq 0\}}], \end{aligned}$$

wobei die letzte Gleichung aus der Unabhängigkeit von  $X$  und  $Y$  folgt (messbare Funktion für  $Y$  ist  $\mathbb{1}_{(\infty, 0]}$ ).

- ③  $\mathbb{P}(X < Y) = \int_{\mathbb{R}} \mathbb{P}(X \leq y) f_Y(y) dy$ .

**Stimmt. Ansatz 1:** Sei  $f_{X,Y}$  die gemeinsame Dichte von  $X$  und  $Y$ . Dann gilt mit dem Satz von FUBINI-TONELLI

$$\begin{aligned} \mathbb{P}(X < Y) &= \int_{\mathbb{R}^2} f_{X,Y}(x, y) \mathbb{1}_{\{x < y\}} dx, y = \int_{\mathbb{R}} \int_{-\infty}^y f_{X,Y}(x, y) dx dy \\ &= \int_{\mathbb{R}} \int_{-\infty}^y f_X(x) f_Y(y) dx dy = \int_{\mathbb{R}} \mathbb{P}(X \leq y) f_Y(y) dy, \end{aligned}$$

wobei der vorletzte Schritt aus der Unabhängigkeit der Zufallsvariablen folgt.

**Ansatz 2:**

$$\mathbb{P}(X < Y) = \mathbb{P}(X - Y < 0) = \mathbb{P}(X - Y \leq 0) - \underbrace{\mathbb{P}(X = Y)}_{=0 \text{ (unabh.)}}.$$

So folgt

$$\begin{aligned} \mathbb{P}(X - Y \leq 0) &= \int_{-\infty}^0 f_{X+(-Y)}(x) dx = \int_{-\infty}^0 (f_X * f_{-Y})(x) dx \\ &= \int_{-\infty}^0 \int_{\mathbb{R}} f_X(x - \tau) f_{-Y}(\tau) d\tau dx \\ &= \int_{\mathbb{R}} \int_{-\infty}^0 f_X(x - \tau) dx f_{-Y}(\tau) d\tau \\ &= \int_{\mathbb{R}} \int_{-\infty}^{-\tau} f_X(x) dx f_{-Y}(\tau) d\tau \\ &= \int_{\mathbb{R}} \mathbb{P}(X \leq -\tau) f_{-Y}(\tau) d\tau \\ &= \int_{\mathbb{R}} \mathbb{P}(X \leq -\tau) f_Y(-\tau) d\tau \\ &= \int_{\mathbb{R}} \mathbb{P}(X \leq \tau) f_Y(\tau) d\tau = \int_{\mathbb{R}} \mathbb{P}(X < \tau) f_Y(\tau) d\tau \end{aligned}$$

- ② Für reellwertige Zufallsvariablen  $X, X_1, X_2, \dots$  auf einem gemeinsamen Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$  gilt

- ① Aus  $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}\text{-f.s.}} X$  folgt  $X_n \xrightarrow[n \rightarrow \infty]{L_1(\mathbb{P})} X$ .

**Falsch.** Aus punktweise Konvergenz folgt nicht Norm-Konvergenz.

Betrachte hierzu Hütchenfunktionen mit höher werdenden Spitzen und schrumpfender Basis, deren Flächeninhalt konstant sind, aber punktweise gegen die Nullfunktion konvergieren.

- ② stochastische Konvergenz  $X_n \rightarrow X$  impliziert die Existenz einer Teilfolge  $(n_k)_{k \in \mathbb{N}}$  mit  $n_k < n_{k+1}$ , sodass  $|X_{n_k} - X| \xrightarrow[k \rightarrow \infty]{\mathbb{P}\text{-f.s.}} 0$  gilt.

**Stimmt.**

**Beweis.** Seien  $\varepsilon > 0$ . Nach Voraussetzung existiert eine Teilfolge  $(n_k)_{k \in \mathbb{N}} \subset \mathbb{N}$  sodass

$$\mathbb{P}(|X_{n_k} - X| > 2^{-k}) \leq 2^{-k}.$$

**TODO: induktiv konstruierbar.**

Nun gilt

$$\sum_{k \in \mathbb{N}} \mathbb{P}(|X_{n_k} - X| > 2^{-k}) \leq \sum_{k \in \mathbb{N}} 2^{-k} = 1 < \infty.$$

Das Lemma von BOREL-CANTELLI impliziert

$$\mathbb{P}\left(\limsup_{k \rightarrow \infty} |X_{n_k} - X| > 2^{-k}\right) = \mathbb{P}\left(\bigcap_{k \in \mathbb{N}} \bigcup_{\ell \geq k} \{|X_{n_\ell} - X| > 2^{-\ell}\}\right) = 0$$

und somit

$$\mathbb{P}\left(\bigcup_{k \in \mathbb{N}} \bigcap_{\ell \geq k} \{|X_{n_\ell} - X| \geq 2^{-\ell}\}\right) = 1$$

und (vgl. Beweis)

$$\lim_{k \rightarrow \infty} \mathbb{P}\left(\bigcup_{\ell \geq k} \{|X_{n_\ell} - X| > 2^{-\ell}\}\right) = \lim_{k \rightarrow \infty} \mathbb{P}(|X_{n_k} - X| > 0) = 0$$

□

- ③  $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}\text{-f.s.}} X$  impliziert  $\mathbb{E}[|X|] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[|X_n|]$ .

**Stimmt.** Da  $X_n \rightarrow X$  fast überall gilt, gilt auch  $|X_n| \rightarrow |X|$  fast überall. Nach dem **Lemma von FATOU** folgt

**Lemma von FATOU**

$$\mathbb{E}[\liminf_{n \rightarrow \infty} |X_n|] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[|X_n|].$$

Da aufgrund der fast überall Konvergenz der  $\lim$  mit dem  $\liminf$  fast überall übereinstimmt, und das Integral Nullmenge ignoriert, folgt die Behauptung.



- ③ Für unkorrelierte reellwertige Zufallsvariablen  $(X_k)_{k \in \mathbb{N}}$  auf  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $|X_k| \leq 52$  für alle  $k \in \mathbb{N}$  gilt für  $S_n := \sum_{k=1}^n X_k$

①  $\frac{1}{n} \sum_{k \in \mathbb{N}} X_k - \mathbb{E}[X_k] \xrightarrow[n \rightarrow \infty]{\text{in W.keit}} 0.$

**Stimmt.**

$$\begin{aligned} \frac{1}{n^2} \sum_{k=1}^n \text{Var}[X_k] &\stackrel{\text{Def.}}{=} \frac{1}{n^2} \sum_{k=1}^n \mathbb{E}[(X_k - \mathbb{E}[X_k])^2] \leq \frac{1}{n^2} \sum_{k=1}^n (2 \cdot 52)^2 \\ &\leq \frac{1}{n^2} 2n \cdot 104^2 = \frac{104^2}{n} \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

Nach der Verallgemeinerung des schwachen Gesetzes der großen Zahlen folgt die Aussage.

②  $\frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{\mathbb{P}\text{-f.s.}} c \in \mathbb{R}.$

**Falsch.**

③  $\sqrt{n} \text{Var} \left( \frac{S_n}{n} \right) \xrightarrow{n \rightarrow \infty} 0.$

**Stimmt.** Nach den Rechenregeln für die Varianz und der Identität von B... gilt

$$\left| \sqrt{n} \text{Var} \left( \frac{S_n}{n} \right) \right| = \left| \frac{\sqrt{n}}{n^2} \sum_{k=1}^n \text{Var}(X_k) \right| \leq \frac{104n}{n^{\frac{3}{2}}} = \frac{104}{\sqrt{n}} \xrightarrow{n \rightarrow \infty} 0.$$

- ④ Seien  $(X_k)_{k \in \mathbb{N}}$  u.i.v. auf  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $\mathbb{E}[X_1] =: \mu$  und  $\text{Var}[X_1] =: \sigma^2 \in (0, \infty)$  sowie  $S_n := \sum_{k=1}^n X_k$ . Dann gilt

①  $\frac{S_n - n\mu}{n\sigma^2} \xrightarrow[n \rightarrow \infty]{d} Z \sim \mathcal{N}(0, 1)$

**Falsch.** Sieht fast aus wie zentraler Grenzwertsatz, es fehlt aber ein Faktor.

②  $\mathbb{P} \left( \frac{S_n}{n} \leq \mu \right) \xrightarrow{n \rightarrow \infty} \frac{1}{2}.$

**Stimmt.** Nach zentralem Grenzwertsatz konvergiert  $S_n/n$  gegen eine normalverteilte Zufallsvariable, die um ihren Erwartungswert symmetrisch ist.

- ③  $(X_k)_{k \in \mathbb{N}}$  genügt dem schwachen schwachen Gesetz der großen Zahlen.

**Stimmt.** Da die Zufallsvariablen unabhängig sind, sind die insbesondere unkorreliert. Da ihre Varianz endlich ist, sind die Voraussetzungen des schwachen Gesetzes der großen Zahlen erfüllt.

- ⑤ Sei  $X$  eine reellwertige Zufallsvariable. Dann gilt für alle  $c > 0$

①  $\mathbb{P}(|X| \geq c) \leq \frac{\mathbb{E}[X^2]}{c^2},$

**Stimmt.** MARKOVsche Ungleichung mit  $\Phi(t) = t^2$ , da  $|X|^2 = X^2$  und  $|X|$  nichtnegativ.

$$\textcircled{2} \quad \mathbb{P}(|X| \geq c) \leq \mathbb{E}[e^{X-c}],$$

**Stimmt.** MARKOVsche Ungleichung mit  $\Phi(t) = e^t$ .

$$\textcircled{3} \quad \mathbb{P}(|X| \geq c) \leq \frac{\text{Var}[X]}{c^2}.$$

**Falsch.** Betrachte eine degenerierte (= konstante) Zufallsvariable, z.B.  $X \sim \text{Ber}(1)$ , also  $X \equiv 1$ . Dann gilt  $\text{Var}[X] = 1 \cdot (1 - 1) = 0$  aber

$$\mathbb{P}(X \geq 1) = \mathbb{P}(X = 1) + \mathbb{P}(X = 0) = 1 + 0 > 0.$$

Stannat 2013 Seien  $(X_k)_{k \in \mathbb{N}}$  unabhängige auf  $[0, 1]$  gleichverteilte Zufallsvariablen und  $f : [0, 1] \rightarrow \mathbb{R}$  eine stetige beschränkte Funktion. Zeigen Sie, dass dann

$\textcircled{1}$  gilt:

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n f(X_k) = \int_0^1 f(x) dx\right) = 1$$

**Beweis.** Dies ist das starke Gesetz der großen Zahlen für  $Y_k := f(X_k)$ . Die Folge  $(Y_k)_{k \in \mathbb{N}}$  ist unabhängig, weil  $f$  messbar ist. Ferner gilt für alle  $k \in \mathbb{N}$

$$\mathbb{E}[Y_k] = \mathbb{E}[f(X_k)] = \int_{\mathbb{R}} f(x) \cdot f_{X_k}(x) dx = \int_0^1 f(x) dx,$$

wobei  $f_{X_k} := \mathbb{1}_{[0,1]}$  die Dichte von  $X_k$  ist. Das starke Gesetz der großen Zahlen impliziert  $\frac{1}{n} \sum_{k=1}^n Y_k \xrightarrow[n \rightarrow \infty]{\mathbb{P}\text{-f.s.}} \mathbb{E}[Y_1]$  und somit insbesondere stochastische Konvergenz.  $\square$

$\textcircled{2}$  für alle  $\varepsilon > 0$

$$\begin{aligned} & \lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{k=1}^n f(X_k) - \int_0^1 f(x) dx\right| \leq \frac{\varepsilon}{\sqrt{n}}\right) \\ &= \frac{1}{\sqrt{2\pi\sigma^2(f)}} \int_{-\varepsilon}^{\varepsilon} \exp\left(-\frac{y^2}{2\sigma^2(f)}\right) dy \end{aligned}$$

gilt, wobei  $\sigma^2(f) := \int_0^1 f^2(x) dx - \left(\int_0^1 f(x) dx\right)^2$  ist.

**Beweis.** Es gilt

$$\text{Var}(Y_k) = \mathbb{E}[Y_k^2] - \mathbb{E}[Y_k]^2 = \sigma^2(f).$$

Nach dem zentralen Grenzwertsatz (ZG) folgt mit  $m := \mathbb{E}[Y_1]$

und  $S_n := \sum_{k=1}^n Y_k$

$$\begin{aligned} & \lim_{n \rightarrow \infty} \mathbb{P} \left( -\varepsilon \leq \sqrt{\frac{n}{\sigma^2(f)}} \left( \frac{S_n}{n} - m \right) \leq \varepsilon \right) \\ &= \lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{1}{\sqrt{\sigma^2(f)}} \left| \left( \frac{S_n}{n} - m \right) \right| \leq \frac{\varepsilon}{\sqrt{n}} \right) \\ &\stackrel{\text{(ZG)}}{=} \frac{1}{\sqrt{2\pi}} \int_{-\varepsilon}^{\varepsilon} e^{-\frac{y^2}{2}} dy = \frac{1}{\sqrt{2\pi\sigma^2(f)}} \int_{-\varepsilon}^{\varepsilon} e^{-\frac{y^2}{2\sigma^2(f)}} dy, \end{aligned}$$

aber die letzte Gleichheit gilt nur für große  $\varepsilon$ ... **TODO**  $\square$