"ZOOM AND ENHANCE" GEHT WIRKLICH MIT ATOMIC NORM MINIMIZATION

(UND OHNE MACHINE LEARNING)

Bachelorarbeit von Viktor Stein, März 2021

Betreuung: Prof. Dr. Gabriele Steidl und Dr. Robert Beinert

AG Angewandte Mathematik



17. Dies Mathematicus, 25.11.2022 Institut für Mathematik, TU Berlin

-"Zoom" unrealistisch: Computer kann Pixel nicht erfinden

- "Zoom" unrealistisch: Computer kann Pixel nicht erfinden
- Mit ANM: "enhancen" = Auflösung verbessern

- "Zoom" unrealistisch: Computer kann Pixel nicht erfinden
- Mit ANM: "enhancen" = Auflösung verbessern




Abb. 1: Links: Bild mit niedriger Auflösung.

- "Zoom" unrealistisch: Computer kann Pixel nicht erfinden
- Mit ANM: "enhancen" = Auflösung verbessern




ABB. 1: Links: Bild mit niedriger Auflösung. Rechts: Das Original.


DAS MODELL IN 2D UND 1D

Spärliche Bilder


Das Modell in 2D und 1D

Spärliche Bilder → Viele Pixel enthalten keine Infos.

Spärliche Bilder \sim Viele Pixel enthalten keine Infos.




Spärliche Bilder \sim Viele Pixel enthalten keine Infos.



1-dimensionales Analogon zu Bildern:

DAS MODELL IN 2D UND 1D


 $\textbf{Sp\"{a}rliche Bilder} \leadsto \text{Viele Pixel enthalten keine Infos.}$



1-dimensionales Analogon zu Bildern:

DAS MODELL IN 2D UND 1D

Spärliche Bilder \sim Viele, viele Pixel enthalten keine Infos.



1-dimensionales Analogon im Grenzwert zu ∞ vielen Pixeln:

Das mathematische Modell - ein spike train

Modelliere Signal als **spike train** auf dem Einheitskreis T:

$$x \coloneqq \sum_{k=1}^{r} c_{k} \delta_{t_{k}}$$

Modelliere Signal als **spike train** auf dem Einheitskreis T:

$$x \coloneqq \sum_{k=1}^r \frac{c_k}{\delta_{t_k}} \delta_{t_k}$$
 $\delta_t(A) \coloneqq \begin{cases} 1, & \text{wenn } t \in A, \\ 0, & \text{sonst.} \end{cases}$

mit Amplituden $(c_k)_{k=1}^r \in \mathbb{C} \setminus \{0\}$ und Positionen $(t_k)_{k=1}^r \subseteq \mathbb{T}$.

Das Mathematische Modell - ein spike train

Modelliere Signal als **spike train** auf dem Einheitskreis \mathbb{T} :

$$x \coloneqq \sum_{k=1}^r c_k \delta_{t_k}$$
 $\delta_{t}(A) \coloneqq \begin{cases} 1, & \text{wenn } t \in A, \\ 0, & \text{sonst.} \end{cases}$

mit Amplituden $(c_k)_{k=1}^r \in \mathbb{C} \setminus \{0\}$ und Positionen $(t_k)_{k=1}^r \subseteq \mathbb{T}$.




ABB. 2: Ein reeller spike train auf \mathbb{T} mit r=4 spikes.

Wegen Beugung: bildgebendes Gerät hat beschränkte Auflösung. ⇒ das wirkliche empfangene, niedrig aufgelöste Signal ist

$$x_{\text{low}} \colon \mathbb{T} \to \mathbb{C}, \qquad t \mapsto (x * g)(t)$$

Das niedrig aufgelöste Signal

Wegen Beugung: bildgebendes Gerät hat beschränkte Auflösung.


⇒ das wirkliche empfangene, niedrig aufgelöste Signal ist

$$x_{\text{low}} \colon \mathbb{T} \to \mathbb{C}, \qquad t \mapsto (x * g)(t)$$

wobei

$$g(t) \coloneqq \frac{1}{2\pi} \sum_{|k| \le f} e^{2\pi i tk}$$

für $f \in \mathbb{N}$.



Das niedrig aufgelöste Signal

Wegen Beugung: bildgebendes Gerät hat beschränkte Auflösung.

⇒ das wirkliche empfangene, niedrig aufgelöste Signal ist


$$x_{\text{low}} \colon \mathbb{T} \to \mathbb{C}, \qquad t \mapsto (x * g)(t)$$


wobei

$$g(t) := \frac{1}{2\pi} \sum_{|k| \le f} e^{2\pi i tk}$$

für $f \in \mathbb{N}$.

Die FOURIER-Transformation von g ist $\hat{g} = \mathbb{1}_{\{-f,...,f\}}$.





Das niedrig aufgelöste Signal

Wegen Beugung: bildgebendes Gerät hat beschränkte Auflösung.

 \implies das wirkliche empfangene, niedrig aufgelöste Signal ist


$$x_{\text{low}} \colon \mathbb{T} \to \mathbb{C}, \qquad t \mapsto (x * g)(t) = \sum_{k=1}^{r} \frac{c_k}{c_k} g(t - t_k) \quad (* : \text{Faltung}).$$


wobei


$$g(t) := \frac{1}{2\pi} \sum_{|k| \le f} e^{2\pi i tk}$$

für $f \in \mathbb{N}$.

Die FOURIER-Transformation von g ist $\hat{g} = \mathbb{1}_{\{-f,...,f\}}$.










Die Fourier-Transformation von x_{low} ist

$$\widehat{x_{\mathrm{low}}} \colon\thinspace \mathbb{Z} \to \mathbb{C}, \qquad j \mapsto \widehat{x}(j) \widehat{g}(j) = \left(\sum_{k=1}^r \underline{c_k} e^{-2\pi \mathrm{i} j t_k}\right) \mathbb{1}_{|j| \le f}(j).$$








Messung: Fourier-Transformation des niedrig aufgelösten Signals

Die Fourier-Transformation von x_{low} ist

$$\widehat{x_{\mathrm{low}}} \colon\thinspace \mathbb{Z} \to \mathbb{C}, \qquad j \mapsto \widehat{x}(j)\widehat{g}(j) = \left(\sum_{k=1}^r \frac{\mathbf{c}_k}{\mathbf{c}_k} e^{-2\pi \mathrm{i} j t_k}\right) \mathbb{1}_{|j| \le f}(j).$$



 \sim Faltung von x mit g löscht die hohen Frequenzen von x.

Da $\hat{g} = \mathbbm{1}_{|\cdot| \le f},$ bleiben $d \coloneqq 2f + 1$ Messungen

Niederfrequente Messungen als Vektor

Da $\hat{g}=\mathbbm{1}_{|\cdot|\leq f},$ bleiben $d\coloneqq 2f+1$ Messungen

$$\tilde{x} \coloneqq \left(\widehat{x_{\text{low}}}(j)\right)_{|j| \le f} = \left(\sum_{k=1}^r \frac{c_k}{c_k} e^{-2\pi i j t_k}\right)_{|j| \le f} = \sum_{k=1}^r \frac{c_k}{c_k} \psi(e^{-2\pi i t_k}) \in \mathbb{C}^d,$$

wobei $\psi(z) := (z^j)_{|j| < f}$.

Da $\hat{g} = \mathbb{1}_{|\cdot| < f}$, bleiben d := 2f + 1 Messungen

$$\tilde{x} := \left(\widehat{x_{\text{low}}}(j)\right)_{|j| \le f} = \left(\sum_{k=1}^r \frac{c_k}{c_k} e^{-2\pi i j t_k}\right)_{|j| \le f} = \sum_{k=1}^r \frac{c_k}{c_k} \psi(e^{-2\pi i t_k}) \in \mathbb{C}^d,$$

wobei $\psi(z) \coloneqq (z^j)_{|j| \le f}$.

Zwischenbilanz:

$$x = \sum_{k=1}^{r} c_{k} \delta_{t_{k}}$$

Niederfrequente Messungen als Vektor

Da $\hat{g} = \mathbb{1}_{|\cdot| < f}$, bleiben $d \coloneqq 2f + 1$ Messungen

$$\tilde{x} \coloneqq \left(\widehat{x_{\mathrm{low}}}(j)\right)_{|j| \le f} = \left(\sum_{k=1}^r \frac{c_k}{c_k} e^{-2\pi \mathrm{i} j t_k}\right)_{|j| \le f} = \sum_{k=1}^r \frac{c_k}{c_k} \psi(e^{-2\pi \mathrm{i} t_k}) \in \mathbb{C}^d,$$

wobei $\psi(z) \coloneqq (z^j)_{|j| \le f}$.

Zwischenbilanz:

$$x = \sum_{k=1}^{r} \frac{c_k}{c_k} \delta_{t_k} \xrightarrow{\text{ergibt die } \atop \text{Messung}} \tilde{x} = \sum_{k=1}^{r} |c_k| e^{-2\pi i \varphi_k} \psi(e^{-2\pi i t_k}).$$

nichtnegative Linearkombination von Vektoren vom Typ $e^{-2\pi i \varphi} \psi(e^{-2\pi i t}) \in \mathbb{C}^d, \ \varphi, t \in \mathbb{T}$.

Da $\hat{g} = \mathbb{1}_{|\cdot| < f}$, bleiben d := 2f + 1 Messungen

$$\tilde{x} \coloneqq \left(\widehat{x_{\mathrm{low}}}(j)\right)_{|j| \le f} = \left(\sum_{k=1}^r \frac{c_k}{c_k} e^{-2\pi \mathrm{i} j t_k}\right)_{|j| \le f} = \sum_{k=1}^r \frac{c_k}{c_k} \psi(e^{-2\pi \mathrm{i} t_k}) \in \mathbb{C}^d,$$

wobei $\psi(z) \coloneqq (z^j)_{|j| \le f}$.

Zwischenbilanz:

$$x = \sum_{k=1}^{r} \frac{c_k}{\delta_{t_k}} \xrightarrow{\text{ergibt die } \atop \text{Messung}} \tilde{x} = \sum_{k=1}^{r} \frac{|c_k|}{|c_k|} e^{-2\pi i \varphi_k} \psi(e^{-2\pi i t_k}).$$

nichtnegative Linearkombination von Vektoren vom Typ $e^{-2\pi i \varphi} \psi(e^{-2\pi i t}) \in \mathbb{C}^d, \ \varphi.t \in \mathbb{T}$.

Wie erhalten wir x aus \tilde{x} zurück?

SPARSAME ZERLEGUNG VON SIGNALEN

- Ziel: gegeben ein dictionary $\mathcal{A} \subseteq \mathbb{C}^d$, zerlege Signal $\tilde{x} \in \mathbb{C}^d$ in endliche nichtnegative Linearkombination bezüglich \mathcal{A} :

$$\tilde{x} = \sum_{a \in A \subset \mathcal{A}} c_a a, \qquad c_a \ge 0, \ |A| < \infty.$$

- Ziel: gegeben ein dictionary $\mathcal{A} \subseteq \mathbb{C}^d$, zerlege Signal $\tilde{x} \in \mathbb{C}^d$ in endliche nichtnegative Linearkombination bezüglich \mathcal{A} :

$$\tilde{x} = \sum_{a \in A \subset A} c_a a, \qquad c_a \ge 0, \ |A| < \infty.$$

 $- \exists$ sehr viele Zerlegungen von \tilde{x} . Welche sind "gut"?

SPARSAME ZERLEGUNG VON SIGNALEN

– Ziel: gegeben ein dictionary $\mathcal{A} \subseteq \mathbb{C}^d$, zerlege Signal $\tilde{x} \in \mathbb{C}^d$ in endliche nichtnegative Linearkombination bezüglich \mathcal{A} :

$$\tilde{x} = \sum_{a \in A \subset A} c_a a, \qquad c_a \ge 0, \ |A| < \infty.$$

- \exists sehr viele Zerlegungen von \tilde{x} . Welche sind "gut"?
- Bilder spärlich \Longrightarrow Gut = sparsam \iff $c_a = 0$ für viele $a \in \mathcal{A}$

SPARSAME ZERLEGUNG VON SIGNALEN

- Ziel: gegeben ein dictionary $\mathcal{A} \subseteq \mathbb{C}^d$, zerlege Signal $\tilde{x} \in \mathbb{C}^d$ in endliche nichtnegative Linearkombination bezüglich \mathcal{A} :

$$\tilde{x} = \sum_{a \in A \subset A} c_a a, \qquad c_a \ge 0, \ |A| < \infty.$$

- \exists sehr viele Zerlegungen von \tilde{x} . Welche sind "gut"?
- Bilder spärlich \Longrightarrow Gut = sparsam \iff $c_a = 0$ für viele $a \in \mathcal{A}$
- \leadsto Gegeben \tilde{x} und \mathcal{A} löse

$$\min_{(c_a)_{a \in \mathcal{A}} \subset [0,\infty)} \|c\|_0 \quad \text{sodass} \quad \tilde{x} = \sum_{a \in \mathcal{A}} c_a a, \tag{P_0}$$

wobei $||c||_0 := \#\{a \in \mathcal{A} : c_a \neq 0\}.$

Sparsame Zerlegung von Signalen

- Ziel: gegeben ein dictionary $\mathcal{A} \subseteq \mathbb{C}^d$, zerlege Signal $\tilde{x} \in \mathbb{C}^d$ in endliche nichtnegative Linearkombination bezüglich A:

$$\tilde{x} = \sum_{a \in A \subset A} c_a a, \qquad c_a \ge 0, \ |A| < \infty.$$


- $-\exists$ sehr viele Zerlegungen von \tilde{x} . Welche sind "gut"?
- Bilder spärlich \Longrightarrow Gut = sparsam \iff $c_a = 0$ für viele $a \in \mathcal{A}$
- \rightarrow Gegeben \tilde{x} und \mathcal{A} löse


$$\min_{(c_a)_{a \in \mathcal{A}} \subset [0, \infty)} \|c\|_0 \quad \text{sodass} \quad \tilde{x} = \sum_{a \in \mathcal{A}} c_a a, \tag{P_0}$$

wobei $||c||_0 := \#\{a \in \mathcal{A} : c_a \neq 0\}.$

 \otimes $\|\cdot\|_0$ ist nicht konvex, nicht "robust". (P_0) ist NP-schwer.

Was ist die nächstbeste konvexe Zielfunktion?






(a) Der $\|\cdot\|_{0}$ -"Einheitsball", $\{(x_1, x_2) \in \mathbb{R}^2 : \|x\|_0 \le 1, |x_1|, |x_2| \le 1\}.$


(b) Der $\|\cdot\|_{1}$ - Einheitsball.

ABB. 3: Die konvexe Hülle von (a) ist (b).

Konvexifizierung: ℓ_1 -Minimierung

Was ist die nächstbeste konvexe Zielfunktion?





- (a) Der $\|\cdot\|_{0}$ -"Einheitsball", $\{(x_1, x_2) \in \mathbb{R}^2 : \|x\|_{0} \le 1, |x_1|, |x_2| \le 1\}.$
- (b) Der $\|\cdot\|_1$ Einheitsball.

ABB. 3: Die konvexe Hülle von (a) ist (b).

→löse stattdessen

$$\min_{(c_a)_{a \in \mathcal{A}} \subset [0, \infty)} \|c\|_1 \coloneqq \sum_{a \in \mathcal{A}} |c_a| \quad \text{sodass} \quad \tilde{x} = \sum_{a \in \mathcal{A}} c_a a. \tag{P_1}$$

DAS MINKOWSKI-FUNKTIONAL

Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.

Das Minkowski-Funktional

Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.

DEFINITION

Das Minkowski-Funktional einer

Menge $A \subseteq X$ ist

$$p_A \colon X \to [0, \infty],$$

 $x \mapsto \inf\{r > 0 : x \in rA\}.$

Das Minkowski-Funktional

Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.


Definition

Das Minkowski-Funktional einer

Menge $A \subseteq X$ ist

$$p_A \colon X \to [0, \infty],$$

$$x \mapsto \inf\{r > 0 : x \in rA\}.$$



Atomische Norm

Das Minkowski-Funktional

Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.


Definition

Das Minkowski-Funktional einer

Menge $A \subseteq X$ ist

$$p_A \colon X \to [0, \infty],$$

$$x \mapsto \inf\{r > 0 : x \in rA\}.$$



DAS MINKOWSKI-FUNKTIONAL

Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.


DEFINITION

 $Das\ Minkowski-Funktional\ einer$

Menge $A \subseteq X$ ist

$$p_A\colon X\to [0,\infty],$$

 $x \mapsto \inf\{r > 0 : x \in rA\}.$



Das Minkowski-Funktional


Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.

DEFINITION

Das Minkowski-Funktional einer Menge $A \subseteq X$ ist

$$p_A\colon X\to [0,\infty],$$

 $x \mapsto \inf\{r > 0 : x \in rA\}.$



DAS MINKOWSKI-FUNKTIONAL


Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.

DEFINITION

Das Minkowski-Funktional einer Menge $A \subseteq X$ ist

$$p_A \colon X \to [0, \infty],$$

 $x \mapsto \inf\{r > 0 : x \in rA\}.$



Atomische Norm

Das Minkowski-Funktional


Seien X ein normierter Raum und $\inf(\emptyset) := \infty$.

Definition

Das Minkowski-Funktional einer Menge $A \subseteq X$ ist

$$p_A \colon X \to [0, \infty],$$

$$x \mapsto \inf\{r > 0 : x \in rA\}.$$



Beispiel. Wenn $B := \{x \in X : ||x|| \le 1\}$, dann $p_B = ||\cdot||$.

Wann ist p_A eine Norm?

SATZ (NORMEIGENSCHAFTEN)

Ist $A \subseteq X$ eine nichtleere,

Menge, dann ist p_A eine Norm auf X.

WANN IST p_A EINE NORM?

SATZ (NORMEIGENSCHAFTEN)

Ist $A \subseteq X$ eine nichtleere, konvexe, beschränkte, symmetrische, volldimensionale Menge, dann ist p_A eine Norm auf X.

SATZ (NORMEIGENSCHAFTEN)

Ist $A \subseteq X$ eine nichtleere, konvexe, beschränkte, symmetrische, volldimensionale Menge, dann ist p_A eine Norm auf X.

symmetrisch: $rA = A \ \forall |r| = 1$.

Wann ist p_A eine Norm?

SATZ (NORMEIGENSCHAFTEN)

Ist $A \subseteq X$ eine nichtleere, konvexe, beschränkte, symmetrische, volldimensionale Menge, dann ist p_A eine Norm auf X.

symmetrisch: $rA = A \ \forall |r| = 1$.


volldimensional: A enthält offene Umgebung von 0.

DEFINITION (ATOMISCHE NORM)

Die von $\mathcal{A} \subseteq \mathbb{C}^d$ induzierte atomische Norm $\|\cdot\|_{\mathcal{A}}$ ist $p_{\text{conv}(\mathcal{A})}$, das MINKOWSKI-Funktional von $\text{conv}(\mathcal{A})$.

DEFINITION (ATOMISCHE NORM)

Die von $\mathcal{A} \subseteq \mathbb{C}^d$ induzierte atomische Norm $\|\cdot\|_{\mathcal{A}}$ ist $p_{\text{conv}(\mathcal{A})}$, das MINKOWSKI-Funktional von $\text{conv}(\mathcal{A})$.



Quelle: Fig. 1 aus: Y. Chi, M. Da Costa: Harnessing Sparsity Over the Continuum: Atomic Norm Minimization for Superresolution. IEEE Signal Process. Mag., 37(2):39–57, 2020.

DIE ATOMISCHE NORM FÜR SUPERRESOLUTION

Erinnerung:
$$\tilde{x} = \sum_{k=1}^{r} |\mathbf{c}_k| e^{-2\pi i \varphi_k} \psi(e^{-2\pi i t_k}).$$

DIE ATOMISCHE NORM FÜR SUPERRESOLUTION

Erinnerung: $\tilde{x} = \sum_{k=1}^{r} |c_k| e^{-2\pi i \varphi_k} \psi(e^{-2\pi i t_k}).$

 \implies Wir wählen $\mathcal{A} := \{e^{-2\pi i \varphi} \psi(e^{-2\pi i t}) : \varphi, t \in \mathbb{T}\} \subset \mathbb{C}^d$.




ABB. 4: $\Re(\mathcal{A})$ und $\Re(\operatorname{conv}(\mathcal{A}))$ für d=3.

Erinnerung:
$$\tilde{x} = \sum_{k=1}^{r} |\mathbf{c}_k| e^{-2\pi i \varphi_k} \psi(e^{-2\pi i t_k}).$$

$$\implies$$
 Wir wählen $\mathcal{A} := \{e^{-2\pi i \varphi} \psi(e^{-2\pi i t}) : \varphi, t \in \mathbb{T}\} \subset \mathbb{C}^d$.

 $\stackrel{\text{Satz}}{\Longrightarrow} \|\cdot\|_{\mathcal{A}} \text{ ist eine Norm.}$




ABB. 4: $\Re(\mathcal{A})$ und $\Re(\operatorname{conv}(\mathcal{A}))$ für d=3.

Die atomische Norm löst das sparsame Zerlegungsproblem (P_1) :

$\|\cdot\|_{\mathcal{A}}$ UND (P_1)

Die atomische Norm löst das sparsame Zerlegungsproblem (P_1) :

SATZ (DARSTELLUNG DER ATOMISCHEN NORM)

Für eine atomische Menge $A \subseteq \mathbb{C}^d$ und $\tilde{x} \in \mathbb{C}^d$ gilt

$$\|\tilde{x}\|_{\mathcal{A}} = \min \left\{ \|c\|_1 : \tilde{x} = \sum_{a \in A} c_a a, \ c_a \ge 0 \right\}.$$

$\|\cdot\|_{\mathcal{A}}$ UND (P_1)

Die atomische Norm löst das sparsame Zerlegungsproblem (P_1) :

SATZ (DARSTELLUNG DER ATOMISCHEN NORM)

Für eine atomische Menge $A \subseteq \mathbb{C}^d$ und $\tilde{x} \in \mathbb{C}^d$ gilt

$$\|\tilde{x}\|_{\mathcal{A}} = \min \left\{ \|c\|_1 : \tilde{x} = \sum_{a \in \mathcal{A}} c_a a, \ c_a \ge 0 \right\}.$$

Wie finden wir die Anzahl der Spikes r, die Positionen $(t_k)_{k=1}^r$ und die Amplituden $(c_k)_{k=1}^r$?

DAS DUALE PROBLEM - POSITIONEN FINDEN

Duale Problem

$$\|\tilde{x}\|_{\mathcal{A}} = \max_{p \in \mathbb{C}^d} \Re(\langle \tilde{x}, p \rangle) \quad \text{sodass} \quad \max_{t \in \mathbb{T}} \left| \langle \psi(e^{2\pi i t}), p \rangle \right| \le 1 \quad (D_{\mathcal{A}})$$

Das duale Problem - Positionen finden

Duale Problem

$$\|\tilde{x}\|_{\mathcal{A}} = \max_{p \in \mathbb{C}^d} \Re(\langle \tilde{x}, p \rangle) \text{ sodass } \max_{t \in \mathbb{T}} \left| \langle \psi(e^{2\pi i t}), p \rangle \right| \le 1 \quad (D_{\mathcal{A}})$$

hat semidefinite Formulierung \sim schnell lösbar.


DAS DUALE PROBLEM - POSITIONEN FINDEN

Duale Problem

$$\|\tilde{x}\|_{\mathcal{A}} = \max_{p \in \mathbb{C}^d} \Re(\langle \tilde{x}, p \rangle) \quad \text{sodass} \quad \max_{t \in \mathbb{T}} |\langle \psi(e^{2\pi i t}), p \rangle| \le 1 \quad (D_{\mathcal{A}})$$

hat semidefinite Formulierung \sim schnell lösbar.

Sei $\tilde{p} \in \mathbb{C}^d$ Lösung von $(D_{\mathcal{A}})$.



Das duale Problem - Positionen finden


Duale Problem

$$\|\tilde{x}\|_{\mathcal{A}} = \max_{p \in \mathbb{C}^d} \Re(\langle \tilde{x}, p \rangle) \text{ sodass } \max_{t \in \mathbb{T}} |\langle \psi(e^{2\pi i t}), p \rangle| \le 1 \quad (D_{\mathcal{A}})$$

hat semidefinite Formulierung \rightarrow schnell lösbar.

Sei $\tilde{p} \in \mathbb{C}^d$ Lösung von (D_A) . Dann

$$\{\mathbf{t}_k\}_{k=1}^r = \{t \in \mathbb{T} : |\langle \psi(e^{2\pi i t}), \tilde{p} \rangle| = 1\}.$$



Das duale Problem - Positionen finden

Duale Problem


$$\|\tilde{x}\|_{\mathcal{A}} = \max_{p \in \mathbb{C}^d} \Re(\langle \tilde{x}, p \rangle) \quad \text{sodass} \quad \max_{t \in \mathbb{T}} \left| \langle \psi(e^{2\pi i t}), p \rangle \right| \le 1 \quad (D_{\mathcal{A}})$$

hat semidefinite Formulierung \rightarrow schnell lösbar.

Sei $\tilde{p} \in \mathbb{C}^d$ Lösung von (D_A) . Dann

If
$$p\in\mathbb{C}^n$$
 Losung von $(D_{\mathcal{A}})$. Dann $\{t_k\}_{k=1}^r=\{t\in\mathbb{T}:|\langle\psi(e^{2\pi\mathrm{i}t}), ilde{p}
angle|=1\}.$


 \sim Positionen $(t_k)_{k=1}^r$ sind Extrema des Be- 02trages des trigonometrischen Polynoms $t \mapsto$ $\langle \psi(e^{2\pi it}), \tilde{p} \rangle$ mit Koeffizientenvektor \tilde{p} .



AMPLITUDEN FINDEN

Mithilfe der Positionen (nährungsweise bestimmt) $(t_k^{\text{est}})_{k=1}^r \subset \mathbb{T}$, finden wir die Amplituden $(c_k)_{k=1}^r$ durch Lösen des linearen Gleichungssystems

$$\sum_{k=1}^{r} c_k e^{-2\pi i j t_k^{\text{est}}} = \tilde{x}_j, \qquad |j| \le f.$$





Vielen Dank für eure Aufmerksamkeit.

QUELLEN

Venkat Chandrasekaran, Benjamin Recht, Pablo Parrilo, and Alan Willsky.

The Convex Geometry of Linear Inverse Problems.

Foundations of Computational Mathematics, 12(6):849, Oct 2012.

Yuejie Chi and Maxime Ferreira Da Costa.

Harnessing Sparsity Over the Continuum: Atomic Norm Minimization for Superresolution.

 $IEEE\ Signal\ Processing\ Magazine,\ 37(2):39-57,\ 2020.$

Gongguo Tang, Badri Narayan Bhaskar, Parikshit Shah, and Benjamin Recht.

Compressed sensing off the grid.

IEEE Transactions on Information Theory, 59(11):7465–7490, 2013.

Diese Folien → viktorajstein.github.io.